



ADsP 데이터분석 준전문가

1과목 데이터 이해

데이터분석 준전문가(ADsP)란?

자격 소개

| ADsP (Advanced Data Analytics Semi-Professional)

- 한국데이터산업진흥원(K-DATA)이 시행하는 국가공인 민간자격
- 데이터 이해를 바탕으로 분석 기획·데이터 분석·시각화 업무를 수행하는 실무자 양성 목적

| 정의

- 데이터 이해 및 처리 기술에 대한 기본지식을 바탕으로 데이터분석 기획, 데이터분석,
- 데이터 시각화 업무를 수행하여 프로세스 혁신 및 과학적 의사결정을 지원하는 전문가

| 응시 자격

- 제한 없음 (학력·경력 무관, 누구나 응시 가능)

✓ 시험 POINT 상위 자격인 ADP(데이터분석 전문가)는 실기시험 포함 — ADsP는 필기(객관식)만으로 취득

데이터분석 준전문가 직무

자격 소개

직무	세부 내용
데이터분석 기획	비즈니스 목표 달성을 위해 분석기회를 발굴하고 분석 목표를 정의, 분석과제 정의·분석로드맵 수립·성과관리 등을 수행
데이터분석	분석 요건 도출, 분석과정 설계, 실무 협의 등 요건정의 → 모델링 → 검증 및 테스트 → 적용을 수행
데이터 시각화	정보 구조 분석과 시각화 요건 정의·시나리오 개발 등 시각화 기획·모델링·디자인·구축·배포 및 유지보수를 수행

시험 개요 및 합격 기준

자격 소개

과목	주요 내용	문항 수	배점
1과목 데이터 이해	데이터와 정보, DB, 빅데이터, 데이터 사이언스	10문항	20점
2과목 데이터분석 기획	분석 기획, 방법론, 과제 발굴, 마스터플랜	10문항	20점
3과목 데이터분석	R 기초, 통계분석, 정형 데이터 마이닝	30문항	60점
합계	객관식 50문항 / 시험시간 90분	50문항	100점

✓ 시험 POINT 합격 기준: 총점 60점 이상 취득, 단 과목별 40% 미만 시 과락(불합격). 3과목(60점)이 당락을 좌우!

1과목 1장

데이터의 이해

데이터·정보·지식, 그리고 데이터베이스의 기초

데이터의 정의와 특성

데이터(Data)의 정의

| 1646년 영국 문헌에 최초 등장, 라틴어 dare(주다) 유래

- 과거: 관념적·추상적 개념 → 현재: 기술적·사실적 의미

| 의미: 추론·추정의 근거가 되는 객관적 사실(fact)

데이터의 두 가지 특성

| 존재적 특성: 있는 그대로의 객관적 사실

- 예: 매장 온도 21도, 오늘 연필 판매량 150개

| 당위적 특성: 추론·예측·전망·추정을 위한 근거(basis)

- 예: 판매량 데이터를 근거로 내일의 수요를 예측
 - ↳ 데이터는 다른 객체와의 상호관계 속에서 가치를 가짐

✓ 시험 POINT '객관적 사실=존재적', '추론·예측의 근거=당위적' 짝을 서로 바꿔 내는 함정 보기가 빈출

정성 데이터 vs 정량 데이터

| 표현 형태에 따른 데이터의 1차 분류

구분	형태	예시	저장·분석 비용
정성 데이터 (qualitative)	언어·문자	회사 매출이 증가함, 설문 주관식, 기상특보	저장·검색·분석에 많은 비용 소요
정량 데이터 (quantitative)	수치·도형·기호	나이, 몸무게, 온도, 주가, 강수량	정형화되어 비용 소모가 적음

✓ 시험 POINT '기상특보'는 정성, '풍속·강수량 수치'는 정량 — 예시로 구분시키는 문제 빈출

데이터의 유형: 정형·반정형·비정형

| 구조(스키마) 유무에 따른 분류 — 빅데이터 시대의 핵심 구분

유형	특징	예시
정형 (Structured)	고정 필드(스키마)에 저장, 행·열의 표 구조	관계형 DB 테이블, 엑셀 시트, CSV
반정형 (Semi-structured)	고정 필드는 없으나 스키마· 메타데이터를 함께 포함	XML, JSON, HTML, 웹로그, 센서 데이터
비정형 (Unstructured)	구조가 정해지지 않아 연산·집계가 불가능	SNS 글, 영상, 이미지, 음성, 일반 문서

✓ 시험 POINT 웹로그·센서 데이터는 비정형이 아니라 '반정형' — 1과목 최다 빈출 함정

암묵지와 형식지

암묵지(Tacit Knowledge)

| 학습·체험으로 개인에게 체화되어 드러나지 않는 지식

- 예: 자전거 타기, 김장김치 담그기, 장인의 손맛
- 개인에게 축적 → 조직으로 공유·전달이 어려움

형식지(Explicit Knowledge)

| 문서·매뉴얼처럼 외부로 표출되어 공유 가능한 지식

- 예: 교과서, 업무 매뉴얼, 데이터베이스, 회계정보
- 전달·공유가 쉬워 조직의 자산으로 관리 가능


지식경영의 핵심

| 암묵지와 형식지의 상호작용(지식변환)으로 지식 창출

↳ 암묵지: 공통화·내면화 / 형식지: 표출화·연결화 담당

✓ 시험 POINT 암묵지-공통화·내면화, 형식지-표출화·연결화 짝짓기가 거의 매회 출제

SECI 지식변환 모델 도식



SECI 지식변환 사이클

SECI 지식변환 4단계 (노나카)

| 암기법 '공표연내' — 순서와 변환 방향까지 함께 암기

단계	변환 방향	의미	예시
공통화 (Socialization)	암묵지 → 암묵지	경험 공유로 타인의 암묵지를 습득	도제식 김장 배우기, 대면 경험 전수
표출화 (Externalization)	암묵지 → 형식지	체화된 지식을 문서·언어로 표현	김치 담그기 노하우를 레시피로 작성
연결화 (Combination)	형식지 → 형식지	형식지를 결합해 새 형식지 창출	각지의 레시피를 모아 요리책 편찬
내면화 (Internalization)	형식지 → 암묵지	형식지를 실천으로 체득해 자기 것화	매뉴얼 보고 반복 연습해 몸에 익힘

✓ 시험 POINT 변환 방향(암→암, 암→형, 형→형, 형→암)을 바꿔 내는 보기가 대표 함정

DIKW 피라미드

DIKW 계층 구조 (아래 → 위)

- | 데이터(Data): 가공하기 전의 순수한 수치·기호
 - 다른 데이터와의 상관관계가 없는 객관적 사실
- | 정보(Information): 데이터를 가공·처리해 의미 부여
 - 데이터 간 연관 관계 속에서 패턴을 인식한 것
- | 지식(Knowledge): 정보를 구조화해 도출한 고유 결과물
 - 유의미한 정보에 개인 경험을 결합해 내재화
- | 지혜(Wisdom): 근본 원리에 대한 깊은 이해
 - 지식의 축적과 아이디어가 결합된 창의적 산물
 - ↳ 피라미드 위로 갈수록 추상화 수준과 가치가 상승



DIKW 피라미드 — 가치의 상승

✓ 시험 POINT 예시 문장을 주고 해당 단계를 고르는 유형으로 출제 — 다음 슬라이드의 사례 필수 암기

DIKW 적용 예제: 연필 구매 사례

사례로 푸는 4단계 판별

- | ① 데이터: A마트 연필 100원, B마트 연필 200원
 - 가공하지 않은 개별 사실의 단순 나열
- | ② 정보: A마트의 연필이 B마트보다 싸다
 - 두 데이터를 비교해 의미(패턴)를 부여
- | ③ 지식: 연필은 더 저렴한 A마트에서 사야겠다
 - 정보를 행동 방침으로 구조화·내재화
- | ④ 지혜: A마트의 다른 상품도 B마트보다 쌀 것이다
 - 원리를 다른 대상으로 확장한 창의적 추론
 - ↳ 판별 순서: 사실 → 비교·의미 → 행동 결정 → 확장 추론

✓ 시험 POINT '~~할 것이다(확장 추론)'는 지혜, '~~해야겠다(행동 결정)'는 지식 — 서술어로 구분

1과목 1장

데이터베이스의 정의와 특징

DB의 역사·4대 특징·설계 절차, 그리고 DBMS

용어의 등장과 발전

- | 1950년대: 미군이 군수물자 관리용 수집 자료를
 - '데이터(data)의 기지(base)'라 부른 데서 유래
- | 1963년 6월: 미국 SDC 심포지엄에서 공식 사용
 - 초기 개념은 '대량의 데이터를 축적하는 기지'
- | 1963년: GE의 바크만, 최초의 DBMS인 IDS 개발
- | 1965년: 2차 심포지엄서 '데이터베이스 시스템' 등장
- | 1970년대 초: 유럽에서 '데이터베이스' 단일어 정착
 - 국내는 1975년 미국 CAC 정보 서비스로 처음 도입

현대적 정의

- | 체계적으로 수집·축적하여 다양한 용도와 방법으로
 - 이용할 수 있게 정리한 정보의 집합체(편집물로 보호)

✓ 시험 POINT 연도 순서 나열형 출제: 1950s 군수 → 1963 SDC → 1965 시스템 → 1970s 단일어

데이터베이스의 4대 특징

| 데이터베이스는 아래 4가지 특징을 모두 만족해야 한다 (암기: 통저공변)

특징	영문	의미
통합된 데이터	Integrated	동일한 내용의 데이터가 중복되어 있지 않음
저장된 데이터	Stored	컴퓨터가 접근할 수 있는 저장 매체에 보관
공용 데이터	Shared	여러 사용자가 서로 다른 목적으로 공동 이용
변화되는 데이터	Changed	추가·삭제·갱신에도 항상 현재의 정확한 데이터 유지

✓ 시험 POINT '중복을 허용해 안정성을 높인다'류 보기는 통합성 위배로 오답 — 단골 함정

데이터베이스의 일반적 특징

운영 관점의 4가지 특징

- | 실시간 접근성: 사용자 질의에 즉시 응답·처리
- | 계속적인 변화: 삽입·삭제·갱신으로 최신 상태 유지
- | 동시 공유: 여러 사용자가 동시에 같은 데이터 이용
- | 내용에 의한 참조: 주소가 아닌 데이터 값으로 검색

측면별 특성 (데이터 가이드 기준)

- | 정보 축적·전달: 기계가독성·검색가능성·원격조작성
- | 정보 이용: 원하는 정보를 신속·정확·경제적으로 획득
- | 정보 관리: 체계적 축적, 갱신·추가·삭제가 용이
- | 정보기술 발전: SW·HW·네트워크 기술 발전을 견인
- | 경제·산업: 정보 인프라로서 이용 활성화·유통 촉진

설계 5단계 (순서 암기: 요-개-논-물-구)

- | ① 요구조건 분석: 사용자 요구사항 수집·명세서 작성
- | ② 개념적 설계: DBMS에 독립적인 개념 스키마 설계
 - E-R 다이어그램(ERD) 작성, 트랜잭션 모델링
- | ③ 논리적 설계: 목표 DBMS에 맞는 논리 스키마 변환
 - 테이블 설계·정규화, 트랜잭션 인터페이스 설계
- | ④ 물리적 설계: 저장 구조와 접근 경로 설계
 - 인덱스·저장 레코드 양식 결정, 성능 고려
- | ⑤ 구현: DDL로 스키마 생성, 실제 데이터 적재
 - ↳ ERD는 개념적 설계, 정규화는 논리적 설계 단계의 산출물

✓ 시험 POINT 산출물의 소속 단계를 묻는 문제 빈출 — ERD=개념적, 정규화=논리적, 인덱스=물리적

DBMS(DataBase Management System) 정의

- | 사용자와 DB 사이에서 데이터를 관리하며, 여러 응용
 - 프로그램이 DB를 공유하는 환경을 제공하는 소프트웨어
 - 목적: 데이터 중복 최소화, 독립성 확보, 무결성 유지

DBMS의 3대 기능

- | 정의 기능: DDL로 DB의 구조(스키마)를 정의·변경
- | 조작 기능: DML로 데이터 검색·삽입·삭제·갱신 처리
- | 제어 기능: 무결성 유지, 보안·권한 관리,
 - 병행 수행 제어(동시성)로 데이터 일관성 보장
 - ↳ 대표 제품: Oracle, MySQL, MS-SQL, PostgreSQL 등

✓ 시험 POINT 정의·조작·제어 3대 기능과 DDL·DML·DCL의 대응 관계를 연결해 출제

DBMS의 종류

| 데이터 구조(모델)에 따른 DBMS 분류

유형	데이터 구조	특징·대표 예
계층형 DBMS	트리(부모-자식) 1:N 관계	최초의 상용 모델, IBM IMS
네트워크형 DBMS	그래프(망) N:M 관계	오너-멤버 구조, IDS
관계형 DBMS	2차원 테이블 (행·열)	현재의 주류, SQL 사용, Oracle·MySQL
객체지향 DBMS	객체 단위 저장	멀티미디어 등 복잡한 데이터 처리에 적합
NoSQL DBMS	비관계형, 유연한 스키마	대용량·수평 확장에 강점, MongoDB·HBase·Redis

✓ 시험 POINT 구조 매칭 문제 빈출: 관계형=테이블, 계층형=트리, 네트워크형=그래프(망)

NoSQL 상서: MongoDB·HBase·Redis

1장 DBMS

| Not Only SQL — 관계형 DB의 한계를 보완하는 비관계형 DB

제품	저장 모델	특징
MongoDB	문서(Document) 기반	JSON 유사(BSON) 문서로 저장, 스키마 유연, 대용량 처리
HBase	컬럼(Column) 기반	하둡 HDFS 위에서 동작, 구글 빅테이블 모델 기반
Redis	키-값(Key-Value)	인메모리 구조로 초고속 처리, 캐싱·세션 관리에 활용

✓ 시험 POINT MongoDB=문서형, HBase=컬럼형(하둡), Redis=키-값(인메모리) — 3종 매칭 암기 필수

1과목 1장

SQL과 데이터 분석 인프라

SQL 명령어 체계 · 데이터 웨어하우스 · OLTP와 OLAP

SQL 명령어 체계 (DDL·DML·DCL·TCL)

1장 SQL

| 관계형 DB를 다루는 표준 언어 SQL의 4대 분류

분류	명령어	기능
DDL (데이터 정의어)	CREATE / ALTER / DROP / RENAME / TRUNCATE	객체 생성 / 구조 변경 / 삭제 / 이름 변경 / 행 전체 삭제
DML (데이터 조작어)	SELECT / INSERT / UPDATE / DELETE	조회 / 삽입 / 수정 / 삭제
DCL (데이터 제어어)	GRANT / REVOKE	권한 부여 / 권한 회수
TCL (트랜잭션 제어)	COMMIT / ROLLBACK / SAVEPOINT	변경 확정 / 변경 취소 / 저장점 지정

✓ 시험 POINT TRUNCATE는 DDL, DELETE는 DML — 소속 분류를 바꿔 내는 함정이 최다 빈출

SELECT 기본 문법과 예제

기본 구문 구조

| SELECT 열 FROM 테이블 WHERE 조건

- GROUP BY 그룹열 HAVING 그룹조건 ORDER BY 정렬

예제: 학생 테이블에서 80점 이상 조회

| SELECT 이름, 점수 FROM 학생

| WHERE 점수 >= 80 ORDER BY 점수 DESC;

- → 80점 이상 학생을 점수 내림차순으로 출력

자주 쓰는 요소

| 집계함수: COUNT, SUM, AVG, MAX, MIN

| WHERE는 행 단위 조건, HAVING은 그룹(집계) 조건

↳ 실행 순서: FROM→WHERE→GROUP BY→HAVING→SELECT→ORDER BY

✓ 시험 POINT WHERE 절에는 집계함수 사용 불가, 집계 조건은 HAVING — 단골 함정

데이터 웨어하우스(DW)의 정의와 4대 특징

1장 DW

정의 (W. H. 인문)

- | 의사결정 지원을 위해 주제 중심으로 통합된
 - 시계열적이고 비휘발적인 데이터의 집합체

4대 특징 (암기: 주통시비)

- | 주제 지향성: 업무 기능이 아닌 주제(고객·상품) 중심
 - 최종 사용자가 이해하기 쉬운 형태로 구성
- | 통합성: 여러 원천의 데이터를 일관된 형식으로 통합
 - 코드·단위·형식을 표준화하여 적재
- | 시계열성: 시점별 변경 이력 데이터를 함께 보유
- | 비휘발성: 적재 후 갱신·삭제 없이 읽기 전용 유지
 - 배치 작업으로만 적재, 조회(분석) 위주로 사용

✓ 시험 POINT 'DW의 데이터는 수시로 갱신된다'는 보기는 비휘발성 위배로 오답 — 매회 출제급

ETL (Extract · Transform · Load)

- | 추출(E): 운영 DB 등 원천 시스템에서 데이터 획득
- | 변환(T): 클렌징, 형식 변환, 표준화, 통합
- | 적재(L): 변환 완료된 데이터를 DW·마트에 저장
 - DW·ODS·데이터 마트 구축의 핵심 프로세스

데이터 마트(Data Mart)

- | 특정 부서·주제에 특화된 소규모 데이터 웨어하우스
 - 예: 마케팅 부서 전용 고객 분석 마트
- | 전사 DW에서 부서별 마트를 파생하는 구조가 일반적
 - ↳ 흐름: 운영계(OLTP) → ETL → DW → 데이터 마트 → 분석

✓ 시험 POINT '데이터 마트=전사 통합 저장소'는 오답 — 전사는 DW(EDW), 마트는 부서·주제 단위

OLTP vs OLAP 비교

1장 DW

| OLTP=거래 처리(Transaction), OLAP=분석(Analytical) — 약자의 뜻으로 구분

구분	OLTP	OLAP
목적	일상 거래(트랜잭션)의 실시간 처리	다차원 분석과 의사결정 지원
데이터	현재의 상세 데이터	요약·이력(시계열) 데이터
주요 연산	INSERT·UPDATE·DELETE 빈번	주로 SELECT(읽기) 중심
저장소	운영계 데이터베이스	데이터 웨어하우스·마트
사용자	실무 담당자·운영 시스템	분석가·경영진
예시	주문 입력, 재고 관리, 계좌 이체	매출 추이 분석, 다차원 보고서

✓ 시험 POINT '호스트가 DB를 액세스해 처리 결과를 즉시 돌려보내는 방식'은 OLTP에 대한 설명

기업 내부 데이터베이스의 발전

1980년대: 운영 효율화 (OLTP)

| 호스트 중심 OLTP 시스템으로 일상 업무를 전산화

- 주문 입력·재고 관리 등 트랜잭션을 즉시 처리

1990년대: 정보의 분석 (DW·OLAP)

| 축적 데이터를 DW로 통합, OLAP으로 다차원 분석

- 데이터마이닝 등 분석 기술의 확산

2000년대: 정보의 전략화 (CRM·SCM)


| 고객(CRM)·공급망(SCM) 중심의 전략적 활용 단계

- 단순 축적을 넘어 가치 창출·경쟁력 강화의 도구로
 - ↳ 흐름: OLTP(처리) → DW·OLAP(분석) → CRM·SCM(전략)

✓ 시험 POINT 시대-키워드 매칭 출제: 80년대 OLTP, 90년대 DW·OLAP, 2000년대 CRM·SCM

기업 데이터 흐름 — OLTP에서 OLAP까지

1장 DW



운영계(OLTP)에서 정보계(OLAP)까지의 데이터 흐름

1과목 1장

산업별 데이터베이스 활용

CRM·SCM과 제조·금융·유통·사회기반 분야의 DB

CRM 상세: 고객관계관리

CRM (Customer Relationship Management)

- | 고객 데이터를 분석·통합해 고객 특성에 맞는
 - 마케팅을 계획·지원·평가하는 고객관계관리 시스템

3대 목적

- | 신규 고객 획득 · 기존 고객 유지 · 고객 수익성 증대
 - 고객 이탈 방지와 생애가치(LTV) 극대화

구성 요소

- | 분석 CRM: 고객 데이터 분석·세분화·캠페인 설계
- | 운영 CRM: 영업·마케팅·서비스 프로세스 자동화
- | 협업 CRM: 콜센터·이메일 등 고객 접점 채널 통합
 - ↳ 활용 예: 이탈 예측, 교차판매(Cross-sell), 타겟 마케팅

✓ 시험 POINT CRM의 목적 3가지(신규 획득·기존 유지·수익성 증대)를 통째로 묻는 문제 출제

SCM (Supply Chain Management)

- | 원자재 조달 → 생산 → 유통 → 판매의 공급망 전체를
 - 하나의 흐름으로 통합 관리해 최적화하는 시스템

핵심 개념

- | 기업 간 정보 공유로 재고 최소화·납기 단축
 - 수요 예측 실패 시 채찍 효과(수요 왜곡 증폭) 발생
- | 제조·물류·유통업체가 실시간 정보를 공동 활용

CRM과의 관계

- | CRM은 고객(수요) 측, SCM은 공급 측의 관리
 - 양측 데이터가 연계될 때 전사 최적화가 달성됨

✓ 시험 POINT CRM=고객 관계, SCM=공급망 — 수요측/공급측 방향을 바꿔 내는 보기 주의

제조 부문의 DB 활용

1장 DB 활용

| 제조 부문 키워드: ERP · BI · CIM · RTE

시스템	전체 명칭	내용
ERP	Enterprise Resource Planning	생산·재무·인사 등 경영자원을 전사적으로 통합 관리
BI	Business Intelligence	데이터 기반 의사결정 지원, 리포팅·대시보드·OLAP 포함
CIM	Computer Integrated Manufacturing	설계~생산 공정을 컴퓨터로 통합한 생산 자동화 시스템
RTE	Real Time Enterprise	기업 내외 정보를 실시간 공유해 즉시 대응하는 실시간 기업

✓ 시험 POINT BI는 '가공된 정보로 의사결정을 지원하는 프로세스·기술의 총칭'이 핵심 정의

금융·유통 부문의 DB 활용

1장 DB 활용

| 부문-시스템 매칭이 출제 포인트

부문	시스템	내용
금융	EAI	기업 내 이질적인 애플리케이션을 연계·통합하는 미들웨어
금융	EDW	전사 차원으로 확장된 DW, 경영 전반의 분석 기반
금융	블록체인	분산원장 기술로 거래 기록의 위·변조를 방지
유통	KMS	조직의 지식(암묵지·형식지)을 관리·공유하는 지식관리시스템
유통	RFID	무선 주파수로 태그를 판독해 사물을 비접촉 자동 식별

✓ 시험 POINT 금융=EAI·EDW·블록체인, 유통=KMS·RFID — 부문과 시스템의 짝 매칭 빈출

사회기반구조로서의 데이터베이스

| 1990년대 중반 이후 무역·통신·물류 등 사회 인프라 분야로 DB 구축 확산

시스템	분야	내용
EDI	무역·물류	표준화된 전자문서를 기업 간 교환(서류 없는 거래)
VAN	통신	부가가치통신망, EDI 전송 등 부가서비스 제공
CALS	전자상거래	제품 설계·생산~폐기까지 전 과정 정보를 디지털 통합
GIS	지리	지리공간 데이터를 수집·분석하는 지리정보시스템
GPS·LBS	위치	위성 측위(GPS)를 기반으로 한 위치기반 서비스(LBS)
ITS	교통	지능형 교통 시스템, 실시간 교통정보 수집·제공
NEIS	교육	교육행정 전반을 전산화한 교육행정정보시스템
PACS	의료	의료영상 저장·전송 시스템, 필름 없는 병원 구현

1장 총정리: 빈출 포인트 체크

1장 총정리

시험 직전 꼭 확인할 10가지

- | ① 정성(언어·문자) vs 정량(수치·기호) 데이터 구분
- | ② 암묵지·형식지와 SECI '공표연내' 순서·변환 방향
- | ③ DIKW: 예시 문장으로 단계 판별 (연필 사례)
- | ④ DB 4대 특징 '통저공변'과 내용에 의한 참조
- | ⑤ 설계 절차 요-개-논-물-구와 단계별 산출물
- | ⑥ DDL·DML·DCL·TCL 명령어의 소속 구분
- | ⑦ NoSQL 3종: MongoDB·HBase·Redis 모델 매칭
- | ⑧ DW 4대 특징 '주통시비'와 ETL·데이터 마트
- | ⑨ OLTP(거래 처리) vs OLAP(분석) 비교
- | ⑩ 부문별 시스템: 제조·금융·유통·사회기반 매칭
 - ↳ 1과목 10문항 20점 중 1장에서 통상 4~5문항 출제

1과목 2장

빅데이터의 이해

정의 · 3V · 출현 배경 · 가치와 영향

빅데이터의 정의 — 3가지 관점


빅데이터의 일반적 정의

- | 기존 DB의 수집·저장·관리·분석 역량을 넘어서는 대량 데이터
 - 맥킨지(2011): 일반적 DB SW의 관리·분석 범위를 초과하는 규모
 - IDC(2011): 대규모 데이터에서 저비용으로 가치를 추출하는 기술·아키텍처

정의의 3가지 관점 (범위 확대 순)

- | ① 규모(양) 관점: 데이터 크기 자체의 변화에 초점 — 맥킨지
- | ② 기술 관점: 처리·분석 기술의 변화까지 포함 — IDC, 하둡·NoSQL
- | ③ 인재·조직 관점: 데이터 사이언티스트, 조직 변화까지 포함
 - 마이어-쾨버거·쿠키어: 새로운 통찰·가치 추출 + 사회 전반의 변화
 - ↳ 좁은 정의 → 넓은 정의: 규모 → 기술 → 인재·조직 순으로 확대

✓ 시험 POINT 정의 주체 매칭 빈출: 맥킨지=규모 관점, IDC=기술 관점. 관점 확대 순서(규모→기술→인재조직) 암기



더그 래니의 3V와 Value

더그 래니의 3V와 확장(4V·5V·7V)

| 더그 래니(Doug Laney, 가트너)가 제시한 3V가 기본, 이후 V가 확장

구분	요소	의미
3V	Volume (규모)	데이터 양의 급증 — 테라·페타바이트급
3V	Variety (다양성)	정형·반정형·비정형 등 유형의 다양화
3V	Velocity (속도)	생성·유통·처리 속도의 고속화(실시간)
4V	+ Value (가치)	저밀도 데이터에서 가치 추출이 핵심 과제
5V	+ Veracity (신뢰성)	데이터의 품질·정확성 확보
7V	+ Validity·Volatility	유효성 + 휘발성(저장·활용 기간) 고려

✓ 시험 POINT 3V는 필수 암기. Value·Veracity는 4V·5V부터의 확장 요소 — 3V에 끼워넣는 함정 보기 주의

새로운 것의 등장이라 아니라 기존 흐름의 패러다임 전환

- | ① 산업계: 고객 데이터의 지속적 축적
 - 축적된 데이터에서 숨은 가치 발굴 → 새로운 성장 동력 확보
- | ② 학계: 거대 데이터를 다루는 과학의 확산
 - 게놈 프로젝트, NASA 기후 시뮬레이션 → 분석 기술·도구 발전
- | ③ 기술 발전: 관련 ICT 기술의 성숙
 - 디지털화, 저장기술 가격 하락, 인터넷·모바일 혁명
 - 클라우드 컴퓨팅(경제적 처리), 하둡 등 분산처리, SNS·IoT 확산

핵심 개념

| 빅데이터는 갑자기 출현한 것이 아님 — 축적과 기술 발전의 결과

✓ 시험 POINT 출현 배경 3주체(산업계·학계·기술 발전) 구분 출제. '갑자기 새로 등장'이라는 보기는 오답

빅데이터의 기능 — 4가지 비유

| 빅데이터가 사회·경제에 미치는 영향을 나타내는 4가지 비유

비유	의미
산업혁명의 석탄·철	생산성을 획기적으로 높여 사회·경제 전반에 혁명적 변화를 가져올 것
21세기의 원유	경제 성장에 필요한 정보를 제공, 산업 전반의 생산성 향상과 신산업 창출
렌즈	현미경이 생물학에 기여했듯 산업 발전에 기여 예: 구글 Ngram Viewer
플랫폼	공동 활용 목적으로 구축된 유무형 구조물 예: 페이스북, 카카오톡 (서드파티 활용)

✓ 시험 POINT 비유-예시 매칭 빈출: 렌즈=Ngram Viewer, 플랫폼=페이스북·카카오톡, 원유=21세기

빅데이터가 만든 본질적 변화 4가지

| 사고방식의 전환 — 화살표의 '방향'이 시험의 핵심

변화	내용
사전처리 → 사후처리	필요 정보만 골라 수집하던 방식에서 가능한 많이 모아 조합하며 가치 발굴
표본조사 → 전수조사	수집·처리 비용 하락(IoT·클라우드) 샘플링이 놓치는 패턴·정보 발견
질 → 양	데이터 양이 많을수록 일부 오류의 영향은 상쇄되어 사소해짐
인과관계 → 상관관계	이론적 인과 규명보다 상관관계로 현상의 발생 가능성을 포착해 대응

✓ 시험 POINT 방향을 뒤집은 함정 보기 최빈출(사후→사전 X, 전수→표본 X). 4가지 세트로 암기

빅데이터 가치 산정이 어려운 이유 3가지

가치 산정이 어려운 이유 3가지

- | ① 데이터 활용 방식: 재사용·재조합·다목적 개발의 일반화
 - 특정 데이터를 언제·어디서·누가 활용하는지 알 수 없음
 - 예: 전기차 충전 데이터가 배터리 개발·도시계획에 재사용
- | ② 새로운 가치 창출: 기존에 없던 가치를 만들어냄
 - 예: 아마존 추천 — 과거에 존재하지 않던 가치라 측정 곤란
- | ③ 분석 기술의 발달: 무가치한 데이터도 잠재 가치 보유
 - 새 분석 기법 등장으로 오늘 버려지는 데이터가 내일 가치 창출

암기 키워드

| '재사용·재조합' / '새로운 가치' / '분석기술 발달' 3종 세트

✓ 시험 POINT 3가지 이유에서 '아닌 것 고르기' 빈출 — '데이터 가격 상승' 류의 보기는 오답

빅데이터 활용 기본 테크닉 7가지

| 예시 문장을 주고 테크닉을 고르는 유형이 최빈출

테크닉	핵심 개념	대표 예시
연관규칙 학습	변수 간 상관관계·동시 발생 규칙 탐색	맥주 구매자가 기저귀도 사는가 (장바구니 분석, 상품 추천)
유형분석(분류)	새 사건을 기존 범주·집단으로 분류	이 사용자는 어떤 특성의 집단에 속하는가 (문서·고객 분류)
유전 알고리즘	자연선택·돌연변이를 모방한 최적화	최대 시청률을 위한 편성 최적화, 응급실 의사 배치 최적화
기계학습	훈련 데이터로 학습하여 예측	넷플릭스 시청기록 기반 영화 추천, 스팸메일 필터링
회귀분석	독립변수가 종속변수에 미치는 영향	구매자 나이가 구매 차량 타입에 어떤 영향을 미치는가
감정분석	글에 담긴 감정·평가 파악	신규 환불 정책에 대한 고객 평가 (리뷰·코멘트 분석)
소셜네트워크 분석	사람 간 관계·영향력 파악(SNA)	특정인과 몇 촌 관계인가, 오피니언 리더 찾기

✓ 시험 POINT 매칭 최빈출: 최적화=유전알고리즘, 영향=회귀, 함께 구매=연관규칙, 훈련=기계학습

테크닉 구분 키워드와 기출 함정

문제 지문 속 키워드 → 정답 테크닉

| '함께.같이 구매' → 연관규칙 학습

| '분류.범주.어떤 집단' → 유형분석

| '최적화.최대화.자연선택' → 유전 알고리즘

| '훈련 데이터.학습해 예측' → 기계학습

| '영향을 미치는가.독립/종속변수' → 회귀분석

| '평가.기분.감성.리뷰' → 감정분석

| '관계.영향력.팔로워' → 소셜네트워크 분석

자주 나오는 함정

- 기계학습 vs 유형분석: '훈련 데이터로 학습' 언급 시 기계학습
- 연관규칙 vs 회귀: 방향 없는 동시 발생=연관, 영향.인과=회귀

✓ 시험 POINT 기출은 개념 정의보다 '예시 문장→테크닉' 매칭형이 압도적 — 키워드 반사훈련 필수

빅데이터 활용 사례 — 기업

2장 빅데이터

| 기업-서비스명 매칭이 그대로 출제

기업	활용 내용
구글	사용자 로그로 검색 품질 개선(페이지랭크 혁신) 자동번역 — 수십억 문장 기반 통계적 번역
넷플릭스	시네매치(Cinematch) 추천 엔진 시청 이력 기반 개인화 영화 추천
IBM 왓슨	퀴즈쇼 제퍼디! 우승(2011) 자연어 질의응답, 의료 진단 지원으로 확장
아마존	구매 이력 기반 도서·상품 추천 시스템 교차판매(크로스셀링) 확대
월마트	구매 패턴 분석으로 상품 진열·재고 관리 (허리케인 예보 시 손전등·맥주 수요 예측)
자라(ZARA)	일별 판매 데이터 분석으로 수요 예측, 매장별 재고 최적화

✓ 시험 POINT 넷플릭스=시네매치, IBM=왓슨, 구글=검색·자동번역, 아마존=추천 — 짝 바꿔치기 함정 주의

정부의 활용 — 3단계 흐름

| 환경 탐색: 실시간 교통정보, 기후·지질, CCTV 데이터 수집

- 상황 분석: 사회 변화 추정, 재해·안보 관련 정보 분석
- 미래 대응: 법제도·거버넌스 정비, 국가 안전 확보 시스템
 - ↳ 예: 싱가포르 국가위험관리시스템(RAHS), 국가안보 모니터링

개인의 활용

| 정치인: 사회관계망 분석으로 유세 지역·유권자 맞춤 공약 선정

- 예: 오바마 캠프의 유권자 DB 기반 마이크로 타겟팅

| 가수: 팬들의 트윗 등 반응 분석으로 공연 곡목·장소 결정

- ↳ 클라우드로 분석 비용이 낮아져 개인도 빅데이터 활용 가능

✓ 시험 POINT 정부 활용 3단계(환경탐색→상황분석→미래대응)와 기업/정부/개인 주체 구분 출제

1과목 2장

빅데이터의 위기와 미래

위기 요인 3가지 · 통제 방안 · 미래의 3요소

위기 요인 3가지와 통제 방안

| 요인-방안의 1:1 매칭이 1과목 최빈출 포인트

위기 요인	내용	통제 방안
사생활 침해	목적 외 활용 시 위험 증가 익명화해도 재식별 우려	동의제 → 책임제 (사용자가 책임지는 방식)
책임 원칙 훼손	예측 알고리즘의 잠재적 위험 (범죄 예측으로 사전 처벌 등)	결과 기반 책임 원칙 고수 (실제 행동 결과에만 책임)
데이터 오용	잘못된 지표·데이터 맹신 → 그릇된 인사이트, 직접 손실	알고리즘 접근권 허용, 알고리즘미스트 양성

✓ 시험 POINT 알고리즘미스트=알고리즘으로 인한 불이익을 구제하는 전문가, 데이터 오용의 통제 방안

동의에서 책임으로 — 옵트인과 옵트아웃

사생활 침해의 통제 — 동의에서 책임으로

- | 정보 제공자의 '동의' → 정보 사용자의 '책임'으로 전환
 - 건건이 동의받는 절차는 비효율 — 활용 주체가 책임지는 방식

옵트인(Opt-in) vs 옵트아웃(Opt-out)

- | 옵트인: 정보 주체의 사전 동의가 있어야 수집·이용 가능
 - 우리나라 개인정보보호법의 기본 원칙(사전 동의제)
- | 옵트아웃: 거부 의사를 밝히기 전까지는 수집·이용 허용
 - 예: 수신 거부 의사를 밝히기 전까지 광고 메일 발송 허용

책임 원칙 훼손의 상징 사례

- | 영화 '마이내리티 리포트' — 범죄 예측으로 잠재 위험자 사전 체포
 - 민주주의 원칙 훼손 — 실제 결과에 기반해서만 책임을 물어야 함

✓ 시험 POINT 옵트인=사전 동의 후 수집, 옵트아웃=사후 거부까지 허용. 정의를 서로 바꾼 함정 주의

빅데이터 활용에 필요한 기본 3요소

- | ① 데이터: 모든 것의 데이터화(Datafication)
 - 사물인터넷(IoT) — 센서·M2M 통신으로 만물이 데이터 생성
- | ② 기술: 진화하는 알고리즘, 인공지능
 - 스스로 학습하는 기계(머신러닝·딥러닝), 패턴 발견 고도화
- | ③ 인력: 데이터 사이언티스트, 알고리즘미스트
 - 사이언티스트=가치 추출, 알고리즘미스트=알고리즘 피해 구제

클라우드 컴퓨팅과의 관계

- | 저렴한 저장·분석 인프라 → 빅데이터 확산의 경제적 기반
 - 분산 병렬처리(맵리듀스 등)로 대용량 데이터를 저비용 처리
 - ↳ IoT는 데이터 요소를, 클라우드는 기술(비용) 요소를 뒷받침

✓ 시험 POINT 3요소=데이터·기술·인력. 각 요소의 연결 키워드(IoT·AI·사이언티스트) 매칭 출제

1과목 3장

데이터 사이언스와 전략 인사이트

회의론을 넘어 가치 창조의 분석으로

빅데이터 회의론 — 2가지 원인

빅데이터 열풍과 회의론

| 열풍은 거품 우려를 낳고, 회의론은 성과까지 부당하게 폄하

회의론의 원인 2가지

| ① 과거의 부정적 학습 효과 — CRM의 트라우마

- 1990년대 CRM: 공포 마케팅으로 고가 도입 → 효과는 미미
- '빅데이터도 CRM처럼 실패할 것'이라는 인식 확산

| ② 과대 포장 — 빅데이터가 필요 없는 사례까지 포장

- 기존 분석으로 충분한 프로젝트를 빅데이터 성공담으로 홍보
- 우수 사례가 알고 보면 빅데이터와 무관 → 신뢰 하락

극복 방향

| 부정론·낙관론 모두 경계, 가치 창출 관점의 냉정한 접근

✓ 시험 POINT 회의론 원인 2가지(부정적 학습효과=CRM, 과대 포장) 고르기 문제 빈출

일차원적 분석 vs 전략 인사이트

일차원적 분석 — 업계 내부 문제에만 초점

- 금융: 신용점수 산정·사기 탐지 / 소매: 재고·판촉 분석
- 제조: 공급사슬 최적화 / 운송: 경로 최적화 / 병원: 질병 관리
 - ↳ 내부 효율은 높이지만 환경 변화·전략 대응에는 취약

전략 인사이트를 주는 가치 기반 분석

| 사업 성과를 견인하는 핵심 이슈에 답하는 분석

- 전략적 통찰로 비즈니스 핵심 가치와 분석을 연결
- 경쟁 환경 변화를 내다보고 기회 포착·위협 대응

시사점

| 분석 자체가 아니라 '전략과 연결된 분석'이 성과를 만든다

↳ 일차원 분석도 출발점으론 의미 — 궁극적으론 전략 차원 확장 필요

✓ 시험 POINT 산업별 일차원적 분석 예(금융=신용점수·사기탐지 등) 매칭 문제 출제 이력 있음

싸이월드 사례 — 인프라가 있어도 실패한 이유

싸이월드의 몰락 (2004년 세계 최대급 SNS → 쇠퇴)

| 실패 원인: 데이터 분석 기반 경영 문화의 부재

- OLAP 등 분석 인프라는 존재 — 중요 의사결정에 활용 안 됨
- 웹로그 분석 수준의 일차원적 분석에 그침
- 트렌드 변화가 사업에 미칠 영향을 읽는 전략 인사이트 부재
- SNS 특성을 반영한 분석 프레임워크·평가지표 부재

교훈

| 분석 도구 보유 ≠ 데이터 기반 경영 — 전략적 활용이 핵심

↳ 회원 이탈·수익모델 등 핵심 질문에 데이터로 답하지 못함

✓ 시험 POINT '분석 인프라가 없어 실패'는 함정 — 인프라는 있었으나 전략적 활용·문화 부재가 정답

데이터 사이언스의 정의와 통계학과의 차이

데이터 사이언스의 정의

| 데이터로부터 의미 있는 정보를 추출해내는 학문

- 정형·비정형을 막론한 다양한 유형의 데이터가 대상
- 분석 + 구현 + 전달까지 포괄하는 총체적(holistic) 접근

통계학과의 차이

| 통계학: 정형화된 실험 데이터를 주된 분석 대상으로 함

| 데이터 사이언스: 비정형 포함 모든 유형 + 구현·전달 포괄

↳ 통계학·수학·컴퓨터과학·시각화·해커 정신의 총합


데이터 사이언스의 역할

| 비즈니스 핵심 이슈에 답하고 사업 성과를 견인

- 전략적 통찰을 주는 분석 — 과학과 인문학의 교차로

✓ 시험 POINT '통계학과 동일' 보기는 오답 — 대상 데이터 범위와 총체적 접근이 결정적 차이

데이터 사이언스 3영역 벤다이어그램



데이터 사이언스 3대 영역

데이터 사이언스의 3대 구성 영역

| 세부 항목이 어느 영역 소속인지 묻는 문제가 빈출

구성 영역	세부 내용
IT 영역 (Data Management)	시그널 프로세싱, 프로그래밍, 데이터 엔지니어링, 데이터 웨어하우징, 고성능 컴퓨팅
분석 영역 (Analytics)	수학, 확률 모델, 머신러닝, 분석학, 패턴 인식과 학습, 불확실성 모델링
비즈니스 분석 (비즈니스 컨설팅)	커뮤니케이션, 프레젠테이션, 스토리텔링, 시각화, 비즈니스 이해

✓ 시험 POINT 머신러닝=분석 영역, 프로그래밍·웨어하우징=IT, 스토리텔링·시각화=비즈니스 — 소속 암기

데이터 사이언티스트의 하드 스킬 · 소프트 스킬

3장 데이터사이언스

구분	역량	세부 내용
하드 스킬	빅데이터에 대한 이론적 지식	관련 기법의 이해와 방법론 습득
하드 스킬	분석 기술에 대한 숙련	최적의 분석 설계, 노하우 축적
소프트 스킬	통찰력 있는 분석	창의적 사고, 호기심, 논리적 비판
소프트 스킬	설득력 있는 전달	스토리텔링, 시각화(Visualization)
소프트 스킬	다분야 간 협력	커뮤니케이션

✓ 시험 POINT 하드=이론지식·분석기술 2개, 소프트=통찰·전달·협력 3개. 소속 바꿔치기 함정 최빈출

가트너 4대 역량과 인문학적 통찰

가트너가 본 데이터 사이언티스트의 4대 역량

- | ① 데이터 관리(Data Management): 데이터에 대한 이해
- | ② 분석 모델링(Analytics Modeling): 분석 기법 이해·활용
- | ③ 비즈니스 분석(Business Analysis): 비즈니스 요소 초점
- | ④ 소프트 스킬(Soft Skill): 커뮤니케이션·협력·리더십

전략적 통찰력과 인문학

- | 단순한 세계 → 복잡한 세계: 다양성·불확실성 증가
 - 정량 분석만으로는 복잡한 인간·시장 이해가 어려움
- | 요구되는 인문학적 요소
 - 스토리텔링, 커뮤니케이션, 창의력, 직관력, 비판적 시각, 열정

✓ 시험 POINT 가트너 4대 역량에 '통계학', 'IT 구축' 등을 끼워넣는 함정 보기 주의


가치 패러다임의 변화 3단계

| 가치 창출의 원천이 시대에 따라 이동한다

단계	시기	내용 · 예시
디지털화 (Digitalization)	과거	아날로그 세상을 효과적으로 디지털화 예: MS 운영체제, 워드·파워포인트
연결 (Connection)	현재	디지털화된 정보·대상의 효과적 연결 예: 구글 검색, SNS, 아마존
에이전시 (Agency)	미래	복잡한 연결을 효과적·신뢰성 있게 관리 예: 사물인터넷 관리, AI 에이전트

✓ 시험 POINT 순서 암기: 디지털화→연결→에이전시. 단계별 대표 예시(MS→구글→IoT) 매칭 출제

가치 패러다임의 변화 도식



디지털화 → 연결 → 에이전시

인문학 열풍의 이유 — 외부 환경 요인 3가지

외부 환경에서 본 인문학 열풍의 이유

- | ① 컨버전스 → 디버전스: 단순 세계화에서 복잡한 세계화로
 - 규격화·표준화의 시대가 끝나고 다양성·개성의 시대로
- | ② 제품 생산 → 서비스: 비즈니스 중심의 이동
 - 제품 자체보다 서비스·경험이 가치를 좌우
- | ③ 생산 → 시장 창조: 공급자 기술 경쟁 → 무형자산 경쟁
 - 새로운 시장을 만들어내는 통찰과 창의성이 경쟁력

시사점

- | 복잡한 세계에서는 인간·사회에 대한 이해(인문학)가 필수
 - ↳ 데이터 사이언티스트에게 인문학적 통찰이 요구되는 배경

✓ 시험 POINT 변화의 방향(컨버전스→디버전스, 생산→서비스, 생산→시장창조)을 뒤집은 함정 빈출

1과목 심화

개인정보 비식별화

안전한 데이터 활용을 위한 5가지 기법

개인정보 비식별화 5가지 기법

비식별화

| 2016년 가이드라인 기준 5개 기법·17개 세부기술

기법	세부 기술	예시
가명처리	휴리스틱 가명화, 암호화, 교환 방법	홍길동, 35세 → 임꺽정, 30대
총계처리	총계·부분총계, 라운딩, 재배열	학생별 키 → 학생 평균 키 165cm (개별 값을 집계값으로)
데이터 삭제	식별자(부분) 삭제, 레코드 삭제	주민번호 901206-1234567 → 90년대생 남자
데이터 범주화	감추기, 랜덤 라운딩, 범위 방법, 제어 라운딩	홍길동, 35세 → 홍씨, 30~40세
데이터 마스킹	임의 잡음 추가, 공백과 대체	홍길동 → 홍○○, 한국대학교 → ○○대학교

✓ 시험 POINT 기법-예시 매칭 최빈출. 범주화(홍씨 30~40세)와 가명처리(임꺽정 30대) 구분이 단골 함정

5가지 기법 구분 포인트

- | 가명처리: 식별 불가능한 다른 값(가명)으로 대체
- | 집계처리: 개별 값을 합계·평균 등 통계값으로 제공
- | 데이터 삭제: 식별자 자체를 제거
- | 데이터 범주화: 정확한 값을 범위·구간으로 변환
- | 데이터 마스킹: 식별 요소를 ○·× 등 기호로 가림

프라이버시 보호 신기술 (간단 소개)

- | 동형암호: 암호화된 상태 그대로 연산·분석이 가능한 기술
- | 차분 프라이버시: 노이즈를 섞어 개인 식별을 막고 통계 제공
 - ↳ 비식별화 후에도 다른 정보와 결합 시 재식별 위험 상존
 - ↳ → 적정성 평가와 사후 관리가 반드시 필요

✓ 시험 POINT 동형암호='암호화 상태에서 연산'이 키워드. 신기술 용어 정의 고르기 유형으로 출제

2~3장 총정리 — 핵심 암기 리스트

총정리

시험 직전 최종 점검 (방향·매칭이 핵심)

- | 3V(더그 래니): Volume·Variety·Velocity / Value는 4V부터
- | 본질 변화: 사전→사후, 표본→전수, 질→양, 인과→상관
- | 가치 산정 곤란 3: 재사용·재조합 / 새 가치 / 분석기술 발달
- | 위기→통제: 사생활→책임제, 책임훼손→결과기반, 오용→알고리즘미스트
- | 미래 3요소: 데이터(IoT) · 기술(AI) · 인력(사이언티스트)
- | 회의론 2원인: 부정적 학습효과(CRM), 과대 포장
- | DS 3영역: IT·분석·비즈니스 / 가트너 4대 역량+소프트스킬
- | 가치 패러다임: 디지털화 → 연결 → 에이전시
- | 인문학 외부요인: 디버전스·서비스·시장창조
- | 비식별화 5기법: 가명·총계·삭제·범주화·마스킹

✓ 시험 POINT 1과목 2~3장에서 통상 4~6문항 출제 — 이 슬라이드 반복 복습으로 마무리

보충

심화·보충 개념

출제기준 대조로 추가된 내용

데이터 크기 단위의 순서

보충 데이터 단위


| 1,024배(약 10의 3승)씩 커진다 — 순서 나열형이 그대로 출제

단위	환산	10진 근사
킬로바이트(KB)	1,024 B	10^3 B
메가바이트(MB)	1,024 KB	10^6 B
기가바이트(GB)	1,024 MB	10^9 B
테라바이트(TB)	1,024 GB	10^{12} B
페타바이트(PB)	1,024 TB	10^{15} B
엑사바이트(EB)	1,024 PB	10^{18} B
제타바이트(ZB)	1,024 EB	10^{21} B
요타바이트(YB)	1,024 ZB	10^{24} B

✓ 시험 POINT 암기: 킬·메·기·테 다음 '페엑제요(PEZY)' — TB 다음 단위 고르기, 크기 비교 문제 빈출

데이터 크기 단위 계단

보충 데이터 단위



데이터 크기 단위의 계층

익명화 vs 가명화 — 복원 가능성으로 구분

익명화(Anonymization)

- | 개인 식별 요소를 삭제·변형해 누구인지 알 수 없게 처리
 - 원본으로의 복원이 불가능 — 재식별 위험 원천 차단

가명화(Pseudonymization)

- | 이름 등 식별자를 가명·일련번호 등 다른 값으로 대체
 - 매핑(대응) 정보가 남아 있으면 원래 정보로 복원 가능

구분 기준은 단 하나 — 복원 가능성

- | 복원 가능하면 가명화, 불가능하면 익명화
 - ↳ 47회 기출: 두 정의를 서로 바꿔 놓은 보기 판별 문제

✓ 시험 POINT '가명화는 복원 불가능하다'는 보기는 오답 — 매핑 정보 존재 시 복원 가능성이 핵심 차이

개인정보·가명정보·익명정보와 데이터 3법

보충 개인정보

| 데이터 3법(개인정보보호법·신용정보법·정보통신망법) 개정으로 도입된 구분

구분	식별 가능성	활용 조건
개인정보	특정 개인을 알아볼 수 있음	정보주체의 사전 동의 필요 (옵트인 원칙)
가명정보	추가 정보와 결합해야 재식별 가능	통계작성·연구·공익 기록 목적은 동의 없이 활용 가능
익명정보	시간·비용·기술을 고려할 때 재식별 불가능	개인정보가 아니므로 제한 없이 자유롭게 활용

✓ 시험 POINT 가명정보=동의 없이 통계·연구 목적 활용이 핵심. 마이데이터=개인신용정보 전송요구권 제도

연관규칙의 3대 평가지표

규칙 'A → B'를 평가하는 3가지 지표

- | 지지도(Support): 전체 거래 중 A·B 동시 구매 비율
 - 공식: $P(A \cap B) = \text{동시 거래 수} \div \text{전체 거래 수}$
- | 신뢰도(Confidence): A 구매자 중 B도 구매한 비율
 - 공식: $P(B|A) = \text{동시 거래 수} \div \text{A 거래 수}$
- | 향상도(Lift): 우연 대비 규칙의 개선 정도
 - 공식: $\text{신뢰도} \div P(B)$ — B의 전체 구매율로 나눔

향상도 해석 (숫자 1이 기준)

- | 향상도 > 1: 양의 상관 — 함께 구매되는 경향
- | 향상도 = 1: 서로 독립 — 관련 없음
- | 향상도 < 1: 음의 상관 — 서로 배타적 관계

✓ 시험 POINT '향상도=1이면 독립'이 최다 출제 포인트 — 1과목·3과목 공통 출제 영역

계산 예제: 지지도·신뢰도·향상도

보충 연관분석

문제

- | 전체 거래 100건, 맥주 구매 40건, 기저귀 구매 30건
- | 동시 구매 20건 — 규칙 '맥주 → 기저귀'를 평가하라

풀이 3단계

- | ① 지지도 = $20 \div 100 = 0.20$ (20%)
- | ② 신뢰도 = $20 \div 40 = 0.50$ (50%)
 - 맥주 구매자의 절반이 기저귀도 함께 구매
- | ③ 향상도 = $0.50 \div (30 \div 100) = 0.50 \div 0.30 \approx 1.67$
 - 1보다 크다 → 맥주와 기저귀는 양의 상관관계

검산

↳ 향상도 = 지지도 $\div$ ($P(A) \times P(B)$) = $0.20 \div 0.12 \approx 1.67$ 동일

✓ 시험 POINT 분모 함정: 신뢰도는 A(조건부) 거래 수로, 향상도는 B의 전체 구매율로 나눈다

분류·회귀·군집·연관규칙 구분

보충 분석기법

레이블(정답) 유무와 출력 형태로 구분 — 46·47회 연속 출제

기법	학습 유형	출력·예시
분류 (Classification)	지도학습 (레이블 있음)	범주(등급) 예측 예: 스팸 여부, 우량·불량 고객
회귀 (Regression)	지도학습 (레이블 있음)	연속형 수치 예측 예: 주택 가격, 매출액 예측
군집 (Clustering)	비지도학습 (레이블 없음)	유사한 것끼리 그룹화 예: 고객 세분화
연관규칙 (Association)	비지도학습 (레이블 없음)	동시 발생 패턴 발견 예: 장바구니 분석

✓ 시험 POINT 한 줄 판별법: 범주를 맞히면 분류, 숫자를 맞히면 회귀, 정답 없이 묶으면 군집


빅데이터 처리 기술 — 하둡 생태계

보충 처리기술

| 저비용 대용량 처리를 가능케 한 기술 — 용어 정의 고르기 유형 출제

기술	핵심 개념
하둡(Hadoop)	대용량 데이터의 분산 저장·처리 오픈소스 프레임워크, HDFS(저장) + 맵리듀스(처리)
HDFS	하둡 분산 파일 시스템 — 데이터를 블록으로 나눠 여러 서버에 복제 저장
맵리듀스 (MapReduce)	Map(분할·매핑) → Reduce(집계) 2단계로 대용량 데이터를 병렬 처리
아파치 스파크 (Spark)	인메모리 기반 분산 처리 — 디스크 기반 맵리듀스보다 빠른 실시간·반복 분석
NoSQL	비관계형 DB, 유연한 스키마 — 수평 확장으로 대용량 처리에 강점
클라우드 컴퓨팅	IT 자원을 필요한 만큼 빌려 쓰는 방식 — 빅데이터 확산의 경제적 기반

✓ 시험 POINT 매칭 암기: 하둡=HDFS+맵리듀스, 스파크=인메모리(더 빠름), 맵리듀스=분할 후 집계



하둡 생태계 — 저장·처리·활용 계층

빅데이터에 의한 경영혁신 4단계

보충 빅데이터 가치

혁신의 수준이 점진적으로 높아지는 4단계

- | ① 생산성 향상: 운영 효율 개선·원가 절감
 - 예: 월마트의 재고·진열 최적화
- | ② 발견에 의한 문제 해결: 숨은 패턴으로 문제 진단
 - 예: 구글 독감 트렌드 — 검색어로 유행 조기 감지
- | ③ 의사결정 향상: 데이터 기반 실시간 의사결정
 - 예: 신용평가 모형, 추천 시스템의 자동 판단
- | ④ 새로운 고객가치와 비즈니스 창출
 - 예: 데이터 판매, 플랫폼 비즈니스 등 신시장 개척
 - ↳ 단계가 올라갈수록 창출되는 가치·혁신 수준 상승

✓ 시험 POINT 순서 나열형 출제: 생산성 → 문제 해결 → 의사결정 → 새로운 가치 창출 (거꾸로 내는 함정 주의)

1과목 핵심 요약 — 시험 직전 체크리스트

핵심 요약

- | 데이터: 정성/정량, 암묵지/형식지, SECI(공→표→연→내), DIKW(D→I→K→W)
- | 데이터베이스: 통·저·공·변 4대 특징, SQL(DDL·DML·DCL)
- | DW 4대 특징: 주제지향성·통합성·시계열성·비휘발성
- | 기업 DB: OLTP(처리)/OLAP(분석), CRM(고객)/SCM(공급망)
- | 분야별: 제조 ERP·BI·RTE / 금융 EAI·EDW / 유통 KMS·RFID / 사회기반 EDI·VAN·CALS
- | 빅데이터: 3V(Volume·Variety·Velocity)+Value, 비유(석탄·철/원유/렌즈/플랫폼)
- | 변화: 사전→사후처리, 표본→전수, 질→양, 인과→상관
- | 위기와 통제: 사생활침해→책임제 / 책임원칙훼손→결과기반책임 / 오용→알고리즘미스트
- | 3요소: 데이터·기술·인력 / 데이터 사이언스 3영역: 분석·IT·비즈니스
- | 역량: 하드 스킬(이론·기술) vs 소프트 스킬(통찰·전달·협력)
- | 가치 패러다임: 디지털화 → 연결 → 에이전시

1과목

문제풀이

기출 유형 50문항 — 풀이 후 정답표로 채점