ADsP 데이터분석 준전문가

3과목(2) 정형 데이터 마이닝

만든이 유연휘

3과목 1장

R 기초와 데이터 마트

시험에 나오는 R 핵심 · 데이터 마트 · 결측값과 이상값

R은 어떤 도구인가

| 통계·그래프에 특화된 무료 언어

1 무료 오픈소스

S언어 기반
누구나 내려받아 사용

2 CRAN 패키지

수많은 추가 기능
= 스마트폰 앱

3 어디서나 실행

윈도우·맥·리눅스

4 인메모리 방식

메모리에 다 올려 계산
→ **대용량엔 불리**

구분	R	Python
강점	통계·시각화 특화	범용(머신러닝·서비스)
비유	통계 전문 계산기	만능 공구 세트
오늘	시험 범위	범위 밖

install.packages("dplyr")

설치: 딱 1번
(앱 설치)

→

library(dplyr)

로드: 쓸 때마다
(앱 실행)

✓ **시험 POINT** 'R은 대용량 처리에 유리하다' = 대표 오답. 설치 1회, 로드는 매번

데이터 타입 3가지

| 숫자 · 문자 · 참거짓, 섞이면 하나로 통일

타입	뜻 (쉽게)	예시
numeric	숫자 (정수·소수)	3, 2.5, -1
character	문자 — 따옴표로 감쌈	"a", "챔버A"
logical	참 / 거짓	TRUE, FALSE (T, F)

섞으면? → 더 '넓은' 타입으로 통일

logical → numeric → character

c(1, "a") → | "1" | "a" | 전부 문자로

c(TRUE, 2) → | 1 | 2 | TRUE → 1

c()로 묶은 값은 **한 가지 타입만**.
문자가 하나라도 섞이면 전부 문자가 됩니다.

✓ **시험 POINT** 문자가 섞이면 전부 문자: c(1, "a") → "1" "a"

특수값 4가지 — NA · NULL · NaN · Inf

NA

값이 비어 있음
(결측값)

c(1, NA, 3)

1	NA	3

길이 3 — 자리는 있음

확인: is.na()

NULL

아예 없음
(자리도 없음)

c(1, NULL, 3)

1	3

길이 2 — 자리 자체가 없음

확인: is.null()

NaN

숫자가 아님
Not a Number

0 / 0

NaN

계산 불가

확인: is.nan()

Inf

무한대
Infinity

1 / 0

Inf

-1 / 0 → -Inf

확인: is.infinite()

✓ **시험 POINT** NA는 자리 있음, NULL은 자리 없음. 0/0 = NaN, 1/0 = Inf

연산자 — 몫과 나머지

기호	뜻	예 → 결과
^	거듭제곱	2^3 → 8
%/%	몫	7 %/% 2 → 3
%%	나머지	7 %% 2 → 1
== !=	같다 / 다르다	3 == 3 → TRUE
& | !	그리고 / 또는 / 아님	TRUE & FALSE → FALSE
<-	대입(저장)	x <- 3
<<-	전역 대입	함수 안에서 바깥 변수 변경

사탕 7개를 2명에게 나누면?



7 %/% 2 = 3

한 사람 몫

7 %% 2 = 1

남는 것(나머지)

또 해 보기: 9 %% 4 = 1, 10 %/% 3 = 3

✓ **시험 POINT** %/% 몫, %% 나머지 — 결과 계산 문제 빈출. <<- 는 전역 대입

R 기초문법 — 출력 · 대입 · 변수 관리 · 함수

| 명령 하나가 하는 일을 표로 정리

명령	하는 일	예시 → 출력
print(a)	값을 화면에 출력	print(10) → 10
a <- 10 **a = 10**	변수에 값을 저장(대입) (둘 다 같은 뜻)	print(a) → 10
ls()	지금 있는 변수 목록 보기	→ "a" "b"
rm(b)	변수 b를 지우기	(조용히 지워짐)
b	지운 변수를 부르면?	**Error: 객체 'b'를 찾을 수 없습니다**

function 안과 밖 — 지역 vs 전역

```
f <- function() {
   x = 10     # 지역
   y <<- 20    # 전역
}
```

지역변수 x

함수 안에서만 존재
f() 뒤 밖에서 x → 오류

전역변수 y

함수 밖에서도 존재
f() 뒤 밖에서 y → 20

✓ **시험 POINT** rm()으로 지운 변수를 부르면 오류. 함수 안 <<- 는 전역변수

R 수학 함수

| 올림·내림·버림·반올림은 음수에서 갈립니다

헷갈리는 4형제 — 올림 · 내림 · 버림 · 반올림

x	ceiling 올림	floor 내림	trunc 버림	round 반올림
2.3	3	2	2	2
2.7	3	2	2	3
−2.7	−2	−3	−2	−3

음수가 함정 −2.7의 올림은 −2, 내림은 −3
trunc는 소수점 아래를 **그냥 잘라 버림** (0 쪽으로)

함수	하는 일	예시 → 결과
round(x, digits=n)	소수 n째 자리까지 반올림	round(2.567, digits=1) → 2.6
sqrt(x)	제곱근	sqrt(16) → 4
exp(x)	지수함수 (e의 x제곱)	exp(0) → 1
log(x)	자연로그	log(1) → 0
log(x, base=a)	a를 밑으로 하는 로그	log(8, base=2) → 3
sin(x) cos(x) tan(x)	삼각함수	cos(0) → 1
factorial(n)	n 팩토리얼 (1부터 n까지 곱)	factorial(4) → 24
choose(n, k)	n개 중 k개 뽑는 조합의 수	choose(5, 2) → 10

✓ 시험 POINT ceiling −2.7 = −2, floor −2.7 = −3, trunc −2.7 = −2

R 통계 함수

| 작은 벡터 하나로 모든 결과를 확인해 봅니다

x <- c(2, 4, 6)

함수	뜻	예시 → 결과
mean(x)	평균	mean(x) → 4
sum(x)	합계	sum(x) → 12
median(x)	중앙값	median(x) → 4
max(x)	최댓값	max(x) → 6
min(x)	최솟값	min(x) → 2
var(x)	분산	var(x) → 4
sd(x)	표준편차	sd(x) → 2
length(x)	값의 개수(길이)	length(x) → 3

y <- c(1, 3, 5)

함수	뜻	예시 → 결과
cov(x, y)	공분산	cov(x, y) → 4
cor(x, y)	상관계수	cor(x, y) → 1
log(x)	각 값의 로그	→ 0.69 1.39 1.79

var = sd의 제곱 (sd 2 → var 4)
cor은 −1 ~ 1 사이 (1 = 완전 정비례)
cov, cor는 변수가 **두 개** 필요

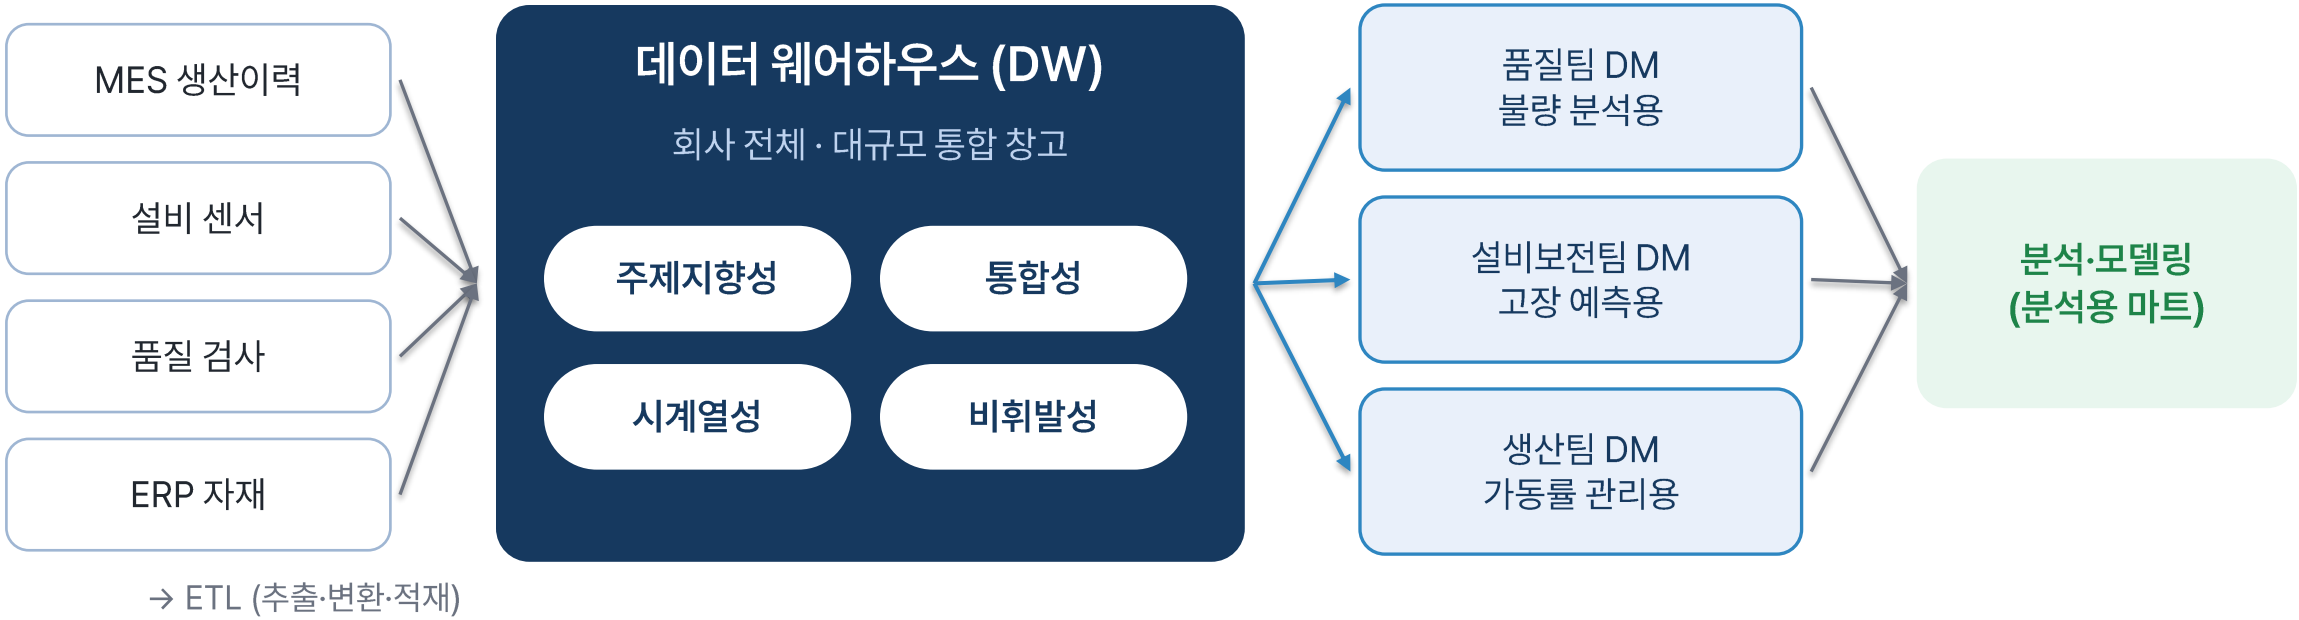
✓ **시험 POINT** var = sd의 제곱, cor은 −1 ~ 1. '다음 R 코드의 결과는?'

3과목 1장

데이터 마트

DW·DM, 요약변수와 파생변수

데이터 웨어하우스와 데이터 마트



DW = 국립중앙도서관
전사 데이터를 모두 · 대규모 · 한번 넣으면 안 바뀜(비휘발)

DM = 우리 학과 자료실
특정 부서·주제에 필요한 것만 · 소규모

✓ **시험 POINT** DW = 전사·대규모, DM = 부서·주제별 소규모. DW 특징 4가지

요약변수 vs 파생변수

구분	요약변수	파생변수
뜻	모은 정보를 합계·횟수·평균으로 **요약**	의미·조건을 붙여 **새로 만든** 변수
설비 예시	월 가동시간 합계, 알람 발생 횟수, 일 평균 챔버 온도	'야간 고장 다발 설비' 여부, 온도 급상승 구간, 설비 위험 등급
성격	객관적 — 누가 계산해도 같음	**주관적** → **논리적 타당성** 필요
재활용성	**높음** — 여러 모델에 두루	낮음 — 특정 목적용
만드는 법	자동화 프로그램으로 구축 가능	분석자의 아이디어·노하우

원본 로그
(센서 값 1초마다)

→

요약변수
월 알람 횟수 = 42

→

파생변수
알람 40회↑ → '위험 설비'

✓ **시험 POINT** '재활용성 높음' = 요약변수, '논리적 타당성 필요' = 파생변수

3과목 1장

결측값·이상값 처리

결측값 대치법과 사분위수(IQR)로 이상값 찾기

결측값과 세 가지 유형

결측값 = 있어야 할 값이 비어 있는 것 (R에서는 **NA**). 비어 있는 **이유**가 정보일 수 있으니 **무조건 삭제 금지**

1 MCAR 완전 무작위 결측

아무 이유 없이 우연히 빠짐

예) 통신 순간 끊김으로
센서 값이 랜덤하게 누락

→ 지워도 편향 적음

2 MAR 무작위 결측

다른 (관측된) 변수와 관련

예) 구형 설비 라인에서만
기록 누락이 잦음

→ 다른 변수로 보정 가능

3 MNAR 비무작위 결측

빠진 값 자체와 관련

예) 온도가 너무 높아
센서 측정 범위를 넘으면 기록 X

→ **가장 다루기 어려움**

✓ **시험 POINT** MCAR(완전 무작위) · MAR(무작위) · MNAR(비무작위)

결측값 대치법 — 빈칸 채우기

방법	어떻게 채우나	주의할 점
① 완전분석법	결측 있는 행을 지우고 분석	데이터가 줄어 효율 ↓
② 평균대치법	비조건부: 관측값 **평균**으로 조건부: **회귀**로 예측한 값으로	**같은 값이 반복 → 퍼짐(표준오차) 과소추정**
③ 단순확률대치법	비슷한 데이터에서 **확률적으로** 뽑아 채움 (예: Hot-deck)	평균대치의 단점 보완
④ 다중대치법	여러 번 채워 여러 세트를 만들고 결과를 합침	가장 정교, 아래 3단계

① 대치

채운 데이터 m세트 만들기

→

② 분석

세트마다 따로 분석

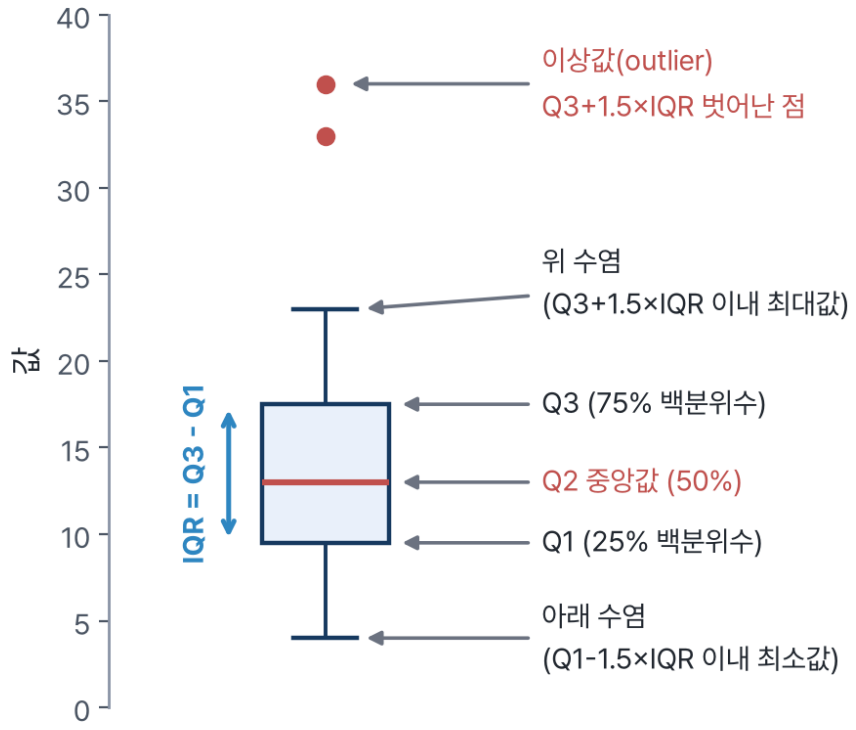
→

③ 결합

결과를 하나로 합치기

✓ **시험 POINT** 평균대치 → 표준오차 과소추정. 다중대치: 대치 → 분석 → 결합

이상값 찾기 — 상자그림과 IQR



IQR = Q3 − Q1
하한 Q1 − 1.5×IQR · 상한 Q3 + 1.5×IQR

예) 챔버 온도: Q1 = 10, Q3 = 20

IQR	20 − 10 = **10**	→ 1.5 × 10 = 15
하한	10 − 15 = **−5**	
상한	20 + 15 = **35**	

−5 ~ 35 밖의 값 (예: 40) → 이상값 후보

✓ **시험 POINT** 하한 Q1 − 1.5×IQR, 상한 Q3 + 1.5×IQR 직접 계산

1교시 핵심 정리

주제	꼭 기억할 한 줄
R 기초	문자가 섞이면 전부 문자, 설치 1회·로드 매번
특수값	NA 자리 있음·NULL 자리 없음, 0/0 NaN·1/0 Inf
연산자	%/% 몫, %% 나머지 (7 %% 2 = 1)
함수	ceiling 올림·floor 내림, var = sd², rm 뒤 호출은 오류
데이터 마트	DW 전사·DM 부서별, 요약 재활용↑·파생 타당성
결측값	MCAR·MAR·MNAR, 다중대치: 대치→분석→결합
이상값	IQR 1.5배: Q1 − 1.5×IQR ~ Q3 + 1.5×IQR

1교시 끝 — 쉬는 시간

다음 2교시

기초 통계와 확률
표본추출 · 척도
평균 · 분산 · 왜도
확률분포 · 정규분포

✓ **시험 POINT** 오늘 1교시 표만 시험 전날 다시 보기

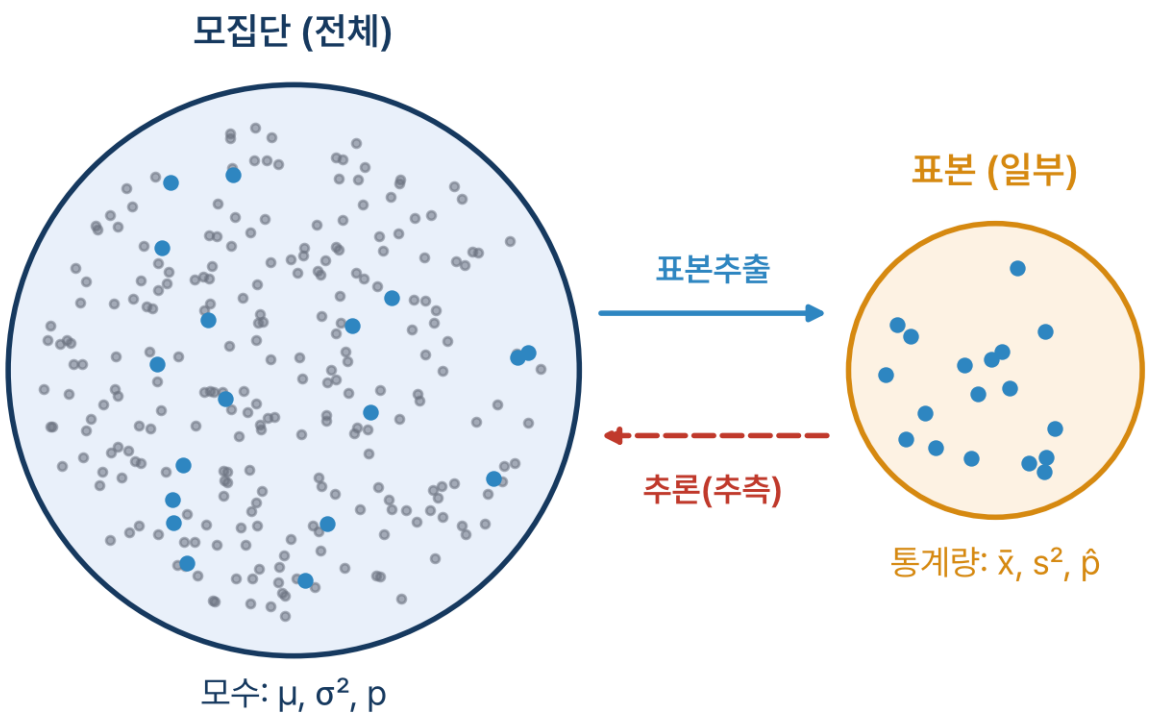
3과목 2장

기초 통계와 확률

모집단·표본, 척도, 기술통계, 확률, 그리고 정규분포·표본분포

모집단과 표본

| 전체를 다 볼 수 없으니, 일부를 보고 전체를 짐작한다



	모집단	표본
뜻	알고 싶은 전체	실제로 조사한 일부
장비 예	이번 달 생산 웨이퍼 전체	그중 검사한 웨이퍼 50장
값의 이름	모수	통계량
평균	μ (뮤)	x̄ (엑스바)
분산	σ^2 (시그마제곱)	s^2
비율	p	p̂ (피햇)

✓ **시험 POINT** 모수 = 모집단의 값(μ, σ^2) / 통계량 = 표본의 값(x̄, s^2) 짝짓기 빈출

기술통계 vs 추론통계

| 요약할 것인가, 추측할 것인가

기술통계 — 있는 그대로 요약

- 모은 자료를 **평균·표·그래프**로 정리
- 예: 어제 설비 온도 평균 350°C, 최고 362°C
- "우리 데이터는 이렇다"까지만

VS

추론통계 — 일부로 전체를 추측

- 표본으로 **모집단**을 짐작
- = **추정** + **가설검정**
- 예: 50장 검사 → 전체 불량률 2~4% 추정

왜 표본을 쓸까?

전부 조사 = 비용·시간 큼, 파괴검사는 불가능
→ 그래서 보통은 **표본조사**

그래서 확률이 필요

표본을 뽑는 순간 **오차**가 생김
→ 그 오차를 확률로 다루는 것이 추론통계

✓ 시험 POINT 추론통계 = 추정 + 가설검정

표본추출 4가지 — 그림으로 구분

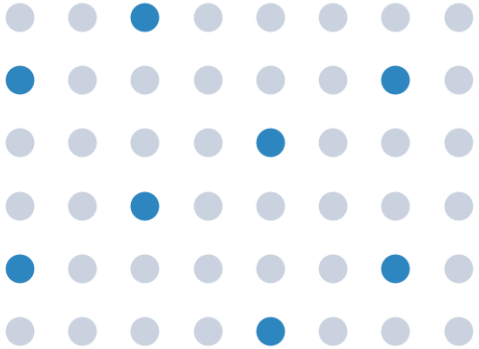
진하게 표시된 점이 뽑힌 표본

① 단순랜덤추출



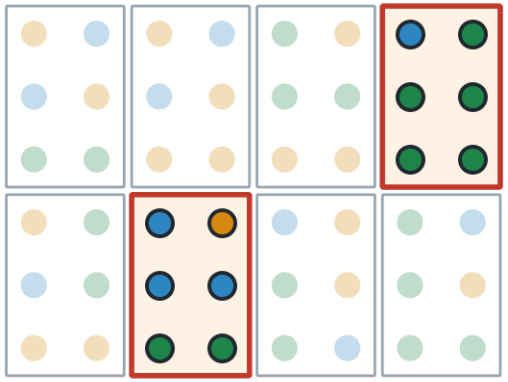
모두 같은 확률로 무작위
예: 난수로 웨이퍼 8장

② 계통추출



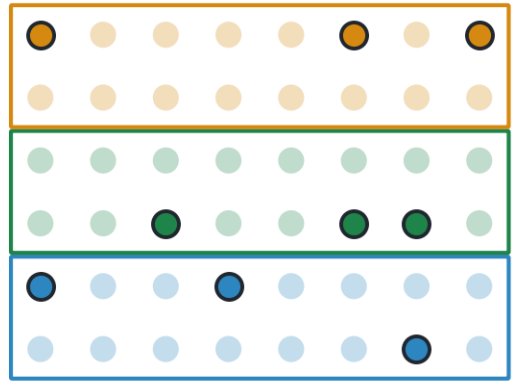
번호 매기고 K번째마다
예: 매 6번째 생산품

③ 집락(군집)추출



묶음(라인·지역)을 골라
그 안은 **통째로** 조사

④ 층화추출



층(설비별)마다 골고루
모든 층에서 조금씩

✓ **시험 POINT** 확률표본추출 4가지: 단순랜덤 · 계통 · 집락 · 층화

측정 척도 4가지

| 정보량: 명목 < 서열 < 등간 < 비율 (아래로 갈수록 할 수 있는 계산이 많다)

척도	성격	장비·현장 예	가능한 계산
명목척도	이름표(분류)만 의미	설비 ID, 라인 번호, 불량 유형	같다/다르다 → **최빈값**
서열(순서)척도	순서만 의미, 간격은 X	알람 등급 상·중·하, 만족도	크다/작다 → **중앙값**
등간(구간)척도	간격 일정, **절대 0 없음**	온도(°C), 날짜, 물가지수	더하기·빼기 → **평균**
비율척도	간격 일정 + **진짜 0** 있음	압력, 무게, 가동시간, 불량 개수	사칙연산 모두 (2배·절반 OK)

✓ **시험 POINT** 온도(°C)는 등간(구간)척도 — 비율척도로 낸 함정 빈출

척도 판별 연습 — 장비 데이터로

| 질문 4개로 순서대로 거르기

이름만? → 명목

↓

순서가 있나? → 서열

↓

간격이 일정? → 등간

↓

진짜 0이 있나? → 비율

변수	척도	한마디 이유
웨이퍼 로트 번호	명목	번호지만 이름표일 뿐
알람 등급(상·중·하)	서열	순서는 있으나 간격 모름
챔버 온도 °C	등간	0°C ≠ 온도 없음
진공 압력 Pa	비율	0 Pa = 압력 없음
하루 불량 개수	비율	0개 = 없음, 2배 비교 가능
작업자 숙련 등급	서열	1등급 > 2등급

✓ **시험 POINT** 숫자로 적혀 있어도 이름표면 명목척도

탐색적 데이터 분석(EDA)의 4가지 주제

기술통계

| 튜키(Tukey): 본격 분석 전에 데이터와 먼저 친해지기

1 저항성 (Resistance)

이상값 하나에 흔들리지 않게
→ 평균 대신 **중앙값**
예: 센서 튐 값 하나가 평균을 망치지 않게

2 잔차 해석 (Residual)

큰 흐름에서 벗어난 값을 보고 **이유** 찾기
예: 추세선 위로 튄 날 → 그날 무슨 일?

3 자료 재표현 (Re-expression)

로그·제곱근 변환으로 보기 쉽게
예: 한쪽으로 치우친 수리시간을 로그로

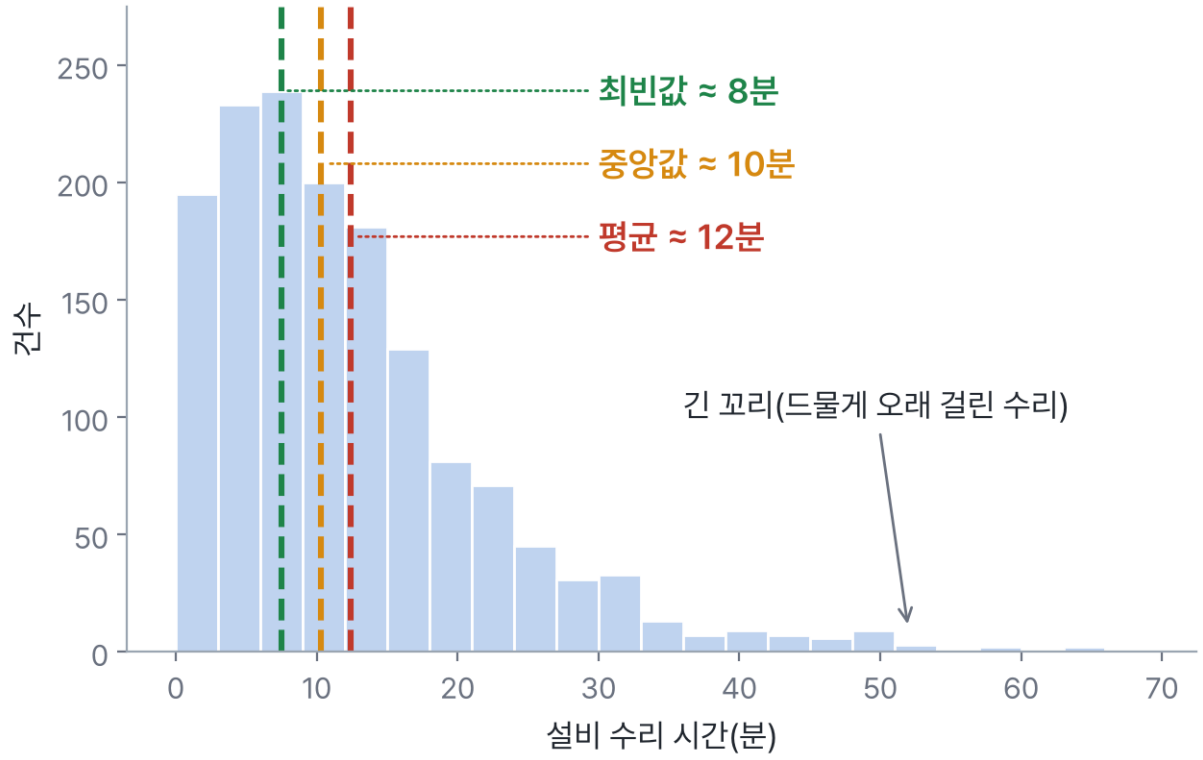
4 현시성 (Revelation)

그래프로 한눈에 드러내기
예: 상자그림·히스토그램·산점도

✓ **시험 POINT** 저항성 · 잔차 해석 · 자료 재표현 · 현시성 — '정확성' 같은 없는 보기 주의

대푯값 — 평균·중앙값·최빈값

| 자료의 '가운데'를 하나의 숫자로



대푯값	뜻
평균	모두 더해 개수로 나눔
중앙값	줄 세운 **한가운데** 값
최빈값	가장 **많이** 나온 값 (범주형 OK)
절사평균	위·아래 일부를 잘라낸 평균

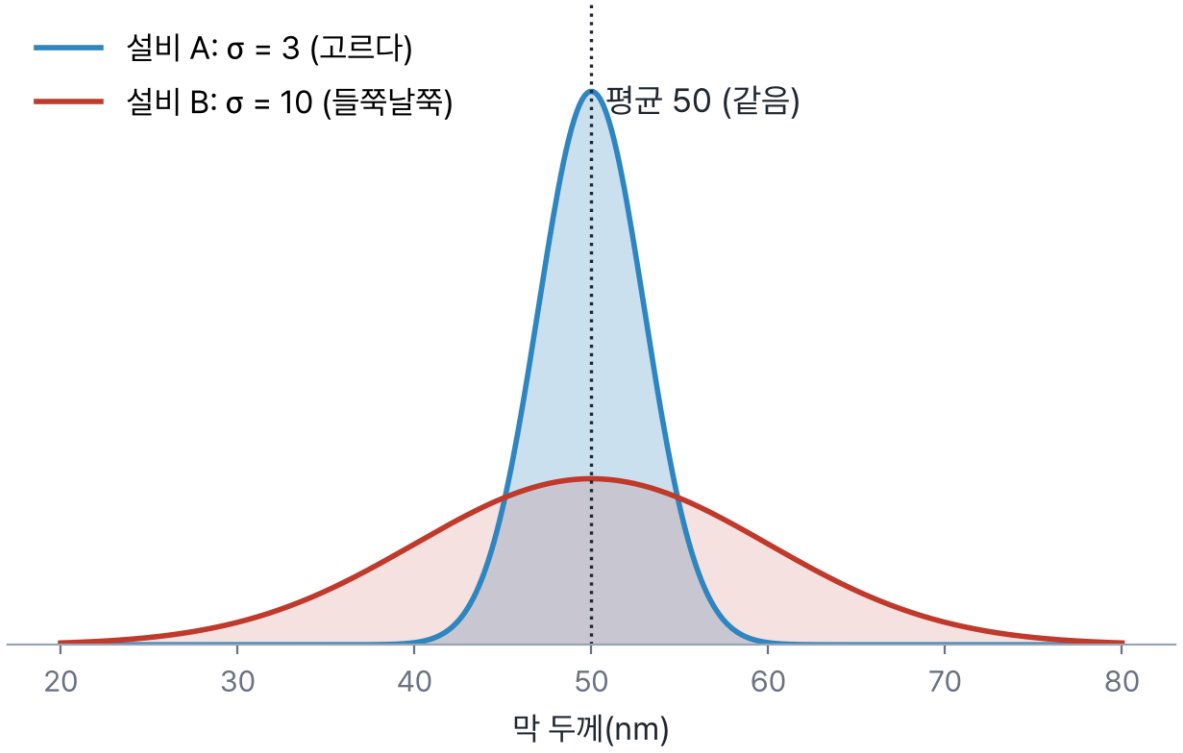
이상값 하나의 힘

자료 1, 2, 2, 3, **100**
평균 = 108 ÷ 5 = **21.6**
중앙값 = 2, 최빈값 = 2

✓ **시험 POINT** 이상값에 강한(저항성 있는) 대푯값 = 중앙값

산포도 — 평균이 같아도 다른 두 설비

'얼마나 흩어져 있나'를 재는 지표들



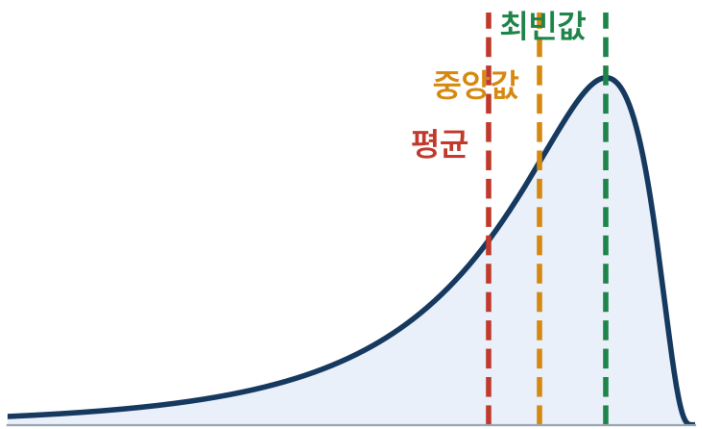
지표	말로 하면
범위	최댓값 − 최솟값
IQR	Q3 − Q1 (가운데 50%의 폭)
분산 s^2	평균에서 떨어진 거리를 **제곱**해서 평균
표준편차 s	분산의 √ → **원래 단위**로
변동계수 CV	표준편차 ÷ 평균 (단위 달라도 비교)

✓ **시험 POINT** 표준편차는 원래 단위, 분산은 단위의 제곱

왜도 — 분포가 어느 쪽으로 치우쳤나

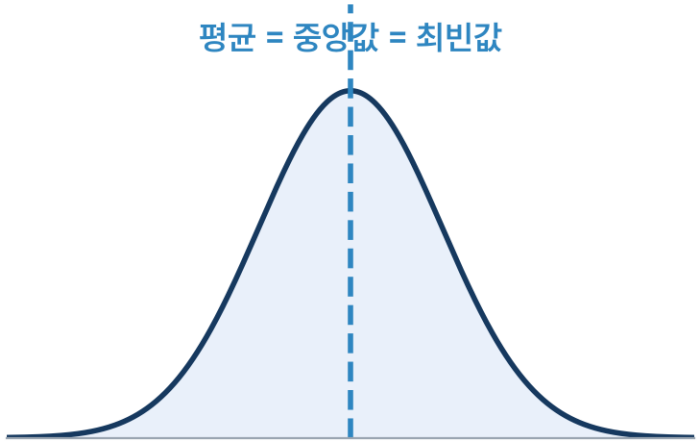
꼬리가 긴 쪽이 기준

왼쪽 꼬리 (왜도 < 0)

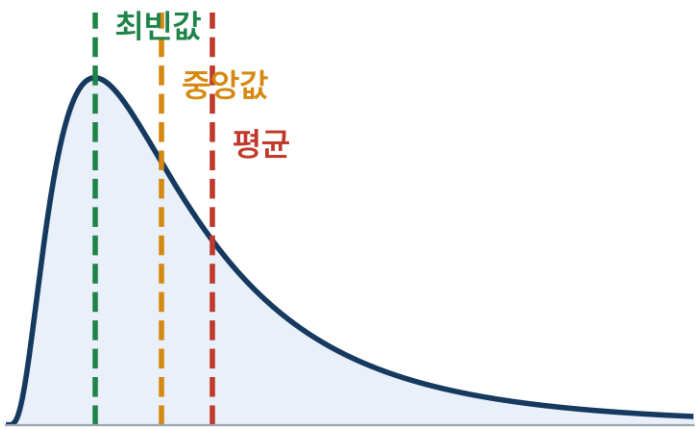


평균 < 중앙값 < 최빈값

대칭 (왜도 = 0)



오른쪽 꼬리 (왜도 > 0)



최빈값 < 중앙값 < 평균

평균은 **꼬리 쪽으로 끌려간다** → 오른쪽 꼬리(소득·수리시간)면 평균이 가장 크다

✓ **시험 POINT** 왜도 > 0 이면 평균 > 중앙값 > 최빈값 — 부등호 뒤집은 함정 최다 빈출

확률의 기초와 조건부확률

주사위 하나로 끝내기

주사위 한 번 : 표본공간 Ω = {1, 2, 3, 4, 5, 6}



A = 짝수 {2, 4, 6} (파란·빨간 칸)

B = 4 이상 {4, 5, 6} (주황·빨간 칸)

A∩B = {4, 6} (빨간 칸)

$$P(B \mid A) = P(A \cap B) \div P(A)$$

말로 하면: A가 이미 일어난 세상에서 B의 비율

- 짝수가 나왔다(A) → 후보는 2, 4, 6 세 개
- 그중 4 이상은 4, 6 두 개 → **2/3**
  - ㄴ 분모가 전체 6이 아니라 A의 3으로 줄어든 것이 핵심

장비 예: 알람이 울렸을 때(A) 실제 고장(B)일 확률

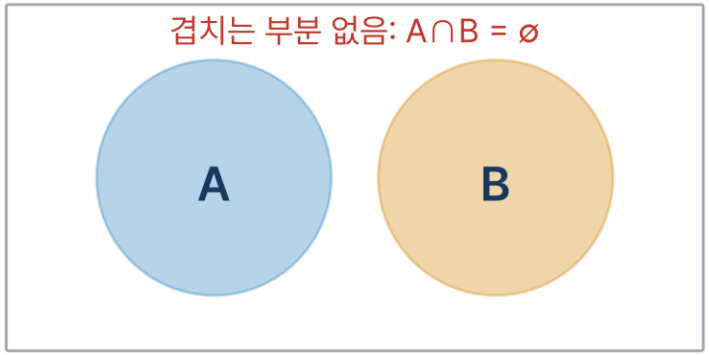
확률 P(E) = 해당 경우 수 ÷ 전체 경우 수, 항상 0 ~ 1

✓ **시험 POINT** 조건부확률 = 조건이 된 사건으로 분모를 좁힌다

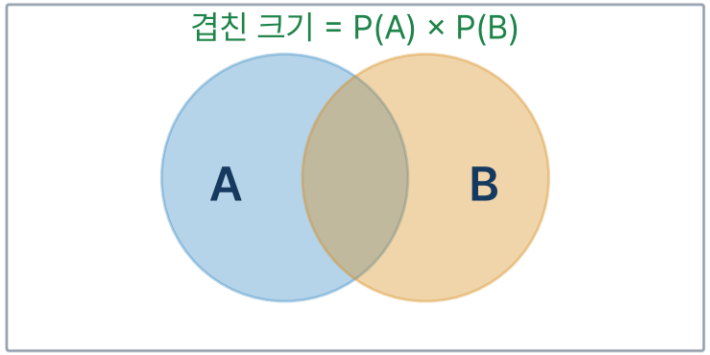
독립 vs 배반 — 그림으로

| 이름은 비슷해 보여도 전혀 다른 개념

배반 — 동시에 일어날 수 없다



독립 — 서로 영향을 주지 않는다

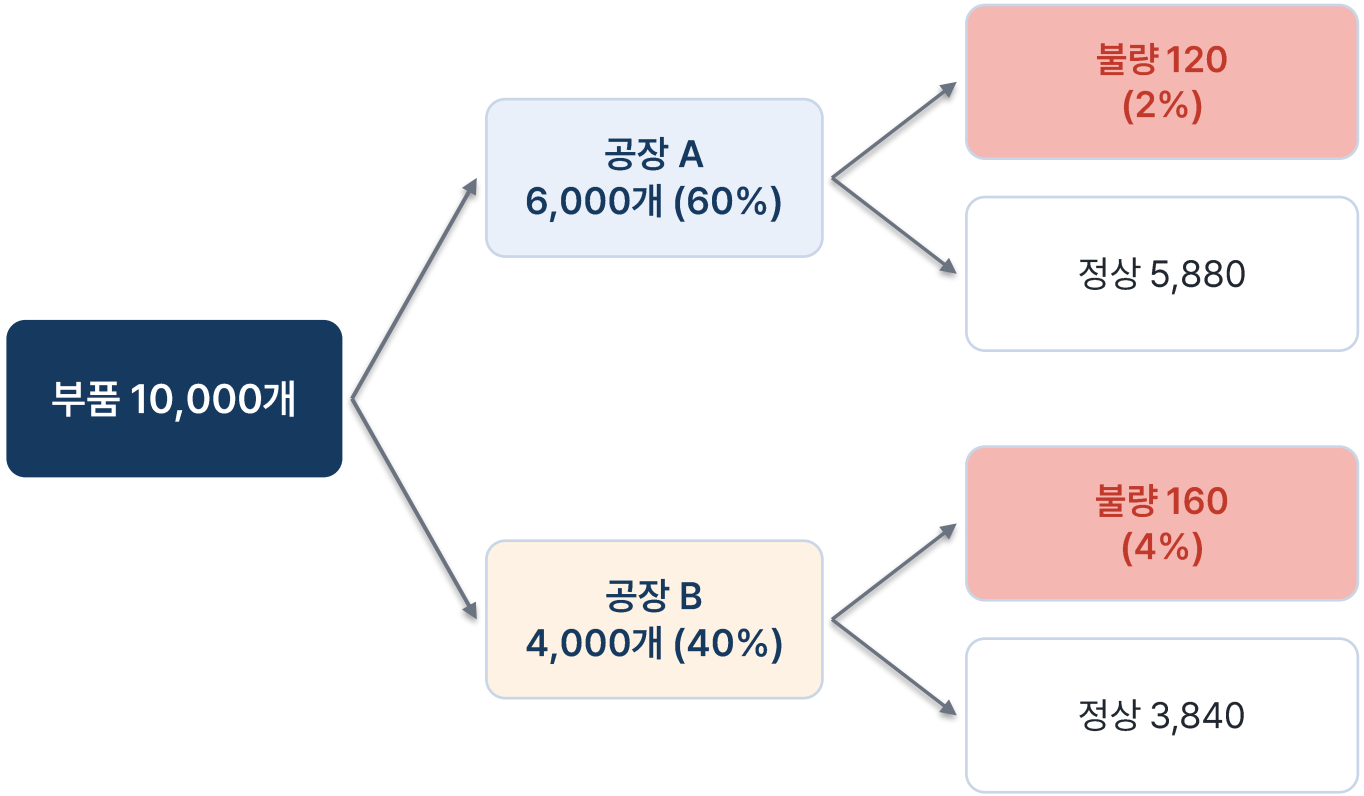


	배반 (mutually exclusive)	독립 (independent)
식	$P(A \cap B) = 0$	$P(A \cap B) = P(A) \times P(B)$, $P(B\|A) = P(B)$
예	한 웨이퍼가 '양품'이면서 '불량'	1호기 고장과 다른 공장 5호기 고장
관계	**A가 일어나면 B는 절대 X → 오히려 종속**	A가 일어나도 B 확률 그대로

✓ **시험 POINT** 독립이면 $P(B|A) = P(B)$. '배반 = 독립'은 오답

베이즈 정리 — 결과를 보고 원인 찾기

| 확률 대신 '개수'로 생각하면 쉽다



질문: 결과(불량)를 보고 원인(공장) 찾기

불량품 하나를 집었다.
어느 공장에서 왔을까?

불량은 모두 120 + 160 = **280개**
그중 A에서 온 것 = **120개**

→ 120 ÷ 280 ≈ **43%**

✓ **시험 POINT** 불량 전체 중 해당 공장에서 온 불량의 비율

확률변수와 기댓값

| 결과에 숫자를 붙이면 확률변수

이산형 확률변수 — 셀 수 있다

- 하루 고장 건수 0, 1, 2 …
- 웨이퍼 한 장의 불량 칩 수

vs

연속형 확률변수 — 잴 수 있다

- 챔버 온도 350.27°C
- 부품 수명 1,234.5시간

하루 고장 건수 x	0	1	2
확률 P(x)	0.5	0.3	0.2
x × P(x)	0	0.3	0.4

기댓값

E(X) = 0 + 0.3 + 0.4 = **0.7건**
= 확률을 가중치로 한 평균
"오래 지켜보면 하루 평균 0.7건"

✓ **시험 POINT** 기댓값 E(X) = Σ x·P(x) — 확률 가중 평균

이산확률분포 6가지

확률분포

| 키워드만 보고 분포를 골라내기

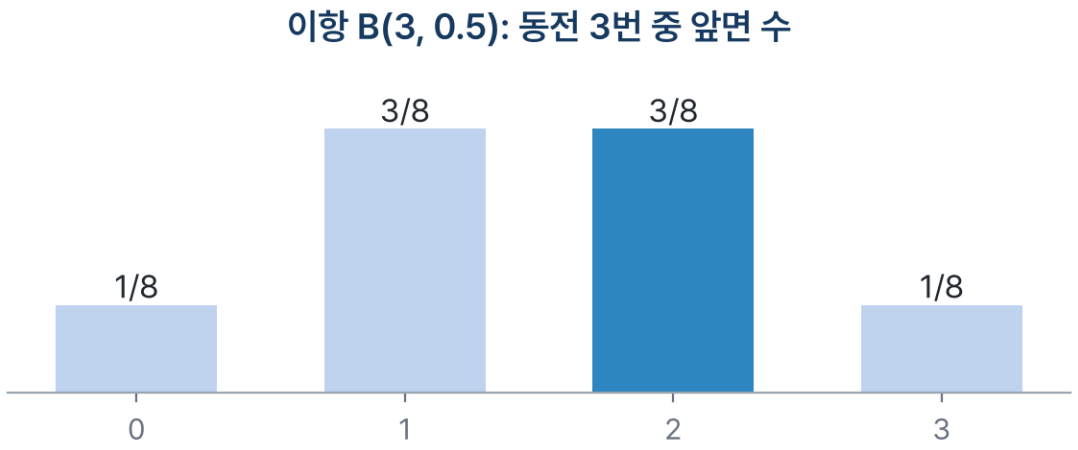
분포	언제 쓰나 (키워드)	장비 예	기댓값·분산
베르누이	성공/실패 **1번**	칩 1개 검사: 양품/불량	E = p, V = p(1−p)
이항 B(n, p)	베르누이를 **n번** → 성공 횟수	칩 100개 중 불량 개수	E = np, V = np(1−p)
포아송	**일정 시간·공간**의 발생 횟수	1시간 동안 알람 횟수	E = V = **λ**
기하	**첫 성공까지** 시행 횟수	첫 불량이 나올 때까지 검사 수	E = 1/p
초기하	**비복원**(되돌리지 않음) 추출	20개 로트에서 5개 꺼낸 불량 수	이항과 달리 독립 아님
다항	결과가 **3가지 이상**, n번	A급·B급·불량 개수	이항분포의 확장

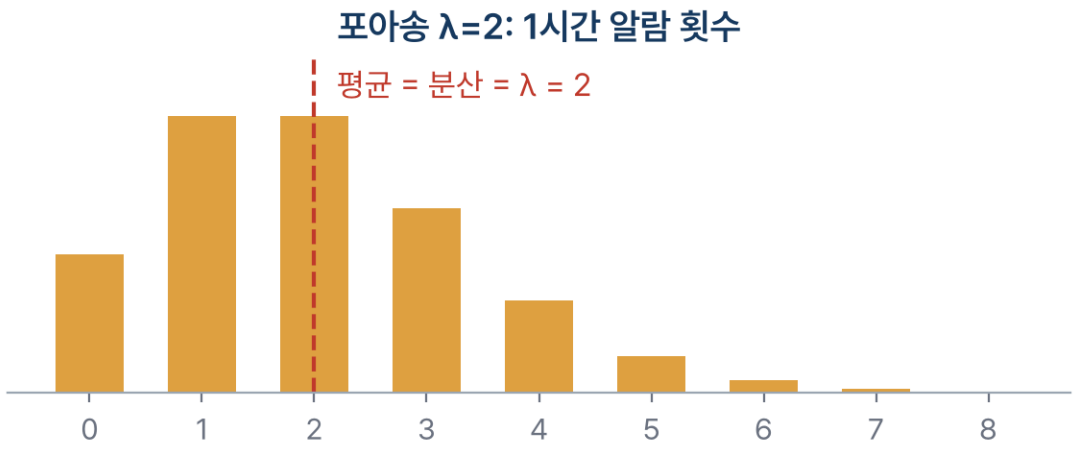
✓ **시험 POINT** 이항 E=np · 포아송 평균=분산=λ · 기하=첫 성공까지 · 초기하=비복원 · 다항=3가지↑

이항분포와 포아송분포 모양 보기

확률분포

| 막대 하나하나가 그 값이 나올 확률





이항분포 계산은 여기까지만

P(앞면 정확히 2번) = 3가지 경우(HHT·HTH·THH) × $(1/2)^3$ = **3/8**
E = np = 3 × 0.5 = **1.5**, V = np(1−p) = 3 × 0.5 × 0.5 = **0.75**

✓ **시험 POINT** 이항 기댓값·분산 계산은 np, np(1−p) 대입만

3과목 5장

데이터 마이닝 개요

정의·추진 5단계·데이터 분할과 검증

데이터 마이닝이란?

| 데이터라는 광산에서 쓸모 있는 패턴을 캐내기

통계분석	vs	데이터 마이닝
• 가설을 **먼저** 세운다 • → 데이터로 맞는지 **검정** • 예) '신규 설비 불량률이 더 낮다?'		• 가설 **없이** 시작 • → 대량 데이터에서 **패턴·규칙 탐색** • 예) '어떤 조건에서 불량이 몰리지?'

고객 세분화

비슷한 고객끼리 묶기

장바구니 분석

같이 팔리는 상품 찾기

이상거래 탐지

FDS: 수상한 카드 결제

불량·고장 예측

센서 값 → 고장 위험

✓ 시험 POINT 마이닝 = '가설 없이 패턴 탐색' / 가설 먼저 세우고 검정 = 통계분석

데이터 마이닝 추진 5단계

| 요리 순서와 똑같다

① 목적 설정	② 데이터 준비	③ 데이터 가공	④ 기법 적용	⑤ 검증
무엇을 알고 싶은가	모으고 정제하기	**목적변수 정의** 분석 형태로 변환	모형 만들기	테스트 데이터로 확인 → 업무 적용
요리: 메뉴 정하기	요리: 장보기	요리: 재료 손질	요리: 조리	요리: 맛보기

암기: 목 · 준 · 가 · 기 · 검　　함정: '목적변수 정의'는 1단계가 아니라 **3단계(데이터 가공)**

✓ **시험 POINT**　순서 나열형 최빈출 — 목적변수 정의는 3단계(데이터 가공)

지도학습 vs 비지도학습

| 정답지가 있는 공부 vs 없는 공부

분석 기법 — 목표변수(정답)가 있나?

있다 → 지도학습

기법	용도
회귀 · 로지스틱 회귀	숫자 / 0·1 예측
의사결정나무 · 앙상블	분류 · 회귀 모두
신경망 · SVM	분류분석 주력
KNN (사례기반 추론)	가까운 이웃에게 묻기

없다 → 비지도학습

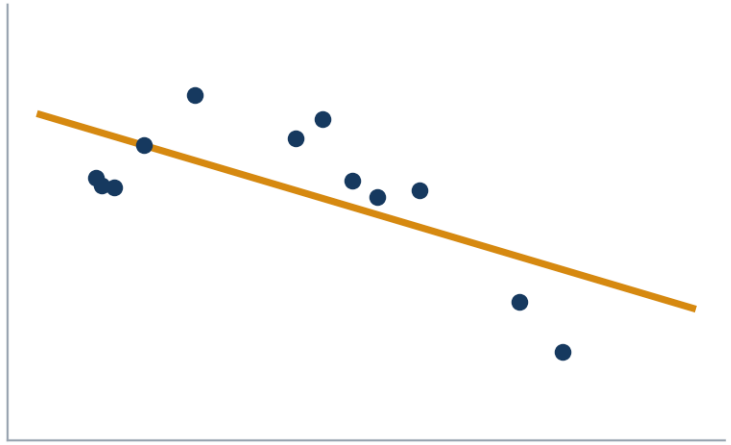
기법	용도
군집분석 (k-평균·계층적)	비슷한 것끼리 묶기
SOM (자기조직화지도)	신경망인데 비지도
연관분석 (Apriori)	장바구니 규칙
주성분분석 (PCA)	변수 요약 · 차원축소

✓ **시험 POINT** SOM은 신경망이지만 비지도학습 — 최빈출 함정

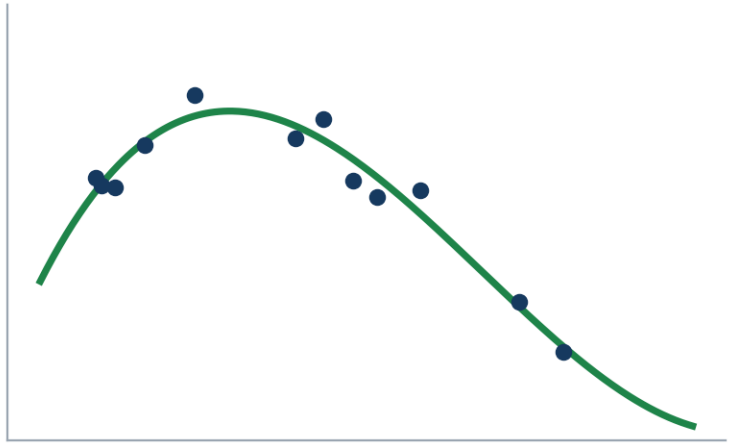
과소적합 · 적정 · 과대적합

| 같은 점들, 세 가지 모형

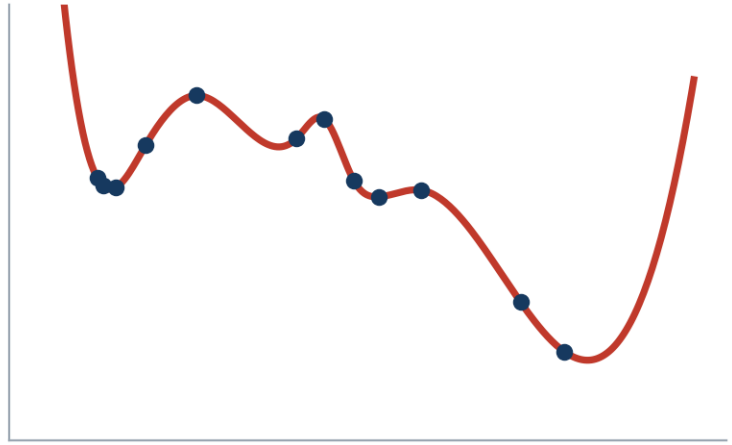
과소적합 — 너무 단순



적정 — 큰 흐름만



과대적합 — 통째로 암기

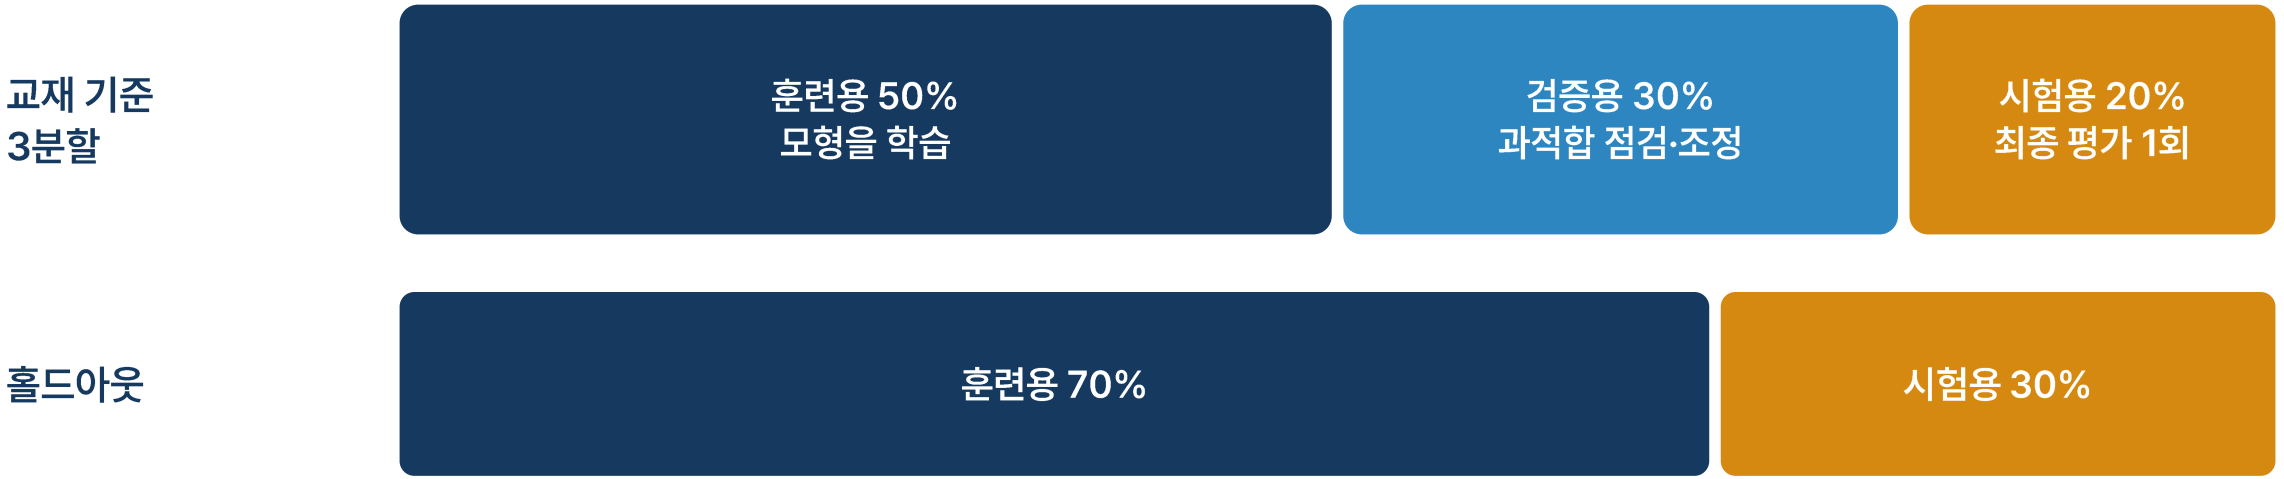


	과소적합	적정	과대적합
훈련 데이터 성적	낮음	좋음	거의 만점
새 데이터 성적	낮음	좋음	뚝 떨어짐

✓ **시험 POINT** 과대적합 = 훈련은 잘 맞고 새 데이터에서 성능 저하

데이터 분할 — 훈련 · 검증 · 시험

| 공부·모의고사·실전으로 나누기



1 훈련 = 교과서·연습문제

여기서 공부(학습)

2 검증 = 모의고사

결과 보고 공부법 조정

3 시험 = 실제 시험

딱 한 번만 본다

✓ **시험 POINT** 훈련:검증:시험 = 5:3:2, 검증용 = 과적합 점검·모형 조정

k-fold 교차검증

| 돌아가며 한 번씩 검증 맡기



방법

데이터를 **k조각**으로 나눠
1조각은 검증, 나머지는 훈련

결과

조각을 바꿔 **k번 반복**
→ k개 점수를 **평균**

장점

모든 데이터가 **한 번씩** 검증
보통 k = 5 또는 10

✓ **시험 POINT** k번 반복 후 평균, 모든 데이터가 한 번씩 검증에 사용

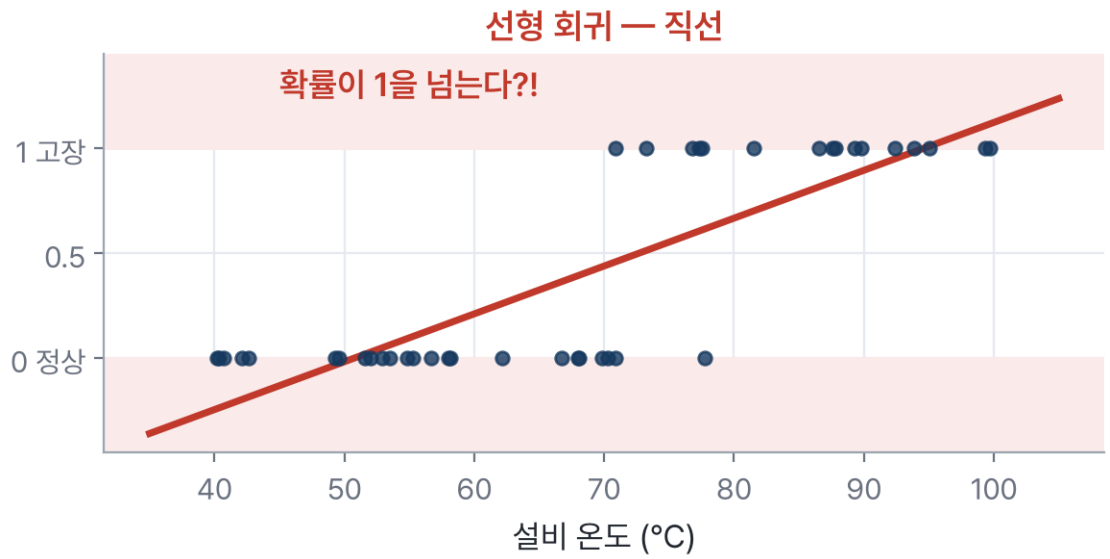
3과목 5장

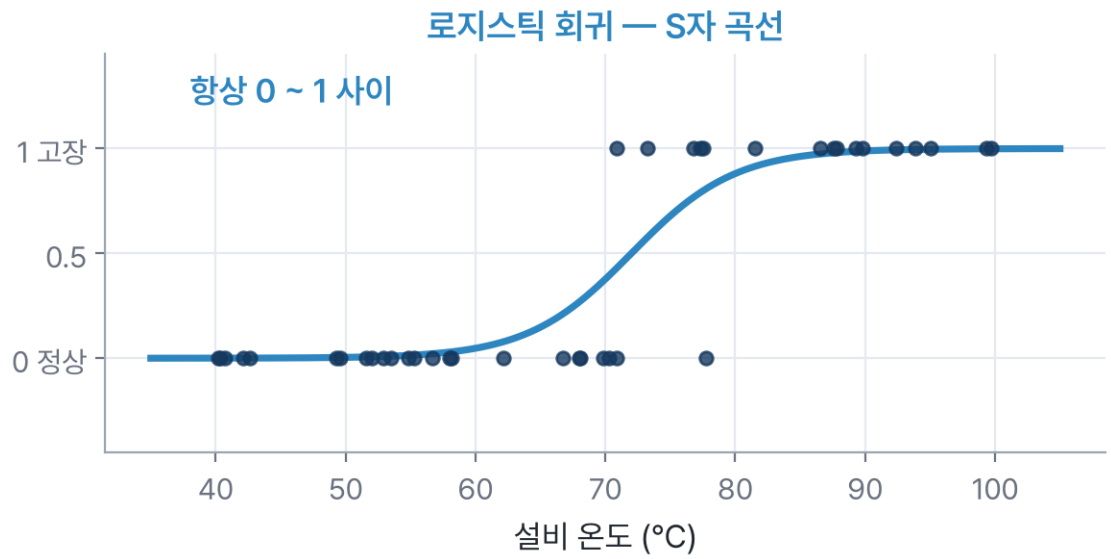
분류분석 I

로지스틱 회귀와 의사결정나무

왜 로지스틱 회귀인가?

| 결과가 0/1일 때 직선은 곤란하다



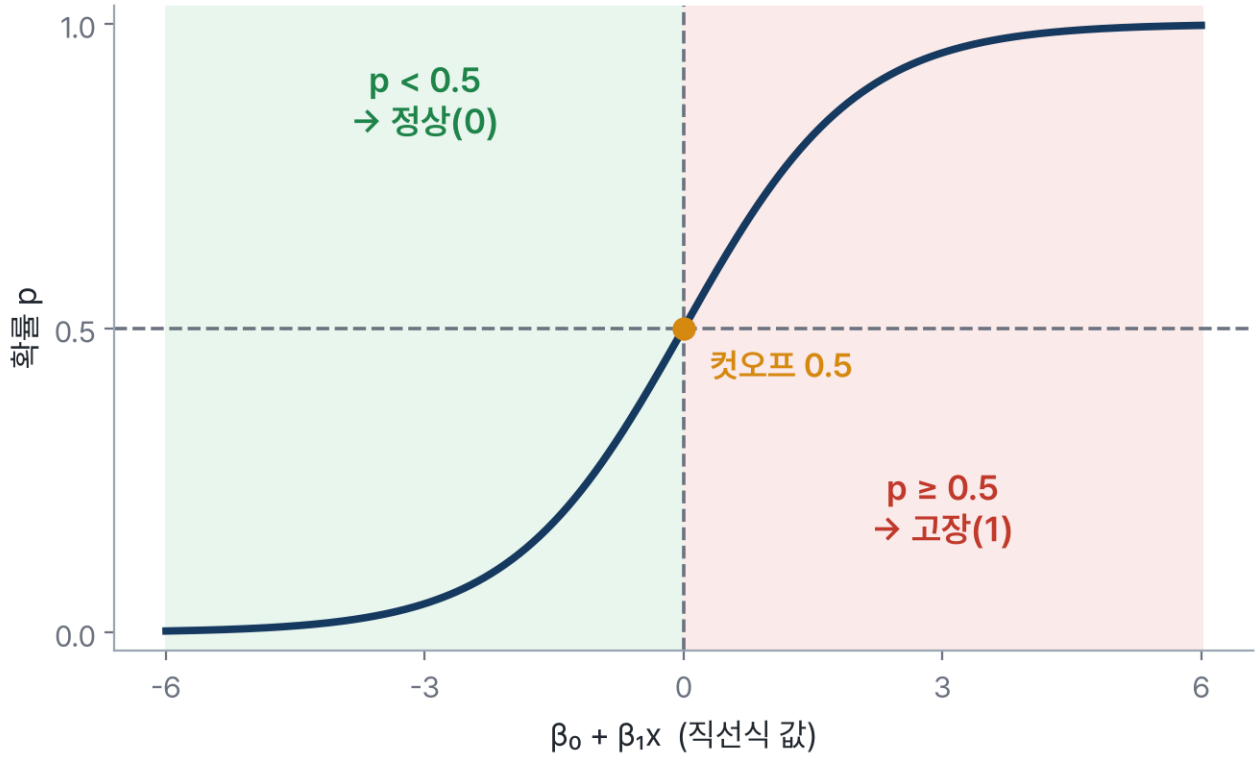


결과가 **0/1 (범주형)** 이면 → 직선 대신 **S자 곡선**으로 '일어날 확률'을 구해 분류한다

✓ **시험 POINT** 로지스틱 회귀 = 종속변수가 범주형일 때 쓰는 회귀

시그모이드 곡선과 컷오프

어떤 값이든 0~1 확률로



$$p = 1 / (1 + e^{-(\beta_0+\beta_1 x)})$$

말로 하면

- 직선식 값을 **0~1 확률**로 눌러 담는 함수
- 값이 0이면 → p = **0.5**

로짓 = ln(p / (1−p))

- 확률을 다시 **직선식**으로 펴는 변환
  - ㄴ 오즈에 로그를 씌운 값

✓ **시험 POINT** 직선식 값 0 → 확률 0.5, 보통 0.5 기준으로 분류

오즈와 오즈비

| 성공이 실패의 몇 배인가

$$\text{오즈} = p / (1 - p)$$

확률 p	오즈	말로 하면
0.5	0.5/0.5 = **1**	반반
0.8	0.8/0.2 = **4**	성공이 실패의 4배
0.2	0.2/0.8 = **0.25**	실패가 4배

오즈비 — 두 집단의 오즈를 나눈 것

A 라인 (경보 O)
불량 확률 0.8
오즈 = 4

B 라인 (경보 X)
불량 확률 0.5
오즈 = 1

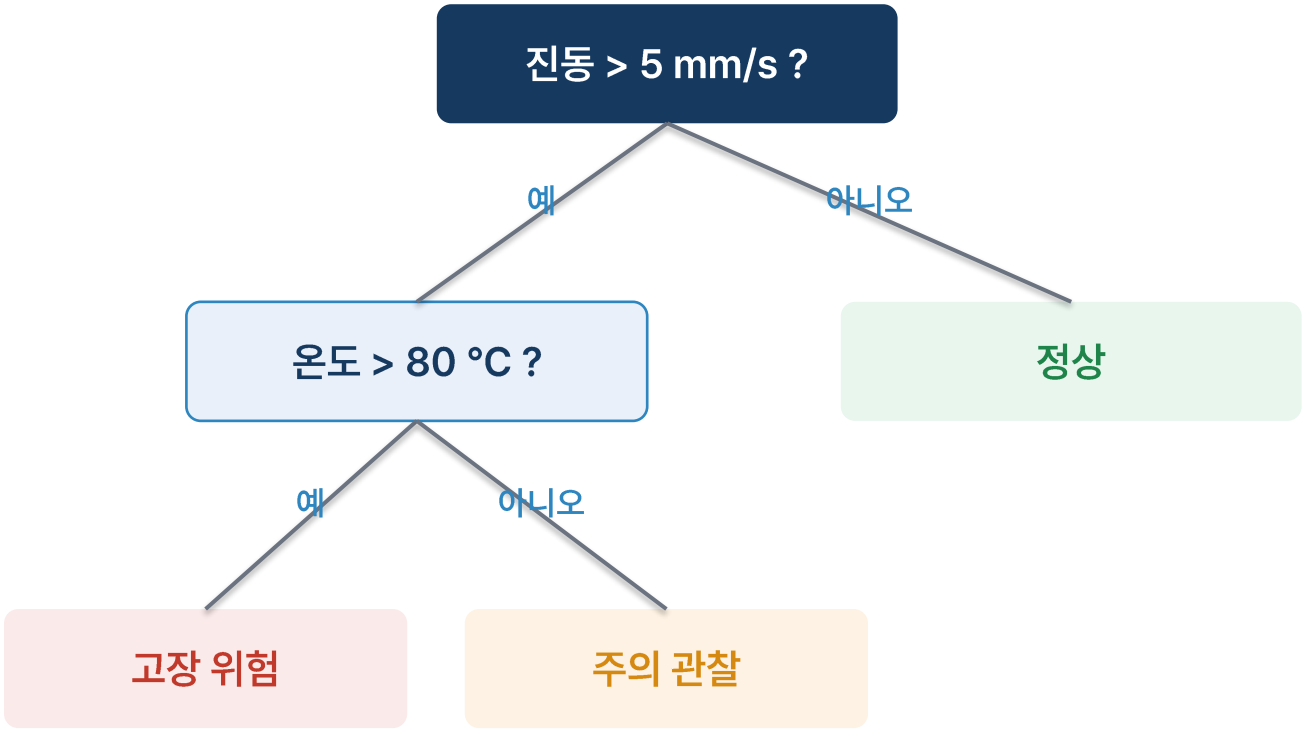
오즈비 = 4 ÷ 1 = **4**
→ A의 불량 오즈가 B의 **4배**

거꾸로: p = 오즈 / (1 + 오즈) (오즈 3 → 0.75)

✓ **시험 POINT** 오즈는 확률이 아니다 → 1을 넘을 수 있다 (0 ~ ∞)

의사결정나무 — 스무고개 분류기

| 설비 고장 판단을 나무로 그리면



1 스무고개처럼

예/아니오 질문으로
데이터를 계속 나눈다

2 분류나무

목표변수가 **범주형**
예) 고장 / 정상

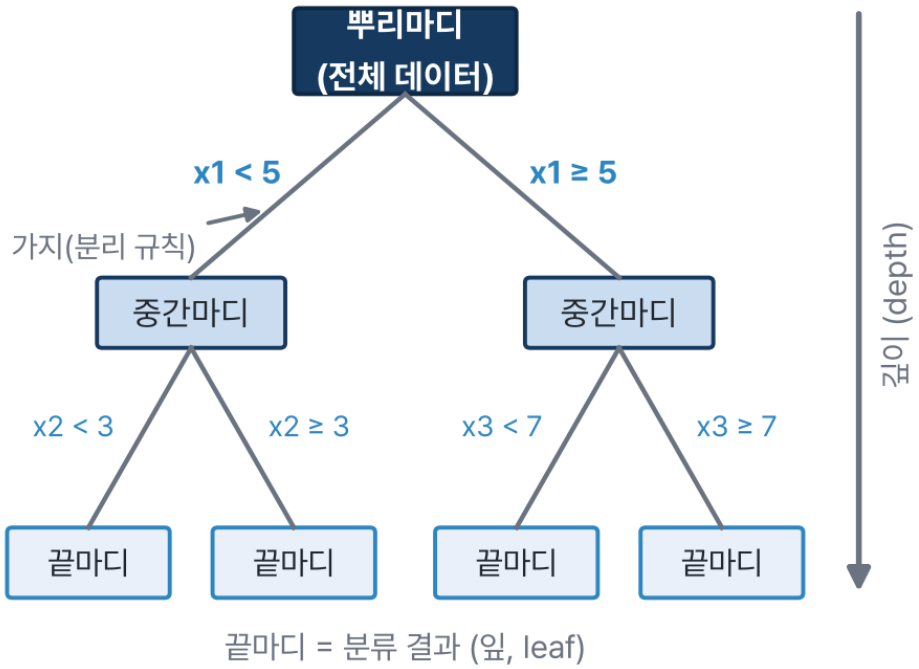
3 회귀나무

목표변수가 **연속형**
예) 남은 수명(일)

✓ **시험 POINT** 목표변수 범주형 → 분류나무, 연속형 → 회귀나무

의사결정나무 구조와 용어

| 뿌리 → 중간 → 끝마디(잎)



용어	뜻
뿌리마디	맨 위 시작점 (전체 데이터)
중간마디	위·아래 모두 연결된 마디
끝마디 (잎, leaf)	더 안 나뉘는 마지막 마디 = 결론
부모 · 자식마디	나뉘기 전 마디 · 나뉜 뒤 마디
가지	마디를 잇는 선
깊이	뿌리~끝마디 사이 **중간마디 수**

✓ **시험 POINT** 끝마디 = 잎(leaf), 깊이 = 뿌리~끝마디 사이 중간마디 수

의사결정나무 분석 절차

| 키우고, 자르고, 확인하고, 쓴다

① 성장

분리 기준 + 정지규칙으로 나무 키우기

→

② 가지치기

쓸모없는 가지 잘라내기

→

③ 타당성 평가

시험 데이터·교차검증으로 성능 확인

→

④ 해석·예측

규칙 해석 → 새 데이터 예측

정지규칙 — 언제 멈추나?

정해진 깊이 도달 · 마디 데이터 수가 너무 적음
더 나눠도 불순도가 거의 안 줄 때

가지치기 — 왜 자르나?

끝마디가 너무 많으면 **과대적합**
정원사가 웃자란 가지를 잘라 모양을 잡듯

✓ **시험 POINT** 성장 → 가지치기 → 타당성 평가 → 해석·예측

의사결정나무 장단점과 활용

| 장단점 바꿔치기 함정 주의

장점	VS	단점
• 규칙이 눈에 보여 **해석이 쉽다** • 분포 가정 **불필요** • 수치형·범주형 모두 처리 • 이상값에 **민감하지 않다**		• 데이터가 조금만 바뀌어도 나무가 크게 변함 (**불안정**) • 경계선 근처에서 오류 ↑ (**비연속성**) • 변수 하나하나의 효과 파악은 어렵다

활용 6가지

세분화 | 분류 | 예측 | 차원축소·변수선택 | 교호작용 파악 | 범주 병합

✓ **시험 POINT** '이상값에 민감하다'(X) / 변수선택·차원축소에도 활용(O)

불순도와 지니지수

| 바구니가 얼마나 섞였나



$$G = 1 - \Sigma\, p_i^2$$

6 : 2 바구니 계산

① 비율: 6/8 = 0.75, 2/8 = 0.25
② 제곱합: 0.5625 + 0.0625 = 0.625
③ G = 1 − 0.625 = **0.375**

✓ **시험 POINT** 지니 = 1 − 비율 제곱합, 두 범주면 0 ~ 0.5

3과목 5장

분류분석 II

앙상블 · 인공신경망 · KNN · SVM

앙상블 — 여러 명의 의견 모으기

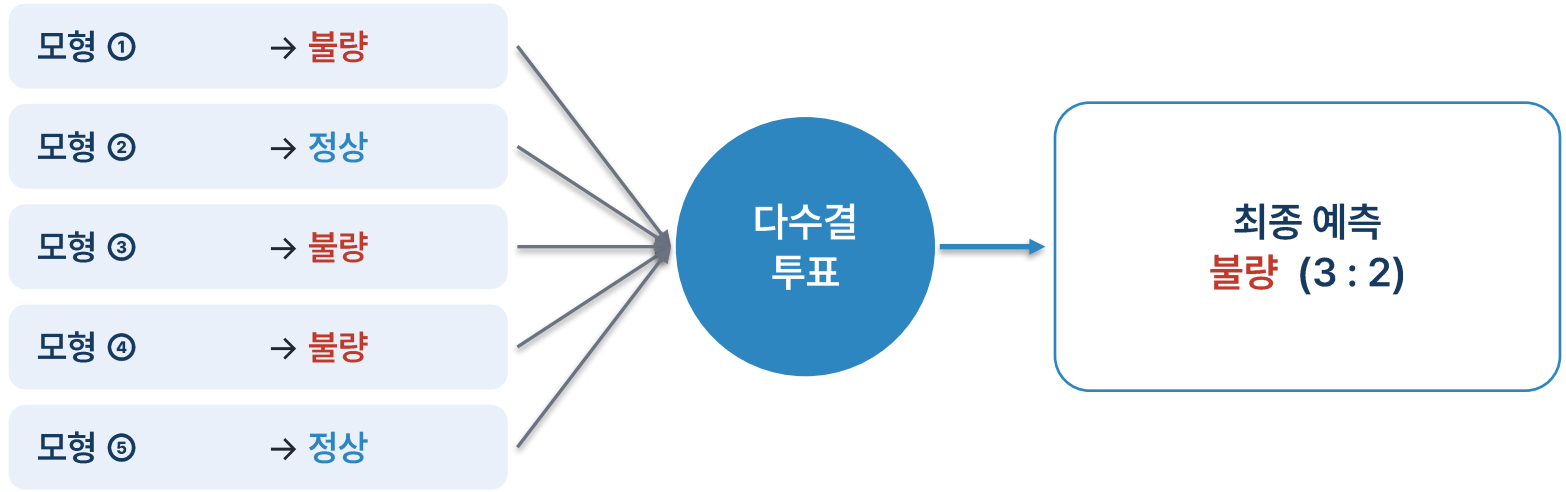
| 모형 하나보다 여러 개를 합치면 더 정확하고 안정적

혼자 판단하면

나무 1그루(모형 1개)

데이터가 조금만 바뀌어도
예측이 확 바뀐다
→ **불안정**

VS



1 배깅

여러 명이 **따로따로** 풀고 투표

2 부스팅

틀린 문제를 **이어서** 집중 복습

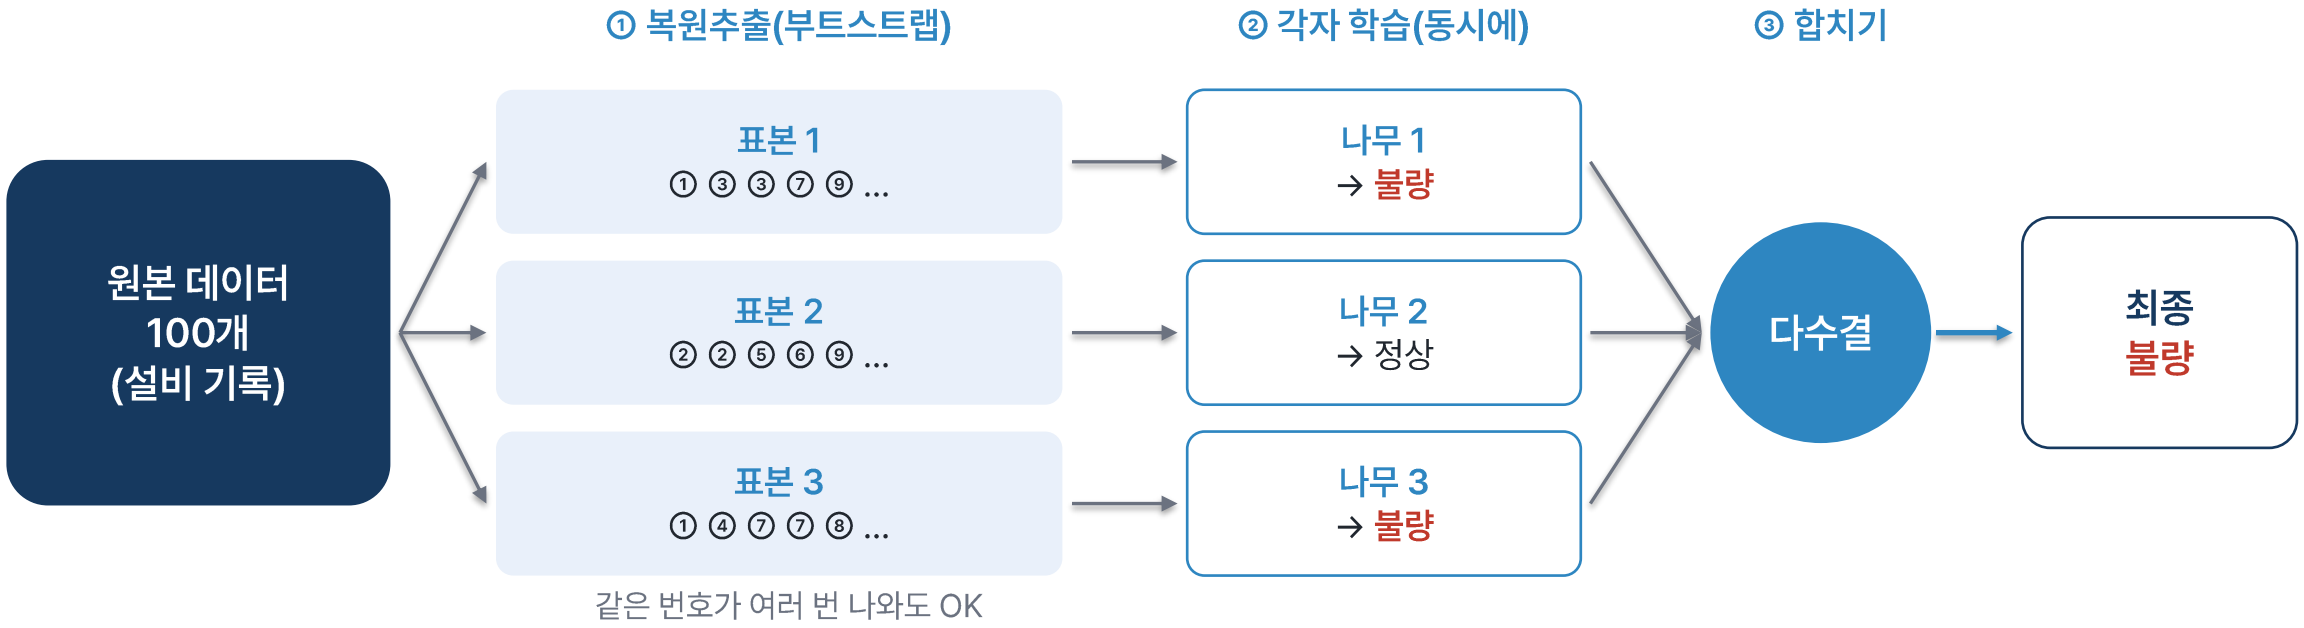
3 랜덤포레스트

배깅 + 참고할 **변수도 무작위**

✓ **시험 POINT** 앙상블 = 여러 모형의 결과를 결합 / 대표: 배깅 · 부스팅 · 랜덤포레스트

배깅(Bagging) = Bootstrap + Aggregating

| 복원추출로 표본 여러 개 → 모형 여러 개 → 투표



같은 번호가 여러 번 나와도 OK

분류 → **다수결 투표** / 회귀 → **평균**

효과: **분산 감소** → 과대적합 완화, 병렬이라 빠름

✓ **시험 POINT** 배깅 = 부트스트랩(복원추출) + 다수결 투표, 병렬 학습으로 분산 감소

랜덤포레스트 = 배깅 + 변수 무작위 선택

| 나무마다, 마디마다 변수 일부만 골라 쓴다

	온도	압력	진동	전류	가스유량
나무 1	선택	·	선택	·	·
나무 2	·	선택	·	선택	·
나무 3	선택	·	·	·	선택
나무 4	·	·	선택	선택	·
나무 5	·	선택	·	·	선택

선택 = 마디를 나눌 때 후보로 뽑힌 변수 (매번 무작위로 일부만)

랜덤포레스트
= 배깅 + 변수 무작위 선택

왜 변수를 섞나?

강한 변수 하나가 모든 나무를 똑같이 만들면
투표해도 소용없다 → 변수를 섞어 주면 나무끼리 덜 닮는다

장점 · 단점

장점: 예측력 높음, 변수 중요도 제공
단점: 나무 수백 그루 → 해석 어려움

✓ **시험 POINT** 랜덤포레스트: 배깅에 변수 무작위 선택을 더함 / 해석은 어렵지만 변수 중요도 제공

부스팅(Boosting) — 틀린 문제를 집중 복습

| 약한 모형을 순서대로 이어 강하게 만든다



●정상 ▲불량 주황 원 = 이번 모형이 틀린 점 → 다음 모형에서 크게(가중치↑)

① 같은 가중치
모든 데이터 동등

→

② 오답 가중치↑
틀린 데이터 강조

→

③ 다음 모형
바뀐 가중치로 학습

→

④ 가중 결합
잘한 모형에 큰 비중

대표 기법

AdaBoost: 가중치 조정
GBM: 남은 오차(잔차) 줄이기
→ XGBoost · LightGBM

✓ **시험 POINT** '오분류된 데이터에 가중치를 높인다' = 부스팅 (순차 학습)

배깅 vs 부스팅 한눈에 비교

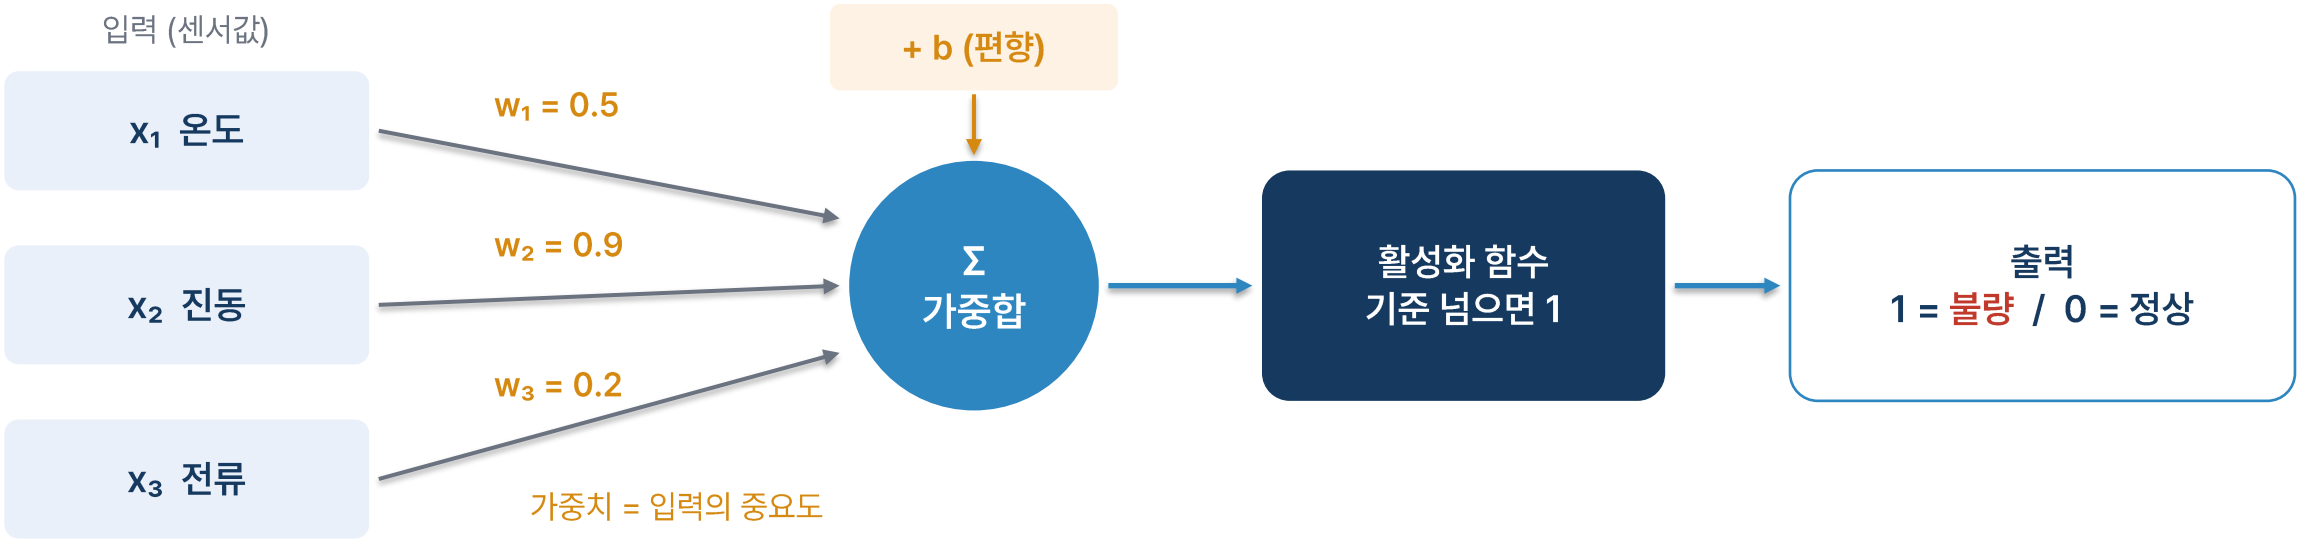
구분	배깅 (Bagging)	부스팅 (Boosting)
비유	여러 명이 **따로** 풀고 투표	한 명이 **오답노트**로 반복 복습
표본	복원추출(부트스트랩), 서로 독립	오분류 데이터에 **가중치↑**
학습 순서	**병렬** (동시에)	**순차** (앞 결과 반영)
결합	다수결 투표 · 평균	성능에 따른 **가중** 결합
주 효과	**분산** 감소, 과대적합 방지	**편향** 감소, 정확도 향상
단점	—	느리고 **과대적합 위험**
대표	랜덤포레스트	AdaBoost, GBM, XGBoost

외우는 법: 배깅 = **병·분·투** (병렬·분산·투표) / 부스팅 = **순·편·가** (순차·편향·가중치)

✓ **시험 POINT** 배깅=병렬·분산 감소, 부스팅=순차·가중치 — 서로 바꿔 낸 함정 보기 주의

인공신경망 ① 퍼셉트론

| 신경망의 가장 작은 단위 — 뇌의 뉴런 하나를 흉내



$$출력 = f\,(\,w_1x_1 + w_2x_2 + w_3x_3 + b\,)$$

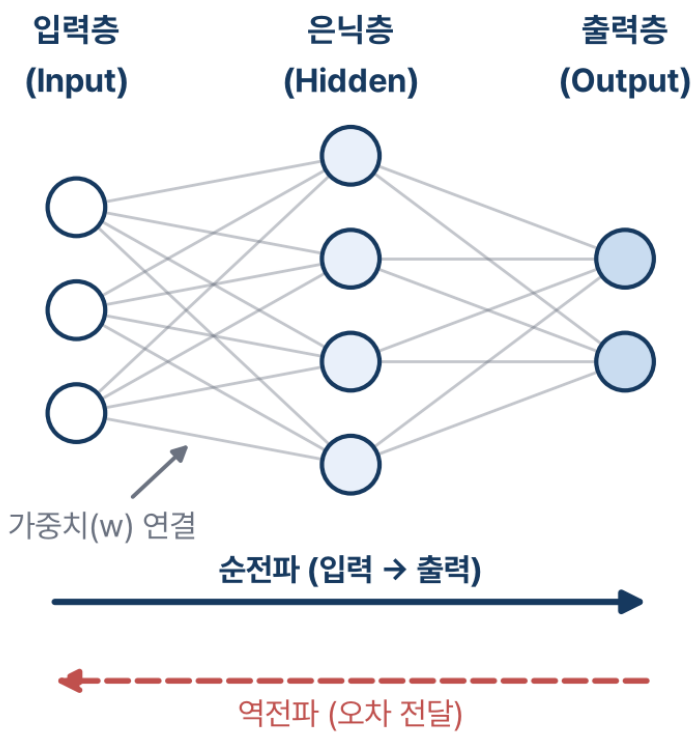
말로 하면

센서값마다 **중요도를 곱해 더하고**,
그 합이 **기준을 넘으면** '불량'이라고 외친다

✓ **시험 POINT** 퍼셉트론 = 입력 × 가중치의 합 + 편향 → 활성화 함수 → 출력

인공신경망 ② 층 구조

| 입력층 – 은닉층 – 출력층, 선마다 가중치가 하나씩



1 입력층

센서값이 들어오는 문 (온도·진동·전류 …)

2 은닉층

입력을 섞어 특징을 만드는 곳
층·노드가 많을수록 복잡한 패턴

3 출력층

결과를 내는 곳 (불량 확률 0.87)

✓ **시험 POINT** 순전파 = 입력 → 출력, 역전파 = 출력 → 입력 (오차 전달)

활성화 함수 용도 정리

함수	출력 범위	말로 하면	어디에 쓰나
계단	0 또는 1	기준 넘으면 켜짐	초기 퍼셉트론
시그모이드	0 ~ 1	확률처럼 부드럽게	**이진 분류** 출력 (= 로지스틱 회귀)
tanh	-1 ~ 1	시그모이드를 0 중심으로	은닉층
ReLU	max(0, x)	음수는 0, 양수는 그대로	딥러닝 은닉층 (가장 많이 씀)
소프트맥스	각 0~1, 합 = 1	여러 후보의 확률 나눠 갖기	**다중 분류** 출력층

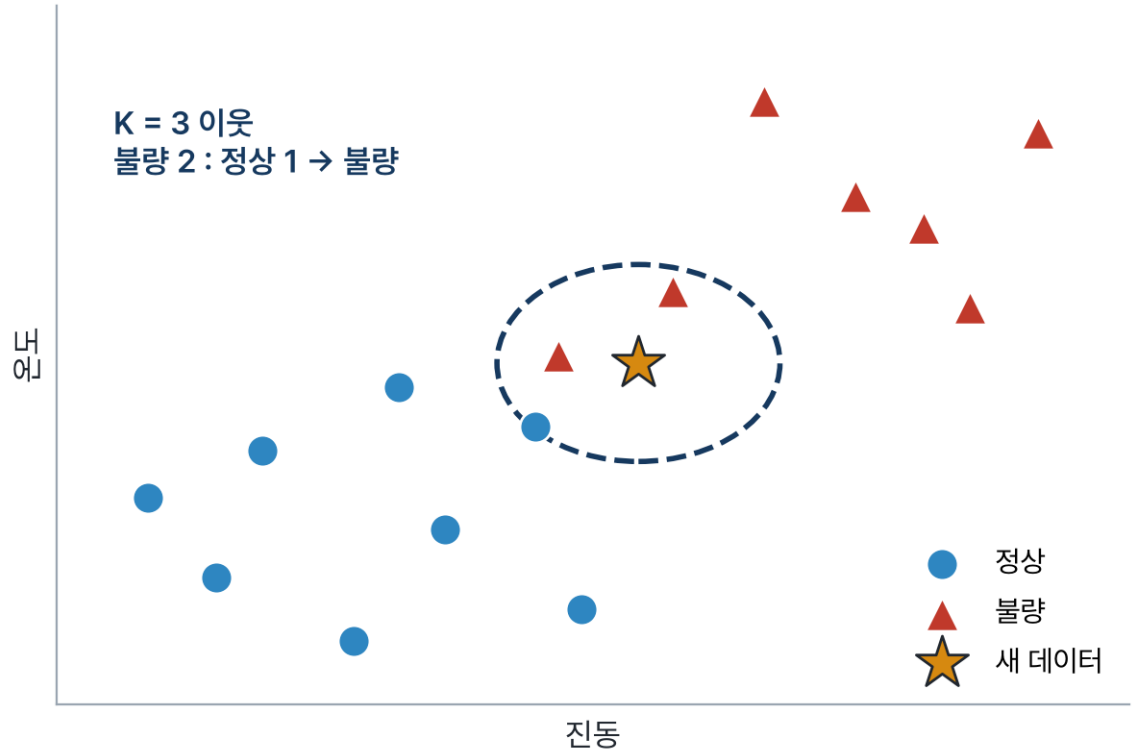
소프트맥스 예

불량 유형 A / B / C 판별 → 소프트맥스 출력 A **0.7**, B 0.2, C 0.1 (합 = 1) → 'A형 불량'으로 분류

✓ 시험 POINT 소프트맥스 = 다중(3범주 이상) 분류, 시그모이드 = 이진 분류 — 용도 구분 빈출

K-최근접 이웃(KNN)

| 새 데이터 주변 K개 이웃에게 물어본다



끼리끼리 모인다

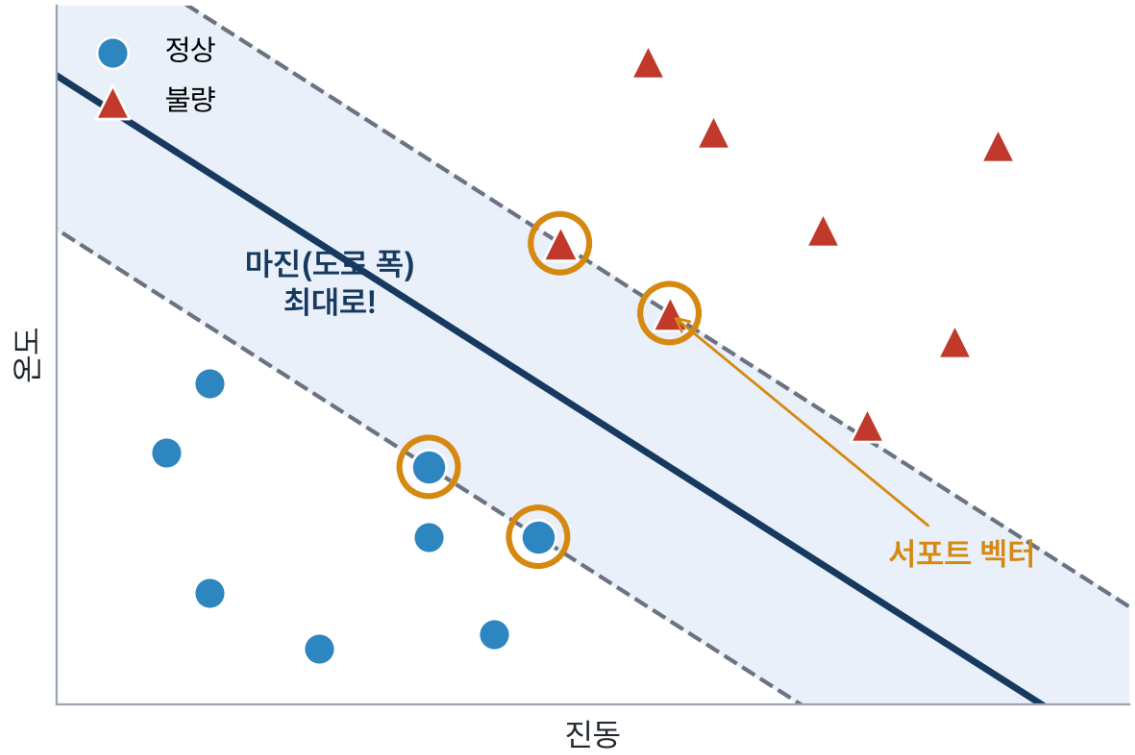
가장 가까운 **K개 이웃의 다수결**
미리 모형을 안 만들고 물어볼 때 계산 → **게으른 학습**

K 값	결과
너무 작다 (K=1)	이웃 하나에 휘둘림 → 과대적합
너무 크다	다 뭉뚱그림 → 과소적합
팁	동점 피하려 **홀수**

✓ **시험 POINT** KNN = 게으른 학습(lazy learning), K 작으면 과대적합 · 크면 과소적합

서포트 벡터 머신(SVM)

| 두 그룹 사이에 가장 넓은 도로 긋기



1 마진 최대화

두 그룹 사이 **가장 넓은 도로**의 한가운데 선

2 서포트 벡터

도로 가장자리에 닿은 점들
→ 경계를 결정하는 주인공

3 커널 트릭

고차원으로 옮겨 **곡선 경계**도 분리

✓ **시험 POINT** SVM 키워드 = 마진 최대화 · 서포트 벡터 · 커널 트릭

3과목 5장

분류 모형 평가

혼동행렬 · 평가지표 · ROC · AUC

혼동행렬 — 불량 검출로 읽기

실제 답과 모형의 답을 짝지어 센 2 × 2 표

	예측: 정상 (P)	예측: 불량 (N)
실제 정상	**TP** 정상을 정상으로 통과 ✓	**FN** 정상인데 불량이라 함 헛경보
실제 불량	**FP** 불량인데 정상이라 함 놓침	**TN** 불량을 불량으로 잡아냄 ✓

읽는 법 (뒤에서부터)

뒷글자 P/N = 모형이 뭐라고 했나
앞글자 T/F = 그게 맞았나

주의

양성(P) = 좋은 쪽이 아니라 찾고 싶은 쪽
→ 불량 검출이면 불량이 양성

정확도

정확도 = (TP + TN) ÷ 전체
불량 1%면 '전부 정상'도 99% → 정확도만 보면 위험

✓ **시험 POINT** 네 칸(TP·FN·FP·TN) 위치 채우기와 정확도 계산 빈출 — 행/열(실제/예측) 확인!

평가지표 총정리 — 분모가 핵심

모형 평가

지표	공식	말로 하면	불량 검출에서
정확도	(TP+TN) / 전체	전체 중 맞힌 비율	전체 판정이 맞은 비율
정밀도	TP / (TP+FP)	**'불량'이라 한 것** 중 진짜 불량	경보가 울리면 믿을 만한가
재현율 = 민감도	TP / (TP+FN)	**실제 불량** 중 잡아낸 비율	불량을 놓치지 않는가
특이도	TN / (TN+FP)	**실제 정상** 중 정상이라 한 비율	정상품을 괜히 버리지 않는가
F1	2×정밀도×재현율 ÷ (정밀도+재현율)	정밀도·재현율의 **조화평균**	둘 다 챙긴 종합 점수
FPR	FP / (FP+TN)	= 1 − 특이도 (헛경보율)	ROC 곡선의 x축

✓ **시험 POINT** 재현율 = 민감도(같은 공식), F1은 조화평균 — '산술평균' 보기는 함정

혼동행렬 계산 예제

| 제품 100개 검사 결과 (양성 = 불량)

제품 100개	예측 불량	예측 정상
실제 불량	TP 30	FN 10
실제 정상	FP 20	TN 40

분모 찾기

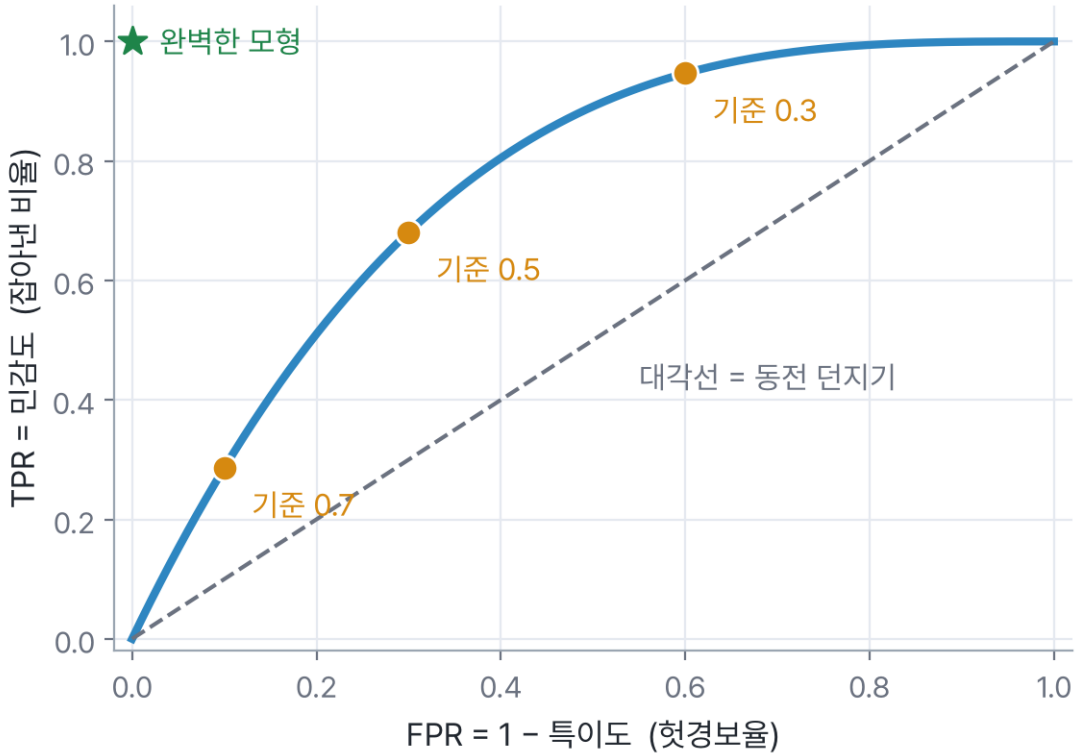
정밀도 → 세로(예측 불량 열)
재현율 → 가로(실제 불량 행)
특이도 → 실제 정상 행

지표	계산	값
정확도	(30 + 40) ÷ 100	0.70
정밀도	30 ÷ (30 + 20)	0.60
재현율	30 ÷ (30 + 10)	0.75
특이도	40 ÷ (40 + 20)	0.67
F1	2 × 0.6 × 0.75 ÷ 1.35	0.67

✓ **시험 POINT** 숫자가 주어진 혼동행렬에서 지표 계산 — 거의 매회 출제

ROC 곡선

| 기준값을 바꿔 가며 그린 성능 곡선



축	정의	말로 하면
x축	FPR = 1 − 특이도	정상인데 불량이라 한 비율
y축	TPR = 민감도	불량을 잡아낸 비율

ROC 곡선이란

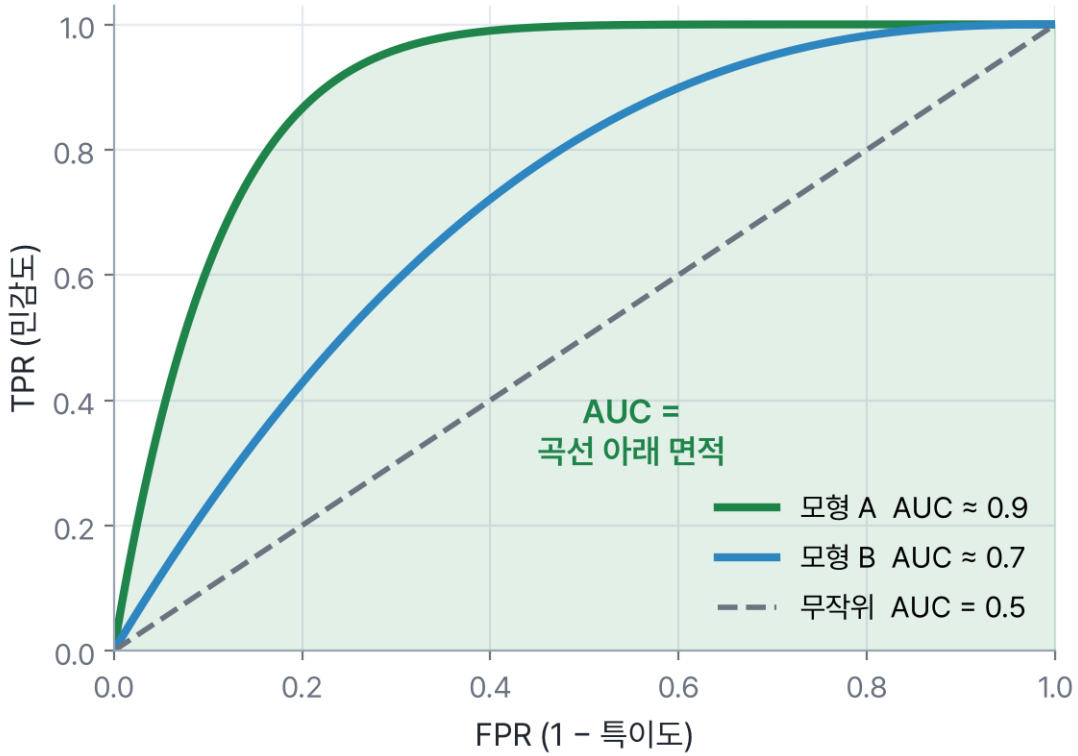
기준값을 바꿀 때마다 혼동행렬이 바뀐다
→ 모든 기준의 (FPR, TPR) 점을 이은 곡선
왼쪽 위에 붙을수록 좋은 모형

✓ **시험 POINT** ROC 축: x = 1 − 특이도(FPR), y = 민감도(TPR) — 축 바꿔치기 함정 최빈출

AUC — 곡선 아래 면적으로 채점

모형 평가

| 0.5(무작위) ~ 1(완벽)



AUC	판정
0.9 이상	뛰어남 (Excellent)
0.8 ~ 0.9	우수 (Good)
0.7 ~ 0.8	보통 (Fair)
0.6 ~ 0.7	미흡 (Poor)
0.5 ~ 0.6	실패 (Fail)

AUC 0.5 = 동전 던지기, 1에 가까울수록 좋다

✓ **시험 POINT** AUC 0.9 이상 뛰어남 · 0.8~0.9 우수 · 0.7~0.8 보통 / 0.5 = 예측력 없음

3과목 5장

군집분석

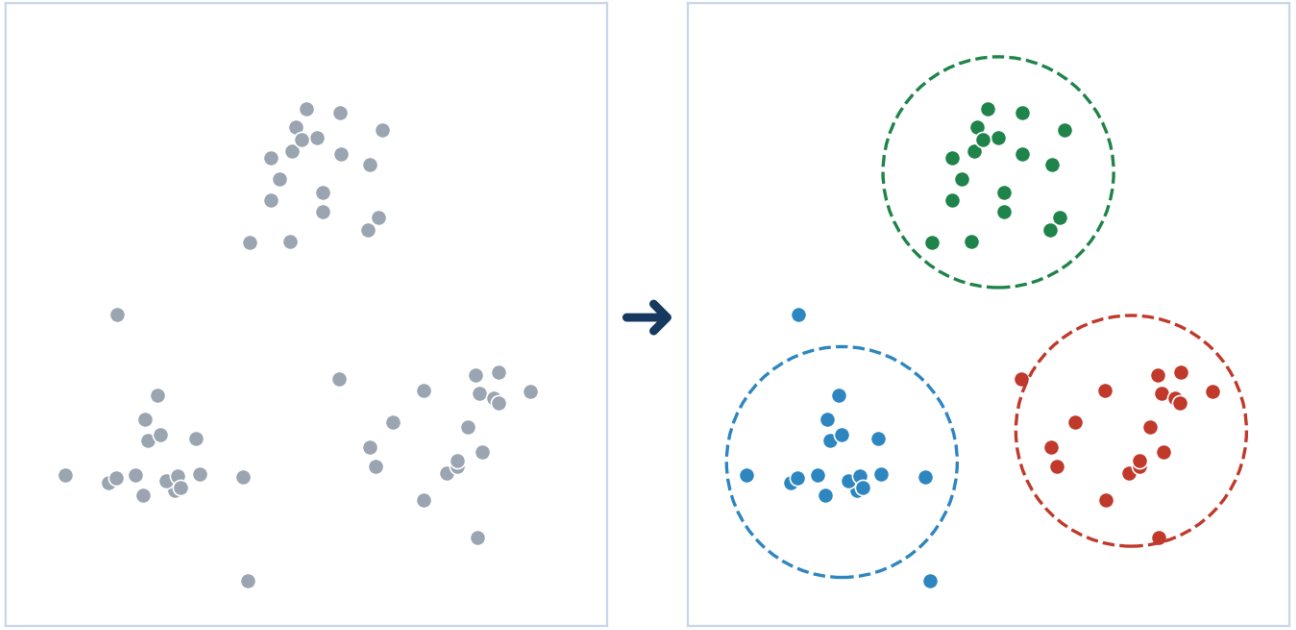
거리 측정 · 계층적 군집 · k-평균 · SOM

군집분석 — 비슷한 것끼리 묶기

| 정답 없이 거리(유사도)만으로 그룹을 찾는 비지도학습

묶기 전: 정답(라벨) 없음

묶은 후: 비슷한 것끼리 3그룹

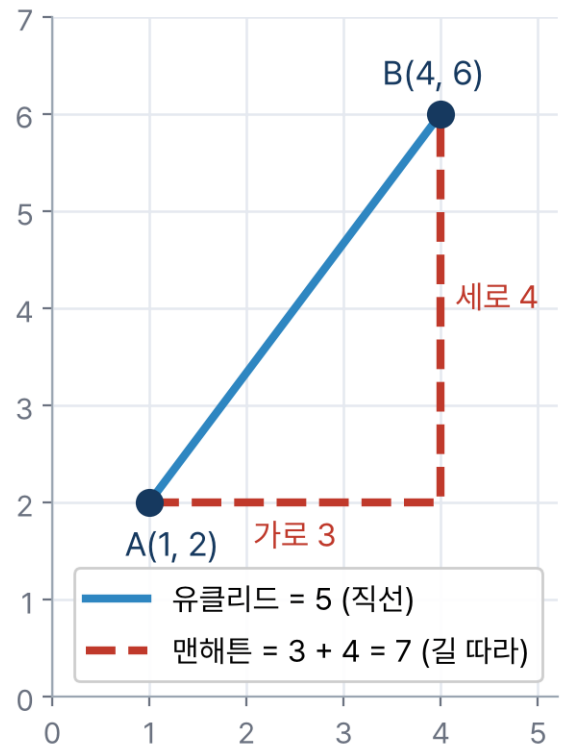


구분	분류 (지도)	군집 (비지도)
정답	있음 (불량/정상)	없음
하는 일	정답 맞히기	비슷한 것끼리 묶기
기준	목표변수	거리·유사도
예	불량 예측	설비 운전 패턴 묶기

✓ **시험 POINT** 군집분석은 **비지도학습**(목표변수 없음) — '분류'와 혼동 주의

유클리드 vs 맨해튼 거리

| A(1, 2)와 B(4, 6) 사이 거리 재기



유클리드 = √Σ(차이)²

√(3² + 4²) = √25 = **5**
두 점을 **자로 잰 직선거리**

맨해튼 = Σ|차이|

|3| + |4| = **7**
바둑판 길을 **따라 걷는 거리**

항상 유클리드 ≤ 맨해튼
(직선이 가장 짧은 길)

✓ 시험 POINT 유클리드 = 제곱합의 루트, 맨해튼 = 절댓값의 합 — 계산 단골

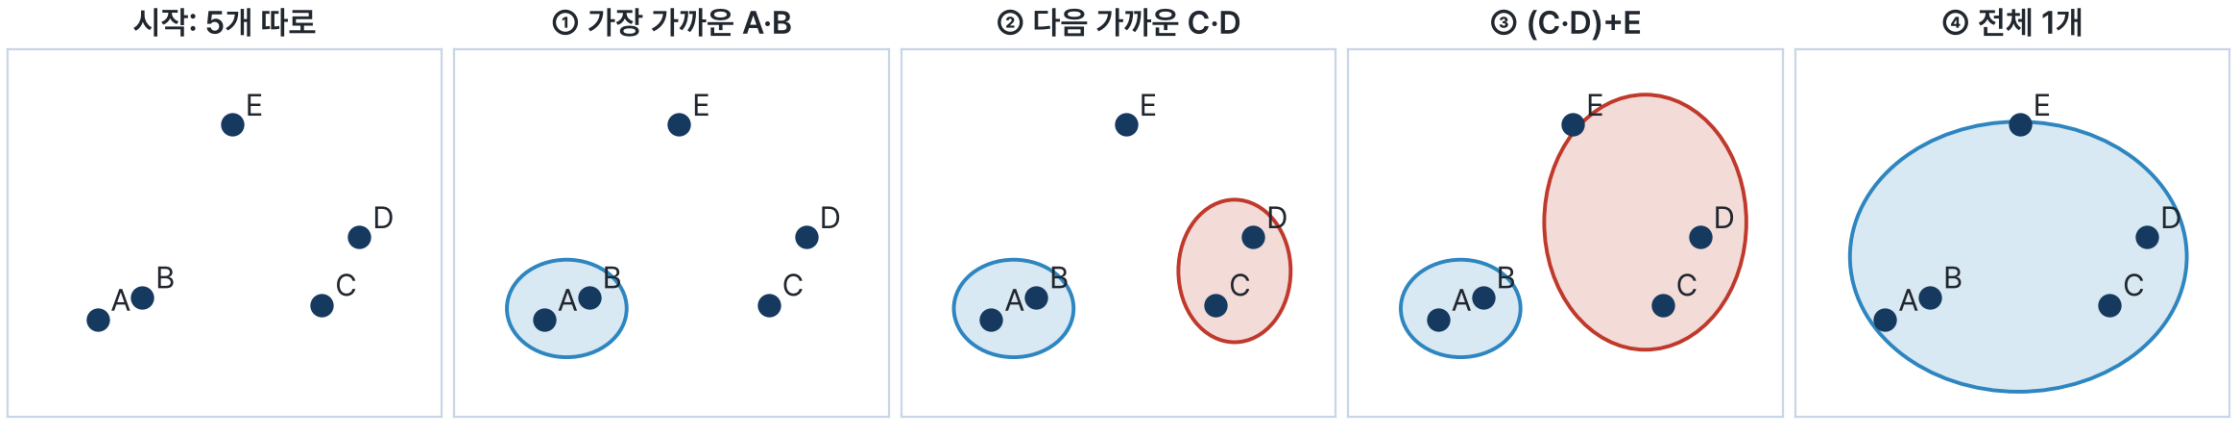
연속형 거리 측도 한눈에

거리 측도	계산 (한 번만 보기)	말로 하면	언제·기억법
유클리드	$\sqrt{\Sigma(x_i - y_i)^2}$	두 점 사이 직선거리	가장 기본
맨해튼	$\Sigma\|x_i - y_i\|$	가로·세로 길 따라 걷는 거리	절댓값의 합
민코프스키	$(\Sigma\|x_i - y_i\|^m)^{(1/m)}$	위 둘을 묶은 일반식	**m = 1 맨해튼, m = 2 유클리드**
표준화 거리	차이를 표준편차로 나눈 뒤 유클리드	단위·크기 차이를 없앤 거리	온도(°C) vs 압력(Pa)처럼 단위가 다를 때
마할라노비스	표준화 + 공분산 반영	변수 간 **상관관계까지** 고려	**공분산 고려** = 마할라노비스
체비셰프	$\max\|x_i - y_i\|$	가장 크게 차이 나는 한 변수의 차이	최댓값 하나만 본다

✓ **시험 POINT** 민코프스키 m=1 맨해튼·m=2 유클리드 / 마할라노비스 = 공분산(상관) 고려

계층적 군집 — 가까운 것부터 차례로

계층적 군집



병합적(Agglomerative) vs 분할적

따로 시작 → 가까운 것끼리 **계속 합친다** (위 그림)
분할적은 반대: 전체 하나 → 계속 나눈다

계층적 군집의 두 가지 특징

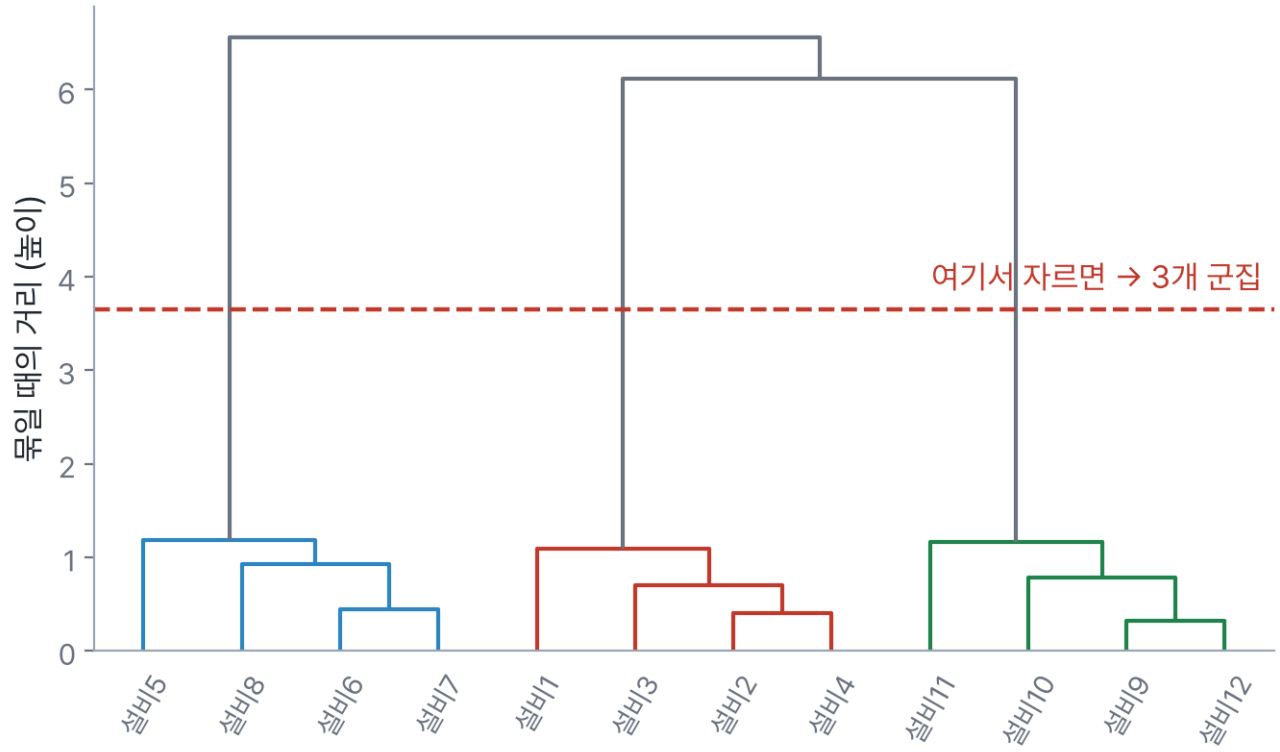
① 군집 수를 **미리 정하지 않는다**
② 한 번 묶이면 **다시 떼지 않는다** (재배치 X)

✓ **시험 POINT** 계층적: 군집 수 사전 지정 X, 한 번 묶이면 재배치 X

덴드로그램 읽기

계층적 군집

| 묶이는 과정을 나무 모양으로



1 세로 높이 = 거리

높은 곳에서 묶일수록
서로 많이 다르다

2 가로로 자르기

잘린 가지 수 = 군집 수
낮게 자르면 군집 많아짐

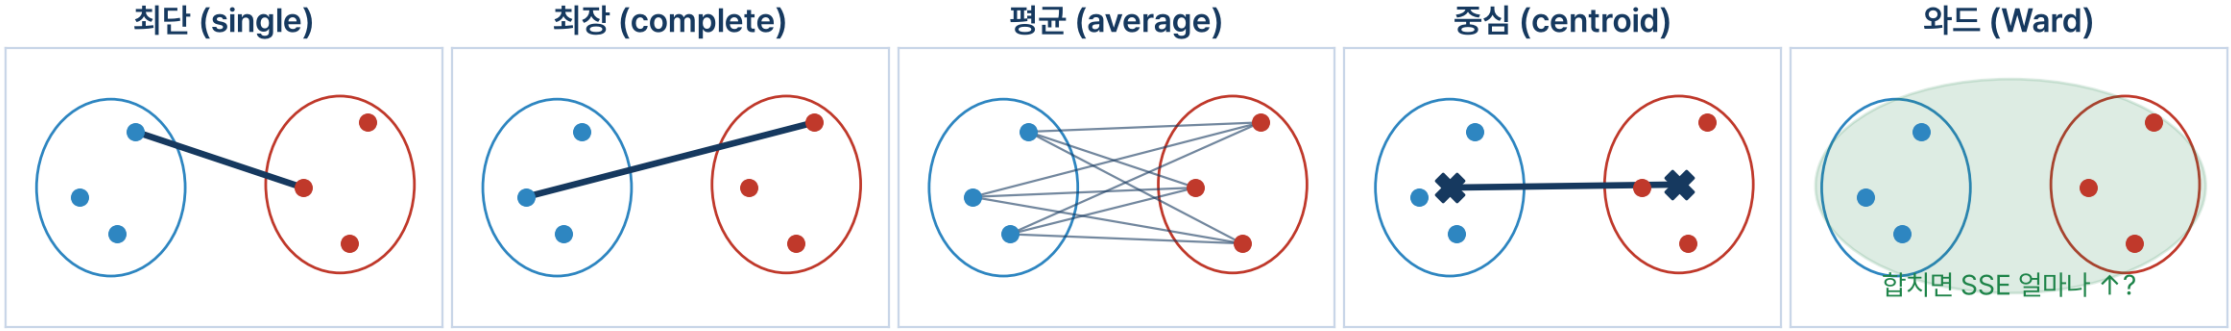
3 R 함수

hclust() (이름만 기억)

✓ **시험 POINT** 덴드로그램을 가로로 자른 높이에 따라 군집 수가 결정된다

연결법 5가지 — 군집 사이 거리 정하기

계층적 군집



군집 간 거리	가장 **가까운** 쌍 = min	가장 **먼** 쌍 = max	모든 쌍의 **평균**	두 군집 **중심** 사이	합칠 때 **오차제곱합 증가량**
특징	사슬(chain) 모양 길게 이어짐	둥글고 조밀한 군집	극단값 영향 완화 계산량 많음	병합 후 중심을 가중평균으로 갱신	비슷한 크기 군집 형성

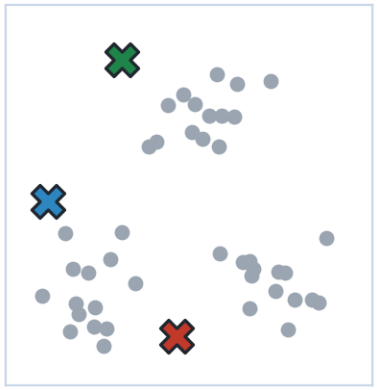
✓ **시험 POINT** 최단=min(사슬), 최장=max, 와드=**오차제곱합 증가량** — 짝짓기 빈출

k-평균 군집 4단계

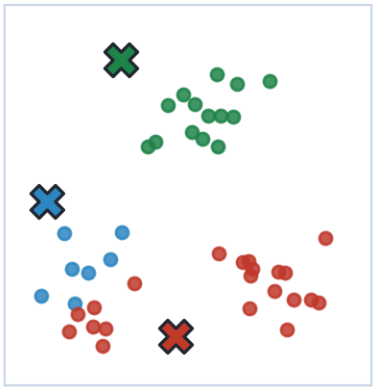
k-means

| k개의 모임 장소를 정하고 옮겨 가며 맞추기

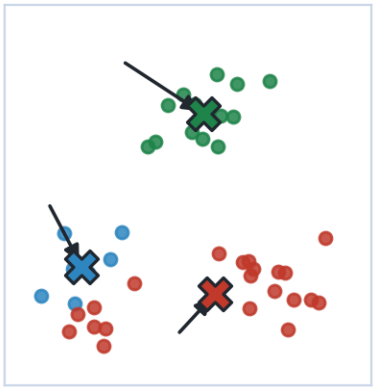
① 중심 k=3개 임의로



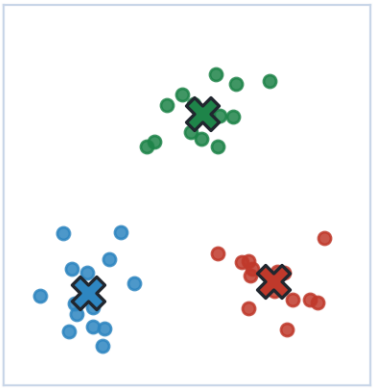
② 가까운 중심에 배정



③ 평균으로 중심 이동



④ 반복 → 중심 고정



k-평균의 핵심

군집 수 **k를 미리 정하고** 시작 (비계층적)
②·③을 반복하며 점이 **다른 군집으로 옮겨 갈 수 있음**

주의: 초기 중심 문제

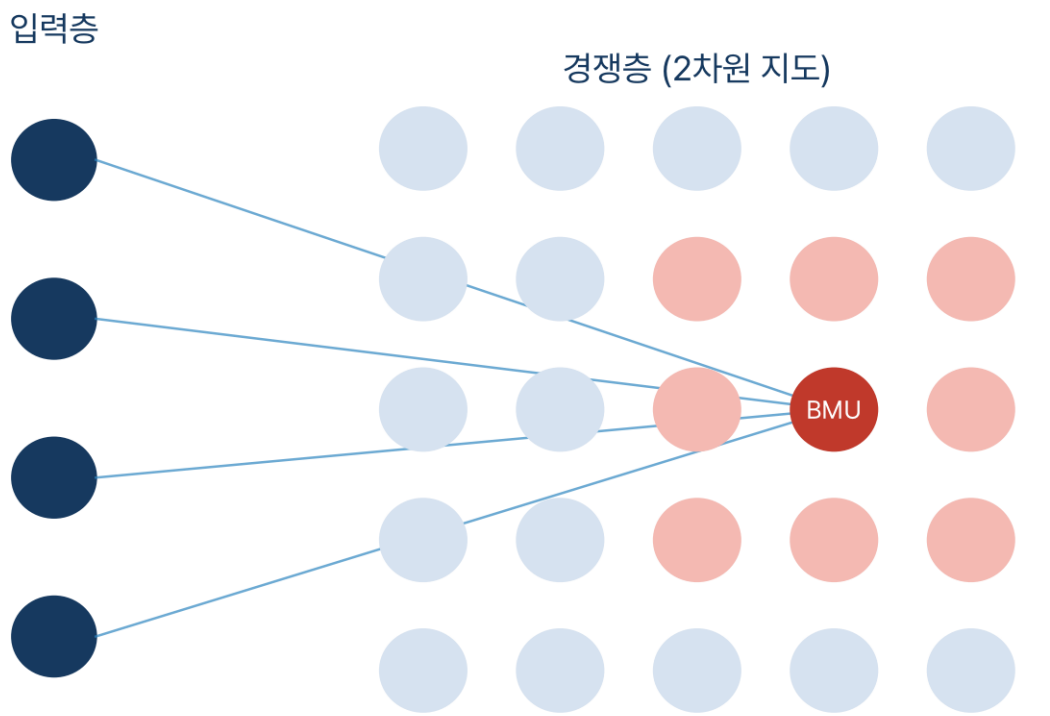
처음 중심을 어디 찍느냐에 따라 결과가 달라짐
→ 여러 번 돌려 비교 (탐욕적 → 최적해 보장 X)

✓ 시험 POINT 순서: 중심 선택 → 할당 → 중심 갱신 → 반복(수렴)

SOM(자기조직화지도)

SOM

| 고차원 데이터를 2차원 지도로 펼치기



빨강 = 승자(BMU), 분홍 = 이웃 → 함께 입력 쪽으로 이동

핵심	내용
정체	코호넨의 **비지도** 신경망
하는 일	고차원 → **2차원 지도** 비슷한 것은 지도에서도 가까이
구조	입력층 + 경쟁층 **2층** **은닉층 없음**
학습	가장 가까운 뉴런 = **BMU(승자)** 승자와 이웃을 입력 쪽으로
속도	**역전파 X**, 전방 패스만 → 빠르고 실시간 가능

✓ **시험 POINT** SOM: 2층(은닉층 X) · 역전파 X · BMU = 승자 뉴런 · 비지도

3과목 5장

연관분석

장바구니 분석과 Apriori

연관분석 — '이거 사면 저것도'

| 장바구니에서 if → then 규칙 찾기

거래 1	거래 2	거래 3
빵 · 우유	기저귀 · 맥주 · 빵	기저귀 · 맥주 · 우유

찾아낸 규칙

기저귀 → 맥주
if 기저귀를 사면
then 맥주도 산다

1 비지도 · 비목적성

목표변수 없이 유용한 패턴 탐색
(= 장바구니 분석)

2 자료 형태

거래 번호 × 함께 산 품목
설비: 시점 × 함께 뜬 알람

3 활용

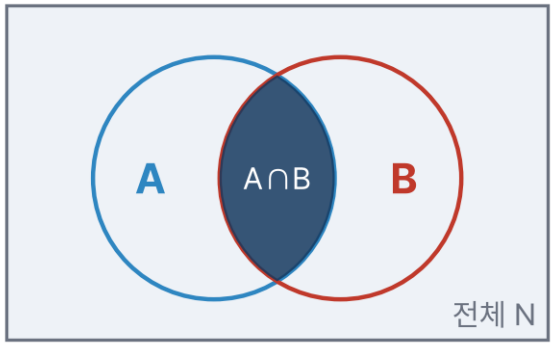
상품 진열·묶음 상품
교차 판매·추천

✓ **시험 POINT** 연관분석 = 장바구니 분석, **비지도학습** — '목표변수 필요'는 오답

지지도 · 신뢰도 · 향상도

| 규칙 A → B 를 평가하는 3가지 잣대

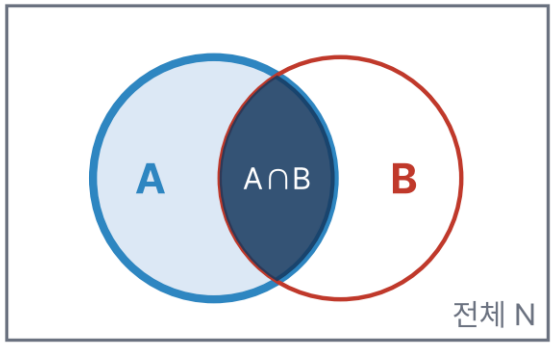
지지도



A∩B ÷ 전체

얼마나 자주 함께 팔리나
(분모 = 전체 거래 수)

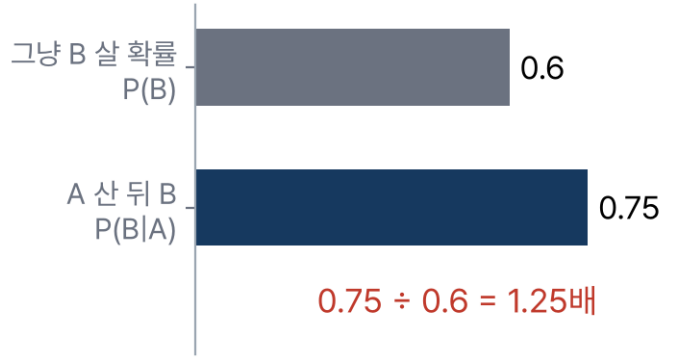
신뢰도



A∩B ÷ A = P(B|A)

A를 산 사람 중
B도 산 비율 (분모 = A)

향상도



P(B|A) ÷ P(B)

A를 사면 B 살 확률이
몇 배가 되나 (기준 1)

✓ **시험 POINT** 지지도 분모 = 전체 / 신뢰도 분모 = P(A) / 향상도 기준 = 1

계산 예제: 기저귀 → 맥주

| 거래 5건으로 세 측도 구하기

거래	빵	우유	기저귀	맥주
T1	O	O		
T2	O		O	O
T3		O	O	O
T4	O	O	O	O
T5	O	O	O	

규칙: 기저귀 → 맥주	계산	값
① 지지도	3 ÷ 5	0.6
② 신뢰도	0.6 ÷ 0.8	0.75
③ 향상도	0.75 ÷ 0.6	1.25 (> 1)

먼저 개수 세기

기저귀 4/5 = 0.8, 맥주 3/5 = 0.6
둘 다(주황 행) 3/5 = 0.6

방향을 바꾸면?

맥주 → 기저귀: 신뢰도 = 0.6 ÷ 0.6 = 1.0 (분모가 P(맥주))
지지도 0.6, 향상도 1.25는 그대로 → 신뢰도만 방향에 따라 달라짐

✓ **시험 POINT** 방향을 바꾸면 **신뢰도만** 달라짐 (지지도·향상도는 동일)

향상도 읽는 법

| 기준은 1

향상도	의미	관계	예시
> 1	A가 있으면 B가 더 잘 일어남	양의 관계 (보완)	기저귀 → 맥주, 진공 알람 → 압력 알람
= 1	A와 B는 서로 무관	독립	볼펜 → 라면
< 1	A가 있으면 B가 덜 일어남	음의 관계 (대체)	콜라 → 사이다

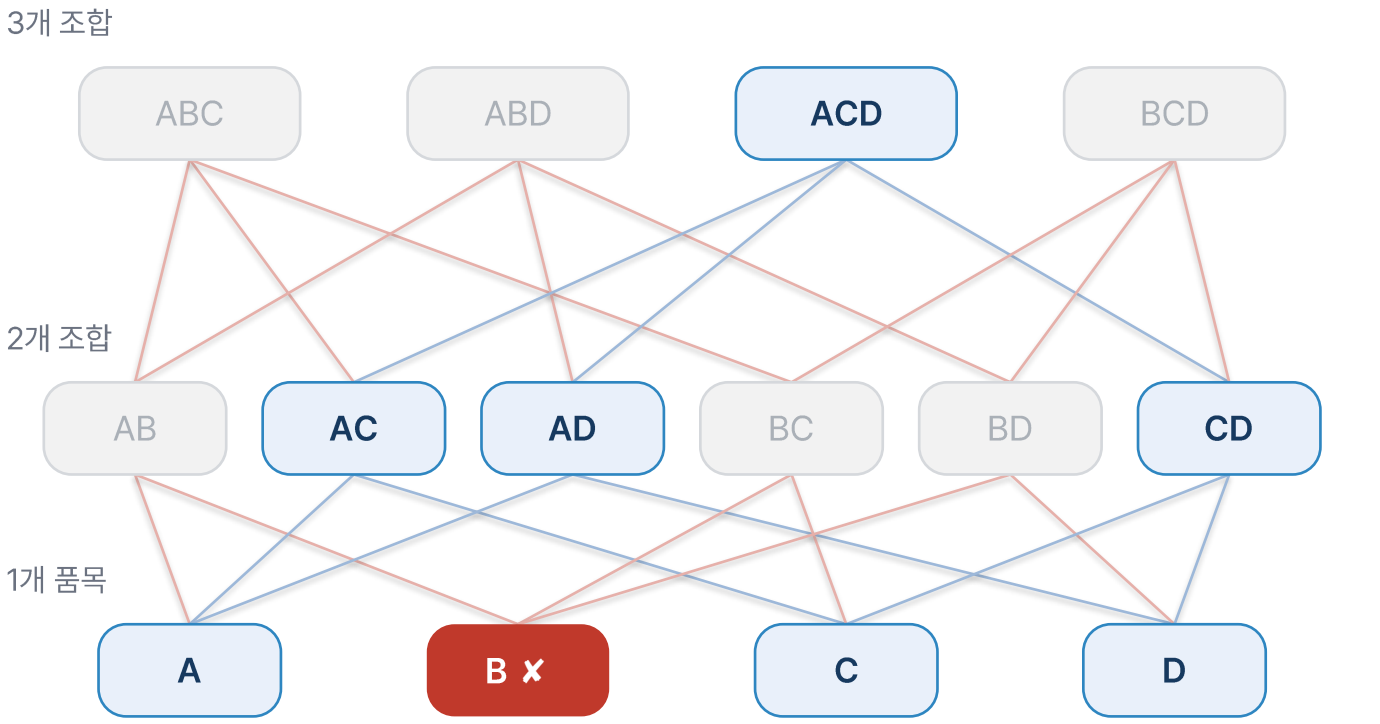
함정 주의

향상도의 기준은 0이 아니라 1 / 지지도·신뢰도가 높아도 향상도가 1 근처면 '원래 잘 팔리는 물건'일 뿐

✓ **시험 POINT** 향상도 >1 양의 관계, =1 독립, <1 음의 관계(대체재)

Apriori — 안 팔리는 건 미리 빼기

| 빈발하지 않은 집합의 상위집합도 빈발하지 않는다



B가 빈발 X → B 들어간 조합(회색)은 계산 안 함

① 1개씩 품목별 지지도 계산

↓

② 가지치기 최소지지도 미만 제거
그 품목 들어간 조합도 제외

↓

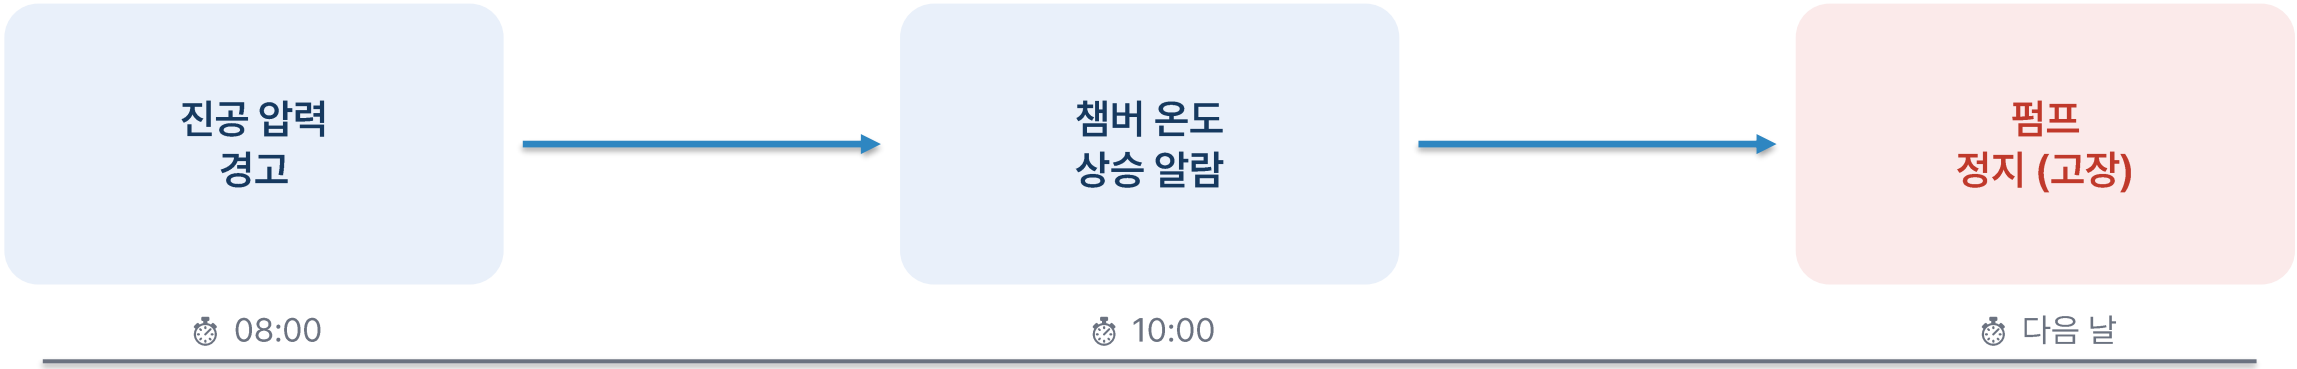
③ 늘려 가기 남은 것끼리 2개 → 3개 조합
빈발항목집합 찾기

✓ **시험 POINT** Apriori = 최소지지도 · 빈발항목집합 · 가지치기

순차패턴분석 — 연관분석 + 시간 순서

연관분석

| 설비 알람이 어떤 순서로 이어지나



구분	연관분석	순차패턴분석
보는 것	같은 거래 안 동시 발생	시간 순서대로 이어짐
필요 정보	거래별 품목	고객·설비 ID + 발생 시점
예	기저귀 → 맥주	프린터 → (다음 방문) 토너

FP-Growth

FP-Tree를 만든 뒤 분할정복
Apriori보다 DB를 적게 스캔

R에서는

arules 패키지의 apriori( )

✓ **시험 POINT** 시간 순서가 있는 연관분석 = 순차패턴분석 / R 패키지 = arules

3-2과목 체크리스트 ① 분류 모형

핵심 요약

| 시험 직전, 한 줄씩 소리 내어 확인

☐	주제	시험장에서 떠올릴 한 줄
☐	마이닝 절차·분할	목적→준비→가공→기법→검증 / 분할 5:3:2, 교차검증 = **k번 반복 후 평균**
☐	로지스틱 회귀	범주형 결과, 오즈 = p ÷ (1 − p), 직선식 0 → 확률 0.5, 추정 = **MLE**
☐	의사결정나무	CART-**지니**, C4.5-**엔트로피**, CHAID-**카이제곱** / 낮을수록 순수
☐	앙상블	배깅 = 복원추출·병렬·분산↓ / 부스팅 = 순차·오분류 가중↑ / RF = 배깅 + 변수 무작위
☐	신경망	역전파 = 출력→입력, 은닉노드 多 = **과대적합** / 다중 분류 = **소프트맥스**
☐	기타 분류	KNN = 게으른 학습 / SVM = 마진 최대화 · 서포트 벡터 · 커널 트릭

3-2과목 체크리스트 ② 평가·군집·연관

핵심 요약

| 계산 공식은 손으로 한 번 더

☐	주제	시험장에서 떠올릴 한 줄
☐	평가 지표	정밀도 TP÷(TP+FP), 재현율 TP÷(TP+FN), 특이도 TN÷(TN+FP), F1 = 조화평균
☐	ROC	x = 1 – 특이도, y = 민감도, AUC 0.5 = 무작위
☐	거리	유클리드 √Σ차이², 맨해튼 Σ|차이|, 민코프스키 m=1·2 / 자카드 a ÷ (a+b+c)
☐	군집	최단 min·최장 max·와드 SSE / k-means = **k 미리 지정**·재배치 가능 / 덴드로그램을 자른 높이 = 군집 수
☐	SOM	2층(은닉층 X) / 승자 뉴런 = **BMU** / 역전파 X / **비지도** 신경망
☐	연관·순차	향상도 **기준 1**, **신뢰도만 비대칭** / 순차패턴 = 연관분석 + **시간 순서**

✓ **시험 POINT** ADsP 50문항·90분 / 60점 이상 합격, 과목별 40% 미만 과락

3과목(2)

문제풀이

정형 데이터 마이닝 기출 유형 75문항 — 풀이 후 정답표로 채점