🎯 ADsP 핵심 오답노트 (59문항) & 전체 정답노트 (100문항)

👤 **응시자:** 조태섭 | 📊 **채점 요약:** 총점 **41 / 100점** (1과목 10/20점 · 2과목 8/20점 · 3과목 23/60점)
📌 **구성:** [PART 0] 노베이스 필수 도형·그래프 12선 + [PART 1] 오답 59문항 집중 노트 + [PART 2] 1~100번 전체 정답노트 (찍어서 맞은 41문항 포함)

📊 PART 0. 노베이스 시험 직전 필수 도형 · 그래프 · 핵심 도식

① DIKW 피라미드 (4번) & DW vs DM / OLTP vs OLAP (8번)



- **지혜:** "다른 물건도 쌀 것이다"(응용)
- **지식(4번): "A마트서 사야겠다"(결정)**
- **정보:** "A마트가 더 싸다"(비교·의미)
- **데이터:** "A 100원, B 200원"(사실)

[7번 NoSQL] **Redis**=인메모리 키-값 | **MongoDB**=문서(Document) | **HBase**=컬럼(Column)
[8번 DW/DM] **DW**=전사 통합(대규모) vs **DM**=부서별(소규모) | **OLTP**=실시간 거래 vs **OLAP**=다차원 분석

② 분석 기획 4유형 매트릭스 (21번) & 과제 발굴 (29번)

구분 (21번)	분석 방법(How) 앎(O)	분석 방법(How) 모름(X)
분석 대상(What) 앎(O)	최적화 (Optimization)	솔루션 (Solution)
분석 대상(What) 모름(X)	★ 통찰 (Insight) [정답]	발견 (Discovery)

- **하향식(Top-Down):** 문제 주어짐 → **수렴(Converge)** · **Why** 관점 · 5영역 단순화 캔버스(31번)
- **상향식(Bottom-Up, 29번):** 데이터 기반 → **발산(Diverge)** · **What** 관점 · 프로토타이핑 · **비지도학습(군집·연관)**

③ ROI 우선순위 사분면 (34·35번) & 분석 조직 3유형 (39번)



[34·35번] 난이도=**3V(비용)**, 시급성=**Value(효과)** | **시급성 기준:** 현재·쉬움 → **현재·어려움** → 미래·어려움
[39번 조직] **집중형**(전담부서) vs **기능형(별도 조직 없이 현업 직접·과거실적 국한)** vs **분산형**(현업 파견)

④ R matrix 열 우선 & apply (44번) · 층화 vs 집락추출 (51번)

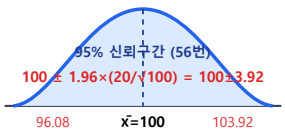
matrix(1:6, nrow=2) [열 우선↓]

1	3	5
2	4	6

↓합 3 ↓합 7 ↓합 11
apply(m, 2, sum) ⇒ 3, 7, 11

- **층화추출 (층내 동질 · 층간 이질)**
  [1학년: A,A,A] [2학년: B,B,B] → 각 층에서 조금씩
- **집락추출 (집락내 이질 · 집락간 동질) ★51번**
  [1반: A,B,C] [2반: A,B,C] → 일부 반만 뽑아 전수조사

⑤ 확률·표준오차·신뢰구간 (53~56번) & 제1·2종 오류 (57·58번)



- **베이즈(53번):** A불량(0.012) / 전체(0.032)
  ⇒ **P(A|불량) = 0.012 / 0.032 = 0.375**
- **분산(54번):** V(3X+2) = 3²×V(X) = **36**
- **표준오차(55번):** SE = σ/√n = 12/√36 = **2**

[57번 p-value] **귀무가설(H₀)이 참일 때** 극단값 나올 확률 (p < α 이면 H₀ 기각)
[58번 오류] 표본 크기 고정 시 **제1종 오류(α)를 줄이면 제2종 오류(β)는 커짐** (상충·반비례 관계)

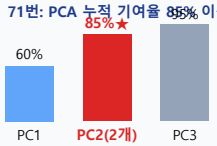
⑥ 시계열 AR vs MA 절단 도식 (69번) & 주성분 누적기여율 (71번)

69번: 시차 2 이후 ACF 절단 ⇒ MA(2)

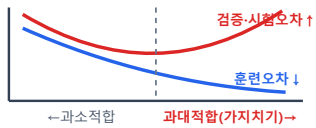


• PACF 절단=AR(p) / • ACF 절단=MA(q)

71번: PCA 누적 기여율 85% 이상



⑦ 데이터 분할·과적합 곡선 (76·80번) & 오즈비·부트스트랩 (77~79번)



- **검증용:** 매개변수 조정·튜닝
- **시험용: 최종 평가만! (튜닝X)**
- **부트스트랩:** 복원추출(36.8% 미포함)
- **가지치기:** 나무 축소(과적합 방지)

[78번 로지스틱] 계수 추정은 최소제곱법이 아닌 **최대우도추정법(MLE)** 사용
[79번 오즈비] x가 1 증가 시 **'오즈(승산)'가 exp(β)=2배** 증가 ('발생 확률이 2배'는 오답!)

⑧ 의사결정나무 지니지수·알고리즘 (82·83번) & 배깅 vs 부스팅 (84번)

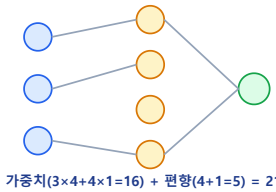
82번 마디: A=8개(0.8), B=2개(0.2)
지니 = 1 − (0.8² + 0.2²)
= 1 − (0.64 + 0.04) = 0.32

- **CART = 지니 지수 (분류) / 분산감소량**
- **C4.5 / C5.0** = 엔트로피(정보이득비)
- **CHAID** = 카이제곱 통계량 / F-통계량

배깅 (Bagging · 랜덤포레스트)
독립적 **병렬 학습** (속도 빠름 · 분산 감소)

부스팅 (Boosting · 84번 정답)
오분류에 가중치 부여 → **순차 학습** (병렬X)

⑨ 인공신경망(3-4-1) 파라미터 21개 (87번) & 혼동행렬 민감도 (89번)



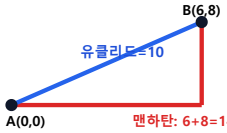
가중치(3×4+4×1=16) + 편향(4+1=5) = 21개

89번 혼동행렬 & 민감도(재현율)

- **실제 양성(50명): TP=40, FN=10**
- 실제 음성(50명): FP=20, TN=30

★ 민감도(재현율) = TP/(TP+FN)
= 40 / (40 + 10) = 40/50 = 0.80
(정확도=70/100=0.70, 특이도=30/50=0.60)

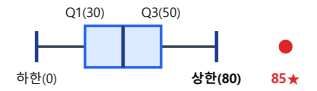
⑩ 유클리드 vs 맨하탄 거리 (93번) & 연관규칙 3대 지표 (97·98번)



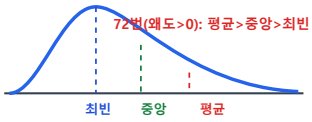
- **연관분석 3대 지표 공식 (A → B)**
① **지지도:** P(A∩B) = 동시구매 / 전체
② **신뢰도(97번): P(A∩B)/P(A) = 20/40 = 0.5**
③ **향상도(98번): 신뢰도/P(B) = 0.8/0.4 = 2.0**

[92번 실루엣] -1~1 범위(1에 가까울수록 우수) | **[95번 k-medoids]** 실제 관측치 중심(이상값 보완)
[96번 SOM] 2층 경쟁학습(역전파X·빠름) | **[100번 FP-Growth]** DB **2회만 스캔**(Apriori는 반복 스캔)

⑪ 상자그림(Boxplot) IQR 이상값 (50번) & 우측 꼬리 왜도>0 (72번)

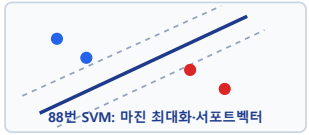


IQR=20 ⇒ 상한 Q3+1.5×IQR = 80 (85=이상값)



- **[66번 규제회귀] 라쏘(L1)**=계수를 0으로(변수선택) / **릿지(L2)**=크기만 축소(0 안됨)
- **[68번 정상성]** 평균 비정상=**차분(Differencing)** / 분산 비정상=**로그·지수 변환**

⑫ SVM 최대 마진 초평면 (88번) & ROC 곡선 · AUC (91번)





- **[70번 다중공선성] VIF > 10** 이면 의심 ⇒ 높은 변수 제거 또는 **PCA(주성분분석)**
- **[74번 상관분석] 피어슨**=등간·비율(선형) / **스피어만**=서열척도(순위·비선형 단조)

❌ PART 1. 핵심 오답노트 (틀린 59문항 집중 공략)

1과목 데이터 이해 — 오답 10문항 (총 10문항)

번호	출제 주제	정답	노베이스 1초 컷 핵심 해설 & 시험장 암기 공식
4번 오답	DIKW 피라미드	③ 지식	"A마트 연필이 더 싸므로 **A마트에서 사야겠다(의사결정·행동)**" = **지식(Knowledge)** 단계 **암기공식** • 데이터(100원/200원) → 정보(A가 더 싸다) → **지식(A에서 사야겠다)** → 지혜(A의 다른 상품도 쌀 것이다)
6번 오답	SQL 명령어 분류	④	**TRUNCATE**는 테이블 구조는 남기고 데이터를 전부 비우는 **DDL(데이터 정의어)**입니다 (DML 아님!) **암기공식** • **DDL(정의):** CREATE, ALTER, DROP, RENAME, **TRUNCATE** / • **DML(조작):** SELECT, INSERT, UPDATE, **DELETE** / • **DCL(제어):** GRANT, REVOKE
7번 오답	NoSQL 저장 구조	①	**Redis** = 인메모리 **키-값(Key-Value)** 저장소 (정답 ①) **암기공식** • **키-값:** Redis, DynamoDB / • **문서(Document):** MongoDB / • **컬럼(Column):** HBase, Cassandra / • **그래프:** Neo4j
8번 오답	DW / DM / OLAP	④ (ㄱ,ㄷ,ㅁ)	**DW** 4대 특징 = 주제지향·통합·시계열·**비휘발성(조회 위주)** / **ETL** = 추출(Extract)→변환(Transform)→적재(Load) **암기공식** • **DW**(전사 대규모) vs **DM**(부서 소규모) [ㄴ반대] / • **OLTP**(실시간 거래) vs **OLAP**(다차원 분석) [ㄹ반대]
9번 오답	빅데이터의 정의	①	**맥킨지(McKinsey)**는 기존 DB 관리·분석 역량을 넘어서는 데이터 **'규모(Volume)'** 관점에서 정의했습니다 **암기공식** • **IDC** = 차세대 기술·아키텍처 관점 / • 정의 범위는 **[규모 → 기술 → 인재·조직]** 순으로 점점 넓어짐
12번 오답	빅데이터 4대 변화	①	빅데이터의 본질적 변화는 '양보다 질'이 아니라 **'질보다 양'**(데이터가 많으면 일부 오류는 상쇄됨)입니다! **암기공식** **[4대 변화 암기]** ① 사전→**사후처리**, ② 표본→**전수조사**, ③ **질보다 양**, ④ 인과→**상관관계**
13번 오답	빅데이터 활용 테크닉	④	"새로운 환불 정책에 대한 고객의 평가·반응은?" → 유형분석이 아니라 **감정분석(Sentiment Analysis)**입니다 **암기공식** • **유형분석:** "이 고객은 어떤 특성 그룹에 속하는가?" / • **유전 알고리즘:** "최대 시청률 프로그램 시간대 편성(최적화)"
14번 오답	위기 요인과 통제 방안	④	**데이터 오용**의 통제 방안 = **알고리즘 접근권 허용 및 알고리즈미스트(Algorithmist) 양성** **암기공식** • **사생활 침해** → 동의제에서 **책임제**로 / • **책임 원칙 훼손** → 예측이 아닌 **결과 기반 책임 원칙** 고수
15번 오답	마이데이터·개인정보	③	**마이데이터(MyData)**는 정보 주체(개인)의 **전송요구권(적극적 의사)**에 기반한 제도입니다 ('동의 없이 제공' X) **암기공식** • **옵트인** = 사전 동의 후 수집 / • **옵트아웃** = 일단 수집 후 사후 거부 허용 / • **가명정보** = 통계·연구 목적 동의 없이 활용 가능
19번 오답	빅데이터 회의론 원인	② (ㄱ,ㄴ)	빅데이터 회의론 2대 원인 = ① 과거 **CRM 공포(투자 실패 부정적 학습효과)**, ② 성공 사례의 **과대 포장** **암기공식** 알고리즘 부재나 저장 비용 상승 때문에 회의론이 생긴 것이 아님(저장 비용은 오히려 하락함)

2과목 데이터 분석 기획 — 오답 12문항 (총 12문항)

번호	출제 주제	정답	노베이스 1초 컷 핵심 해설 & 시험장 암기 공식
21번 오답	분석 주제 4유형	③ 통찰	분석 대상(What)은 **모르지만(X)** 분석 방법(How)은 **알고 있는(O)** 경우 = **통찰(Insight)** **암기공식** • 대상O·방법O = **최적화** / • 대상O·방법X = **솔루션** / • 대상X·방법O = **통찰** / • 대상X·방법X = **발견**

번호	출제 주제	정답	노베이스 1초 컷 핵심 해설 & 시험장 암기 공식
23번 오답	분석 기획 고려사항	② (ㄱ,ㄴ,ㄷ,ㄹ)	분석 기획 3대 고려사항 = ① 가용 데이터 파악, ② 적절한 유스케이스 탐색, ③ **장애요소 사전 계획(고정관념·편향·프레이밍 효과)** 암기공식 • 텍스트·이미지·영상은 '정형'이 아니라 **'비정형 데이터'**이므로 RDB에 그대로 적재 불가 (ㅁ 오답)
24번 미응답	개발 모델 (미응답)	①	**나선형(Spiral) 모델**은 반복 개발과 위험 분석을 수행하므로 관리가 복잡하며 **대규모·고위험 프로젝트**에 적합합니다 암기공식 • **폭포수 모델** = 순차 진행 / • **프로토타입 모델** = 요구사항이 불명확할 때 시제품으로 점진적 개선
25번 오답	KDD 분석 방법론	③ 변환	변수 선택·생성, **차원 축소(PCA 등), 학습용/시험용 데이터 분리**를 수행하는 단계 = **데이터 변환(Transformation)** 암기공식 • KDD 5단계: 데이터셋 선택 → **전처리(결측값·이상값·잡음 처리)** → **변환(변수생성·차원축소·분할)** → 마이닝 → 해석/평가
28번 오답	빅데이터 분석 방법론	③	**모델 발전 계획 수립**은 시스템 구현 단계가 아니라 마지막 5단계인 **[평가 및 전개]** 단계의 태스크입니다 암기공식 • 빅데이터 방법론 5단계: 분석 기획 → 데이터 준비 → 데이터 분석 → 시스템 구현 → **평가 및 전개(모델 발전 계획)**
29번 오답	하향식 vs 상향식	④	**상향식(Bottom-Up)** 접근법에서는 군집분석·연관분석 등 **비지도학습 기법**이 주로 활용됩니다 암기공식 • **하향식** = 수렴(Converge)·Why 관점·체계적 / • **상향식** = 발산(Diverge)·What 관점·프로토타이핑(시행착오)·비지도학습
31번 오답	하향식 문제 탐색	①	비즈니스 모델 캔버스 9개 블록을 그대로 쓰지 않고 **5개 영역(업무·제품·고객 + 규제와 감사·지원 인프라)으로 단순화**합니다 암기공식 • 하향식 4단계: **문제 탐색**(5영역 캔버스) → **문제 정의**(분석 문제로 변환) → **해결방안 탐색** → **타당성 검토**(경제·기술)
33번 오답	마스터플랜 고려요소	③	**전략적 중요도**는 '우선순위' 고려 요소입니다! **적용 범위·방식** 고려 요소는 **'~적용 수준' 3가지**입니다 암기공식 • **우선순위 3요소:** 전략적 중요도, 비즈니스 성과(ROI), 실행 용이성 / • **적용 범위·방식 3요소:** 업무 내재화·분석 데이터·기술 적용 **수준**
34번 오답	ROI 관점 평가 기준	②	투자 비용 요소인 **3V(Volume·Variety·Velocity)는 '난이도'**를, 비즈니스 효과인 **Value(가치)는 '시급성'**을 판단합니다 암기공식 • **투자 비용(난이도)** = 3V(데이터 획득·저장·가공 비용) / • **비즈니스 효과(시급성)** = Value(전략적 중요도·성과)
35번 오답	우선순위 사분면 순서	④	**시급성 기준**(현재 과제 우선) 추진 순서 = **현재·쉬움(1순위) → 현재·어려움(2순위) → 미래·어려움** 암기공식 • **난이도 기준**(쉬운 과제 우선)일 때가 [현재·쉬움 → **미래·쉬움** → 미래·어려움](②번 보기)입니다. 시험 빈출 함정!
36번 오답	분석 거버넌스 5요소	① (ㄱ~ㅁ)	분석 거버넌스 체계 5대 구성요소 = **조직(O), 프로세스(P), 시스템(S), 데이터(D), 인력·교육(H)** (**'예산'은 제외!**) 암기공식 • 암기팁: **조·프·시·데·인** (연간 분석 예산(ㅂ)은 거버넌스 체계 5대 구성요소에 포함되지 않음)
39번 오답	분석 조직 구조 3유형	② 기능형	별도 분석 조직 없이 **각 현업 부서에서 직접 분석**하여 과거 실적 분석에 국한되기 쉬운 구조 = **기능형 구조** 암기공식 • **집중형** = 전사 전담 분석조직 별도 설치(현업과 이원화 가능성) / • **분산형** = 분석 전문인력을 현업 부서로 파견 배치

3과목 데이터 분석 — 오답 37문항 (총 37문항)

번호	출제 주제	정답	노베이스 1초 컷 핵심 해설 & 시험장 암기 공식
42번 오답	R 산술 연산자	④ (1, 2)	**7 %% 3 = 1** (나머지 연산) / **7 %/% 3 = 2** (정수 몫 연산) 암기공식 • **%%** = 나눗셈의 **나머지** / • **%/%** = 나눗셈의 **정수 몫** (가운데 슬래시 / 가 있으면 몫!)

번호	출제 주제	정답	노베이스 1초 컷 핵심 해설 & 시험장 암기 공식
43번 오답	R rep() 반복 함수	③ (1 1 2 2)	**rep(c(1, 2), each = 2)**는 각 원소를 2번씩 먼저 반복하므로 **1 1 2 2**가 출력됩니다 **암기공식** • **each = 2** → 원소별 각각 반복(1 1 2 2) / • **times = 2** → 벡터 통째로 반복(1 2 1 2)
44번 오답	R matrix & apply	① (3 7 11)	**matrix(1:6, nrow=2)**는 열 우선 채움([1,3,5 / 2,4,6]) → **apply(m, 2, sum)**은 열(2) 합계이므로 **3, 7, 11** **암기공식** • apply 두 번째 인자: **1 = 행(Row) 단위** 합계(9, 12) / **2 = 열(Column) 단위** 합계(3, 7, 11)
45번 오답	R 자료 구조 특징	④	**행렬(matrix)**은 벡터·배열과 마찬가지로 **오직 한 가지(단일) 자료형**만 가질 수 있습니다! **암기공식** • **단일 자료형:** 벡터(1차원), 행렬(2차원), 배열(다차원) / • **다중 자료형 허용:** 데이터프레임(열별 다른 형), 리스트(길이도 자유)
48번 오답	R 데이터 핸들링 패키지	③	**reshape**는 melt/cast 구조 변환 패키지입니다. 결측값 **다중 대치(Multiple Imputation)**는 **Amelia, mice** 패키지! **암기공식** • **sqldf** = SQL 문장 조회 / • **plyr** = split-apply-combine (ddply는 df→df) / • **data.table** = 키 기반 초고속 처리
51번 오답	표본추출 4대 방법	②	**집락(군집)추출**은 **집락 내부는 이질적, 집락 간은 동질적**이 되도록 묶은 뒤 일부 집락을 뽑아 전수조사합니다! **암기공식** • **층화추출** = 층 내 **동질**, 층 간 **이질** (각 층에서 모두 조금씩 추출) — 집락추출과 정반대!
52번 오답	측정 척도 4분류	①	**섭씨온도(℃)**의 0℃는 '열이 전혀 없음(절대 0)'이 아니므로 비율척도가 아니라 **구간(등간)척도**입니다! **암기공식** • **명목**(성별·혈액형) → **순서/서열**(만족도·직급) → **구간/등간**(온도℃·지수, 절대0 없음) → **비율**(키·무게·소득, 절대0 있음)
53번 오답	베이즈 정리(조건부확률)	④ 0.375	전체 불량 확률 = A불량(0.6×0.02=**0.012**) + B불량(0.4×0.05=**0.020**) = **0.032** ⇒ P(A|불량) = 0.012 / 0.032 = **0.375** **암기공식** • 베이즈 공식: **내가 원하는 경로(A불량 0.012) ÷ 전체 불량 경로 합(0.012 + 0.020 = 0.032) = 3/8 = 0.375**
54번 오답	확률변수의 분산 성질	③ 36	**V(aX + b) = a² · V(X)** 공식에 따라 V(3X + 2) = **3² × 4 = 9 × 4 = 36**입니다! **암기공식** • 평균 E(aX+b) = aE(X)+b 이지만, **분산 V(aX+b)에서 더해진 상수(+2)는 퍼짐 정도에 영향을 주지 않아 사라지고 앞의 3은 제곱(9)**이 됨!
55번 오답	중심극한정리 & 표준오차	②	표본 크기 n=36이 충분히 크므로 표본평균은 근사적으로 **평균 50, 표준오차(SE) = σ/√n = 12/√36 = 2인 정규분포**를 따릅니다 **암기공식** • **표준오차(SE) 공식 = σ / √n** (표준편차 12를 그대로 쓰거나 n=36으로 그냥 나누면 오답! 반드시 **루트 n(√36=6)**으로 나눌 것)
56번 오답	모평균 95% 신뢰구간	④ 100 ± 3.92	95% 신뢰구간 = **$\bar{x}$ ± 1.96 × (σ / √n)** = 100 ± 1.96 × (20 / √100) = 100 ± 1.96 × 2 = **100 ± 3.92** **암기공식** • n=100이므로 √n = 10 → 표준오차(SE) = 20/10 = 2 → 오차한계 = 1.96 × 2 = **3.92**
57번 오답	유의확률 (p-value)	①	**p-값(p-value)** = **귀무가설(H_0)이 참이라는 가정 하에서** 관측된 통계량만큼 극단적인 값이 나올 확률 **암기공식** • '귀무가설이 참일 확률'이나 '대립가설이 참일 확률'이 아님! / • **p-value < 유의수준(α, 보통 0.05)이면 귀무가설 기각!**
58번 오답	가설검정 제1·2종 오류	③	표본 크기가 고정된 상태에서 **제1종 오류(α)를 줄이면 제2종 오류(β)는 반대로 커집니다!** (상충 관계) **암기공식** • **1종 오류(α):** H_0가 참인데 기각 / • **2종 오류(β):** H_0가 거짓인데 채택 / • **검정력(Power) = 1 − β**
60번 오답	카이제곱 검정 3종류	②	**카이제곱(χ^2) 검정**은 **범주형 변수(빈도·교차표)**에 쓰며, 두 연속형 변수의 선형 상관은 **상관분석(cor.test)**을 씁니다! **암기공식** • 카이제곱 검정 3종: **적합도 검정**(주사위 확률), **독립성 검정**(성별과 브랜드 연관성), **동질성 검정**(지역별 응답 분포 동일 여부)

번호	출제 주제	정답	노베이스 1초 컷 핵심 해설 & 시험장 암기 공식
63번 오답	선형 회귀분석 4대 가정	④	회귀분석의 정규성 가정은 설명변수(X)가 아니라 **'오차항(잔차, ε)'이 정규분포를 따라야 한다**는 것입니다! **암기공식** • 회귀 4대 가정: **선형성**(X·Y 선형), **등분산성**(잔차 분산 일정), **독립성**(자기상관 없음, 더빈-왓슨≈2), **정상성/정규성**(오차항 정규분포)
65번 오답	다중공선성 & 더미변수	③	범주가 **k개**인 범주형 변수는 회귀분석 투입 시 기준 범주 1개를 뺀 **(k − 1)개의 더미변수**로 변환합니다! **암기공식** • **VIF(분산팽창요인) ≥ 10**이면 다중공선성 의심 / • 변수 선택 시 **AIC, BIC는 작을수록** 우수한 모형
67번 오답	단순 선형회귀 계수 계산	③ (2, 2, 16)	기울기 $\beta_1 = Cov(X,Y)/V(X) = 8/4 = 2$ | 절편 $\beta_0 = \bar{y} - \beta_1\bar{x} = 12 - 2\times5 = 2$ | x=7일 때 $\hat{y} = 2 + 2\times7 = 16$ **암기공식** • 필수 공식 2개: ① **기울기 β_1 = 공분산 ÷ X분산**, ② 회귀선은 반드시 평균점 **$(\bar{x}, \bar{y})$를 지난다 ($\bar{y} = \beta_0 + \beta_1\bar{x}$)**
69번 오답	시계열 AR(p) vs MA(q)	④ MA(2)	**자기상관함수(ACF)가 시차 2 이후 절단(0으로 끊김)**되고 PACF가 지수적으로 감소하면 **MA(2) 모형**입니다! **암기공식** • **1초 암기법:** PACF가 시차 p 후 절단되면 **AR(p)** / ACF가 시차 q 후 절단되면 **MA(q)**
71번 오답	주성분분석(PCA) 표 해석	② 2개	표의 맨 아랫줄 **Cumulative Proportion(누적 기여율)**이 **PC2에서 0.850(85%)**에 도달하므로 **주성분 2개**를 선택합니다! **암기공식** • Proportion of Variance = 개별 설명력(60%, 25%) / • **Cumulative Proportion = 누적 설명력(60% → 85% → 95%)**
73번 오답	데이터 마이닝 6대 기능	①	"유사한 특성의 고객끼리 묶어 시장을 세분화"하는 기능은 기술(Description)이 아니라 **군집(Clustering)**입니다! **암기공식** • **분류**(승인/거절 등 범주 판별) / • **추정**(연소득 등 연속형 값 산출) / • **예측**(미래 시점 값) / • **연관**(장바구니 규칙)
76번 오답	데이터 분할과 과적합	③ (ㄱ,ㄴ,ㄷ,ㄹ)	**시험용(Test) 데이터**는 오직 **최종 성능 평가에만 1회 사용**해야 하며, 매개변수 조정에 쓰면 안 됩니다(ㅁ 오답)! **암기공식** • **훈련용(Train):** 모형 가중치 학습 / • **검증용(Validation):** 과적합 점검 및 **매개변수(하이퍼파라미터) 조정**
77번 오답	교차검증 & 부트스트랩	②	**부트스트랩(Bootstrap)**은 비복원추출이 아니라 **'복원추출'**로 원 데이터 크기만큼 반복 추출하는 기법입니다! **암기공식** • 부트스트랩에서 특정 관측치가 한 번도 뽑히지 않을 확률(OOB 비율) = $e^{-1} \approx 36.8\%$ (뽑힐 확률 63.2%)
78번 오답	로지스틱 회귀분석	①	로지스틱 회귀의 계수는 최소제곱법(OLS)이 아니라 **최대우도추정법(MLE, 최대가능도법)**으로 추정합니다! **암기공식** • 종속변수가 이진 범주형(0/1), 예측값은 0~1 확률, R에서는 **glm(..., family = binomial)** 사용
79번 오답	로지스틱 오즈비 (Odds Ratio)	④	회귀계수가 0.693(ln 2)이면 x가 1 증가할 때 **'오즈(승산, P/(1−P))'가 2배**가 되는 것이지 **'발생 확률'이 2배가 되는 것이 아닙니다!** **암기공식** • 오즈비(OR) = **exp(β) = e^0.693 ≈ 2** / • x가 2 증가하면 오즈는 exp(2×0.693) = **2^2 = 4배** 증가
80번 오답	의사결정나무 가지치기	③	**가지치기(Pruning)**는 나무를 더 깊게 키우는 것이 아니라, **과대적합을 막기 위해 불필요한 가지를 잘라내 단순화**하는 과정입니다! **암기공식** • 의사결정나무 4단계: 의사결정나무 형성(성장) → **가지치기** → 타당성 평가 → 해석 및 예측
82번 오답	지니 지수(Gini Index) 계산	④ 0.32	전체 10개 중 A가 8개(0.8), B가 2개(0.2)일 때 **지니 지수 = $1 - (0.8^2 + 0.2^2) = 1 - (0.64 + 0.04) = 0.32$** **암기공식** • **지니 지수 공식 = $1 - \Sigma$(각 범주 비율)²** (0.68은 제곱합 자체이므로 반드시 1에서 빼야 함!)
83번 오답	의사결정나무 알고리즘	①	분류 문제에서 **CART 알고리즘은 '지니 지수(Gini Index)'**를 분리 기준으로 사용합니다! **암기공식** • **CART:** 지니지수(분류) / 분산감소량(회귀) | • **C4.5/C5.0:** 엔트로피(정보이득비) | • **CHAID:** 카이제곱(분류) / F-통계량(회귀)

번호	출제 주제	정답	노베이스 1초 컷 핵심 해설 & 시험장 암기 공식
84번 오답	앙상블 (배깅 vs 부스팅)	③	독립적·병렬적으로 학습하는 것은 **배깅(Bagging)**입니다! **부스팅(Boosting)**은 오분류 가중치를 높이며 **순차적으로 학습**합니다 암기공식 • **배깅** = 부트스트랩 + 병렬 학습(분산 감소) / • **부스팅** = 오답 가중치 + 순차 학습(편향 감소, AdaBoost·GBM·XGBoost)
87번 오답	신경망 파라미터 개수 계산	② 21	입력(3)→은닉(4)→출력(1): **가중치 = (3×4) + (4×1) = 16개**, **편향(Bias) = 은닉 4 + 출력 1 = 5개** ⇒ 총 **21개** 암기공식 • **[공식]** 총 파라미터 = **(앞층×뒷층 가중치 합) + (은닉층·출력층 노드 수만큼 편향 추가)** (입력층에는 편향 없음!)
89번 오답	혼동행렬 민감도 (재현율)	③ 0.80	**민감도(Sensitivity = 재현율 Recall)** = 실제 양성(50명) 중 예측 양성(40명) 비율 = **TP / (TP + FN) = 40 / 50 = 0.80** 암기공식 • **정밀도(Precision)** = 예측 양성 중 실제 양성 = 40/(40+20) ≈ 0.67 / • **특이도** = 30/50 = 0.60 / • **정확도** = 70/100 = 0.70
92번 오답	군집 타당성 (실루엣·Dunn)	④	**실루엣(Silhouette) 계수**는 **−1 ~ +1 범위**를 가지며, **1에 가까울수록** 군집화가 잘 된 것입니다! 암기공식 • **Dunn 지수** = (군집 간 최소거리) ÷ (군집 내 최대거리) → 역시 **값이 클수록** 우수한 군집!
93번 오답	유클리드 vs 맨하탄 거리	① (10, 14)	A(0,0)와 B(6,8): **유클리드(직선) = √(6² + 8²) = √100 = 10** / **맨하탄(격자 합) = |6| + |8| = 14** 암기공식 • 피타고라스 3:4:5 삼각형의 2배인 **6:8:10 직각삼각형**! / • 크기 관계: 체비셰프(8) ≤ 유클리드(10) ≤ 맨하탄(14)
95번 오답	k-평균 보완 (k-medoids)	④ k-medoids(PAM)	k-평균(k-means)이 이상값에 민감한 단점을 보완하기 위해 중심점으로 평균 대신 **실제 관측치(Medoid)**를 쓰는 기법 = **k-medoids(PAM)** 암기공식 • DBSCAN = 밀도 기반 군집(군집 수 k 사전 지정 불필요, 기하학적 모양 군집 탐색 가능)
96번 오답	자기조직화지도 (SOM)	③	**SOM(코호넨 맵)**은 은닉층이 없는 2층(입력층·경쟁층) 구조의 비지도 신경망으로, **역전파가 아닌 경쟁학습을 써서 속도가 매우 빠릅니다!** 암기공식 • 고차원 데이터의 **위상(Topology)을 2차원 격자 지도에 그대로 보존**하여 시각화·군집화에 활용
97번 오답	연관분석 신뢰도 계산	④ 0.5	규칙 {빵} → {우유}의 **신뢰도(Confidence) = P(빵∩우유) / P(빵) = 빵·우유 동시 구매(20건) ÷ 빵 구매(40건) = 0.5** 암기공식 • 지지도 = 20/100 = 0.2 / • **신뢰도 = 동시구매 ÷ 조건부(화살표 앞 '빵') 구매건수 = 20/40 = 0.5**
98번 오답	연관분석 향상도 계산	① (2.0, 양의 관계)	신뢰도 = 40/50 = **0.8**, P(B) = 80/200 = **0.4** ⇒ **향상도(Lift) = 0.8 / 0.4 = 2.0 (>1 이므로 양의 상관관계!)** 암기공식 • **향상도 공식 = 신뢰도 ÷ P(B)** / • 판정 기준: **Lift > 1 (양의 관계)**, **Lift = 1 (서로 독립)**, **Lift < 1 (음의 관계)**
100번 오답	Apriori vs FP-Growth	③	**Apriori**는 후보 항목집합을 생성하며 **DB를 여러 번 반복 스캔**합니다! DB를 **단 2회만 스캔**하는 것은 **FP-Growth**입니다 암기공식 • **Apriori** = 빈발 항목집합(최소 지지도 이상)으로 후보 생성·반복 스캔 / • **FP-Growth** = FP-Tree 구조로 DB 2회 스캔(속도 빠름)

✅ PART 2. 전체 정답노트 (1~100번 전 문항 · 찍어서 맞힌 41문항 완벽 복습)

1과목 데이터 이해 (1번 ~ 20번 전체) (전체 20문항 — 맞힌 문항 10개 · 오답 10개 모두 수록)

번호	내 상태	출제 주제	정답	노베이스 전 문항 핵심 요약 & 찍어서 맞힌 문제 완벽 복습 포인트
1번	정답(점검)	데이터의 특성	①	**존재적 특성** = 있는 그대로의 **객관적 사실(Fact)** (예: 매장 온도 21℃) / **당위적 특성** = 추론·예측·전망·추정의 근거 **핵심요약** 데이터는 독자적으로 존재하기보다 다른 객체와의 **상호관계** 속에서 가치를 가짐
2번	정답(점검)	정형·반정형·비정형	④	**반정형 데이터** = 데이터 내부에 스키마(메타데이터)를 포함 (**웹 로그, 센서 데이터, XML, JSON, HTML**) **핵심요약** **정형** = RDB 테이블, 스프레드시트 / **비정형** = 소셜 자유 텍스트, 영상, 음성, 이미지
3번	정답(점검)	SECI 지식변환	② 표출화	개인 머릿속의 **암묵지**를 매뉴얼·문서 등 **형식지로 변환**하는 단계 = **표출화(Externalization)** **핵심요약** **공통화**(암→암) → **표출화**(암→형) → **연결화**(형→형) → **내면화**(형→암) 4단계 순환
4번	오답 복습	DIKW 피라미드	③ 지식	"A마트 연필이 더 싸므로 **A마트에서 사야겠다(의사결정·행동)**" = **지식(Knowledge)** 단계 **핵심요약** • 데이터(100원/200원) → 정보(A가 더 싸다) → **지식(A에서 사야겠다)** → 지혜(A의 다른 상품도 쌀 것이다)
5번	정답(점검)	DB 특징과 설계	①	**통합된 데이터(Integrated Data)**는 데이터 **중복을 최소화**한 상태입니다 ('여러 곳에 중복 저장'이 오답!) **핵심요약** DB 설계 순서: 요구사항 분석 → **개념적(ERD)** → **논리적(정규화)** → **물리적(인덱스·성능)** 설계
6번	오답 복습	SQL 명령어 분류	④	**TRUNCATE**는 테이블 구조는 남기고 데이터를 전부 비우는 **DDL(데이터 정의어)**입니다 (DML 아님!) **핵심요약** • **DDL(정의):** CREATE, ALTER, DROP, RENAME, **TRUNCATE** / • **DML(조작):** SELECT, INSERT, UPDATE, **DELETE** / • **DCL(제어):** GRANT, REVOKE
7번	오답 복습	NoSQL 저장 구조	①	**Redis** = 인메모리 **키-값(Key-Value)** 저장소 (정답 ①) **핵심요약** • **키-값:** Redis, DynamoDB / • **문서(Document):** MongoDB / • **컬럼(Column):** HBase, Cassandra / • **그래프:** Neo4j
8번	오답 복습	DW / DM / OLAP	④ (ㄱ,ㄷ,ㅁ)	**DW** 4대 특징 = 주제지향·통합·시계열·**비휘발성(조회 위주)** / **ETL** = 추출(Extract)→변환(Transform)→적재(Load) **핵심요약** • **DW**(전사 대규모) vs **DM**(부서 소규모) [ㄴ반대] / • **OLTP**(실시간 거래) vs **OLAP**(다차원 분석) [ㄹ반대]
9번	오답 복습	빅데이터의 정의	①	**맥킨지(McKinsey)**는 기존 DB 관리·분석 역량을 넘어서는 데이터 **'규모(Volume)'** 관점에서 정의했습니다 **핵심요약** • **IDC** = 차세대 기술·아키텍처 관점 / • 정의 범위는 **[규모 → 기술 → 인재·조직]** 순으로 점점 넓어짐
10번	정답(점검)	빅데이터 3V·가치	④ (ㄱ,ㄷ,ㅁ)	더그 래니의 기본 **3V = Volume(규모), Variety(다양성), Velocity(속도)** / 출현 배경 = 산업계·학계·기술 발전 **핵심요약** • Veracity(정확성)·Value(가치)는 4V·5V 확장 요소 / • 가치 산정 난해 이유 = 활용 방식 변화, 새로운 가치 창출, 분석 기술 발전
11번	정답(점검)	빅데이터 비유	②	**렌즈(Lens)** = 현미경이 생물학 발전에 기여했듯 산업 발전에 기여 (대표 예시: **구글 Ngram Viewer**) **핵심요약** • **플랫폼** = 공동 활용 구조물(카카오톡·페이스북) / • **21세기 원유** = 신산업 창출 / • **석탄·철** = 사회·경제 혁명적 변화

번호	내 상태	출제 주제	정답	노베이스 전 문항 핵심 요약 & 찍어서 맞힌 문제 완벽 복습 포인트
12번	오답 복습	빅데이터 4대 변화	①	빅데이터의 본질적 변화는 '양보다 질'이 아니라 **'질보다 양'**(데이터가 많으면 일부 오류는 상쇄됨)입니다! **핵심요약** **[4대 변화 암기]** ① 사전→**사후처리**, ② 표본→**전수조사**, ③ **질보다 양**, ④ 인과→**상관관계**
13번	오답 복습	빅데이터 활용 테크닉	④	"새로운 환불 정책에 대한 고객의 평가·반응은?" → 유형분석이 아니라 **감정분석(Sentiment Analysis)**입니다 **핵심요약** • **유형분석:** "이 고객은 어떤 특성 그룹에 속하는가?" / • **유전 알고리즘:** "최대 시청률 프로그램 시간대 편성(최적화)"
14번	오답 복습	위기 요인과 통제 방안	④	**데이터 오용**의 통제 방안 = **알고리즘 접근권 허용 및 알고리즈미스트(Algorithmist) 양성** **핵심요약** • **사생활 침해** → 동의제에서 **책임제**로 / • **책임 원칙 훼손** → 예측이 아닌 **결과 기반 책임 원칙** 고수
15번	오답 복습	마이데이터·개인정보	③	**마이데이터(MyData)**는 정보 주체(개인)의 **전송요구권(적극적 의사)**에 기반한 제도입니다 ('동의 없이 제공' X) **핵심요약** • **옵트인** = 사전 동의 후 수집 / • **옵트아웃** = 일단 수집 후 사후 거부 허용 / • **가명정보** = 통계·연구 목적 동의 없이 활용 가능
16번	정답(점검)	사이언티스트 역량	② (ㄴ,ㄷ,ㅁ)	**소프트 스킬 3가지** = **통찰력 있는 분석(창의적 사고), 설득력 있는 전달(스토리텔링), 다분야 간 협력(소통)** **핵심요약** • **하드 스킬** = 빅데이터 이론적 지식, 분석 기술에 대한 숙련
17번	정답(점검)	가치 패러다임 변화	①	가치 패러다임 순서 = **디지털화(Digitalization) → 연결(Connection) → 에이전시(Agency)** **핵심요약** • 디지털화(아날로그→디지털, OS) → 연결(인터넷·검색엔진) → 에이전시(IoT·복잡한 연결을 대신 관리)
18번	정답(점검)	개인정보 비식별화	④	식별 가능한 속성 자체를 지우는 것은 **'데이터 삭제'**입니다. **총계처리**는 합계·평균 등 통계값으로 대체하는 기법! **핵심요약** • **가명처리**(홍길동→임꺽정) / • **데이터 마스킹**(홍길동→홍○○) / • **데이터 범주화**(35세→30~40세)
19번	오답 복습	빅데이터 회의론 원인	② (ㄱ,ㄴ)	빅데이터 회의론 2대 원인 = ① 과거 **CRM 공포(투자 실패 부정적 학습효과)**, ② 성공 사례의 **과대 포장** **핵심요약** 알고리즘 부재나 저장 비용 상승 때문에 회의론이 생긴 것이 아님(저장 비용은 오히려 하락함)
20번	정답(점검)	하둡 · 스파크 · 클라우드	①	**HDFS**는 블록 분할·복제 저장, **맵리듀스(MapReduce)**는 Map(키-값 생성) → Reduce(집계) 병렬 처리 **핵심요약** • **스파크(Spark)** = 인메모리 방식(반복 분석 빠름) vs **맵리듀스** = 디스크 기반 / • **NoSQL** = 유연한 스키마·수평 확장

2과목 데이터 분석 기획 (21번 ~ 40번 전체) (전체 20문항 — 맞힌 문항 8개 · 오답 12개 모두 수록)

번호	내 상태	출제 주제	정답	노베이스 전 문항 핵심 요약 & 찍어서 맞힌 문제 완벽 복습 포인트
21번	오답 복습	분석 주제 4유형	③ 통찰	분석 대상(What)은 **모르지만(X)** 분석 방법(How)은 **알고 있는(O)** 경우 = **통찰(Insight)** **핵심요약** • 대상O·방법O = **최적화** / • 대상O·방법X = **솔루션** / • 대상X·방법O = **통찰** / • 대상X·방법X = **발견**
22번	정답(점검)	목표 시점별 기획	③	**과제 중심적 접근(단기)** = **Speed & Test, Quick-Win, Problem Solving** (당면 과제 빠르게 해결) **핵심요약** • **장기적 마스터플랜** = Accuracy & Deploy, Long Term View, Problem Definition (두 방식을 융합해 활용)
23번	오답 복습	분석 기획 고려사항	② (ㄱ,ㄴ,ㄷ,ㄹ)	분석 기획 3대 고려사항 = ① 가용 데이터 파악, ② 적절한 유스케이스 탐색, ③ **장애 요소 사전 계획(고정관념·편향·프레이밍 효과)** **핵심요약** • 텍스트·이미지·영상은 '정형'이 아니라 **'비정형 데이터'**이므로 RDB에 그대로 적재 불가 (ㅁ 오답)

번호	내 상태	출제 주제	정답	노베이스 전 문항 핵심 요약 & 찍어서 맞힌 문제 완벽 복습 포인트
24번	미응답	개발 모델 (미응답)	①	**나선형(Spiral) 모델**은 반복 개발과 위험 분석을 수행하므로 관리가 복잡하며 **대규모·고위험 프로젝트**에 적합합니다 **핵심요약** • **폭포수 모델** = 순차 진행 / • **프로토타입 모델** = 요구사항이 불명확할 때 시제품으로 점진적 개선
25번	오답 복습	KDD 분석 방법론	③ 변환	변수 선택·생성, **차원 축소(PCA 등), 학습용/시험용 데이터 분리**를 수행하는 단계 = **데이터 변환(Transformation)** **핵심요약** • KDD 5단계: 데이터셋 선택 → **전처리(결측값·이상값·잡음 처리)** → **변환(변수생성·차원축소·분할)** → 마이닝 → 해석/평가
26번	정답(점검)	CRISP-DM 방법론	④	모델 자체의 기술적 평가는 **[모델링]** 단계에서도 수행하며, **[평가]** 단계에서는 비즈니스 목적 부합성을 평가합니다 **핵심요약** • CRISP-DM 6단계: 업무 이해 → 데이터 이해 → 데이터 준비 → 모델링 → 평가 → 전개
27번	정답(점검)	방법론 계층 구조	③	**빅데이터 분석 방법론**은 **3계층(단계→태스크→스텝)**이지만, **CRISP-DM**은 **4레벨(단계→일반화→세분화→실행)**입니다 **핵심요약** • 스텝(Step)은 WBS의 워크패키지 단위이며 입력(Input)-처리 및 도구-출력(Output)으로 구성됨
28번	오답 복습	빅데이터 분석 방법론	③	**모델 발전 계획 수립**은 시스템 구현 단계가 아니라 마지막 5단계인 **[평가 및 전개]** 단계의 태스크입니다 **핵심요약** • 빅데이터 방법론 5단계: 분석 기획 → 데이터 준비 → 데이터 분석 → 시스템 구현 → **평가 및 전개(모델 발전 계획)**
29번	오답 복습	하향식 vs 상향식	④	**상향식(Bottom-Up)** 접근법에서는 군집분석·연관분석 등 **비지도학습 기법**이 주로 활용됩니다 **핵심요약** • **하향식** = 수렴(Converge)·Why 관점·체계적 / • **상향식** = 발산(Diverge)·What 관점·프로토타이핑(시행착오)·비지도학습
30번	정답(점검)	분석 기회 발굴 확장	③	하향식 문제 탐색의 4대 확장 관점 중 **"고객, 채널, 영향자"**를 탐색하는 것 = **시장의 니즈 탐색 관점** **핵심요약** • **거시적 관점** = STEEP(사회·기술·경제·환경·정치) / • **경쟁자 확대** = 대체재·경쟁자·신규진입자 / • **역량 재해석** = 내부역량·파트너
31번	오답 복습	하향식 문제 탐색	①	비즈니스 모델 캔버스 9개 블록을 그대로 쓰지 않고 **5개 영역(업무·제품·고객 + 규제와 감사·지원 인프라)으로 단순화**합니다 **핵심요약** • 하향식 4단계: **문제 탐색**(5영역 캔버스) → **문제 정의**(분석 문제로 변환) → **해결방안 탐색** → **타당성 검토**(경제·기술)
32번	정답(점검)	5대 프로젝트 관리 속성	②	**정확도(Accuracy)**는 모델과 실제 값의 차이(**활용 측면**), **정밀도(Precision)**는 반복 시 일관성(**안정성 측면**)으로 상충 가능 **핵심요약** • 5대 관리 속성: Data Size(양), Data Complexity(복잡도), Speed(속도), Analytic Complexity(분석 복잡도), Accuracy & Precision
33번	오답 복습	마스터플랜 고려요소	③	**전략적 중요도**는 '우선순위' 고려 요소입니다! **적용 범위·방식** 고려 요소는 **'~적용 수준' 3가지**입니다 **핵심요약** • **우선순위 3요소:** 전략적 중요도, 비즈니스 성과(ROI), 실행 용이성 / • **적용 범위·방식 3요소:** 업무 내재화·분석 데이터·기술 적용 **수준**
34번	오답 복습	ROI 관점 평가 기준	②	투자 비용 요소인 **3V(Volume·Variety·Velocity)는 '난이도'**를, 비즈니스 효과인 **Value(가치)는 '시급성'**을 판단합니다 **핵심요약** • **투자 비용(난이도)** = 3V(데이터 획득·저장·가공 비용) / • **비즈니스 효과(시급성)** = Value(전략적 중요도·성과)
35번	오답 복습	우선순위 사분면 순서	④	**시급성 기준**(현재 과제 우선) 추진 순서 = **현재·쉬움(1순위) → 현재·어려움(2순위) → 미래·어려움** **핵심요약** • **난이도 기준**(쉬운 과제 우선)일 때가 [현재·쉬움 → **미래·쉬움** → 미래·어려움](②번 보기)입니다. 시험 빈출 함정!
36번	오답 복습	분석 거버넌스 5요소	① (ㄱ~ㅁ)	분석 거버넌스 체계 5대 구성요소 = **조직(O), 프로세스(P), 시스템(S), 데이터(D), 인력·교육(H)** (**'예산'은 제외!**) **핵심요약** • 암기팁: **조·프·시·데·인** (연간 분석 예산(ㅂ)은 거버넌스 체계 5대 구성요소에 포함되지 않음)

번호	내 상태	출제 주제	정답	노베이스 전 문항 핵심 요약 & 찍어서 맞힌 문제 완벽 복습 포인트
37번	정답(점검)	분석 성숙도 4단계	②	**활용 단계** = 분석 결과를 실제 업무에 적용하며 **미래 결과를 예측·시뮬레이션**하는 단계 **핵심요약** • 성숙도 4단계: **도입**(실적분석·OLAP·일부부서) → **활용**(예측·전문담당) → **확산**(전사 표준·CoE) → **최적화**(혁신·사이언스그룹)
38번	정답(점검)	분석 수준 진단 4유형	② 정착형	준비도는 낮지만(↓) 내부에서 제한적으로 사용해 **성숙도가 높은(↑)** 기업 유형 = **정착형** (1차 정착 필요) **핵심요약** • 준비도↓·성숙도↓ = **준비형** / • 준비도↓·성숙도↑ = **정착형** / • 준비도↑·성숙도↓ = **도입형** / • 준비도↑·성숙도↑ = **확산형**
39번	오답 복습	분석 조직 구조 3유형	② 기능형	별도 분석 조직 없이 **각 현업 부서에서 직접 분석**하여 과거 실적 분석에 국한되기 쉬운 구조 = **기능형 구조** **핵심요약** • **집중형** = 전사 전담 분석조직 별도 설치(현업과 이원화 가능성) / • **분산형** = 분석 전문인력을 현업 부서로 파견 배치
40번	정답(점검)	SAS SEMMA 방법론	③	SEMMA 5단계 순서 = **Sample(샘플링) → Explore(탐색) → Modify(수정/변환) → Model(모델링) → Assess(평가)** **핵심요약** • 영문 철자 **S-E-M-M-A**에서 첫 M이 **Modify(수정)**이고 두 번째 M이 **Model(모델링)**임을 주의!

3과목 데이터 분석 (41번 ~ 100번 전체) (전체 60문항 — 맞힌 문항 23개 · 오답 37개 모두 수록)

번호	내 상태	출제 주제	정답	노베이스 전 문항 핵심 요약 & 찍어서 맞힌 문제 완벽 복습 포인트
41번	정답(점검)	R 특수값 (Inf/NaN/NA)	①	R에서 **1/0의 결과는 Inf(무한대)**입니다! (NA가 아님) **핵심요약** • **0/0 = NaN**(숫자 아님) / • **NA** = 결측값(벡터 자리 차지함) / • **NULL** = 정의되지 않음(자리 차지 안 함)
42번	오답 복습	R 산술 연산자	④ (1, 2)	**7 %% 3 = 1** (나머지 연산) / **7 %/% 3 = 2** (정수 몫 연산) **핵심요약** • **%%** = 나눗셈의 **나머지** / • **%/%** = 나눗셈의 **정수 몫** (가운데 슬래시 / 가 있으면 몫!)
43번	오답 복습	R rep() 반복 함수	③ (1 1 2 2)	**rep(c(1, 2), each = 2)**는 각 원소를 2번씩 먼저 반복하므로 **1 1 2 2**가 출력됩니다 **핵심요약** • **each = 2** → 원소별 각각 반복(1 1 2 2) / • **times = 2** → 벡터 통째로 반복(1 2 1 2)
44번	오답 복습	R matrix & apply	① (3 7 11)	**matrix(1:6, nrow=2)**는 열 우선 채움([1,3,5 / 2,4,6]) → **apply(m, 2, sum)**은 열(2) 합계이므로 **3, 7, 11** **핵심요약** • apply 두 번째 인자: **1 = 행(Row) 단위** 합계(9, 12) / **2 = 열(Column) 단위** 합계(3, 7, 11)
45번	오답 복습	R 자료 구조 특징	④	**행렬(matrix)**은 벡터·배열과 마찬가지로 **오직 한 가지(단일) 자료형**만 가질 수 있습니다! **핵심요약** • **단일 자료형:** 벡터(1차원), 행렬(2차원), 배열(다차원) / • **다중 자료형 허용:** 데이터프레임(열별 다른 형), 리스트(길이도 자유)
46번	정답(점검)	요약변수 vs 파생변수	②	"고객별 총 구매금액"처럼 단순 집계는 **요약변수**, "100만 원 이상 VIP 분류"처럼 조건·의미를 부여한 것은 **파생변수**! **핵심요약** • **요약변수** = 기간별 합계·평균 등 종합(재활용성 높음) / • **파생변수** = 주관적 조건 부여(논리적 타당성 필수)
47번	정답(점검)	reshape melt / cast	④	**melt()** = 여러 열에 흩어진 넓은(Wide) 데이터를 **id-variable-value 형태의 긴(Long) 형식**으로 녹이는 함수 **핵심요약** • **melt()** = Wide → Long (녹이기) / • **cast()** = Long → Wide (주조·재구성) / • **merge()** = 공통 키 병합
48번	오답 복습	R 데이터 핸들링 패키지	③	**reshape**는 melt/cast 구조 변환 패키지입니다. 결측값 **다중 대치(Multiple Imputation)**는 **Amelia, mice** 패키지! **핵심요약** • **sqldf** = SQL 문장 조회 / • **plyr** = split-apply-combine (ddply는 df→df) / • **data.table** = 키 기반 초고속 처리

번호	내 상태	출제 주제	정답	노베이스 전 문항 핵심 요약 & 찍어서 맞힌 문제 완벽 복습 포인트
49번	정답(점검)	결측값 대치 방법	①	**다중대치법(Multiple Imputation)**의 올바른 3단계 순서는 **[대치(Imputation) → 분석(Analysis) → 결합(Combination)]**입니다 **핵심요약** • 단순확률대치법(Hot-deck 등)은 단순평균대치법의 '표준오차 과소추정' 문제를 보완함
50번	정답(점검)	상자그림(IQR) 이상값	② 85	Q1=30, Q3=50이면 **IQR = 50 − 30 = 20**. 정상 상한은 Q3 + 1.5×IQR = 50 + 30 = **80**이므로 **85는 이상값!** **핵심요약** • 정상 범위 공식: **[Q1 − 1.5×IQR , Q3 + 1.5×IQR]** = [30 − 30, 50 + 30] = **[0, 80]**
51번	오답 복습	표본추출 4대 방법	②	**집락(군집)추출**은 **집락 내부는 이질적, 집락 간은 동질적**이 되도록 묶은 뒤 일부 집락을 뽑아 전수조사합니다! **핵심요약** • **층화추출** = 층 내 **동질**, 층 간 **이질** (각 층에서 모두 조금씩 추출) — 집락추출과 정반대!
52번	오답 복습	측정 척도 4분류	①	**섭씨온도(℃)**의 0℃는 '열이 전혀 없음(절대 0)'이 아니므로 비율척도가 아니라 **구간(등간)척도**입니다! **핵심요약** • **명목**(성별·혈액형) → **순서/서열**(만족도·직급) → **구간/등간**(온도℃·지수, 절대0 없음) → **비율**(키·무게·소득, 절대0 있음)
53번	오답 복습	베이즈 정리(조건부확률)	④ 0.375	전체 불량 확률 = A불량(0.6×0.02=**0.012**) + B불량(0.4×0.05=**0.020**) = **0.032** ⇒ P(A|불량) = 0.012 / 0.032 = **0.375** **핵심요약** • 베이즈 공식: **내가 원하는 경로(A불량 0.012) ÷ 전체 불량 경로 합(0.012 + 0.020 = 0.032) = 3/8 = 0.375**
54번	오답 복습	확률변수의 분산 성질	③ 36	**V(aX + b) = a² · V(X)** 공식에 따라 V(3X + 2) = **3² × 4 = 9 × 4 = 36**입니다! **핵심요약** • 평균 E(aX+b) = aE(X)+b 이지만, **분산 V(aX+b)에서 더해진 상수(+2)는 퍼짐 정도에 영향을 주지 않아 사라지고 앞의 3은 제곱(9)**이 됨!
55번	오답 복습	중심극한정리 & 표준오차	②	표본 크기 n=36이 충분히 크므로 표본평균은 근사적으로 **평균 50, 표준오차(SE) = σ/√n = 12/√36 = 2인 정규분포**를 따릅니다 **핵심요약** • **표준오차(SE) 공식 = σ / √n** (표준편차 12를 그대로 쓰거나 n=36으로 그냥 나누면 오답! 반드시 **루트 n(√36=6)**으로 나눌 것)
56번	오답 복습	모평균 95% 신뢰구간	④ 100 ± 3.92	95% 신뢰구간 = **$\bar{x}$ ± 1.96 × (σ / √n)** = 100 ± 1.96 × (20 / √100) = 100 ± 1.96 × 2 = **100 ± 3.92** **핵심요약** • n=100이므로 √n = 10 → 표준오차(SE) = 20/10 = 2 → 오차한계 = 1.96 × 2 = **3.92**
57번	오답 복습	유의확률 (p-value)	①	**p-값(p-value)** = **귀무가설(H_0)이 참이라는 가정 하에서** 관측된 통계량만큼 극단적인 값이 나올 확률 **핵심요약** • '귀무가설이 참일 확률'이나 '대립가설이 참일 확률'이 아님! / • **p-value < 유의수준(α, 보통 0.05)이면 귀무가설 기각!**
58번	오답 복습	가설검정 제1·2종 오류	③	표본 크기가 고정된 상태에서 **제1종 오류(α)를 줄이면 제2종 오류(β)는 반대로 커집니다!** (상충 관계) **핵심요약** • **1종 오류(α):** H_0가 참인데 기각 / • **2종 오류(β):** H_0가 거짓인데 채택 / • **검정력(Power) = 1 − β**
59번	정답(점검)	독립 이표본 t-검정 절차	③	서로 다른 두 집단(A반·B반) 평균 비교는 먼저 **var.test()로 등분산 검정** 후 **독립 이표본 t-검정(t.test)**을 수행합니다 **핵심요약** • 같은 사람의 전·후 비교는 **대응표본 t-검정(paired=TRUE)** / • 3개 이상 집단 평균 비교는 **분산분석(ANOVA)**
60번	오답 복습	카이제곱 검정 3종류	②	**카이제곱(χ^2) 검정**은 **범주형 변수(빈도·교차표)**에 쓰며, 두 연속형 변수의 선형 상관은 **상관분석(cor.test)**을 씁니다! **핵심요약** • 카이제곱 검정 3종: **적합도 검정**(주사위 확률), **독립성 검정**(성별과 브랜드 연관성), **동질성 검정**(지역별 응답 분포 동일 여부)

번호	내 상태	출제 주제	정답	노베이스 전 문항 핵심 요약 & 찍어서 맞힌 문제 완벽 복습 포인트
61번	정답(점검)	분산분석(ANOVA) 대립가설	④	ANOVA의 대립가설(H_1)은 '모든 평균이 다르다'가 아니라 **"적어도 한 집단의 평균은 다른 집단과 다르다"**입니다! **핵심요약** • 귀무가설(H_0): $\mu_1 = \mu_2 = \dots = \mu_k$ (모든 집단 평균이 같다) / • F-통계량 = 집단 간 분산 ÷ 집단 내 분산
62번	정답(점검)	피어슨·스피어만 상관분석	①	**상관계수가 0**이라는 것은 **'선형(직선) 관계'가 없다**는 뜻이지, 2차곡선 같은 비선형 관계가 있을 수 있어 **독립이라고 단정할 수 없습니다!** **핵심요약** • 두 변수가 독립이면 상관계수는 0이지만, **상관계수가 0이라고 반드시 독립인 것은 아님(역은 불성립!)**
63번	오답 복습	선형 회귀분석 4대 가정	④	회귀분석의 정규성 가정은 설명변수(X)가 아니라 **'오차항(잔차, ε)'이 정규분포를 따라야 한다**는 것입니다! **핵심요약** • 회귀 4대 가정: **선형성**(X·Y 선형), **등분산성**(잔차 분산 일정), **독립성**(자기상관 없음, 더빈-왓슨≈2), **정상성/정규성**(오차항 정규분포)
64번	정답(점검)	R 회귀분석(lm) 결과 해석	①	x의 p-값(`Pr(>|t|)`)이 **0.00033**으로 유의수준 0.05보다 훨씬 작으므로 **x는 매우 유의한 변수**입니다! **핵심요약** • 추정 회귀식: $\hat{y} = 3.2 + 1.5x$ / • 결정계수(R^2) = 0.82 (총 변동의 82% 설명) / • 모형 전체 유의성 = F-통계량 p-값 (0.00033)
65번	오답 복습	다중공선성 & 더미변수	③	범주가 **k개**인 범주형 변수는 회귀분석 투입 시 기준 범주 1개를 뺀 **(k − 1)개의 더미변수**로 변환합니다! **핵심요약** • **VIF(분산팽창요인) ≥ 10**이면 다중공선성 의심 / • 변수 선택 시 **AIC, BIC는 작을수록** 우수한 모형
66번	정답(점검)	릿지(L2) vs 라쏘(L1) 회귀	②	**라쏘(Lasso) 회귀**는 **L1 규제(절댓값 합)**를 사용하여 중요하지 않은 **회귀계수를 정확히 0으로 만들어 변수 선택 효과**가 있습니다 **핵심요약** • **릿지(Ridge) = L2 규제(제곱합)** → 계수를 0에 가깝게 줄이지만 0으로 만들지는 않음(변수 선택 X)
67번	오답 복습	단순 선형회귀 계수 계산	③ (2, 2, 16)	기울기 $\beta_1 = Cov(X,Y)/V(X) = 8/4 = 2$ | 절편 $\beta_0 = \bar{y} - \beta_1\bar{x} = 12 - 2\times5 = 2$ | x=7일 때 $\hat{y} = 2 + 2\times7 = 16$ **핵심요약** • 필수 공식 2개: ① **기울기 β_1 = 공분산 ÷ X분산**, ② 회귀선은 반드시 평균점 **$(\bar{x}, \bar{y})$를 지난다 ($\bar{y} = \beta_0 + \beta_1\bar{x}$)**
68번	정답(점검)	시계열 정상성 변환	①	**분산이 일정하지 않은 경우**에는 **로그 변환(Log)이나 지수 변환**을 쓰며, **차분(Differencing)은 평균(추세)이 일정하지 않을 때** 씁니다! **핵심요약** • 정상 시계열 3조건: ① 평균 일정, ② 분산 일정, ③ 공분산은 시점(t)이 아닌 시차(lag)에만 의존
69번	오답 복습	시계열 AR(p) vs MA(q)	④ MA(2)	**자기상관함수(ACF)가 시차 2 이후 절단(0으로 끊김)**되고 PACF가 지수적으로 감소하면 **MA(2) 모형**입니다! **핵심요약** • **1초 암기법:** PACF가 시차 p 후 절단되면 **AR(p)** / ACF가 시차 q 후 절단되면 **MA(q)**
70번	정답(점검)	분해 시계열 & 지수평활법	②	**지수평활법**은 **최근 자료일수록 더 큰 가중치**를 부여하고, 과거 자료일수록 가중치를 지수적으로 줄입니다! **핵심요약** • 분해 시계열 4요인: **추세**(장기 경향), **계절**(고정 주기 반복), **순환**(주기 미상 경기 변동), **불규칙**(우연 변동)
71번	오답 복습	주성분분석(PCA) 표 해석	② 2개	표의 맨 아랫줄 **Cumulative Proportion(누적 기여율)**이 **PC2에서 0.850(85%)**에 도달하므로 **주성분 2개**를 선택합니다! **핵심요약** • Proportion of Variance = 개별 설명력(60%, 25%) / • **Cumulative Proportion = 누적 설명력(60% → 85% → 95%)**
72번	정답(점검)	왜도(Skewness)와 대푯값	②	오른쪽으로 꼬리가 긴 분포(**왜도 > 0, 양의 왜도**)에서는 큰 이상값에 평균이 끌려가므로 **평균 > 중앙값 > 최빈값** 순입니다 **핵심요약** • 대칭 분포(왜도=0): 평균=중앙값=최빈값 / • 왼쪽 꼬리 분포(왜도<0): **평균 < 중앙값 < 최빈값**

번호	내 상태	출제 주제	정답	노베이스 전 문항 핵심 요약 & 찍어서 맞힌 문제 완벽 복습 포인트
73번	오답 복습	데이터 마이닝 6대 기능	①	"유사한 특성의 고객끼리 묶어 시장을 세분화"하는 기능은 기술(Description)이 아니라 **군집(Clustering)**입니다! **핵심요약** • **분류**(승인/거절 등 범주 판별) / • **추정**(연소득 등 연속형 값 산출) / • **예측**(미래 시점 값) / • **연관**(장바구니 규칙)
74번	정답(점검)	데이터 마이닝 추진 5단계	④	추진 5단계 = **목적 설정 → 데이터 준비 → 데이터 가공 → 기법 적용 → 검증** (앞글자: **목·준·가·기·검**) **핵심요약** • 3단계 **[데이터 가공]**에서 목적변수 정의 및 소프트웨어 적용 가능한 형태로 가공 수행
75번	정답(점검)	지도학습 vs 비지도학습	③ (ㄴ,ㄷ,ㅁ)	목적변수(정답 Y)가 없는 **비지도학습** = **k-평균 군집(ㄴ), 자기조직화 지도 SOM(ㄷ), 연관분석(ㅁ)** **핵심요약** • **지도학습(정답 Y 있음):** 의사결정나무(ㄱ), 로지스틱 회귀(ㄹ), 인공신경망, SVM, k-NN, 선형회귀
76번	오답 복습	데이터 분할과 과적합	③ (ㄱ,ㄴ,ㄷ,ㄹ)	**시험용(Test) 데이터**는 오직 **최종 성능 평가에만 1회 사용**해야 하며, 매개변수 조정에 쓰면 안 됩니다(ㅁ 오답)! **핵심요약** • **훈련용(Train):** 모형 가중치 학습 / • **검증용(Validation):** 과적합 점검 및 **매개변수(하이퍼파라미터) 조정**
77번	오답 복습	교차검증 & 부트스트랩	②	**부트스트랩(Bootstrap)**은 비복원추출이 아니라 **'복원추출'**로 원 데이터 크기만큼 반복 추출하는 기법입니다! **핵심요약** • 부트스트랩에서 특정 관측치가 한 번도 뽑히지 않을 확률(OOB 비율) = $e^{-1} \approx 36.8\%$ (뽑힐 확률 63.2%)
78번	오답 복습	로지스틱 회귀분석	①	로지스틱 회귀의 계수는 최소제곱법(OLS)이 아니라 **최대우도추정법(MLE, 최대가능도법)**으로 추정합니다! **핵심요약** • 종속변수가 이진 범주형(0/1), 예측값은 0~1 확률, R에서는 **glm(..., family = binomial)** 사용
79번	오답 복습	로지스틱 오즈비(Odds Ratio)	④	회귀계수가 0.693(ln 2)이면 x가 1 증가할 때 **'오즈(승산, P/(1−P))'가 2배**가 되는 것이지 **'발생 확률'이 2배가 되는 것이 아닙니다!** **핵심요약** • 오즈비(OR) = **exp(β) = e^0.693 ≈ 2** / • x가 2 증가하면 오즈는 exp(2×0.693) = **2^2 = 4배** 증가
80번	오답 복습	의사결정나무 가지치기	③	**가지치기(Pruning)**는 나무를 더 깊게 키우는 것이 아니라, **과대적합을 막기 위해 불필요한 가지를 잘라내 단순화**하는 과정입니다! **핵심요약** • 의사결정나무 4단계: 의사결정나무 형성(성장) → **가지치기** → 타당성 평가 → 해석 및 예측
81번	정답(점검)	의사결정나무 장단점	②	의사결정나무는 구획 기준으로 나누므로 **이상값(Outlier)에 민감하지 않은 것이 장점**입니다 ('반드시 제거' 오답!) **핵심요약** • 장점: 해석 용이(화이트박스), 비모수적(정규성 가정 불필요), 이상값에 강함 / • 단점: 경계 부근 오류, 자료 변화에 불안정
82번	오답 복습	지니 지수(Gini Index) 계산	④ 0.32	전체 10개 중 A가 8개(0.8), B가 2개(0.2)일 때 **지니 지수 = 1 − (0.8^2 + 0.2^2) = 1 − (0.64 + 0.04) = 0.32** **핵심요약** • **지니 지수 공식 = 1 − Σ(각 범주 비율)²** (0.68은 제곱합 자체이므로 반드시 1에서 빼야 함!)
83번	오답 복습	의사결정나무 알고리즘	①	분류 문제에서 **CART 알고리즘은 '지니 지수(Gini Index)'**를 분리 기준으로 사용합니다! **핵심요약** • **CART:** 지니지수(분류) / 분산감소량(회귀) | • **C4.5/C5.0:** 엔트로피(정보이득비) | • **CHAID:** 카이제곱(분류) / F-통계량(회귀)
84번	오답 복습	앙상블 (배깅 vs 부스팅)	③	독립적·병렬적으로 학습하는 것은 **배깅(Bagging)**입니다! **부스팅(Boosting)**은 오분류 가중치를 높이며 **순차적으로 학습**합니다 **핵심요약** • **배깅** = 부트스트랩 + 병렬 학습(분산 감소) / • **부스팅** = 오답 가중치 + 순차 학습(편향 감소, AdaBoost·GBM·XGBoost)

번호	내 상태	출제 주제	정답	노베이스 전 문항 핵심 요약 & 찍어서 맞힌 문제 완벽 복습 포인트
85번	정답(점검)	단층 vs 다층 퍼셉트론	③ XOR 문제	단층 퍼셉트론(직선 1개)으로는 비선형 문제인 **XOR(배타적 논리합) 문제**를 풀 수 없어 은닉층을 둔 **다층 퍼셉트론(MLP)**이 필요합니다 **핵심요약** • AND, OR, NOT 문제는 직선 하나로 선형 분리가 가능하여 단층 퍼셉트론으로 해결 가능
86번	정답(점검)	인공신경망 활성화·은닉층	①	은닉 노드 수가 너무 적으면 **과소적합**, 너무 많으면 **과대적합**이 발생하므로 **적절한 수**를 설정해야 합니다 **핵심요약** • 출력층 활성화 함수: **이진 분류 = 시그모이드(0~1)**, **다중 분류 = 소프트맥스(합이 1인 확률)**, 회귀 = 항등함수
87번	오답 복습	신경망 파라미터 개수 계산	② 21	입력(3)→은닉(4)→출력(1): **가중치 = (3×4) + (4×1) = 16개**, **편향(Bias) = 은닉 4 + 출력 1 = 5개** ⇒ 총 **21개** **핵심요약** • **[공식]** 총 파라미터 = **(앞층×뒷층 가중치 합) + (은닉층·출력층 노드 수만큼 편향 추가)** (입력층에는 편향 없음!)
88번	정답(점검)	서포트 벡터 머신(SVM)	④ SVM	**마진(Margin) 최대화** 초평면, **서포트 벡터**, 고차원 비선형 분류를 위한 **커널 트릭(Kernel Trick)** = **SVM** **핵심요약** • k-NN = 별도 모형 학습 없이 예측 시점에 거리를 재는 게으른 학습(Lazy Learning)
89번	오답 복습	혼동행렬 민감도(재현율)	③ 0.80	**민감도(Sensitivity = 재현율 Recall)** = 실제 양성(50명) 중 예측 양성(40명) 비율 = **TP / (TP + FN) = 40 / 50 = 0.80** **핵심요약** • **정밀도(Precision)** = 예측 양성 중 실제 양성 = 40/(40+20) ≈ 0.67 / • **특이도** = 30/50 = 0.60 / • **정확도** = 70/100 = 0.70
90번	정답(점검)	F1-Score (조화평균)	②	**F1 점수(F1-Score)**는 정밀도와 재현율의 산술평균이 아니라 **'조화평균'**입니다! **핵심요약** • 공식: **F1 = 2 × (정밀도 × 재현율) / (정밀도 + 재현율)**
91번	정답(점검)	ROC 곡선과 AUC	①	ROC 곡선은 대각선(AUC=0.5, 무작위 찍기)에서 멀어져 **왼쪽 위 모서리(좌상단)에 가까울수록(AUC→1)** 좋은 모형입니다! **핵심요약** • **x축 = 1 − 특이도(FPR, 거짓양성률)** / • **y축 = 민감도(TPR, 참양성률)**
92번	오답 복습	군집 타당성 (실루엣·Dunn)	④	**실루엣(Silhouette) 계수**는 **−1 ~ +1 범위**를 가지며, **1에 가까울수록** 군집화가 잘 된 것입니다! **핵심요약** • **Dunn 지수** = (군집 간 최소거리) ÷ (군집 내 최대거리) → 역시 **값이 클수록** 우수한 군집!
93번	오답 복습	유클리드 vs 맨하탄 거리	① (10, 14)	A(0,0)와 B(6,8): **유클리드(직선) = √(6² + 8²) = √100 = 10** / **맨하탄(격자 합) = |6| + |8| = 14** **핵심요약** • 피타고라스 3:4:5 삼각형의 2배인 **6:8:10 직각삼각형**! / • 크기 관계: 체비셰프(8) ≤ 유클리드(10) ≤ 맨하탄(14)
94번	정답(점검)	계층적 군집분석	②	계층적 군집에서는 **한 번 병합(또는 분할)된 개체는 이후 단계에서 절대 다른 군집으로 재배치되지 않습니다!** **핵심요약** • **와드(Ward) 연결법** = 군집 내 오차제곱합(ESS) 증가분이 최소가 되도록 병합 (크기가 비슷한 구형 군집 생성)
95번	오답 복습	k-평균 보완 (k-medoids)	④ k-medoids(PAM)	k-평균(k-means)이 이상값에 민감한 단점을 보완하기 위해 중심점으로 평균 대신 **실제 관측치(Medoid)**를 쓰는 기법 = **k-medoids(PAM)** **핵심요약** • DBSCAN = 밀도 기반 군집(군집 수 k 사전 지정 불필요, 기하학적 모양 군집 탐색 가능)
96번	오답 복습	자기조직화지도(SOM)	③	**SOM(코호넨 맵)**은 은닉층이 없는 2층(입력층·경쟁층) 구조의 비지도 신경망으로, **역전파가 아닌 경쟁학습을 써서 속도가 매우 빠릅니다!** **핵심요약** • 고차원 데이터의 **위상(Topology)을 2차원 격자 지도에 그대로 보존**하여 시각화·군집화에 활용

번호	내 상태	출제 주제	정답	노베이스 전 문항 핵심 요약 & 찍어서 맞힌 문제 완벽 복습 포인트
97번	오답 복습	연관분석 신뢰도 계산	④ 0.5	규칙 {빵} → {우유}의 **신뢰도(Confidence) = P(빵∩우유) / P(빵) = 빵·우유 동시구매(20건) ÷ 빵 구매(40건) = 0.5** **핵심요약** • 지지도 = 20/100 = 0.2 / • **신뢰도 = 동시구매 ÷ 조건부(화살표 앞 '빵') 구매건수 = 20/40 = 0.5**
98번	오답 복습	연관분석 향상도 계산	① (2.0, 양의 관계)	신뢰도 = 40/50 = **0.8**, P(B) = 80/200 = **0.4** ⇒ **향상도(Lift) = 0.8 / 0.4 = 2.0 (>1 이므로 양의 상관관계!)** **핵심요약** • **향상도 공식 = 신뢰도 ÷ P(B)** / • 판정 기준: **Lift > 1 (양의 관계)**, **Lift = 1 (서로 독립)**, **Lift < 1 (음의 관계)**
99번	정답(점검)	연관분석 특징과 장단점	②	연관분석(장바구니 분석)은 **목적변수(종속변수)가 없는 대표적인 비지도 학습** 기법입니다! **핵심요약** • 단점: 품목 수가 늘면 계산량이 기하급수적 증가, 거래가 적은 희소 품목은 최소 지지도에 걸려 제외되기 쉬움
100번	오답 복습	Apriori vs FP-Growth	③	**Apriori**는 후보 항목집합을 생성하며 **DB를 여러 번 반복 스캔**합니다! DB를 **단 2회만 스캔**하는 것은 **FP-Growth**입니다 **핵심요약** • **Apriori** = 빈발 항목집합(최소 지지도 이상)으로 후보 생성·반복 스캔 / • **FP-Growth** = FP-Tree 구조로 DB 2회 스캔(속도 빠름)