

반도체장비AI비전실무

보충자료

인공지능이란?


인간의 학습/추론/문제해결 능력을 컴퓨터가 모방하는 기술

➡ 어떻게 '사람'처럼 행동하게 만들까?

학습시켜서!


➡ 기계를 어떻게 학습시킬까?

엄청나게 많은 데이터로!!!



**“데이터”와 “학습”만 알면
AI의 원리를 이해할 수 있다!**

형태에 따른 데이터 분류



형태에 따른 데이터 분류

- 정형 데이터

- 미리 정해진 구조에 따라 저장된 데이터로, 주로 테이블 형태로 표현됨
- 성적표, 매출표 등


제품별 매출내역 (상위10개 제품)

단위 : 천원, 개

항목	전분기	당해분기		
	매 출	매 출	판매량	매출비교
제품1	848,600	314,300	90,000	37.04%
제품2	616,900	536,400	190,000	86.95%
제품3	711,600	788,000	1,610,000	110.74%
제품4	409,400	424,700	930,000	103.74%
제품5	344,600	213,100	80,000	61.84%
제품6	514,500	984,400	170,000	191.33%
제품7	487,800	224,300	50,000	45.98%
제품8	836,100	696,100	180,000	83.26%
제품9	704,200	284,600	200,000	40.41%
제품10	779,100	893,400	830,000	114.67%

형태에 따른 데이터 분류

- 비정형 데이터
 - 정해진 구조가 없이 저장된 데이터
 - 영상, 이미지, 음원, 소셜 미디어의 게시물 등



정형 데이터일까, 비정형 데이터일까?

수험번호	성명		생년월일	성별	출신고교(반 또는 졸업연도)		
12345678	홍길동		99.09.05.	남	한국고등학교(9)		
구분	한국사 영역	국어 영역	수학영역	영어 영역	사회탐구영역		제2외국어/ 한문영역
			나형		생활과 윤리	사회·문화	일본어I
표준점수		131	137		53	64	69
백분위		93	96		75	93	95
등급	2	2	2	1	4	2	2

정형 데이터일까, 비정형 데이터일까?



정형 데이터일까, 비정형 데이터일까?

CASH RECEIPT

Shop Name: Lorem Ipsum
Manager: Ipsum Lorem

ITEM	QTY	DESCRIPTION	COST
3456	5	Duis aute irure	\$5.60
5678	7	Ut enim ad	\$2.95
6789	3	Nacididuntai	\$13.65
7890	1	Laboris nisi	\$7.80

Order Total : 29.70


How did we do?

Visit www.loremipsum.dol and
tell us about your shopping trip

CLUBCARD NUMBER 123456
POINTS THIS VISIT 45
TOTAL POINTS 167

Date DD/MM/YYYY Time 00:00

정형 데이터일까, 비정형 데이터일까?



넷플릭스vs왓챠vs유튜브, 이들의 추천 알고리즘은 어떻게 다를까? 쉽게 설명해드립니다 😊



서울경제 NOW
구독자 17.3만명

구독

👍 565



🔗 공유

⬇️ 오프라인 저장



컴퓨팅 파워의 발전 + 딥러닝 + 빅데이터

= 생성형 AI의 등장

생성형 AI란?


➡ 인간의 **창작활동을 모방**하여 새로운 **콘텐츠를 생성**하는 인공지능



인공지능의

생성형 AI 모델

콘텐츠나 데이터를 생성하는 데
특화된 인공지능




AI 모델

정해진 문제를 해결하는 데
특화된 인공지능

데이터와 학습

- 학습의 재료 → 데이터
- 학습의 방법 → 머신러닝 알고리즘
- 어떤 데이터에 어떤 학습 방법을 적용하느냐에 따라 인공지능이 할 수 있는 일이 달라진다.



데이터의 분류: 특성에 따라




그림 1-11 특성에 따른 데이터 분류

데이터의 분류: 특성에 따라

- 범주형 데이터

- 종류를 나타내는 값을 가진 데이터

- 명목형 데이터


- : 순서(서열)가 없는 값을 가지는 데이터

- : 성별, 혈액형, 학과명, 거주 지역, 음식 메뉴, MBTI 검사 결과

- 순서형 데이터 (ordinal data)

- : 순서(서열)가 있는 값을 가지는 데이터

- : 학년, 학점, 회원 등급



데이터의 분류: 특성에 따라

- 수치형 데이터
 - 숫자 값을 가진 데이터
 - 이산형 데이터
 - : 개수를 셀 수 있는 띄엄띄엄 단절된 숫자 값을 가지는 데이터
 - : 고객 수, 판매량, 합격자 수
 - 연속형 데이터
 - : 측정을 통해 얻어지는 연속적으로 이어진 숫자 값을 가지는 데이터
 - : 키, 몸무게, 온도, 점수



머신러닝 핵심 용어정리



1. 데이터 (Data)

머신러닝 학습의 재료가 되는 사례들의 모음입니다.
데이터가 많고 정확할수록 학습 결과가 좋아집니다.



2. 특징 (Feature)

데이터에서 예측을 위해 사용하는 입력 정보(속성)입니다.
(예: 스팸 분류 시 '메일 제목', '발신자', '특정 단어 빈도' 등)



3. 레이블 (Label)

우리가 예측하고자 하는 정답(목표 변수)입니다.
지도학습에서 필수적입니다.
(예: 이 메일은 '스팸이다', 이 환자는 '정상이다')



4. 모델 (Model)

데이터의 패턴을 학습한 결과물입니다.
새로운 데이터(입력)가 들어오면 결과를 예측하는
역할을 합니다.

머신러닝 핵심 용어정리

- 데이터(data): 학습에 사용하는 사례들
- 특징(feature): 입력으로 쓰는 정보
- 레이블(label): 정답 값
- 모델(model): 패턴을 학습한 결과물
- 예시:
 - 메일 길이, 발신자, 특정 단어 사용 → 스팸 여부

특징(feature)과 라벨(label)

Features								Label
date	lat	long	temp	humidity	cloud_coverage	wind_direction	atmp_pressure	rainfall
2021-09-09	49.71N	82.16W	74	20	3	N	18.6	.01
2021-09-09	32.71N	117.16W	82	42	6	SW	29.94	.23

Example

Features							
date	lat	long	temp	humidity	cloud_coverage	wind_direction	atmp_pressure
2021-09-09	49.71N	82.16W	74	20	3	N	18.6
2021-09-09	32.71N	117.16W	82	42	6	SW	29.94

Example

특징(feature)과 라벨(label)

부채붓꽃(Iris Setosa)



꽃잎 꽃받침

붓꽃(Iris Versicolor) 북미산 붓꽃(Iris Virginica)



꽃잎 꽃받침




꽃잎 꽃받침

객체
(샘플, 인스턴스, 관측치)


No	꽃받침 길이	꽃받침 너비	꽃잎 길이	꽃잎 너비	종류
1	5.3	3.3	1.3	0.2	부채붓꽃
2	4.8	3.2	1.4	0.3	부채붓꽃
...	...	...	...	...	...
100	7.0	3.6	4.6	1.1	붓꽃
...	...	...	...	...	...
200	6.0	2.8	4.9	1.7	북미산붓꽃

특징
(피처, 속성, 측정값, 설명변수, 독립변수)

라벨
(목적변수, 종속변수)



머신러닝 학습 방법




머신러닝 학습의 6단계 프로세스

알고리즘보다 먼저 문제 정의와 데이터가 중요하다



머신 러닝 알고리즘 유형



지도학습 (Supervised Learning)

핵심 개념

입력 데이터와 정답(레이블)이 함께 주어지는 학습 방식

마치 선생님이 문제와 정답을 같이 알려주며 가르치는 것과 유사

가장 널리 사용되며 높은 정확도를 기대할 수 있음

대표적인 과제 유형:

분류 (Classification)

회귀 (Regression)



사례 1: 스팸 메일 판별

입력: 메일 내용, 발신자, 제목

정답: 스팸 또는 정상

→ 새로운 메일이 오면 스팸 여부 분류




사례 2: 집값 예측

입력: 평수, 방 개수, 위치, 연식

정답: 5억 2천만원 (실거래가)

→ 새로운 집의 가격을 숫자로 예측

지도학습 (Supervised Learning)



지도학습 > 분류 (Classification)

결과가 '범주'인 문제

예측하려는 결과가 몇 가지 정해진 종류(Category) 중 하나인 경우

이진 분류 (Binary Classification)

두 가지 중 하나를 선택 (예: 예/아니오, 스팸/정상)

다중 분류 (Multi-class Classification)

세 가지 이상의 종류 중 하나를 선택 (예: 고양이/개/사람)



이미지 인식

사진 속 객체가 무엇인지 분류

고양이

개

사람



텍스트 분류



댓글의 악성 여부나 감정 상태 분류

악성 댓글

긍정 리뷰

문의

지도학습 > 분류 (Classification)



지도학습 > 회귀 (Regression)

핵심 개념

결과가 연속적인 숫자(Numeric)인 문제

입력 데이터와 출력값 사이의 관계를 함수 형태로 찾아냄

"얼마나 많이?", "언제?", "몇 점?" 같은 질문에 대한 답

대표적인 예측 사례:

집값


배달 시간

매출액

기온

주식 가격



데이터 분포와 예측선



트렌드를 읽는다


데이터의 경향성을 파악하여
미래의 값을 수치로 예측합니다.

지도학습 > 회귀 (Regression)




지도학습 > 분류와 회귀

- 분류 (classification)
 - X와 Y를 가장 잘 구분하는 경계 함수를 찾음
 - Y는 0, 1, 2와 같이 이산적인 값을 가짐



결과가 숫자가 아니라 종류면 분류


- 회귀 (regression)
 - X와 Y 관계를 가장 잘 나타내는 함수식을 찾음
 - Y는 연속적인 값을 갖는 숫자형 데이터



집값, 시간, 점수처럼 숫자를 맞히면 회귀

Sequential 클래스 : 간단한 딥러닝 모델 만들기 (2)


- 단층 신경망 모델 아키텍처



[그림 5-7] 단일 레이어 모델 아키텍처

Sequential 클래스 : 간단한 딥러닝 모델 만들기 (3)

- 단층 신경망 모델의 학습



[그림 5-8] 모델 학습

배운 것을 확인하는 방법: 데이터셋 분할



모델이 진정으로 이해했는지 확인하기 위해 데이터를 **시험 공부**처럼 나눠서 사용합니다.

훈련 데이터 (Training Set) 60%

검증 (Validation) 20%

테스트 (Test) 20%

훈련 데이터: 문제집 (공부용)

모델이 패턴을 직접 학습하는 데이터
(가중치 업데이트)

"교과서로 공부하는 단계"

검증 데이터: 모의고사 (점검용)

학습 중간에 성능을 확인하고
모델 설정을 조정하는 데이터


"모의고사를 보며 공부법 수정"

테스트 데이터: 수능/실전 (최종 평가)


학습이 끝난 후 최종 성능을
평가하기 위한 데이터 (절대 학습 금지)

"처음 보는 문제로 실력 확인"


훈련 데이터 / 테스트 데이터 / 검증 데이터



데이터로 보는 워크플로우



데이터로 보는 워크플로우



일반화 (Generalization): 머신러닝의 진짜 목표

" 훈련 데이터만 잘 맞추는 것이 아니라,
처음 보는 새로운 데이터에도 잘 작동하는 능력"

시험 공부 비유



기출문제 정답 암기

문제집은 100점이지만, 조금만 변형된 실전 문제는 틀림



기본 원리와 개념 이해

어떤 문제가 나와도 응용해서 풀 수 있음 (일반화 성공)

현장에서 왜 중요한가?



실제 고객

과거 데이터와
다른 행동 패턴



새로운 환자

학습 때 없었던
증상 조합




실제 도로


날씨, 공사 등
돌발 상황

과소적합 vs 과대적합

- 과소적합 (Underfitting)
 - : 모델이 너무 단순하여 데이터의 패턴을 제대로 학습하지 못한 상태.
- 과대적합 (Overfitting)
 - : 모델이 훈련 데이터에 너무 맞춰져서, 새로운 데이터에 대한 예측 성능이 떨어지는 상태.



과소적합 vs 과대적합



왼쪽: 모델이 너무 단순해서 둘 다 못 맞춤 (과소)
중간: 가장 적절한 균형점 (일반화)
오른쪽: 훈련은 완벽하지만 테스트는 엉망 (과대)



과소적합 (Underfitting)

훈련 점수 낮음 / 테스트 점수 낮음

"공부를 너무 안 해서 기본 개념도 모르는 상태"
모델이 너무 단순하여 패턴을 학습하지 못함



적정 적합 (Ideal)

훈련 점수 높음 / 테스트 점수 높음

"원리를 이해해서 응용 문제도 잘 푸는 상태"
일반화가 잘 된 가장 바람직한 모델




과적합 (Overfitting)

훈련 점수 매우 높음 / 테스트 점수 낮음

"기출문제 답만 달달 외운 상태"
훈련 데이터의 노이즈까지 암기하여 실전 성능 저하

퀴즈 ②: 어떤 모델이 더 좋을까?

? 실제 서비스라면?



질문: 실제 서비스에 더 적합한 모델은 무엇일까요?

훈련 점수가 높다고 무조건 좋은 것은 아닙니다. 일반화(Generalization) 능력이 중요합니다.

모델 평가의 필요성

왜 모델을 평가해야 할까?

모델의 예측 품질과 한계를 객관적으로 파악하기 위함

해결하려는 문제(분류/회귀)에 맞는 적절한 지표 선택이 필수

단순 점수(정확도)보다 '어떤 실수를 하는지' 분석하는 것이 중요

평가 관점:

정확성

일반화 능력

실수 유형



단순 점수 그 이상

"99점 모델"이라도 치명적인 실수 하나가 전체 시스템을 망칠 수 있습니다.

→ 예: 암 환자를 정상으로 오진



문제 유형별로 평가 지표가 다름

분류

정확도, 정밀도, 재현율, F1

회귀

MSE, MAE, R^2 (오차 크기)

성능 평가: 혼동 행렬(Confusion Matrix)

- 모델의 예측 결과를 실제 값과 비교하여 시각적으로 보여주는 표
- 분류 모델의 예측 성능을 평가하는 데 사용

		Predicted Class	
		P	N
Actual Class	P	True Positives (TP)	False Negatives (FN)
	N	False Positives (FP)	True Negatives (TN)

- TP/진양성 : 실제 양성, 예측 양성
- TN/진음성 : 실제 음성, 예측 음성
- FP/위양성 : 실제 음성, 예측 양성 (거짓 양성)
- FN/위음성 : 실제 양성, 예측 음성 (거짓 음성)

성능 평가: 혼동 행렬

- 정확도 (Accuracy)
 - 전체 중 정답을 맞춘 비율

$$Accuracy = \frac{TP + TN}{\text{전체}}$$

		Predicted Class	
		P	N
Actual Class	P	True Positives (TP)	False Negatives (FN)
	N	False Positives (FP)	True Negatives (TN)

- 불균형 데이터에서는 정확도 (accuracy) 만으로는 부족하다!
 - 데이터셋이 불균형할 때 (예: 정상 메일 99%, 스팸 메일 1%),
 - 모델이 모든 메일을 '정상'으로 예측해도 정확도는 99%
 - 하지만 실제 스팸 메일은 하나도 걸러내지 못하는 문제가 발생

성능 평가: 혼동 행렬

- 유방암 진단과 같은 문제에서 위양성과 위음성
 - FP (위양성): 실제로는 암이 아닌데 암이라고 진단하는 경우
 - : 환자에게 불필요한 공포와 추가적인 검사 비용을 발생시킴
 - FN (위음성): 실제로는 암인데 암이 아니라고 진단하는 경우
 - : 환자의 치료 시기를 놓치게 하여 생명을 위협할 수 있는 가장 치명적인 오류
- 정확도가 99%라도 모든 양성 사례를 놓치고 있다면(FN이 높다면) 쓸모가 없을 수 있음
- 문제의 특성에 따라 다른 평가 지표를 고려해야함.
- 혼동행렬을 통해 정확도만으로는 알 수 없는 정보를 제공받을 수 있음!

성능 평가: 혼동 행렬

- 정밀도 (Precision)
 - 맞다고 한 것 중 진짜 맞은 비율
 - '양성'이라고 예측한 것들 중에서 실제로 '양성'인 비율

$$\text{정밀도} = \frac{TP}{TP + FP}$$

- FP(위양성)를 줄이는 것이 중요한 상황에서 평가 지표로 사용됨
 - 스팸 메일: 스팸이 아닌 중요한 메일을 스팸으로 분류(FP)하면 사용자에게 불편을 줌
 - 자율 주행: 보행자가 아닌 물체를 보행자로 잘못 인식(FP)하여 급정거하는 상황 등

		Predicted Class	
		P	N
Actual Class	P	True Positives (TP)	False Negatives (FN)
	N	False Positives (FP)	True Negatives (TN)

성능 평가: 혼동 행렬

- 재현율 (Recall)

- 실제 맞는 것 중 얼마나 찾아냈는가
- 실제 '양성'인 것들 중에서 모델이 '양성'이라고 예측한 비율

$$\text{재현율} = \frac{TP}{TP + FN}$$

- FN(위음성)을 줄이는 것이 중요한 상황에서 성능 지표로 사용
 - 예) 유방암 진단, 금융 사기 탐지

		Predicted Class	
		P	N
Actual Class	P	True Positives (TP)	False Negatives (FN)
	N	False Positives (FP)	True Negatives (TN)

성능 평가: 혼동 행렬

- F1 Score
 - 정밀도와 재현율의 조화 평균
 - 정밀도와 재현율이 한쪽으로 치우치지 않고 모두 높은 값을 가질 때 높은 점수를 얻음

$$\text{F1-Score} = 2 \times \frac{\text{정밀도} \times \text{재현율}}{\text{정밀도} + \text{재현율}}$$

- 데이터셋에 클래스 불균형이 심할 때, 또는 정밀도와 재현율 모두 중요한 상황에서 모델의 성능을 하나의 숫자로 표현하고 싶을 때 유용

**머신러닝은 “얼마나 많이 맞췄는가” 보다
“무엇을 틀렸는가”가 더 중요하다**

평가 지표 정리

혼동 행렬 (Confusion Matrix)

		예측 (Prediction)	
실제 (Actual)	양성	TP True Positive (진짜 양성)	FP False Positive (가짜 양성/오진)
	음성	FN False Negative (가짜 음성/놓침)	TN True Negative (진짜 음성)

1. 정확도 (Accuracy)

전체 데이터 중에서 올바르게 예측한 비율
 $(TP + TN) / \text{전체}$

2. 정밀도 (Precision) - 스팸 메일

모델이 양성이라고 한 것 중 진짜 양성 비율
중요: 정상 메일을 스팸으로 분류하면 안 될 때 (FP 최소화)

3. 재현율 (Recall) - 암 진단

실제 양성 중에서 모델이 찾아낸 비율
중요: 실제 암 환자를 놓치면 안 될 때 (FN 최소화)

		Predicted	
		Spam	Non-spam
Actual	Spam	600 (True positive)	300 (False negative)
	Non-spam	100 (False positive)	9000 (True negative)

Accuracy

		Predicted	
		Spam	Not
Actual	Spam	600 (TP)	300 (FN)
	Not	100 (FP)	9000 (TN)

Accuracy =

True predictions
(TP + TN)

All predictions
(TP + TN + FP + FN)

Precision

		Predicted	
		Spam	Not
Actual	Spam	600 (TP)	300 (FN)
	Not	100 (FP)	9000 (TN)

Precision =

Actual spam
(TP)

Predicted spam
(TP + FP)


Recall

		Predicted	
		Spam	Not
Actual	Spam	600 (TP)	300 (FN)
	Not	100 (FP)	9000 (TN)

Recall

Actual spam
(TP)

All spam
(TP + FN)



끝!

