


반도체장비예지보전실무 01

예지보전과 머신러닝

1. 예지보전의 이해

유지보수 패러다임 변화

- 사후 유지보수 (Reactive Maintenance): 고장 발생 후 수리
- 예방 유지보수 (Preventive Maintenance): 정해진 주기에 따라 수리
- 예지 보전 (Predictive Maintenance): 데이터 분석을 통해 최적의 수리 시점 예측




반도체 펌에서 예지보전이 필요한 이유

- 반도체 산업은 막대한 자본 투자와 촉박한 생산 일정을 가지고 운영됨
 - 생산 시간 손실, 수율 감소, 비상 수리 비용을 포함한 계획되지 않은 가동 중단과 관련된 비용은 천문학적이다
 - 예지 보전은 예측 불가능하고 비용이 많이 드는 고장을 계획되고 관리 가능한 유지보수 이벤트로 전환한다
 - 재정적 영향을 크게 줄일 뿐만 아니라 직원 안전과 전반적인 운영 효율성을 향상시킨다.

유지보수 전략 비교

유지보수 전략	정의	핵심 특징	장점	단점/고려사항	반도체 제조 적용 가능성
사후 유지보수	장비 고장 후 수리	긴급/비상 대응	단순, 초기 비용 없음	높은 가동 중단 비용, 생산 지연, 안전 문제	극히 제한적, 치명적 손실 초래 가능
예방 유지보수	정해진 일정(시간/사용량)에 따라 수리	시간 기반, 스케줄 기반	예상치 못한 고장 감소, 계획 가능	불필요한 유지보수, 비효율성, 과잉 비용	여전히 널리 사용되나 최적화 필요
상태 기반 유지보수	장비 상태 모니터링 후 필요 시 수리	상태 기반, 센서 경고	효율성 증대, 자산 수명 연장	유지보수 사전 계획 어려움, 실시간 모니터링 필요	데이터 기반 접근의 초기 단계, 계획성 부족
예지 보전	데이터 및 ML로 고장 시점 예측 후 수리	데이터 기반, 예측 기반, ML 활용	가동 중단 최소화, 수율/생산량 증대, 비용 최적화, 공정 제어 강화	높은 초기 비용, 데이터 품질/양 요구, 모델 복잡성	필수적이고 최적의 전략, 높은 투자 수익률

머신 러닝 알고리즘 유형



지도학습 (Supervised Learning)

핵심 개념

입력 데이터와 **정답(레이블)**이 함께 주어지는 학습 방식

마치 선생님이 **문제와 정답**을 같이 알려주며 가르치는 것과 유사

가장 널리 사용되며 높은 정확도를 기대할 수 있음

대표적인 과제 유형:

분류 (Classification)

회귀 (Regression)



사례 1: 스팸 메일 판별

입력: 메일 내용, 발신자, 제목

정답: **스팸** 또는 **정상**

→ 새로운 메일이 오면 스팸 여부 분류




사례 2: 집값 예측

입력: 평수, 방 개수, 위치, 연식

정답: **5억 2천만원** (실거래가)

→ 새로운 집의 가격을 숫자로 예측

지도학습 (Supervised Learning)



비지도학습 (Unsupervised Learning)

핵심 개념

정답(레이블) **없이** 데이터의 숨겨진 구조나 패턴을 탐색

"이 데이터들은 어떻게 묶일 수 있을까?"를 스스로 학습

대표적인 목적:

군집화 (Clustering)

연관 규칙

차원 축소



사례 1: 고객 군집화

입력: 구매 이력, 접속 시간, 나이 등

결과: **비슷한 성향의 그룹 A, B, C**

→ 정답 없이 스스로 그룹을 나눔



사례 2: 유사 상품 묶기

입력: 상품 설명 텍스트, 이미지

결과: **함께 진열하면 좋은 상품군**

→ 라벨 없이 유사도 기반으로 추천

비지도학습 (Unsupervised Learning)



머신 러닝 알고리즘 분류

구분	유형	알고리즘
지도학습	분류	• K-최근접 이웃(K-nearest neighbors, KNN) • 서포트 벡터 머신(Support vector machine, SVM) • 결정 트리(Decision tree, DT) • 로지스틱 회귀(Logistic regression)
	회귀	• 선형 회귀(Linear regression)
비지도학습	군집	• K-평균 군집(K-means clustering) • 밀도 기반 군집 분석(Density-based clustering analysis, DBSCAN)
	차원축소	• 주성분 분석(Principal component analysis, PCA)

예지 보전의 주요 작업 및 적합한 알고리즘

- 이상감지(상태 모니터링)
 - 작업 : 정상 작동 조건에서 크게 벗어나는 비정상적인 장비 동작을 식별
 - 알고리즘 : 군집화 알고리즘 (비지도 알고리즘)
- 고장 분류
 - 작업 : 특정 유형의 장비 고장(예: 베어링 고장, 전기 단락)을 분류하거나
: 이진 분류(예: 특정 기간 내에 고장이 발생할지 예측: " 고장 " 대 " 비고장 ")를 수행
 - 알고리즘 : 결정 트리, 랜덤 포레스트, SVM, 로지스틱 회귀 및 신경망이 널리 사용됨
- 잔여수명(RUL) 추정
 - 작업 : 장비 고장까지의 연속적인 시간(예: 시간, 주기)을 예측
: 이를 통해 유지보수를 정확하고 사전 예방적으로 계획할 수 있음
 - 알고리즘 : 회귀 모델(연속 값을 예측하는 데 적합)
: 더 전문화된 접근에서는 시간 데이터를 활용하기도 함

예지 보전의 주요 작업 및 적합한 알고리즘

예지 보전 작업	일반적인 알고리즘	반도체 예지 보전의 일반적인 적용	예지 보전을 위한 강점	예지 보전을 위한 고려사항
이상 감지	K-평균, Isolation Forest, One-Class SVM	예상치 못한 센서 스파이크 감지, 비정상적인 장비 동작 식별	레이블이 없는 데이터에 적합, 조기 경고 가능	신중한 임계값 설정 필요, 오탐/미탐 균형 중요
고장 분류	결정 트리, 랜덤 포레스트, 로지스틱 회귀, SVM, 신경망, XGBoost	웨이퍼 핸들링 로봇 고장 예측, 특정 고장 유형 분류	해석 가능한 규칙 제공 (트리 기반), 비선형성 처리	대규모 레이블 데이터셋 필요, 이상치에 민감할 수 있음
잔여 수명 (RUL) 추정	선형 회귀, 생존 모델, 열화 모델	펌프 베어링의 잔여 수명 추정, 공정 장비의 수명 예측	연속적인 값 예측, 유지보수 계획 최적화	정확한 고장 이력 데이터 필요, 복잡한 모델링

2. 제조AI와 제조 데이터

제조 AI 개요

제조 AI란?

- 제조 공정 데이터를 분석하여 생산성 향상 및 문제 해결에 활용하는 인공지능 기술
- 패턴 학습, 예측, 판단 등을 통해 제조 현장의 의사결정을 지원

활용 목적

- 생산 효율 향상과 불량률 감소
- 장비의 고장 예측 및 예지보전 시스템 구축
- 공정 변수의 최적화를 통한 비용 절감

그림 1 | 제조 분야에서의 산업별 AI 시장 규모




〈마켓앤마켓 자료 재구성〉

제조 데이터란 무엇인가?

제조 데이터의 정의

- 제품의 생산 과정에서 발생하는 모든 정보를 의미
- 장비의 센서 데이터, 품질 검사 이미지, 공정 동영상, 작업자의 음성 등 다양한 형태로 수집
- 생산 공정 최적화를 위한 핵심 자원으로 활용
- 장비 상태 모니터링, 품질 검사, 공정 제어 등 다양한 영역에서 의사결정 지원



제조 데이터의 4가지 형태



숫자 데이터



이미지 데이터



동영상 데이터



소리 데이터

제조 데이터의 4가지 형태

숫자 데이터

장비의 온도, 압력, 진동, 전류 등 센서 측정값

반도체 공정의 Wafer 두께, Coating 정도 등 정량적 데이터


시계열 분석, 이상치 탐지, 공정 최적화에 활용

Nominal Image Sensor Format Type Size								
CRT / Image Sensor Format Type	CRT Dia (mm)	Diagonal (mm)	4:3 Aspect Ratio		3:2 Aspect Ratio		16:9 Aspect Ratio	
			Width (mm)	Height (mm)	Width (mm)	Height (mm)	Width (mm)	Height (mm)
35mm Full Frame	N/A	43.3	34.64	25.98	36.03	24.02	37.74	21.23
APS-C	N/A	30.1	24.08	18.06	25.04	16.70	26.23	14.76
4/3"	33.9	21.3	17.07	12.80	17.75	11.83	18.59	10.46
1"	25.4	16.0	12.80	9.60	13.31	8.88	13.95	7.84
2/3"	16.9	10.7	8.53	6.40	8.88	5.92	9.30	5.23
1/1.55"	16.4	10.3	8.26	6.19	8.59	5.73	9.00	5.06
1/1.7"	14.9	9.4	7.53	5.65	7.83	5.22	8.20	4.61
1/1.8"	14.1	8.9	7.11	5.33	7.40	4.93	7.75	4.36
1/2"	12.7	8.0	6.40	4.80	6.66	4.44	6.97	3.92
1/2.3"	11.0	7.8	6.26	4.70	6.51	4.34	6.82	3.84
1/2.5"	10.2	7.2	5.76	4.32	5.99	3.99	6.28	3.53
1/2.7"	9.4	6.7	5.33	4.00	5.55	3.70	5.81	3.27
1/3"	8.5	6.0	4.80	3.60	4.99	3.33	5.23	2.94
1/3.2"	7.9	5.6	4.50	3.38	4.68	3.12	4.90	2.76
1/3.6"	7.1	5.0	4.00	3.00	4.16	2.77	4.36	2.45
1/4"	6.4	4.5	3.60	2.70	3.74	2.50	3.92	2.21
1/6"	4.2	3.0	2.40	1.80	2.50	1.66	2.61	1.47
1/9"	2.8	2.0	1.60	1.20	1.66	1.11	1.74	0.98

제조 데이터의 4가지 형태

이미지 데이터


- 제품 외관, 미세한 결함, 장비 상태 등을 촬영한 이미지
- 비전 검사를 통한 불량 판별 및 부품 마모 상태 확인
- 패턴 인식, 결함 탐지, 분류 작업에 활용



제조 데이터의 4가지 형태

동영상 데이터

- 공정 진행 상황, 로봇 팔 움직임, 작업자 동작 기록
- 생산 라인의 이상 감지, 작업자 안전 관리에 활용
- 시간 경과에 따른 움직임 패턴 분석, 프로세스 최적화



제조 데이터의 4가지 형태

🔊 소리 데이터


장비 동작 소리, 이상음, 모터 진동음 등 음향 데이터

특정 주파수 분석을 통한 장비 비정상 상태 감지

음향 신호 처리, 스펙트럼 분석을 통한 예지보전



제조 AI 활용 분야




제조 데이터 분석: 기술적 목적



본 과목에서 다루는 것

[교재]

- 제조 데이터를 이해하고 AI를 적용하는 실습
 - 교재를 중심으로 다양한 형태의 제조 데이터를 하나씩 다룸
 - 반도체 장비의 실제 데이터는 기업 보안 등의 이유로 공개 데이터 확보가 어려움
 - 따라서 반도체 데이터에 한정하지 않고, 유사한 특성을 가진 제조 데이터를 활용하여 실습
 - 대상이나 설비가 달라도 데이터의 형태와 해결하려는 문제가 유사하면 적용되는 AI의 원리는 동일



본 과목에서 다루는 것

- 제조 현장의 데이터는 일반적인 예제 데이터와 달리 그대로 학습에 사용하기 어려운 경우가 많음
- 그래서 제조 데이터에서 특히 다룰 것
 - 데이터 품질 관리 : 결측값, 이상값 등 실제 데이터에서 발생하는 문제 처리
 - 불균형 데이터 처리 : 정상 데이터가 많고 고장·불량 데이터가 적은 문제 보완
 - 장비 데이터 이해 및 해석 : 데이터의 변화가 무엇을 의미하는지 해석
 - 다양한 제조 데이터 실습 : 데이터 특성에 맞는 AI 모델 적용
 - 최종 프로젝트 : 공개된 웨이퍼 이송 장치 데이터 활용
: 데이터 이해 → 전처리 → 모델링 → 결과 해석까지 종합 적용

→ 장비 데이터를 읽고 이해하여, 제조 현장의 문제에 AI를 적용하는 능력을 기른다!

3. 머신러닝 개념 정리

머신러닝 핵심 파이썬 라이브러리



고성능 행렬(matrix) 처리 라이브러리



구조화된 데이터 처리 라이브러리



데이터 시각화 라이브러리

Numpy : 배열·행렬 연산 도구

- 소개
 - Numerical Python
 - 파이썬에서 과학 컴퓨팅을 위한 핵심 라이브러리
 - 고성능 다차원 배열 객체와 이러한 배열을 다루는 도구를 제공
 - 행렬 (Matrix), 벡터 (Vector)와 같은 배열 (array) 연산의 사실상의 표준
- 특징
 - List에 비해 빠르고 메모리 효율적
 - 반복문 없이 데이터 배열에 대한 처리를 지원
 - 선형대수 관련 다양한 기능 제공

Pandas : 데이터 처리 도구

- Pandas의 필요성:
 - NumPy 배열은 빠르고 강력하지만, 각 열이 무엇을 의미하는지 알 수 없다.
 - NumPy 위에 구축되었으며, 레이블(인덱스, 컬럼명)이 있는 데이터를 다루는 데 특화.
 - 엑셀 스프레드시트나 데이터베이스 테이블을 파이썬으로 가져온 것이라 생각하면 쉽다.
- Pandas
 - Python Data Analysis Library
 - R 프로그래밍 언어의 data.frame을 본떠 만들었음.
 - 행과 열로 이루어진 표(tabular) 형식의 데이터를 쉽고 직관적으로 다룰 수 있도록 도와주는 도구
 - 핵심 데이터 구조: Series와 DataFrame

Pandas 주요 기능

- 데이터 읽기/쓰기 : CSV/Excel/JSON/SQL 등 다양한 포맷의 파일 처리
- 데이터 선택 및 필터링 : 특정 조건에 맞는 행이나 열을 추출
- 데이터 정렬 : 특정 열을 기준으로 오름차순/내림차순으로 정렬.
- 결측치 처리 : 비어있는 값을 찾고, 채우거나 제거
- 데이터 그룹화 및 집계 : 특정 그룹별로 묶어 평균, 합계, 개수 등을 계산
- 데이터 병합 및 연결 : 여러 개의 DataFrame을 하나로 합침

→ 데이터 처리의 거의 모든 과정을 지원

Matplotlib : 데이터 시각화 도구

- 탐색적 데이터 분석(EDA)에서의 시각화의 역할
 - 숫자만으로는 알 수 없는 데이터의 분포, 이상치, 변수 간의 관계를 직관적으로 파악하게 해줌
- 시각화 도구별 역할
 - Matplotlib: 모든 시각화의 기초
 - : 저수준 API로, 모든 요소를 제어할 수 있어 발표/논문용 그래프 제작에 필수
 - Pandas Plotting: 데이터프레임에 내장된 가장 빠르고 간편한 도구
 - : 데이터 처리 중간중간 빠르게 경향을 확인할 때 사용
 - Seaborn: Matplotlib 기반의 고수준 API
 - : 통계 정보를 아름답고 쉽게 시각화하는 데 특화. 탐색적 분석에서 빛을 발하는 만능 툴킷

특징(feature)과 라벨(label), 데이터 샘플(sample)


Features								Label
date	lat	long	temp	humidity	cloud_coverage	wind_direction	atmp_pressure	rainfall
2021-09-09	49.71N	82.16W	74	20	3	N	18.6	.01
2021-09-09	32.71N	117.16W	82	42	6	SW	29.94	.23

Example


Features							
date	lat	long	temp	humidity	cloud_coverage	wind_direction	atmp_pressure
2021-09-09	49.71N	82.16W	74	20	3	N	18.6
2021-09-09	32.71N	117.16W	82	42	6	SW	29.94

Example

판다스 자료구조: Series, DataFrame



판다스 자료구조: Series, DataFrame



판다스 자료구조: Series, DataFrame

The diagram illustrates a pandas DataFrame with the following structure and annotations:

- Column names:** Name, Team, Number, Position, Age, Height, Weight, College, Salary.
- Index label:** The first column (0-6) is labeled as the index.
- Columns axis=1:** Points to the column headers.
- Index axis=0:** Points to the index values.
- Missing value:** Points to the 'NaN' value in the 'Number' column for index 3.
- Data:** Points to the numerical values in the 'Age', 'Height', 'Weight', and 'Salary' columns.

	Name	Team	Number	Position	Age	Height	Weight	College	Salary
0	Avery Bradley	Boston Celtics	0.0	PG	25.0	6-2	180.0	Texas	7730337.0
1	John Holland	Boston Celtics	30.0	SG	27.0	6-5	205.0	Boston Uniersity	NaN
2	Jonas Jerebko	Boston Celtics	8.0	PF	29.0	6-10	231.0	NaN	5000000.0
3	Jordan Mickey	Boston Celtics	NaN	PF	21.0	6-8	235.0	LSU	1170960.0
4	Terry Rozier	Boston Celtics	12.0	PG	22.0	6-2	190.0	Louisville	1824360.0
5	Jared Sullinger	Boston Celtics	7.0	C	NaN	6-9	260.0	Ohio State	2569260.0
6	Evan Turner	Boston Celtics	11.0	SG	27.0	6-7	220.0	Ohio State	3425510.0



배운 것을 확인하는 방법: 데이터셋 분할

 모델이 **진짜로 이해했는지** 확인하기 위해 데이터를 **시험 공부**처럼 나눠서 사용합니다.

훈련 데이터 (Training Set) 60%

검증 (Validation) 20%

테스트 (Test) 20%

훈련 데이터: 문제집 (공부용)

모델이 패턴을 **직접 학습**하는 데이터
(가중치 업데이트)

"교과서로 공부하는 단계"

검증 데이터: 모의고사 (점검용)

학습 중간에 **성능을 확인**하고
모델 설정을 조정하는 데이터


"모의고사를 보며 공부법 수정"

테스트 데이터: 수능/실전 (최종 평가)


학습이 끝난 후 **최종 성능**을
평가하기 위한 데이터 (절대 학습 금지)

"처음 보는 문제로 실력 확인"

훈련 데이터 / 테스트 데이터 / 검증 데이터



지도학습의 학습 프로세스



일반화 (Generalization): 머신러닝의 진짜 목표

"훈련 데이터만 잘 맞추는 것이 아니라,
처음 보는 새로운 데이터에도 잘 작동하는 능력"

시험 공부 비유



기출문제 정답 암기

문제집은 100점이지만, 조금만 변형된 실전 문제는 틀림



기본 원리와 개념 이해

어떤 문제가 나와도 응용해서 풀 수 있음 (일반화 성공)

현장에서 왜 중요한가?



실제 고객

과거 데이터와
다른 행동 패턴



새로운 환자

학습 때 없었던
증상 조합




실제 도로


날씨, 공사 등
돌발 상황

과소적합 vs 과대적합

- 과소적합 (Underfitting)
 - : 모델이 너무 단순하여 데이터의 패턴을 제대로 학습하지 못한 상태.
- 과대적합 (Overfitting)
 - : 모델이 훈련 데이터에 너무 맞춰져서, 새로운 데이터에 대한 예측 성능이 떨어지는 상태.



과소적합 vs 과대적합



왼쪽: 모델이 너무 단순해서 둘 다 못 맞춤 (과소)
중간: 가장 적절한 균형점 (일반화)
오른쪽: 훈련은 완벽하지만 테스트는 엉망 (과대)

과소적합 (Underfitting)



훈련 점수 낮음 / 테스트 점수 낮음

"공부를 너무 안 해서 기본 개념도 모르는 상태"
모델이 너무 단순하여 패턴을 학습하지 못함

적정 적합 (Ideal)



훈련 점수 높음 / 테스트 점수 높음

"원리를 이해해서 응용 문제도 잘 푸는 상태"
일반화가 잘 된 가장 바람직한 모델

과적합 (Overfitting)



훈련 점수 매우 높음 / 테스트 점수 낮음

"기출문제 답만 달달 외운 상태"
훈련 데이터의 노이즈까지 암기하여 실전 성능 저하

퀴즈 ②: 어떤 모델이 더 좋을까?

? 실제 서비스라면?

모델 A

훈련 정확도: 99%

테스트 정확도: 68%

특징: 훈련 데이터만 완벽 암기?

VS

모델 B

훈련 정확도: 88%

테스트 정확도: 85%

특징: 새로운 데이터에도 안정적



질문: 실제 서비스에 더 적합한 모델은 무엇일까요?

훈련 점수가 높다고 무조건 좋은 것은 아닙니다. **일반화(Generalization)** 능력이 중요합니다.

모델 평가의 필요성

왜 모델을 평가해야 할까?

모델의 **예측 품질**과 **한계**를 객관적으로 파악하기 위함

해결하려는 문제(분류/회귀)에 맞는 **적절한 지표** 선택이 필수

단순 점수(정확도)보다 '**어떤 실수를 하는지**' 분석하는 것이 중요

평가 관점:

정확성

일반화 능력

실수 유형



단순 점수 그 이상

"99점 모델"이라도 **치명적인 실수** 하나가 전체 시스템을 망칠 수 있습니다.

→ 예: 암 환자를 정상으로 오진



문제 유형별로 평가 지표가 다름

분류

정확도, 정밀도, 재현율, F1

회귀

MSE, MAE, R^2 (오차 크기)

평가 지표

혼동 행렬 (Confusion Matrix)

		예측 (Prediction)	
실제 (Actual)	양성	TP True Positive (진짜 양성)	FP False Positive (가짜 양성/오진)
	음성	FN False Negative (가짜 음성/놓침)	TN True Negative (진짜 음성)

1. 정확도 (Accuracy)

전체 데이터 중에서 올바르게 예측한 비율
 $(TP + TN) / \text{전체}$

2. 정밀도 (Precision) - 스팸 메일

모델이 양성이라고 한 것 중 진짜 양성 비율
중요: 정상 메일을 스팸으로 분류하면 안 될 때 (FP 최소화)

3. 재현율 (Recall) - 암 진단


실제 양성 중에서 모델이 찾아낸 비율
중요: 실제 암 환자를 놓치면 안 될 때 (FN 최소화)

머신러닝 학습의 6단계 프로세스

알고리즘보다 먼저 문제 정의와 데이터가 중요하다



머신러닝 프로세스



※ EDA (Exploratory Data Analysis) : 탐색적 데이터 분석

4. 선형 회귀 : 예측 문제

지도학습 > 회귀 (Regression)

핵심 개념

결과가 **연속적인 숫자(Numeric)**인 문제

입력 데이터와 출력값 사이의 관계를 **함수 형태**로 찾아냄

"얼마나 많이?", "언제?", "몇 점?" 같은 질문에 대한 답

대표적인 예측 사례:

집값


배달 시간

매출액

기온

주식 가격

데이터 분포와 예측선





트렌드를 읽는다




데이터의 경향성을 파악하여
미래의 값을 수치로 예측합니다.

지도학습 > 회귀 (Regression)



선형 회귀 개념



선형 회귀 개념

((앞 페이지 영상 내용 번역))

선형 회귀는 일반인이 이해하기 쉽도록 출력 변수와 하나 이상의 입력 변수 간의 관계를 모델링하는 통계 기법입니다. 여기에 표시된 것처럼 일부 데이터 포인트를 통과하는 선을 맞추는 것으로 생각하면 알 수 없는 데이터에 대한 예측을 할 수 있습니다.

변수 간에 선형 관계가 있다고 가정합니다.

선형 함수 $y = mx + b$ 에 익숙할 수 있습니다. 여기서 y 는 출력 변수라고도 하며 종속 변수라고도 합니다. x 로 표현되는 것을 볼 수도 있습니다. 반면에 입력 변수 x 의 함수는 독립 변수라고도 하는 입력 변수 역할을 합니다. 계수 m 과 b 는 각각 베타 1과 베타 0으로 표현되는 것을 볼 수 있을 것입니다.

그렇다면 m 과 b 계수는 무엇을 할까요?

m 또는 베타 1 계수는 선의 기울기를 제어하고 b 또는 베타 0은 머신 러닝에서 선의 절편을 제어합니다. 우리는 이것을 편향이라고도 합니다. 이 두 계수는 선형 회귀에서 풀고 있는 것입니다. 또한 여러 입력 변수를 확장하여 x_1 x_2 x_3 을 베타 1 베타 2 및 베타 3 등으로 각각의 기울기로 사용할 수 있습니다.

이러한 고차원의 변수 중 선형 회귀를 초평면으로 시각화할 수 있으므로 이러한 점에 선을 어떻게 잘 맞출까요?

점과 선 사이에 이러한 차이가 있는 것을 알 수 있습니다. 이 작은 빨간색 세그먼트는 잔차라고 합니다. 이것은 데이터 점과 선이 생성할 예측 사이의 차이입니다. 이러한 잔차를 각각 가져와 제공합니다. 이것은 제곱 오차이며 잔차가 클수록 제곱의 면적이 더 증폭됩니다. 주어진 선에 대한 이러한 모든 제곱의 면적을 합하면 제곱 오차의 합을 얻을 수 있으며 이것을 손실 함수라고 합니다. 제곱 오차의 합을 최소화하는 베타 0 및 베타 1 계수를 찾아야 합니다. 계수는 행렬 분해에서 여기에 표시된 경사 하강까지 다양한 기술로 풀 수 있습니다. 다행히도 이 작업을 수행할 수 있는 라이브러리가 많이 있으며 다른 비디오에서 이러한 주제에 대해 심층적으로 살펴보겠습니다.

선형 회귀를 검증하기 위해 여러 기술이 있습니다.

머신 러닝 실무자는 종종 데이터의 1/3을 가져가서 테스트 데이터 세트에 넣으면 나머지 2/3이 학습 데이터 세트가 됩니다. 학습 데이터 세트는 회귀선을 맞추는 데 사용됩니다. 테스트 데이터 세트는 회귀선을 검증하는 데 사용됩니다. 이는 회귀가 이전에 본 적이 없는 데이터에서 잘 수행되는지 확인하기 위해 수행됩니다.

선형 회귀 개념

- 하는 일? 데이터를 예측하는 가장 기본적인 기계학습모델
- 어떻게 예측? 데이터 간의 선형적인 관계를 찾아 예측
(변수 간에 선형관계가 있다고 가정함)
- 어떨 때 사용? 집 값 예측, 판매량 예측, 시험 점수 예측 등
- 왜 중요? 다른 복잡한 모델을 이해하기 위한 기반 지식이 됨

선형 회귀 개념

- 선형 함수

$$y = Wx + b$$

$$y = \beta_1 x + \beta_0$$

y : 출력 변수 (종속 변수)

x : 입력 변수 (독립 변수)

W : 가중치 (weight) 또는 기울기 (Slope)

- x 값이 1단위 변할 때 y 값이 얼마나 변하는지를 나타냄

b : 편향 (bias) 또는 절편 (Intercept)

- x 값이 0일 때 y 값 (직선이 y 축과 만나는 점)


- 우리의 목표는 데이터를 가장 잘 설명하는 최적의 W 와 b 값을 찾는 것!

비용 함수

- "가장 잘 통과하는 직선"은 어떻게 정의할까?
 - 직선과 실제 데이터 포인트 간의 **오차를 최소화하는 직선**이 가장 좋은 직선
- 오차를 계산하는 함수 == 손실 함수(또는 비용 함수)
 - 평균 제곱 오차 (Mean Squared Error, MSE)
 - : 가장 흔히 사용되는 손실 함수 중 하나
 - : 각 데이터 포인트의 (실제 값 - 예측 값)² 을 모두 더한 후 평균을 낸 값
 - : 오차가 크면 제곱 때문에 패널티가 크게 부여되어, 작은 오차를 선호하게 됨
- 목표: 이 **MSE 값이 가장 작아지는 W와 b를 찾는 것!**

비용 함수

- MSE 값이 가장 작아지는 W 와 b 를 어떻게 찾을까?
 - 손실 함수는 W 와 b 에 따라 오목한 그릇 모양을 가짐
 - 이 그릇의 가장 낮은 지점(최소값)을 찾으면 됨.
- 전역 최적점(Global minima)
 - :다른 어떤 파라미터들보다 손실이 가장 낮아지는 지점의 파라미터 조합




경사 하강법 개념

- 하는 일? 최적의 모델 파라미터를 찾음
- 어떻게 찾아? 비용 함수의 값이 작아지는 방향을 찾아 경사면을 조금씩 내려가며 찾음
- 왜 중요? 딥러닝의 신경망을 이해할 때 필수적임

경사 하강법 개념

- 실제로 모델을 최적화할 때는 파라미터에 대한 모든 손실 값의 분포를 한번에 알 수가 없으며, 어느 방향으로 모델의 파라미터를 갱신해야 할지 전혀 모르는 상태의 연속
- 마치 한치 앞도 보이지 않는 안개 속을 걸어 나가는 느낌
- 그래서 현재 손실 값으로 각 파라미터들의 경사도를 구해, 손실 값이 낮아질 가능성이 큰 쪽으로 파라미터를 갱신하는 과정을 반복하는 것이 최선의 방법



경사 하강법 동작 원리

- 동작 원리 (학습 과정)

1. 모델 파라미터를 임의의 값으로 초기화
2. 훈련 데이터셋에서 하나의 데이터 샘플(x, y)을 무작위로 선택
3. 선택된 샘플로 예측값 생성
4. 예측값과 실제값의 차이(손실) 계산
5. 손실을 줄이는 방향(기울기) 계산
6. 기울기와 학습률을 사용하여 모델 파라미터 업데이트

$$\text{파라미터}_{\text{새로운값}} = \text{파라미터}_{\text{현재값}} - \text{학습률} \times \text{기울기}$$

7. 2~6번 과정 반복

- : 모든 훈련 데이터셋을 한 번씩 사용할 때까지 반복 == 에포크(epoch)
- : 손실이 더 이상 크게 감소하지 않을 때까지 에포크를 반복

[실습] 사이킷런으로 선형 회귀 모델 프로세스 따라가기

- 별도 자료 참고 : 반도체장비예지보전실무 01 실습01 선형 회귀 기본형.pdf
- 실습 내용
 - 데이터 준비 : 판다스로 가상의 데이터 생성
 - 데이터 분할 : 모델 평가 시 사용하기 위함
 - 선형 회귀 모델 생성 및 훈련 : 훈련 데이터를 사용하여 최적의 W 와 b 를 찾도록 학습시킴
 - 예측 수행 : 훈련된 모델을 사용하여 테스트 세트에 대한 예측 값을 만듦
 - 모델 평가 : 모델이 실제 문제를 얼마나 잘 해결하는지 파악하기 위함

[연습문제] 개인 의료비용 예측

- 문제 : 개인의 건강 및 생활 습관 관련 데이터를 사용하여,
해당 개인의 예상 의료비용(Medical Charges)을 예측하는 선형 회귀 모델을 구축해 보세요.
- 사용할 데이터셋 : Kaggle 등에서 구할 수 있는 Medical Cost Personal Datasets
- 데이터의 주요 특성(Features):
 - age: 나이
 - sex: 성별 (male/female)
 - bmi: 체질량 지수 (Body Mass Index)
 - children: 부양 자녀 수
 - smoker: 흡연 여부 (yes/no)
 - region: 거주 지역 (northeast, northwest, southeast, southwest)
- 타겟(Target): charges: 예상 의료비용 (달러)

별도 자료 참고: ::반도체장비예지보전실무 01 연습문제01 개인 의료비용 예측 실습가이드.pdf

캐글(Kaggle) 데이터셋 사용하기

- 캐글(Kaggle) 데이터셋 다운로드 및 사용 방법
 - 단계 1: 캐글 계정 생성 및 로그인
 - : 캐글 웹사이트 (<https://www.kaggle.com/>)에 접속
 - 단계 2: 원하는 데이터셋 찾기
 - 단계 3: 데이터셋 다운로드
 - : 일반적으로 CSV 파일 형태로 다운로드
 - : 다운로드한 .csv 파일을 본인의 구글 드라이브에 업로드
 - : 코랩에서 구글 드라이브 마운트
 - 단계 4: 파이썬에서 pandas 라이브러리를 사용하여 데이터셋 불러오기

캐글(Kaggle) 데이터셋 사용하기

- 캐글(Kaggle) 데이터셋 다운로드 및 사용 방법

```
import pandas as pd

# --- 1. 파일 경로 설정 ---
# 다운로드한 CSV 파일이 파이썬 코드 파일과 같은 폴더에 있다면 파일 이름만 적습니다.
# 만약 다른 폴더에 있다면, 파일의 전체 경로를 입력해야 합니다.
# 예시: file_path = 'C:/Users/YourUser/Downloads/insurance.csv'
file_path = 'insurance.csv' # 같은 폴더에 저장했을 경우


# --- 2. CSV 파일 불러오기 ---
df = pd.read_csv(file_path)
print("데이터셋을 성공적으로 불러왔습니다!")
print("\n데이터프레임 상위 5개 행:")
print(df.head())
print("\n데이터프레임 정보:")
df.info()
```

[연습문제 결과분석] 개인 의료비용 예측

- 결과 분석: 과소적합 발생

```
===== 모델 평가 (테스트 세트) =====  
테스트 MSE (Mean Squared Error): 33596915.85  
테스트 R2 Score: 0.7836  
  
===== 모델 평가 (훈련 세트) =====  
훈련 MSE (Mean Squared Error): 37277681.70  
훈련 R2 Score: 0.7417
```

선형회귀에서 과소/과대 적합 처리 방법



- 과대적합
 - 가중치의 영향력을 낮춤
 - 릿지 / 라쏘 모델

- 과소적합
 - 모델의 복잡도를 높임
 - 다항 회귀

5. 로지스틱 회귀 : 분류 문제

지도학습 > 분류 (Classification)

결과가 '범주'인 문제

예측하려는 결과가 몇 가지 정해진 종류(Category) 중 하나인 경우

이진 분류 (Binary Classification)

두 가지 중 하나를 선택 (예: 예/아니오, 스팸/정상)

다중 분류 (Multi-class Classification)

세 가지 이상의 종류 중 하나를 선택 (예: 고양이/개/사람)

이미지 인식

사진 속 객체가 무엇인지 분류

고양이

개

사람

텍스트 분류



댓글의 악성 여부나 감정 상태 분류

악성 댓글

긍정 리뷰

문의

지도학습 > 분류 (Classification)




로지스틱 회귀 개념

- 하는 일? 입력 값이 0과 1 중 1에 **속할 확률을 예측**
- 어떻게? **선형 회귀의 예측값($z=Wx+b$)을 0과 1 사이의 확률로 변환!**
- 어떨 때 사용? 스팸 메일 분류(스팸/정상), 질병 진단(양성/음성)
- 왜 중요? 분류 문제를 해결하기 위해 가장 널리 쓰이는 모델
인공신경망이 기반이 되는 개념
- 왜 이름에 ‘회귀’가 붙었을까?
 - 내부적으로 선형 회귀 개념을 사용하기 때문
 - 선형 회귀를 분류 문제에 쓰기 위해 로그 함수를 적용한 모델이라고 생각해보자


로지스틱 회귀 개념

- 예를 들어 어떤 학생이 공부하는 시간에 따라 시험에 합격할 확률이 달라진다고 해보자.
- 선형 회귀를 사용하면 아래와 같은 그림으로 나타낼 수 있다.




로지스틱 회귀 개념

- 만약 로지스틱 회귀를 사용하면 아래와 같이 나타난다.
- 시험에 합격할 확률이 0과 1 사이의 값으로 그려진다.



로지스틱 회귀 개념



로지스틱 회귀 개념

((앞 슬라이드 영상 번역))

로지스틱 회귀는 하나 이상의 독립 변수가 주어진 경우 이벤트의 확률을 모델링하는 통계적 기법입니다. 숫자형 입력 데이터로 시작 하지만 출력 변수는 이진수이며 0 또는 1이 되어 각각 거짓 또는 참 값을 나타냅니다. 그런 다음 이 데이터에 로지스틱 함수라고 하는 S자 모양의 곡선을 맞춰 이벤트가 발생할지 여부를 확률적으로 예측하는 데 사용할 수 있습니다.

예를 들어, 비가 몇 시간 동안 내렸을 때 홍수 확률은 얼마일까요? 이러한 점들이 로지스틱 함수에 어떻게 투영될 수 있는지 주목하고 최대 우도 추정을 사용하여 곡선을 맞출 수 있습니다. 곧 설명하겠지만 참과 거짓 사례가 혼합된 중간 지점이 있습니다. 이러한 지점이 이벤트가 발생할 가능성이 더 높거나 발생하지 않을 가능성을 점점 더 보여주는 과도기적 추세를 따르면 S자 모양의 곡선이 각각 올라가거나 감소하는 것을 볼 수 있습니다. 그런 다음 이를 활용하여 0과 1 사이의 확률을 예측할 수 있습니다.

비가 6.2인치 예상되고 이로 인해 홍수 확률이 75 또는 75%가 되는 경우를 생각해 보겠습니다. 홍수가 발생하면 임계값을 0.5로 정의하고 0.5보다 큰 값은 참이고 0.5보다 작은 값은 거짓입니다. 그러면 홍수가 발생할 것이라고 예측할 수 있습니다. 필요에 따라 이 임계값을 조정할 수 있습니다. 예를 들어 임계값을 0.8로 설정하면 실제로 거짓으로 분류되어 홍수가 발생하지 않습니다. 임계값을 0.2로 줄여 홍수 분류에 대한 장벽을 훨씬 낮출 수도 있습니다.


이것이 S자 모양 곡선을 생성하는 함수입니다.

e 는 오일러 수로, 베타 $1X$ 라는 특수 상수입니다. 베타 0은 실제로 로그 오즈 함수인 선형 함수입니다. 중요한 것은 이 함수가 S자 모양 곡선을 생성한다는 것입니다. 예측을 해야 합니다. 여기에서 볼 수 있듯이 이를 더 많은 입력 변수로 확장하여 다차원 로지스틱 회귀를 생성할 수도 있습니다. 최대 우도 추정에 대해 간략히 설명하겠습니다. 작동 방식은 이러한 각 지점을 가져와 해당 우도를 곱하여 총 우도를 생성하는 것입니다. 베타를 찾아야 합니다. S자 모양 곡선이 이 모든 점을 생성할 가능성을 최대화하는 계수는 경사 하강법, 뉴턴의 방법 및 기타 최적화 기술을 사용하여 수행할 수 있습니다.

1.0에서 거짓 사례를 뺀 이유가 궁금할 수 있습니다. 거짓 사례를 양수로 처리하여 최대화해야 하기 때문입니다. 최대 우도 추정에 대해 자세히 설명하는 별도 비디오에서 이에 대해 다룰 것입니다. 별도 비디오에서 거짓 양성 및 거짓 음성을 처리하는 방법에 대해 설명하고 혼동 행렬을 예측 성능을 추적하는 도구로 사용할 수 있습니다. 시청해 주셔서 감사합니다.

로지스틱 회귀 개념

- 시그모이드 함수
 - 선형 회귀의 예측 값($Wx+b$)을 0과 1 사이의 확률로 변환해주는 함수



$$\sigma = \frac{1}{1 + e^{-z}} = \frac{1}{1 + e^{-Wx+b}}$$


손실 함수: 교차 엔트로피(Cross-Entropy)

- 왜 선형 회귀의 MSE를 사용하지 않을까?
 - 분류 문제에서 MSE를 사용하면 비용함수가 볼록함수가 아니게 됨
 - 그러면 경사 하강법이 전역 최소값을 찾지 못하고 지역 최소값에 갇힐 위험이 있음
 - 교차 엔트로피 함수
 - 분류 문제에 적용하면 항상 볼록 함수 형태를 가지는 비용 함수
- 이 교차 엔트로피 값이 가장 작아지는 W 와 b 를 찾는 게 목표!

손실 함수: 교차 엔트로피(Cross-Entropy)


- 동작원리 :

- : 정답을 1에 가깝게 예측하면 비용이 낮아지고
- : 오답을 1에 가깝게 예측하면 비용이 매우 높아짐



손실 함수: 교차 엔트로피(Cross-Entropy)

- 그래서 교차 엔트로피를 최소화하는 W 와 b 를 찾는 방법은? → 경사 하강법!



[실습] 사이킷런으로 로지스틱 회귀 모델 프로세스 따라가기

- 별도 자료 참고 : 반도체장비예지보전실무 01 실습02 로지스틱 회귀 기본형.pdf

[연습문제] 유방암 진단 예측

- 사이킷런이 제공하는 유방암 데이터셋 (load_breast_cancer)을 사용하여 로지스틱 회귀 모델을 직접 만들어보고 평가해 보세요.
- 데이터 로드, 전처리, 분할, 모델 훈련, 예측, 평가까지 모든 과정을 직접 수행해 보세요.

별도 자료 참고: ::반도체장비예지보전실무 01 연습문제02 유방암 진단 예측 실습가이드.pdf

불균형 데이터의 성능 평가

- 정확도 (accuracy) 만으로는 부족하다!
 - 데이터셋이 불균형할 때 (예: 정상 메일 99%, 스팸 메일 1%),
 - 모델이 모든 메일을 '정상'으로 예측해도 정확도는 99%
 - 하지만 실제 스팸 메일은 하나도 걸러내지 못하는 문제가 발생

성능 평가: 혼동 행렬(Confusion Matrix)

- 모델의 예측 결과를 실제 값과 비교하여 시각적으로 보여주는 표
- 분류 모델의 예측 성능을 평가하는 데 사용

		Predicted Class	
		P	N
Actual Class	P	True Positives (TP)	False Negatives (FN)
	N	False Positives (FP)	True Negatives (TN)

- TP/진양성 : 실제 양성, 예측 양성
- TN/진음성 : 실제 음성, 예측 음성
- FP/위양성 : 실제 음성, 예측 양성 (거짓 양성)
- FN/위음성 : 실제 양성, 예측 음성 (거짓 음성)

성능 평가: 혼동 행렬

- 정확도 (Accuracy)
 - 전체 중 정답을 맞춘 비율

$$Accuracy = \frac{TP + TN}{\text{전체}}$$

		Predicted Class	
		P	N
Actual Class	P	True Positives (TP)	False Negatives (FN)
	N	False Positives (FP)	True Negatives (TN)

- 불균형 데이터에서는 정확도 (accuracy) 만으로는 부족하다!
 - 데이터셋이 불균형할 때 (예: 정상 메일 99%, 스팸 메일 1%),
 - 모델이 모든 메일을 '정상'으로 예측해도 정확도는 99%
 - 하지만 실제 스팸 메일은 하나도 걸러내지 못하는 문제가 발생

성능 평가: 혼동 행렬

- 유방암 진단과 같은 문제에서 위양성과 위음성
 - FP (위양성): 실제로는 암이 아닌데 암이라고 진단하는 경우
 - : 환자에게 불필요한 공포와 추가적인 검사 비용을 발생시킴
 - FN (위음성): 실제로는 암인데 암이 아니라고 진단하는 경우
 - : 환자의 치료 시기를 놓치게 하여 생명을 위협할 수 있는 가장 치명적인 오류
- 정확도가 99%라도 모든 양성 사례를 놓치고 있다면(FN이 높다면) 쓸모가 없을 수 있음
- 문제의 특성에 따라 다른 평가 지표를 고려해야함.
- 혼동행렬을 통해 정확도만으로는 알 수 없는 정보를 제공받을 수 있음!

성능 평가: 혼동 행렬

- 정밀도(Precision)

- 맞다고 한 것 중 진짜 맞은 비율
- '양성'이라고 예측한 것들 중에서 실제로 '양성'인 비율

$$\text{정밀도} = \frac{TP}{TP + FP}$$

- FP(위양성)를 줄이는 것이 중요한 상황에서 평가 지표로 사용됨
 - : 스팸 메일: 스팸이 아닌 중요한 메일을 스팸으로 분류(FP)하면 사용자에게 불편을 줌
 - : 자율 주행: 보행자가 아닌 물체를 보행자로 잘못 인식(FP)하여 급정거하는 상황 등

		Predicted Class	
		P	N
Actual Class	P	True Positives (TP)	False Negatives (FN)
	N	False Positives (FP)	True Negatives (TN)

성능 평가: 혼동 행렬

- 재현율 (Recall)

- 실제 맞는 것 중 얼마나 찾아냈는가
- 실제 '양성'인 것들 중에서 모델이 '양성'이라고 예측한 비율

$$\text{재현율} = \frac{TP}{TP + FN}$$

- FN(위음성)을 줄이는 것이 중요한 상황에서 성능 지표로 사용
 - : 예) 유방암 진단, 금융 사기 탐지

		Predicted Class	
		P	N
Actual Class	P	True Positives (TP)	False Negatives (FN)
	N	False Positives (FP)	True Negatives (TN)

성능 평가: 혼동 행렬

- F1 Score
 - 정밀도와 재현율의 조화 평균
 - 정밀도와 재현율이 한쪽으로 치우치지 않고 모두 높은 값을 가질 때 높은 점수를 얻음

$$\text{F1-Score} = 2 \times \frac{\text{정밀도} \times \text{재현율}}{\text{정밀도} + \text{재현율}}$$

- 데이터셋에 클래스 불균형이 심할 때, 또는 정밀도와 재현율 모두 중요한 상황에서 모델의 성능을 하나의 숫자로 표현하고 싶을 때 유용

**머신러닝은 “얼마나 많이 맞췄는가” 보다
“무엇을 틀렸는가”가 더 중요하다**

평가 지표 정리

혼동 행렬 (Confusion Matrix)

		예측 (Prediction)	
실제 (Actual)	양성	TP True Positive (진짜 양성)	FP False Positive (가짜 양성/오진)
	음성	FN False Negative (가짜 음성/놓침)	TN True Negative (진짜 음성)

1. 정확도 (Accuracy)

전체 데이터 중에서 올바르게 예측한 비율
 $(TP + TN) / \text{전체}$

2. 정밀도 (Precision) - 스팸 메일

모델이 양성이라고 한 것 중 진짜 양성 비율
중요: 정상 메일을 스팸으로 분류하면 안 될 때 (FP 최소화)

3. 재현율 (Recall) - 암 진단

실제 양성 중에서 모델이 찾아낸 비율
중요: 실제 암 환자를 놓치면 안 될 때 (FN 최소화)

끝!