

연습문제: 유방암 진단 예측

문제 설명:

세포 핵의 디지털화된 이미지에서 추출한 특징들을 기반으로, 종양이 양성(Benign)인지 악성(Malignant)인지 예측하는 로지스틱 회귀 모델을 구축해 보세요. 이 문제는 실제 의료 분야에서 머신러닝이 어떻게 활용될 수 있는지 보여주는 좋은 예시입니다.

사용할 데이터셋:

sklearn.datasets 모듈에서 제공하는 load_breast_cancer 데이터를 사용합니다.

데이터의 주요 특성(Features):

세포 핵의 이미지에서 계산된 30가지 수치형 특징들입니다.

(예: 반지름, 질감, 둘레, 면적, 부드러움, 압축성 등)

- mean radius
- mean texture
- mean perimeter
- ... (총 30개)

타겟(Target):

- target: 종양의 종류 (0: 악성, 1: 양성)
 - **중요:** 이 데이터셋에서는 0이 '악성(Malignant)', 1이 '양성(Benign)'을 의미합니다. 일반적으로 '양성'을 긍정 클래스(Positive)로 두는 경우가 많으므로, 필요에 따라 타겟 값을 뒤집어 해석할 수도 있습니다. 여기서는 데이터셋의 기본값(0: 악성, 1: 양성)을 따르겠습니다.

단계별 연습 가이드

다음 단계를 따라가면서 로지스틱 회귀 모델을 구축하고 분석해 보세요. 각 단계에서 어떤 코드를 사용해야 할지, 무엇을 확인해야 할지 스스로 고민해 보는 것이 중요합니다.

단계 1: 데이터 로드 및 탐색

1. 데이터셋 로드:

- sklearn.datasets에서 load_breast_cancer 함수를 사용하여 데이터를 로드합니다.
- 로드된 데이터는 딕셔너리 형태이므로, data와 target 키를 사용하여 특성(X)과 타겟(y)을 분리합니다.
- feature_names를 사용하여 각 특성의 이름을 확인합니다.
- target_names를 사용하여 타겟 클래스의 이름을 확인합니다.

2. DataFrame으로 변환:

- pandas를 사용하여 특성(X)과 타겟(y)을 하나의 DataFrame으로 만듭니다. (이렇게 하면 데이터 탐색이 용이합니다.)

3. 데이터 기본 정보 확인:

- df.head(): 데이터의 상위 몇 행을 확인하여 데이터의 형태를 파악합니다.
- df.info(): 각 열의 데이터 타입, 결측치 여부, 전체 행 수 등을 확인합니다.
- df.describe(): 각 수치형 특성의 통계적 요약(평균, 표준편차, 최소/최대값 등)을 확인합니다.
- df['target'].value_counts(): 타겟 클래스(악성/양성)의 분포를 확인합니다. **클래스 불균형이 있는지 확인하는 것이 중요합니다.**
- **질문:** 이 데이터셋에 결측치(NaN)가 있나요? 있다면 어떻게 처리해야 할까요? (이 데이터셋은 결측치가 없습니다.)

단계 2: 데이터 전처리

1. 특성 스케일링 (Feature Scaling):

- 이 데이터셋의 특성들은 값의 범위가 매우 다릅니다.
(예: mean radius와 mean area는 스케일이 다름)
 - 로지스틱 회귀는 경사 하강법 기반의 모델이므로, 특성 스케일링이 모델의 수렴 속도와 성능에 영향을 미칠 수 있습니다.
 - sklearn.preprocessing의 StandardScaler를 사용하여 특성들의 스케일을 조정해 보세요.
 - **질문:** 왜 특성 스케일링이 필요한가요?
(경사 하강법의 효율성, 가중치 해석의 용이성 등과 연결하여 생각해 보세요.)
 - **주의:** StandardScaler는 훈련 데이터에 fit()하고, 훈련/테스트 데이터 모두에 transform()을 적용해야 합니다.
-

단계 3: 훈련 세트와 테스트 세트 분할

1. 데이터 분할:

- sklearn.model_selection의 train_test_split 함수를 사용하여 스케일링된 데이터를 훈련 세트와 테스트 세트로 나눕니다.
- test_size는 0.2 또는 0.3 정도로 설정하고, random_state를 고정하여 재현성을 확보합니다.
- **stratify=y 옵션을 반드시 사용합니다.** 분류 문제, 특히 클래스 불균형이 있을 수 있는 경우 각 클래스의 비율을 훈련/테스트 세트에 균등하게 분배하기 위함입니다.
- **질문:** 데이터를 훈련 세트와 테스트 세트로 나누는 가장 중요한 이유는 무엇인가요?
(모델의 일반화 성능 평가와 연결)

단계 4: 로지스틱 회귀 모델 훈련

1. 모델 객체 생성:

- `sklearn.linear_model`에서 `LogisticRegression` 클래스를 임포트하고 모델 객체를 생성합니다.
- `solver='liblinear'` (작은 데이터셋에 적합) 또는 `solver='lbfgs'` (기본값, 더 큰 데이터셋에 적합)를 지정할 수 있습니다.
- `random_state`를 설정하여 재현성을 확보합니다.
- `max_iter` (최대 반복 횟수)를 충분히 크게 설정하여 모델이 수렴하도록 합니다 (예: `max_iter=200` 또는 `1000`).

2. 모델 훈련:

- `fit()` 메서드를 사용하여 훈련 세트(`X_train_scaled`, `y_train`)로 모델을 학습시킵니다.
- **질문:** `fit()` 메서드 안에서는 어떤 과정이 일어난다고 설명했었죠? (교차 엔트로피를 최소화하는 경사 하강법을 통한 최적의 W 와 b 찾기)

3. 가중치(W)와 편향(b) 확인:

- `model.coef_`와 `model.intercept_`를 출력하여 학습된 모델의 가중치와 편향 값을 확인합니다.
- **질문:** 각 가중치(`model.coef_`)가 의미하는 바는 무엇일까요?
(해당 특성이 악성/양성 분류에 미치는 영향의 크기와 방향. 스케일링된 데이터이므로 가중치 크기 비교가 의미 있음.)

단계 5: 모델 예측 및 평가

1. 예측 수행:

- 훈련된 모델의 `predict()` 메서드를 사용하여 테스트 세트(`X_test_scaled`)에 대한 종양 종류를 예측합니다.
- `predict_proba()` 메서드를 사용하여 각 샘플이 각 클래스에 속할 확률도 예측해 봅니다.

2. 모델 평가 (핵심!):

- `sklearn.metrics`에서 `accuracy_score`, `precision_score`, `recall_score`, `f1_score`, `confusion_matrix`를 임포트합니다.
- 테스트 세트의 실제 값(`y_test`)과 예측 값(`y_pred`)을 사용하여 다음 지표들을 계산하고 출력합니다.
 - **정확도 (Accuracy):** 전체 예측 중 올바르게 예측한 비율.
 - **혼동 행렬 (Confusion Matrix):** `confusion_matrix(y_test, y_pred)`
 - `[[TN, FP], [FN, TP]]` 형태로 출력됩니다.
 - **중요:** 이 혼동 행렬을 보고 TP, TN, FP, FN 값을 직접 파악해 봅니다.
- **질문 (매우 중요!):**
 - 유방암 진단과 같은 의료 문제에서, **False Positive (FP)**와 **False Negative (FN)** 중 어떤 오류가 더 치명적일까요?
 - FP: 실제로는 양성(암 아님)인데 암이라고 오진. (불필요한 추가 검사, 심리적 고통)
 - FN: 실제로는 악성(암)인데 암이 아니라고 오진. (치료 시기 놓침, 생명 위협)

단계 6: 결과 해석 및 시사점 도출

1. 모델 해석:

- 학습된 가중치(model.coef_)와 해당 특성 이름을 매칭하여 다시 확인하며, 어떤 특성들이 악성/양성 진단에 가장 큰 영향을 미치는지 해석해 보세요.
- **질문:** 세포의 어떤 특징(예: 평균 반지름, 평균 질감 등)이 악성 종양을 예측하는 데 가장 중요한 요인으로 나타났나요?

2. 모델의 한계 및 개선 방향:

- 이 로지스틱 회귀 모델이 유방암 진단에 어떤 한계를 가질 수 있을까요?
(선형 결정 경계의 한계, 데이터의 복잡성 등)
- 모델의 성능을 더 높이기 위해 어떤 방법을 시도해 볼 수 있을까요?
(다른 모델 사용, 특성 공학, 더 많은 데이터 등)