

반도체장비예지보전실무 02

제조데이터 품질 관리

목차

REVIEW

1. 제조데이터 품질 관리
2. 제조데이터 품질확보 방법론
3. 실습 (1) : 품질 확보를 위한 데이터 전처리
4. ML 입문자를 위한 핵심 통계
5. 데이터 전처리
 - 5-(1) 결측치 처리 전략
 - 5-(2) 이상치 처리 전략
6. 실습 (2) : 전처리 심화_데이터 손실 최소화


REVIEW

제조 데이터 분석: 기술적 목적



유지보수 패러다임 변화

- 사후 유지보수 (Reactive Maintenance): 고장 발생 후 수리
- 예방 유지보수 (Preventive Maintenance): 정해진 주기에 따라 수리
- 예지 보전 (Predictive Maintenance): 데이터 분석을 통해 최적의 수리 시점 예측



예지 보전의 주요 작업 및 적합한 알고리즘

- 이상감지(상태 모니터링)
 - 작업 : 정상 작동 조건에서 크게 벗어나는 비정상적인 장비 동작을 식별
 - 알고리즘 : 군집화 알고리즘 (비지도 알고리즘)
- 고장 분류
 - 작업 : 특정 유형의 장비 고장(예: 베어링 고장, 전기 단락)을 분류하거나
: 이진 분류(예: 특정 기간 내에 고장이 발생할지 예측: " 고장 " 대 " 비고장 ")를 수행
 - 알고리즘 : 결정 트리, 랜덤 포레스트, SVM, 로지스틱 회귀 및 신경망이 널리 사용됨
- 잔여수명(RUL) 추정
 - 작업 : 장비 고장까지의 연속적인 시간(예: 시간, 주기)을 예측
: 이를 통해 유지보수를 정확하고 사전 예방적으로 계획할 수 있음
 - 알고리즘 : 회귀 모델(연속 값을 예측하는 데 적합)
: 더 전문화된 접근에서는 시간 데이터를 활용하기도 함

제조 데이터의 4가지 형태

숫자(numeric data)


[illegible]

(정의) 생산설비, 품질검사기계 및 계측장비 등 현장공장에서 제조활동을 통해 실시간 또는 주기별로 생성되는 수치형 제조데이터

(수집방법) IoT 센서, 설비 PLC, 생산
운영 시스템 인터페이스 등

예) 생산실적 데이터, 품질검사 데이터, 설비상태 데이터

이미지(image data)




(정의) 품질검사, 검사이력 등 생산성 및 품질 향상을 위해 카메라 또는 비전 장비로 촬영 및 수집된 픽셀의 행렬 제 조데이터

(수집방법) 비전 카메라, 스마트폰, 테블릿 PC 등

예) 제품 양품/불량품 판정 이미지 데이터

동영상(video data)




(정의) 생산현장 모니터링, 안전관리 등 제조현장을 관리하기 위한 목적으로 카메라를 통해 촬영 및 수집된 연속적인 이미지 시퀀스 데이터

(수집방법) 일반 카메라, 초고속 카메라, 열화상 카메라 등

예) 위험구역 촬영 데이터, 작업자 이상행동 촬영 데이터

소리(sound data)



(정의) 설비 이상 탐지, 제품 이상 탐지 등 생산성 향상 및 설비 가동률을 높이기 위해 제조현장에서 수집된 음파 형태의 데이터


(수집방법) 마이크, 산업용 청진기 센서, 디지털 음파 센서 등

예) 볼트체결 정상/이상 소리 데이터,
설비 이상 소리 데이터, 전력 변압기
이상 탐지 소음 데이터

1. 제조데이터 품질 관리

제조데이터셋

- 데이터 분석 및 AI를 훈련시키기 위해 제조현장에서 수집한 제조데이터의 집합체



<사출성형기 제조AI데이터셋 수집변수>

[출처: 인공지능 제조플랫폼(url:https://www.kamp-ai.kr/)]


[열] 제조물의 특성
- 컬럼 - 파라미터 - 속성 - 공정변수

No	고압사출시간(High Pressure Injection Time)	쿠션위치(Cushion Position)	스크류회전속도(Max. Screw RPM)	최대주입압력(Max. Injection Pressure)	재료주입온도(Hopper Temperature)
1	9.600000381	653.4099731	30.70000076	141.8000031	66.20000208
2	9.600000381	653.4099731	30.79999924	141.8000031	66.19999675
3	9.600000381	653.4099731	30.79999924	141.8000031	66.19999675
4	9.590000153	653.4199829	31	141.8000031	66.90000153
5	9.590000153	653.4199829	31	141.8000031	66.90000153
6	9.579999924	653.4099731	30.89999962	141.6999969	66.5
7	9.579999924	653.4099731	30.89999962	141.6999969	66.5
8	9.579999924	653.4099731	30.60000038	141.8000031	66
9	9.579999924	653.4099731	30.60000038	141.8000031	66
10	9.569999695	653.4099731	30.79999924	141.6000061	66.67999675
11	9.569999695	653.4099731	30.79999924	141.6000061	66.67999675
12				141.6000061	66
13				141.6000061	66
14				141.6999969	67
15				135.4898464	67
16				141.8000031	66.90000153
17				141.8000031	66.90000153
18		653.4099731	30.70000076	141.6999969	66.80000305
19	9.579999924	653.4099731	30.70000076	141.6999969	66.80000305
20	9.579999924	653.4099731	30.70000076	141.6999969	66.59999847
21	10.659	653.4099731	30.70000076	141.6999969	66.59999847
22	9.590000153	653.4099731	30.79999924	141.8000031	66.09999847
23	9.590000153	653.4099731	30.79999924	135.4898464	66.09999847
24	9.590000153	653.4099731	30.60000038	135.4898464	66.09999847
25	9.590000153	653.4099731	30.60000038	135.4898464	66.09999847
26	9.590000153	653.4099731	30.60000038	135.4898464	66.5
27	10.25	653.4099731	30.60000038	135.4898464	66.5
28	9.56000042	653.4099731	30.79999924	135.4898464	66.30000305
29	9.56000042	653.4099731	30.79999924	141.6000061	66.30000305
30	9.56000042	653.4199829	30.79999924	141.6999969	66
31	9.56000042	653.4199829	30.79999924	141.6999969	66
32	9.56000042	653.4099731	30.89999962	141.5	66.09999847
33	9.56000042	653.4099731	30.89999962	141.5	66.09999847

[행] -로우
- 제조물에 대한 제조데이터 샘플
- 사출성형물에 대한 전체 제조데이터는 33개의 샘플이 있음

<제조AI데이터셋의 기본적 구조 (예) 플라스틱 볼트 제조>

제조 현장에서 구축할 수 있는 데이터의 예시



<제조 AI데이터셋 구축범위>

데이터 품질이 왜 중요할까?

- 저품질 데이터로 인한 AI 적용 실패 사례


제조업종	저품질 제조데이터 활용 후 AI적용 실패사례
사출성형	사출성형업종 S사는 타발기의 칼(cutter) 최적 교체시점을 도출하기 위해 제조AI를 적용하였으나 제조데이터 전처리 및 정제 과정이 미흡하여 AI 솔루션 구축 및 현장 적용 실패
정밀가공	정밀가공업종 H사는 CNC 공구 마모 및 파손 불량 예지보전을 위하여 제조 AI를 적용하고자 하였으나 라벨(태그) 값과 연관성이 없는 제조데이터를 수집하고 활용하여 제조AI 모델 구축 실패
기계부품	기계부품업종 I사는 부품 체결기의 불량을 예측하기 위해 제조AI를 적용하였으나 중복값을 가지는 주요 변수들로 인해 제조AI 모델 성능이 낮아 현장 적용 실패

데이터 품질이 왜 중요할까?

- 데이터의 품질은 AI 모델의 성능과 직결된다.
 - 즉, 제조AI의 성능은 제조 데이터의 품질에 종속적이다.

Garbage In, Garbage Out

"품질이 낮은 데이터로는
아무리 복잡한 AI 모델을 사용하더라도
원하는 성과를 얻기 어렵다"



<고품질 제조데이터 선순환 사이클>

제조 데이터 품질 평가 지표



완전성 (Completeness)

데이터에 누락된 값이 없는지 여부



유효성 (Validity)

데이터의 값이 미리 정해진 규칙이나 범위에 부합하는지 여부 (예: 온도 0°C ~ 1000°C)



일관성 (Consistency)

데이터의 값이 서로 모순되지 않고 일관된 의미를 가지는지 여부



유일성 (Uniqueness)

중복된 데이터가 없는지 여부



정확성 (Accuracy)

데이터가 실제 현상을 얼마나 정확하게 반영하는지 여부

또 하나 필요한 것 : 데이터 표준

- 표준(Standard)이란?

- 정의: 여러 사람이 같은 방식으로 만들고, 사용하고, 해석할 수 있도록 정해 놓은 **공통 기준**
- 방법: 크기, 모양, 단위, 규격, 표현 방법 등을 미리 약속
- 장점: 제품이나 시스템이 서로 **호환**되도록 함

: 사용자마다 다르게 판단하거나 처리하는 일을 줄여 줌

예시	정해진 표준	표준이 있어서 좋은 점
A4 용지	210 × 297 mm	프린터, 복사기, 파일철 등에 동일하게 사용 가능
스테이플러 심	24/6, 26/6 등 규격	규격에 맞는 스테이플러와 심을 함께 사용할 수 있음
건전지	AA, AAA 등의 크기·전압 규격	제조사 가 달라도 같은 기기에 사용할 수 있음

→ **표준이 있으면 누가 만들고 사용하더라도 같은 규칙으로 연결될 수 있다**

또 하나 필요한 것 : 데이터 표준

- 공장 간 절차와 용어가 모두 다르게 되면 제조 데이터의 의미를 파악할 수 없음
 - 예: 같은 온도 데이터라도 아래와 같이 서로 다르게 기록한다면
 - : 설비 A : TEMP = 35.2
 - : 설비 B : Temperature = 308.35 K
 - : 설비 C : temp01 = "35.2℃"
 - 프로그램이 바로 통합해서 사용하기는 어려움.
- 공장간 느슨한 표준 사전을 만들어 *제조데이터 기반 협력을 강화*할 수 있음
- 데이터 표준을 적용하면 데이터 간에 *상호운용성을 확보*할 수 있음

표준 제조데이터 스크립트

- 데이터에 대한 설명 (metadata)
 - 이 데이터가 무엇인지 설명하는 데이터 명세서
- 제조데이터가
 - 어떤 목적으로, 누가, 언제,
 - 어떤 방식으로 수집했는지와
 - 각 변수의 이름, 의미, 척도,
 - 수집 방법, 수집 주기 등을 정리한
 - 데이터 정의·명세 문서

<표준 제조데이터 스크립트(예)>

[파일형식] 제공기업/기관명_데이터셋명_기준일자.hwp

파일명 : ㈜한국플라스틱_사출성형기_제조데이터셋_종합설명_20230911.hwp

기업명 : K-플라텍

업종 : 사출성형 (플라스틱)

공장 : 울산 제1공장

공정 : 플라스틱사출

설비명 : LS엠트론 (WIZ-E시리즈)

제조데이터 수집목적 : ① 제조데이터를 통한 생산이력 기록 ② AI분석을 통한 불량원인진단 분석

제조데이터 수집방법 :

사출압력(sensor), 사출시간(PLC), 사출속도 (PLC), 냉각수온도(sensor), 호퍼온도(sensor), 품질(inspection)

[제조데이터 표준 스크립트(표준사전)] ID, 변수명, 척도, 형태, 수집방법, 수집주기, 변수(속성)명, 범주값


헤더			바디					
ID	공정 변수명 (한글)	변수명 (프로 그램)	척도	형태	수집방법 (센서유형)	수집 주기	정의 / 내용	범주 값
A 1	사출 압력	Injection_ pressure	연속 형	float 64	설비 WIZ-E 의 압력센 서	1sec	설정된 속도에 따라 금형에 서 발생하는 압력에 대한 제 한 압력	-
A 2	사출 시간	Injection_ time	연속 형	dateti me	PLC 사출시간	1sec	공급 시간 및 유지 시간이 포 함	-
A 3	사출 속도	Injection_ speed	연속 형	float 64	PLC 사출속도	1sec	사출기의 노즐에서 사출되 는 수지의 속도	-
A 4	냉각수 온도	Water_ temperat ure	연속 형	float 64	설비 WIZ-E 의 온도센 서	1sec	냉각수의 정상적인 온도는 80~90℃	-
A 5	호퍼 온도	Hopper_ temperat ure	연속 형	float 64	설비 WIZ-E 의 온도센 서	1sec	원재료를 한 군데로 모아서 이송시켜주는 v자형 도구의 온도	-
A 6	품질	quality	명목 형	int64	육안 검사 결과	5min	제조물의 품질결정, 모델의 종속변수	'0' (양품) '1' (불량)

제조데이터 품질 확보와 표준

- 제조데이터 표준은 제조데이터 품질을 평가하는 비교 대상, 즉 평가 기준의 역할을 함


→ 제조데이터 표준을 준수하면

제조데이터 품질의 모든 지표관점에서
품질을 향상시킬 수 있다는 의미




<제조데이터 품질확보 방법론 수행 시, 표준의 적용>

제조데이터 표준의 활용 개념



※ 제조기업 A, B는 기업간 제조데이터 동일한 표준체계가 존재함을 가정



<제조데이터 표준을 통한 공유 · 연결의 범위> <WEF, 2020>

제조데이터 표준의 기대 성과

공동활용 성과	세부 내용
제조AI 모델 구축을 위한 부족한 제조데이터 수급 문제 공동해결	제조AI가 보다 많은 결함요소 이해
	보다 정확한 공동활용 제조AI 탄생
	설비운영 정밀도 향상
협력 제조기업 간 운영 효율성 향상	용어 명확화, 기업 간 업무중복 문제해소
	실시간성 기반 생산성 향상(실시간 공정관리)
	전사적 수요관리, 의사결정력 향상

제조 AI 개발 절차와 프로세스

🔧 개발 프로세스의 이해

- 제조 AI 개발은 데이터 기반의 체계적인 접근 필요
- 각 단계별 품질 확보가 최종 성능에 결정적 영향
- 현장 특성을 고려한 맞춤형 프로세스 설계 중요

📌 단계별 핵심 포인트

문제 정의	: 해결하려는 제조 문제의 명확한 정의와 목표 설정
데이터 수집	: 센서, 장비 로그, 검사 결과 등 다양한 데이터 확보
데이터 전처리	: 결측치 처리, 정규화, 표준화 등 분석 준비
모델 학습	: 적합한 AI 알고리즘 선택 및 최적화 진행
평가 및 검증	: 정확도, 신뢰성, 일관성 등 다각적 검증
현장 적용	: 지속적인 모니터링과 모델 업데이트 체계 구축

🔍 1. 문제 정의



🗄️ 2. 데이터 수집



🔹 3. 데이터 전처리



🧠 4. 모델 학습



✅ 5. 평가 및 검증



🏭 6. 현장 적용


2. 제조데이터 품질확보 방법론

제조데이터 품질 개요

- 제조데이터 품질의 정의
 - 제조데이터가 제조기업의 현장공장 문제해결 및 지속가능한 경영전략 발굴을 위해 솔루션 개발 및 분석에 활용되었을 때, 얼마나 목적에 부합하는지에 대한 가치 및 유용성을 의미
- 데이터 품질이 떨어지는 이유
 - 실제 공정에서 발생하는 제조데이터는 결측치, 이상치, Key값의 중복, 실제 공장과의 이질현상 등이 발생할 가능성이 존재함

→ 전처리를 통해 원시 데이터를 걸러 양질의 제조데이터를 확보해야 함

제조데이터 품질확보 방법론 (Manufacturing Data Quality Assurance Methodology)



<제조데이터 품질확보 방법론MDQAM>
KAIST 제조AI빅데이터센터, 2024

제조데이터 품질확보 방법론 (Manufacturing Data Quality Assurance Methodology)

완전성 Completeness	필요한 모든 속성과 값이 누락 없이 포함되어 있는 수준
유효성 Validity	데이터 값이 정해진 유효 범위, 도메인을 충족하는 정도
일관성 Consistency	데이터 값이 동일한 구조, 값, 표현 형태로 저장되고 있는 정도
유일성 Uniqueness	데이터 값이 중복 없이 독립적인 값으로 저장하고 있는 정도
정확성 Accuracy	데이터 값이 실제 존재하는 객체의 표현 값을 정확하게 반영하는 정도

제조데이터 품질확보 방법론 (Manufacturing Data Quality Assurance Methodology)

STEP	품질평가 지표	품질평가 내용	품질평가 지수 불량 제조데이터가 발생할 수 있는 상황
1	완전성 (Completeness)	필수 제조데이터 항목에 누락이 없어야 한다.	$q1 = (1 - (\text{결측치 수} / \text{전체 제조 데이터 수})) * 100$
2	유효성 (Validity)	제조데이터는 제조현장의 도메인을 반영한 관리범위 내에 존재해야 한다.	$q2 = (\text{유효성 만족 데이터 수} / \text{STEP ① 전처리 후 제조 데이터 수}) * 100$
3	일관성 (Consistency)	표준 제조데이터 스크립트가 제시하는 통일된 속성규칙을 가져야 한다.	$q3 = (\text{일관성 만족 데이터 수} / \text{STEP ② 전처리 후 제조 데이터 수}) * 100$
4	유일성 (Uniqueness)	제조데이터의 키값은 중복 없이 독립적인 값을 가져야 한다.	$q4 = (1 - (\text{중복 데이터 수} / \text{STEP ③ 전처리 후 제조 데이터 수})) * 100$
5	정확성 (Accuracy)	제조데이터는 실제 제조현장 의 공정상황을 반영해야 한다.	$q5 = (1 - (\text{정확성 위배 데이터 수} / \text{STEP ④ 전처리 후 제조 데이터 수})) * 100$


제조데이터 품질확보 방법론 (Manufacturing Data Quality Assurance Methodology)

- 제조데이터 품질지수 (MDQI, Manufacturing Data Quality Index)
 - 5개의 지표별 품질평가 지수를 통합하여 제조데이터 품질지수를 도출함

제조데이터 품질지수 (MDQI, Manufacturing Data Quality Index)	• 제조데이터 품질을 5가지 평가지표로 통합 평가한 스코어(수치)를 백분율(%)로 나타낸 결과입니다. • 백분율이 높을수록 품질이 좋은 것을 나타냅니다.	
제조데이터 품질지수 도출식 (MDQI, Manufacturing Data Quality Index)	정의 5가지 품질지수의 평균값	
	$MDQI = (\sum_{i=1}^5 q_i / 5) * 100$	Q : 종합 품질평가 지수 q : 품질평가 지표별 지수 항목 i : q1, q2, q3, q4, q5

제조데이터 품질확보 방법론 (Manufacturing Data Quality Assurance Methodology)

- 제조데이터 품질지수 (MDQI, Manufacturing Data Quality Index)



<출처 : KAIST 제조AI빅데이터센터>

Q. 지표와 지수는 무엇일까요?

지표(criterion)란 어떤 것을 측정하거나 판단(결정)하기 위한 기준입니다. 그리고 지수(index)란 하나 또는 여러 지표들을 측정한 후 각각을 합산하거나 가중치를 두어 연산하는 과정을 거친 객관적인 수치(score)입니다. 예를 들면 지표는 자나 각도기, 지수는 그 눈금값을 의미합니다. 마찬가지로 제조AI데이터셋이 가치 있게 활용될 수 있을지 품질 수준을 진단하기 위해서는 '제조AI데이터셋 품질평가 지표'를 알아야 합니다. 제조AI데이터셋 품질평가 지표란 제조AI데이터셋의 품질 수준을 측정하는 도구를 의미합니다. 그리고 제조AI데이터셋 품질평가 지수란 달성하려는 품질평가 지표별 수식에 맞추어 현재의 제조AI데이터셋의 품질 수준을 정량화한 숫자입니다.



제조AI데이터셋
품질평가 지표
(Criteria)

제조AI데이터셋의 품질 수준을 측정하는 도구
ex) 자, 각도기

제조AI데이터셋
품질평가 지수
(Index)

제조AI데이터셋의 품질평가 지표별 수식에 맞추어
제조AI데이터셋의 품질수준을 정량화한 숫자
ex) 자의 눈금, 각도기의 눈금

<제조데이터 품질평가 지표와 지수의 개념>

3. 실습 (1)

: 품질 확보를 위한 데이터 전처리


화학물 제조공장 현장 문제 파악

- 울산에 있는 화학물 제조기업 K사는 접착제를 완제품으로 생산함
- 특정 공정에서 유해물질이 발생하는 공정이 존재
- 해당 공정에 문제 발생 시, 양품과 불량률을 자동으로 알려주는 머신러닝 모델이 필요



화학물 제조공장 현장 문제 파악


- 데이터 수집 전략
 - 대상 공정의 설비인 교반기에 IoT 센서를 부착
 - 온도, 점도를 수집하고 양품일 때와 불량일 때를 구분



화학물 제조를 위한 교반기



온도, 점도 센서



실습 데이터셋 개요

업종	화학
제조AI데이터셋 요약	접착제 제조공정에서 수집한 제조데이터 집합체
전처리 교육용 제조AI데이터셋 이름(포맷)	Chemical_Numeric_Data_Quality.csv
제조AI데이터셋 위치	KAMP 제조데이터 라이브러리 → MARKET PLACE → 교육용 전처리 제조AI데이터셋 → 다운로드
제조AI데이터셋 형태 및 수집방법	• 분석에 사용된 변수명 : Lot, Temp(°C), Viscosity(cP), Failure, Failure code • 제조AI데이터셋 수집방법 : 교반기 온도, 점도 센서 • 제조AI데이터셋 파일 확장자 : csv
제조데이터 개수	1,000개 세트(전체 5,000개)
제조AI데이터셋 총량	24KB
라이선스	(주)에이비에이치
제조AI데이터셋 출처	(KAMP 제조데이터 라이브러리) url: mdata.kamp-ai.kr/product/detail/425

표준 데이터셋 스크립트

- 특성 X : 온도, 점도
- 타겟 y : 양품/불량 유무
- 구분: 지도학습 >> 분류
 - K-최근접 이웃
 - 로지스틱 회귀
 - 결정트리
 - 서포트 벡터 머신

헤더		바디			
No	변수명	척도	유형 타입	변수 설명	속성/범주값
1	Lot	범주형	int64	일정 단위로 생산된 화학물의 고유번호	정수 11자리
2	Temp(°C)	연속형	float64	교반기 내 화학물 용액의 온도	범위 : 20~60°C, 소수점 2자리
3	Viscosity(cP)	연속형	float64	교반기 내 화학물 용액의 점도	범위 : 0~60cP, 소수점 2자리
4	Failure	범주형	int64	화학물 품질 정상/불량 여부	0 : 정상, 1 : 불량
5	Failure code	범주형	object	화학물 품질 불량 시 불량 유형	1 : 불량 유형1, 2 : 불량 유형2, 3 : 불량 유형3, 4 : 불량 유형4, 5 : 불량 유형5

STEP ① 완전성 지표

- 전체 제조데이터의 결측치missing value가 없는 정도로 평가

결측치
(missing value)

- 제조데이터가 입력되지 않은 값을 의미
- 제조AI 모델 성능과 제조데이터 품질을 저해하는 원인

- 완전성 품질 지수

$$\text{완전성 품질 지수} = \left(1 - \frac{\text{결측치 수}}{\text{전체 데이터 수}}\right) \times 100$$

- 완전성 품질 지수 > 90% 이면, YES를 충족

STEP ① 완전성 지표

- 1000개의 샘플과 5개의 공정변수로 이루어져 있음
 - Lot번호, 온도, 점도, 양품/불량 라벨, 불량 원인 코드

	Lot	Temp(* C)	Viscosity(cP)	Failure	Failure code
0	2110262249	24.44	101.80	1	2
1	2109975633	23.95	82.63	1	None
2	2109024936	23.24	1.52	1	4
3	2110009104	NaN	81.49	1	None
4	2109169908	23.33	71.92	1	None
...	...	...	...	...	...
995	2110447898	23.38	NaN	0	None
996	2109846324	23.31	NaN	0	None
997	2109194716	23.28	NaN	0	None
998	2109416608	23.28	NaN	0	None
999	2110343258	NaN	NaN	0	5
1000 rows × 5 columns					

STEP ① 완전성 지표

- 결측치 확인 방법

직접 해보는 손코딩

```
data.isnull().sum()
```

Lot	0
Temp(° C)	130
Viscosity(cP)	89
Failure	0
Failure code	0
dtype: int64	

$$\text{완전성 품질 지수} = \left(1 - \frac{\text{결측치 수}}{\text{전체 데이터 수}}\right) \times 100 = \left(1 - \frac{209}{1000}\right) \times 100 = 79.1\%$$

STEP ① 완전성 지표

- 결측치 처리 방법

```
data.dropna(how = 'any', axis = 0, inplace = True)  
data
```

	Lot	Temp(^ C)	Viscosity(cP)	Failure	Failure code
0	2110262249	24.44	101.80	1	2
1	2109975633	23.95	82.63	1	None
2	2109024936	23.24	1.52	1	4
4	2109169908	23.33	71.92	1	None
5	2109027362	25.96	2.36	불량	4
...	...	...	...	...	...
951	2111214194	27.10	41.05	불량	None
961	2111224103	24.05	42.45	1	None
975	2111247872	23.50	2.04	정상	None
980	2111256812	44.22	51.68	불량	None
986	2111262910	24.19	1.29	1	2

791 rows x 5 columns

$$\text{완전성 품질 지수} = \left(1 - \frac{0}{791}\right) \times 100 = 100\%$$

STEP ② 유효성 지표

- 데이터의 관리 범위를 기반으로 유효범위 밖, 즉 **이상치(outlier)**를 파악해야 함

- 유효성 품질지수

$$\text{유효성 품질 지수} = \left(1 - \frac{\text{이상치 수}}{\text{전체 데이터 수}}\right) \times 100 = \frac{\text{유효성 만족 데이터 수}}{\text{전체 데이터 수}} \times 100$$

STEP ② 유효성 지표

- 유효성 지표를 확인하기 위해서는 제조기업의 도메인 지식이 필요함
- 해당 회사는 온도[Temp(°C)]와 점도[Viscosity(cP)]가 주요 관리 포인트
 - 관리범위: $20^{\circ}\text{C} \leq Temp \leq 30^{\circ}\text{C}$ $Viscosity \leq 3cP$
 - 이상치: $Temp < 20^{\circ}\text{C}$ or $Temp > 30^{\circ}\text{C}$ or $Viscosity > 3cP$

STEP ② 유효성 지표

- 이상치 확인

직접 해보는 손코딩

```
conditions = ((data['Temp(°C)'] < 20)) | ((data['Temp(°C)'] > 30)) | ((data['Viscosity(cP)'] > 3))
```

직접 해보는 손코딩

```
outlier = data[conditions]  
outlier
```


STEP ② 유효성 지표

- 이상치 확인
 - 296개의 샘플에 이상치 존재

	Lot	Temp(° C)	Viscosity(cP)	Failure	Failure code
0	2110262249	24.44	101.80	1	2
1	2109975633	23.95	82.63	1	None
4	2109169908	23.33	71.92	1	None
6	2109032490	54.11	2.10	정상	None
7	2109332619	24.39	71.14	1	None
...	...	...	...	...	...
938	2111185019	26.36	3.01	정상	None
947	2111211907	23.61	3.55	정상	None
951	2111214194	27.10	41.05	불량	None
961	2111224103	24.05	42.45	1	None
980	2111256812	44.22	51.68	불량	None

296 rows × 5 columns

유효성 품질 지수 = $\left(1 - \frac{296}{791}\right) \times 100 = 62.5\%$

STEP ② 유효성 지표

- 이상치 처리

```
data.drop(outlier.index, axis = 0, inplace = True)
data
```

	Lot	Temp(° C)	Viscosity(cP)	Failure	Failure code
2	2109024936	23.24	1.52	1	4
5	2109027362	25.96	2.36	불량	4
25	2109078504	23.37	2.81	불량	None
58	2109138516	24.87	1.34	불량	2
73	2109175382	27.14	1.59	정상	4
...	...	...	...	...	...
922	2111152172	26.45	1.59	정상	None
942	2111191949	27.16	1.52	불량	5
944	2111207472	23.30	1.61	정상	None
975	2111247872	23.50	2.04	정상	None
986	2111262910	24.19	1.29	1	2
495 rows × 5 columns					

STEP ③ 일관성 지표

- 표준 스크립트에 규정된 공정변수의 형태_{type}와 실제 수집된 제조데이터의 형태_{type}가 일치하는지를 평가

스크립트 규정유형 ≠ 수집 제조데이터 유형

- 일관성 품질 지수

$$\text{일관성 품질 지수} = \frac{\text{일관성 만족 데이터 수}}{\text{전체 데이터 수}} \times 100$$

STEP ③ 일관성 지표

- 자료형(type) 확인

No	변수명	척도	유형 (타입)	변수 설명	속성/범주값
1	Lot	범주형	int64	일정단위로 생산된 화학물의 고유번호	정수 11자리
2	Temp(°C)	연속형	float64	교반기 내 <u>화학물</u> 용액의 온도	범위 : 20 ~ 60°C, 소수점 2자리
3	Viscosity(cP)	연속형	float64	교반기 내 <u>화학물</u> 용액의 점도	범위 : 0~60cP, 소수점 2자리
4	Failure	범주형	int64	화학물 품질 정상/불량 여부	0 : 정상, 1 : 불량
5	Failure code	범주형	object	화학물 품질 불량시 불량 유형	1 : 불량유형1, 2 : 불량유형2, 3 : 불량유형3, 4 : 불량유형4, 5 : 불량유형5

<표준 제조데이터 스크립트>

```
Lot int64
Temp float64
Viscosity float64
Failure object
Failure code object
dtype: object
```

<품질평가 결과>

STEP ③ 일관성 지표

- 자료형 일치 처리 ① Failure 열에 어떤 값이 들어가 있는지 확인

직접 해보는 손코딩

```
data['Failure'].value_counts()
```

```
0      412
정상    45
1       33
불량     5
Name: Failure, dtype: int64
```

STEP ③ 일관성 지표

- 자료형 일치 처리 ② 범주형 데이터 인코딩 → 숫자형으로 맞춰주기

직접 해보는 손코딩

```
data.loc[data['Failure'] == '정상', 'Failure'] = 0
data.loc[data['Failure'] == '불량', 'Failure'] = 1
data = data.astype({'Failure': 'int'})
data.dtypes
```

Lot	int64
Temp(* C)	float64
Viscosity(cP)	float64
Failure	int64
Failure code	object
dtype: object	

STEP ④ 유일성 지표

- 제조AI데이터셋 내 '제조데이터 중복값(redundant value)에 의한 오류'가 있는지를 평가

중복값
(redundant value)

- 2개의 이상의 동일한 값이 저장된 상태
- 식별자 변수는 반드시 1개의 값 만을 가지고 있어야 함

- 유일성 품질 지수

$$\text{유일성 품질 지수} = \frac{\text{유일성 만족 데이터 수}}{\text{전체 데이터 수}} \times 100$$

STEP ④ 유일성 지표

- 본 제조기업은 LoT 번호의 중복이 제조물의 유일성 훼손에 가장 큰 영향을 미친다 함
 - LoT 번호가 중복되면 식별이 안되는 문제가 발생하기 때문
- 중복값 확인하기: value_counts()

```
data['Lot'].value_counts()
```

```
2109811675    5
2110753363    4
2110212078    4
2110092816    3
2110595295    3
```

```
..
2109289585    1
2109903772    1
2109351191    1
2111154459    1
2111247872    1
```

```
Name: Lot, Length: 455, dtype: int64
```


STEP ④ 유일성 지표

- 중복값 처리: `drop_duplicates`
 - `keep = 'first'` 옵션으로 중복값 중 첫 번째 값은 제거하지 않음

직접 해보는 손코딩

```
data = data.drop_duplicates(['Lot'], keep = 'first')
```

```
data['Lot'].value_counts()
```

```
2109024936    1
2109403580    1
2110650664    1
2110253033    1
2110649000    1
...
2111030346    1
2111212392    1
2110066067    1
2110477211    1
2111247872    1
Name: Lot, Length: 455, dtype: int64
```

STEP ④ 유일성 지표

- 유일성까지 확보 후 데이터 확인

	Lot	Temp(* C)	Viscosity(cP)	Failure	Failure code
2	2109024936	23.24	1.52	1	4
5	2109027362	25.96	2.36	1	4
25	2109078504	23.37	2.81	1	None
58	2109138516	24.87	1.34	1	2
73	2109175382	27.14	1.59	0	4
...	...	...	...	...	...
910	2111216272	25.09	0.74	0	None
911	2109108579	24.03	0.74	0	None
922	2111152172	26.45	1.59	0	None
944	2111207472	23.30	1.61	0	None
975	2111247872	23.50	2.04	0	None

455 rows × 5 columns

참고: 중복 데이터 제거 방법

```
# 중복 데이터 확인
df.duplicated().sum() # duplicated() 중복된 행에 True를 반환

#df.duplicated()
```

np.int64(1)

```
# 중복 데이터 출력
df[df.duplicated()]
```

```
#df.loc[df.duplicated(), :] # 불리언 인덱싱
```

	sepal_length	sepal_width	petal_length	petal_width	Target
142	5.8	2.7	5.1	1.9	2

코드에 사용된 예제는 iris_classification

```
# 중복 데이터 모두 출력
# df.loc[(df.sepal_length==5.8)&(df.petal_width==1.9), :]

df[(df.sepal_length==5.8)&(df.petal_width==1.9)]
```

	sepal_length	sepal_width	petal_length	petal_width	Target
101	5.8	2.7	5.1	1.9	2
142	5.8	2.7	5.1	1.9	2

```
# 중복 데이터 제거
df = df.drop_duplicates()

#df.loc[(df.sepal_length==5.8)&(df.petal_width==1.9), :]
df[(df.sepal_length==5.8)&(df.petal_width==1.9)]
```

	sepal_length	sepal_width	petal_length	petal_width	Target
101	5.8	2.7	5.1	1.9	2

STEP ⑤ 정확성 지표

- 제조데이터가 실제 제조현장을 정확히 반영하는가를 평가
 - 표준 제조데이터 스크립트의 규칙을 적용하여 '정확성 위배상황'을 확인
- 정확성 품질 지수

$$\text{정확성 품질 지수} = \left(1 - \frac{\text{정확성 위배 데이터 수}}{\text{전체 데이터 수}} \right) \times 100$$

STEP ⑤ 정확성 지표

- 본 제조기업의 제조 스크립트에서 아래의 경우 정확성이 없다고 판단함
 - 정상인데 Failure code 변수에 값이 있는 경우
 - 불량인데 Failure code 변수에 값이 없는 경우

No	변수명	척도	유형 (타입)	변수 설명	속성/범주값
1	Lot	범주형	int64	일정단위로 생산된 화학물의 고유번호	정수 11자리
2	Temp(*C)	연속형	float64	교반기 내 <u>화학물</u> 용액의 온도	범위 : 20 ~ 60°C, 소수점 2자리
3	Viscosity(cP)	연속형	float64	교반기 내 <u>화학물</u> 용액의 점도	범위 : 0~60cP, 소수점 2자리
4	Failure	범주형	int64	화학물 품질 정상/불량 여부	0: 정상, 1: 불량
5	Failure code	범주형	object	화학물 품질 불량시 불량 유형	1: 불량유형1, 2: 불량유형2, 3: 불량유형3, 4: 불량유형4, 5: 불량유형5

<표준 제조데이터 스크립트>

표준 스크립트와 일치 X
- 정상(0)인데 불량코드 존재

Temp(* C)	Viscosity(cP)	Failure	Failure code
27.14	1.59	0	4
24.87	1.34	1	2
27.14	1.59	0	None
25.96	2.75	1	None

표준 스크립트와 일치 X
- 불량(1)인데 불량코드 없음

<품질평가 결과>

STEP ⑤ 정확성 지표

- CASE ① 정상인데 Failure code 변수에 값이 있는 경우
 - Failure 값이 0이고 Failure code가 None이 아닌 샘플
 - Failure 가 아닌 데이터의 Failure code를 None으로 변경

직접 해보는 손코딩

```
ok_data = data[(data['Failure'] == 0) & (data['Failure code'] != 'None')]
```

```
data.loc[ok_data.index, 'Failure code'] = 'None'
```

- 인덱스 : `ok_data.index`
- 변수(열) : `'Failure code'`
- 변경할 값 : `'None'`

STEP ⑤ 정확성 지표

- CASE ② 불량인데 Failure code 변수에 값이 없는 경우
 - Failure 값이 1이고 Failure code가 None인 샘플
 - 제조물이 불량임에도 불량값이 없는 제조데이터 샘플을 삭제
 - : 해당 공장은 불량원인 코드를 역추적하기 힘들 상황이므로, 삭제

직접 해보는 손코딩

```
ng_data = data[(data['Failure'] == 1) & (data['Failure code'] ==  
      'None')]
```

```
data.drop(ng_data.index, axis = 0, inplace = True)
```

- 인덱스 : ng_data.index
- '행' 기준 : axis = 0
- 기존 제조데이터 덮어쓰기²⁷ 여부 : inplace = True

MDQAM 수행 후 제조데이터셋

	Lot	Temp(* C)	Viscosity(cP)	Failure	Failure code
2	2109024936	23.24	1.52	1	4
5	2109027362	25.96	2.36	1	4
58	2109138516	24.87	1.34	1	2
73	2109175382	27.14	1.59	0	None
82	2109201022	26.16	2.01	1	5
...	...	...	...	...	...
910	2111216272	25.09	0.74	0	None
911	2109108579	24.03	0.74	0	None
922	2111152172	26.45	1.59	0	None
944	2111207472	23.30	1.61	0	None
975	2111247872	23.50	2.04	0	None

449 rows × 5 columns

MDQAM 수행 후 제조데이터셋

	individual 품질평가	MDQAM 품질평가	MDQAM 활용 품질확보
완전성(q1)	79.1%	79.1%	100%
유효성(q2)	49.5%	62.6%	100%
일관성(q3)	82.4%	89.9%	100%
유일성(q4)	86.9%	91.9%	100%
정확성(q5)	79.2%	90.3%	100%
전체 지수Q	75.4%	82.8%	100%

- 제조 AI의 정확도 향상을 견인하는 제조AI데이터셋 품질이 확보됨
- 전반적인 신뢰성을 보장할 수 있는 상태가 됨

실습: 전처리가 완료된 데이터셋으로 모델링을 해보자.

〈문제 정의〉

- 특성 X : 온도, 점도
- 타겟 y : 양품/불량 유무
- 구분: 지도학습 >> 분류

1. 로지스틱 회귀 모델을 사용하여 이진 분류 모델을 학습시켜보세요.
2. 학습 후 모델의 성능을 평가하세요. (정확도 사용)
3. 과적합/과소적합 유무를 확인하세요.




4. ML 입문자를 위한 핵심 통계

머신러닝 입문자를 위한 핵심 통계




- 머신러닝은 데이터를 통해 학습하고 예측하는 강력한 도구
- 이 도구를 제대로 활용하려면 데이터 자체를 이해하는 것이 중요
- 데이터를 이해하는 가장 기본적인 언어가 바로 '통계'

데이터의 '대표 얼굴' 찾기: 중심 경향성

- 데이터의 중심을 나타내는 값은 무엇일까?
 - 평균(Mean): 모든 값을 더해서 개수로 나눈 값.
 - 중앙값(Median): 데이터를 크기 순으로 쭉 나열했을 때,
정확히 가운데에 있는 값
 - 최빈값(Mode): 데이터에서 가장 자주 나타나는 값



데이터의 '대표 얼굴' 찾기: 중심 경향성


	최빈치(mode)	중앙치(median)	산술평균(mean)
의미	가장 빈번하게 나타나는 값 	자료를 크기 순으로 나열했을 때, 중앙에 위치하는 값 	자료를 모두 더해서 자료의 개수로 나눈 값 
특징	명목자료에서는 최빈치가 대푯값이다.	서열자료의 경우 평균을 사용할 수 없으므로 중앙치를 사용한다.	- 일부 극단적인 값들에 크게 영향을 받는다. - 수학적인 연산에 의해 계산되므로 수학적인 조작이 용이하다.
예	유행하는 가방 인기 투표	학교 석차 100명 중 50 등	년간 평균 강우량 기말 고사 평균 점수

데이터는 얼마나 '퍼져' 있니? - 산포도

- 데이터가 중심 주변에 얼마나 모여 있는지, 아니면 넓게 퍼져 있는지를 나타냄
- 분산 (Variance)
 - 각 데이터가 평균으로부터 얼마나 떨어져 있는지를 '제공'해서 평균 낸 값
- 표준편차(Standard Deviation)
 - 분산에 제곱근을 취한 값
 - 데이터가 평균으로부터 '평균적으로' 얼마나 떨어져 있는지를 원래 데이터의 단위로 나타냄

데이터는 어떤 '모양'을 하고 있니? - 확률 분포


- 확률분포: 데이터가 특정 패턴을 따르는 경향
- 정규 분포 (Normal Distribution)
 - 데이터가 평균을 중심으로 대칭적으로 분포하고, 가운데가 모양(Bell Curve)의 확률 분포
 - 자연현상, 시험점수, 신체지수 등 많은 실세계 데이터가 근,
 - 많은 머신러닝 알고리즘이 데이터가 정규 분포를 따른다고
- 표준정규분포 (Standard Normal Distribution)
 - 평균 $\mu=0$, 표준편차 $\sigma=1$
 - Z-score로 변환하면 어떤 정규분포든 표준정규분포가 됨




데이터 속 특이점 : 이상치 (Outliers)

- 다른 데이터 포인트들과 비교했을 때, 극단적으로 동떨어져 있는 값을 의미


Negatively-Skewed



Symmetrical



Positively-Skewed



Drhongdatanote.tistory.com

데이터 속 특이점 : 이상치 (Outliers)

- 어떻게 처리할까?
 - 제거: 이상치가 명백한 오류일 경우 데이터를 삭제. 데이터 손실이 발생할 수 있음
 - 변환: 로그 변환 등을 통해 이상치의 영향을 줄임
 - 대체: 이상치를 평균, 중앙값 등 다른 값으로 대체
 - 모델 선택: 이상치에 덜 민감한 모델(예: 트리 기반 모델)을 사용
 - 분리: 이상치 그룹을 따로 분석하거나, 이상치를 다루는 특화된 모델을 사용하기도 함

데이터 스케일

- 스케일(Scale)
 - 머신러닝에서 스케일(Scale)은 데이터가 가지고 있는 값의 크기 범위를 의미
 - : 키 데이터: 보통 150cm ~ 190cm 사이의 값. (단위: cm)
 - : 소득 데이터: 연봉 3천만 원 ~ 1억 원 이상까지, 값의 범위가 매우 클 수 있음. (단위: 원)
 - : 시험 점수: 0점 ~ 100점 사이의 값 (단위: 점)
 - 머신러닝 모델은 데이터의 스케일에 민감한 경우가 많음.



데이터 스케일링

- 스케일링(Scaling)
 - 각 데이터(또는 특성, Feature)의 스케일을 맞춰주는 것
- 왜 필요?
 - 값 범위가 큰 특성의 과도한 영향력
 - 경사 하강법 기반 모델의 학습 속도 및 수렴
 - 거리 기반 알고리즘의 민감성
- 어떻게 맞추나? '정규화'와 '표준화'

데이터 스케일링 - 정규화와 표준화

정규화 (Normalization)


- 최솟값 0, 최댓값 1로 바꾸어 모든 특성이 동일한 스케일을 갖도록 함
- 사용 목적: 각기 다른 단위의 특성(feature)을 같은 기준으로 맞춰 줌



데이터 스케일링 - 정규화와 표준화

표준화 (Standardization)

- 평균 0, 표준편차 1이 되도록 변환 (Z-점수 변환)
- 각 데이터 포인트가 평균으로부터 표준편차의 몇 배만큼 떨어져 있는지를 나타냄.



데이터 스케일링 - 정규화와 표준화

- 사이킷런에서 정규화: MinMaxScaler

```
from sklearn.preprocessing import MinMaxScaler
X = np.array([[1], [2], [3], [4], [5]])
scaler = MinMaxScaler()
X_norm = scaler.fit_transform(X)
print(X_norm.ravel()) # 결과: [0.  0.25 0.5  0.75 1.  ]
```

- ```
from sklearn.preprocessing import StandardScaler
scaler = StandardScaler()
X_std = scaler.fit_transform(X)
print(X_std.ravel()) # 결과: 평균 0, 표준편차 1이 되도록 변환
```

# 통계 참고자료

---

- 통계 개념 : 기술통계와 추리통계
  - <https://ikcoo.tistory.com/74>
- 3Blue1Brown 한국어
  - <https://www.youtube.com/@3Blue1BrownKR>
- 정승제의 확률과 통계 유튜브
  - <https://youtube.com/playlist?list=PLEM1jVr2P8dKqfeLdP7IZ5HzdBqnTbos7&si=MAAs9lgxQlEi2oIKH>



## **5-(1). 결측치 처리 전략**

# 결측치(Missing Value)

---

- 결측치 찾아내는 방법
  - NumPy 데이터 유형의 경우, np.nan이 누락된 데이터를 나타냄
  - df.isnull() / df.isna() : 결측치 위치에 True를 반환하는 DataFrame을 생성
  - df.isnull().sum() : 열(Column)별 결측치 개수 # 가장 일반적인 방법

---

```
각 열의 결측치 개수 확인
df.isnull().sum()
```

---

# 결측치 처리 전략 1: 제거 (dropna)

---

- `df.dropna()`: 결측치가 하나라도 있는 행을 모두 제거.
  - `axis=0` 옵션: 결측치가 있는 행을 제거.
  - 언제 사용하는가?
    - : 데이터가 충분히 많고,
    - : 결측치가 있는 행의 비율이 낮을 때.
    - : 또는 특정 열이 거의 다 비어있을 때.

```
data.dropna(how = 'any', axis = 0, inplace = True)
data
```

# 결측치 처리 전략 2: 채우기 (fillna)

---

- `df.fillna(0)`: 특정 값으로 채우기
  - `df['Age'].fillna(df['Age'].mean())`:
    - : 다른 값(평균, 중앙값, 최빈값 등)으로 채우기. → 가장 일반적인 결측치 처리 방법
  - 어떤 값으로 채울까?
    - : 숫자형 데이터: 평균(mean) 또는 중앙값(median).
    - : 범주형 데이터: 최빈값(mode).

# 결측치 처리 전략 2: 채우기 (fillna)

---

- `df.fillna(0)`: 특정 값으로 채우기

---

```
age 열의 결측치를 age 열의 평균값으로 채우기
mean_age = df['age'].mean()
df['age'].fillna(mean_age, inplace=True)
```

```
print(f"age 열의 평균값: {mean_age:.2f}")
```

---

```
embarked 열의 최빈값 찾기
mode_embarked = df['embarked'].mode()[0]
df['embarked'].fillna(mode_embarked, inplace=True)
```

```
embark_town 열의 최빈값 찾기
mode_embark_town = df['embark_town'].mode()[0]
df['embark_town'].fillna(mode_embark_town, inplace=True)
```

```
print(f"embarked 열의 최빈값: {mode_embarked}")
print(f"embark_town 열의 최빈값: {mode_embark_town}")
```

---

# 불필요한 데이터 제거 (drop)

---

- `df.drop('column_name', axis=1)`: 특정 열(들)을 제거.
- `df.drop(index_number)`: 특정 행을 제거.
- 왜 제거하는가?
  - 분석에 필요 없는 열(e.g., ID),
  - 중복된 정보,
  - 너무 많은 고유값을 가져 모델 성능에 방해가 되는 열 등을 제거.

---

# deck 열 삭제하기

```
df.drop('deck', axis=1, inplace=True)
```

```
df.info()
```

---

## **5-(2) 이상치 처리 전략**

# 이상치 (Outliers)



---

- 정의: 다른 데이터 포인트들과 비교했을 때, 극단적으로 동떨어져 있는 값을 의미
  - 예를 들어, 학생들의 키를 측정하는데 250cm나 100cm 같은 값이 있다면 이상치로 볼 수 있음
- 이상치의 영향
  - 데이터의 평균이나 표준편차를 왜곡시킴
  - 선형 회귀(Linear Regression)나 SVM처럼 거리에 민감한 모델의 학습을 방해할 수 있음



# 이상치 (Outliers)

- 이상치 탐지 방법
  - 시각화 활용 : Box Plot, 산점도
  - 통계적 기법 활용 : Z-Score



# 이상치 처리 전략

---

① 삭제: 이상치로 판단된 행 전체를 제거

② 대체: 이상치를 다른 값으로 바꿈

- 평균(Mean) / 중앙값(Median) / 최빈값(Mode)으로 대체
  - : 중앙값은 이상치의 영향을 덜 받기 때문에 일반적으로 평균보다 더 선호됨
- 상한/하한 설정 (Capping/Winsorizing)
  - : 이상치를 특정 분위수(예: 1%, 99%) 값으로 설정합니다.
  - : 예를 들어, 하위 1%보다 작은 값은 모두 1% 값으로, 상위 99%보다 큰 값은 모두 99% 값으로 강제로 맞춤
  - : 데이터의 극단적인 분포를 부드럽게 만들어줍니다.

# 이상치 처리 전략

---

③ 변환 : 데이터 전체에 특정 수학 함수를 적용하여 이상치의 영향을 줄임

- 로그변환
- 제곱근 변환

④ 강건한 모델 사용 (Robust Model)

- 데이터를 직접 건드리는 대신 이상치에 덜 민감한 머신러닝 모델을 사용
  - : 트리 기반 모델이 대표적

# 이상치 처리 전략: 어떤 방법을 선택해야 할까?

- 이상치의 원인 파악이 최우선

- "가장 좋은 방법"은 정해져 있지 않으며, 데이터와 문제의 종류에 따라 달라짐

|                      |                                                                                                                                                                |
|----------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 측정 오류나 데이터 입력 실수일 경우 | <ul style="list-style-type: none"><li>• 삭제하거나 수정(대체)</li></ul>                                                                                                 |
| 이상치가 중요한 정보일 경우      | <ul style="list-style-type: none"><li>• 사기 탐지, 불량품 예측 등에서는 이상치 자체가 가장 중요한 데이터</li><li>• 이 경우 삭제해서는 절대 안 됨</li><li>• 이상치 탐지 모델(Anomaly Detection)을 적용</li></ul> |
| 데이터가 충분하지 않을 경우      | <ul style="list-style-type: none"><li>• 삭제보다는 대체나 변환을 고려하는 것이 좋음</li></ul>                                                                                     |
| 모델 선택의 자유도가 높을 경우    | <ul style="list-style-type: none"><li>• 데이터 수정을 최소화하고 싶다면 강건한 모델을 사용</li><li>• (예: Random Forest)</li></ul>                                                    |

## 6. 실습 (2)

**: 전처리 심화\_데이터 손실 최소화**

# 실습: 데이터를 삭제하지 않고 대체하여 실험해보자.

---

## ① 완전성

온도, 점도의 결측치 -> 산술평균으로 대체

## ② 유효성

온도, 점도의 이상치 -> 산술평균으로 대체

## ⑤ 정확성

case1. 정상인데 FailureCode에 값이 있는 경우

-> 정상 -> 불량

case2. 불량인데 FailureCode가 없는 경우

-> FailureCode의 최빈값으로 채우는데,

-> None을 제외하고 최빈값

## [참조 코드]

```
1. 평균값으로 대체
먼저 평균값을 계산합니다.
mean_age = df_mean['housing_median_age'].mean()
print(f"housing_median_age의 평균값: {mean_age:.2f}")

fillna를 사용하여 결측치를 평균값으로 채웁니다.
df_mean['housing_median_age'].fillna(mean_age, inplace=True)

2. 중앙값으로 대체
중앙값을 계산합니다.
median_age = df_median['housing_median_age'].median()
print(f"housing_median_age의 중앙값: {median_age}")

fillna를 사용하여 결측치를 중앙값으로 채웁니다.
df_median['housing_median_age'].fillna(median_age, inplace=True)
```

# 실습: 전처리가 완료된 데이터셋으로 모델링을 해보자.

---

## 〈문제 정의〉

- 특성  $X$ : 온도, 점도
- 타겟  $y$ : 양품/불량 유무
- 구분: 지도학습 >> 분류

1. 이전 실습(1)과 동일하게 로지스틱 회귀 모델을 사용하여 이진 분류 모델을 학습시킨다.
2. 이전 실습(1)과 동일하게 모델의 성능을 평가하고, 과적합/과소적합 유무를 확인한다.
3. 이전 실습(1)과 지금 수행한 실습(2)의 모델 성능을 비교한다.



# 참고 자료

---

- 『제조AI빅데이터 분석 기법 (코딩편)』, 김일중 외 6인 공저, 보민출판사 (2024)

끝!