

반도체장비예지보전실무 04

특성 공학

(Feature Engineering)

특성공학의 이해

특성 공학 Feature Engineering

- 개념

- 원시 데이터를 다루고 있는 문제를 더 잘 표현할 수 있는 특성으로 변환하는 과정

- 필요성

- 특성을 잘 정의하면 단순한 모델로도 좋은 결과를 낼 수 있음 → 비용 절감
 - 특성이 많아질수록 경우의 수가 많아져 차원의 저주에 걸림 → 차원의 저주 회피

특성 공학 Feature Engineering

- 어떤 특성이 중요한지 어떻게 아는가?
 - 상관 계수 : 특성과 타겟 간의 선형적 관계
 - 회귀 계수 : 학습된 가중치 W (독립변수가 1 단위 변할 때 종속 변수가 얼마나 변하는 가)
 - 결정 트리의 특성 중요도
 - p-value (probability value) : 두 그룹 간의 결과 차이가 유의미한지 판단하는데 도움을 주는 통계적 지표

특성 공학 Feature Engineering

- 특성공학의 주요 기법 (1)

변환 Transformation	개념	기존 변수의 의미는 유지하면서 표현 방법을 바꾸는 것
	예시	- 로그 변환, 스케일링 - 값이 2,000, 3,000, 500,000처럼 한쪽으로 치우쳐 있으면 로그 변환을 해서 분포를 완화한다. - 키와 연봉처럼 변수마다 숫자의 크기가 크게 다르면 StandardScaler나 MinMaxScaler로 크기를 맞춘다.
생성 Creation	개념	여러 기존 변수로부터 새로운 의미를 가진 변수를 만드는 것
	예시	- 키 + 몸무게 → BMI - 구매금액 ÷ 구매횟수 → 평균 구매금액 - 현재 온도 - 이전 온도 → 온도 변화량

특성 공학 Feature Engineering

- 특성공학의 주요 기법 (2)

추출 Extraction	개념	원본 데이터가 가지고 있는 많은 정보 중에서 학습에 필요한 특징을 뽑아내는 것
	예시	날짜가 2026-09-18 14:30으로 들어 있다면 그대로 쓰는 대신, 연도 = 2026월 = 9요일 = 금요일시간대 = 오후처럼 뽑아서 사용할 수 있다.
선택 Selection	개념	변수를 전부 사용하는 것보다, 예측에 도움이 되는 변수만 골라서 사용하는 것
	예시	타겟과 거의 관계없는 변수나 서로 거의 같은 정보를 가지는 변수를 제거한다.

특성 공학 Feature Engineering

- 보통 특성공학에는 이런 작업들이 포함된다.
 - 특성 생성: 기존 변수 조합해서 새 변수 만들기
 - 특성 변환: 로그 변환, 스케일링, 정규화 등
 - 범주형 변수 인코딩: 원-핫 인코딩, 라벨 인코딩
 - 구간화(Binning): 나이 → 10대/20대/30대
 - 상호작용 특성 생성: 키 × 몸무게, 온도 × 습도
 - 다항 특성 생성: x^2 , x^3 , $x_1 * x_2$
 - 날짜/시간 특성 추출: 날짜 → 월, 요일, 시간대
 - 집계 특성 생성: 고객별 평균 구매액, 최근 7일 평균
 - 결측 여부 자체를 특성화: 결측이면 1, 아니면 0
 - 특성 선택: 불필요한 변수 제거

→ 사실 우리는 이미 특성 공학을 하고 있었다!

파생 변수

- 개념

- 기존에 있던 특성들을 계산·조합·변환하여 새로운 의미를 가진 특성을 만드는 것.

- 예시

기존 변수	파생변수	의미
키, 몸무게	$BMI = \text{몸무게} / \text{키}^2$	체형·비만 정도
생년월일	나이	현재 연령
주문금액, 구매횟수	평균 구매금액	한 번 구매할 때 얼마나 쓰는지
출발시간, 도착시간	소요시간	이동에 걸린 시간
국어·영어·수학 점수	평균점수	전체적인 학업 성취 수준

파생 변수

- 제조 분야 관련 예시


기존 변수	파생변수 예시	의미
온도	온도차 = 현재온도 - 기준온도	정상 범위에서 얼마나 벗어났는지
진동값	최근 10개 진동값의 평균	순간값이 아닌 최근 진동 수준
압력	압력 변화량 = 현재압력 - 이전압력	압력이 급격히 변하는지
가동 시작시간, 종료시간	가동시간	장비를 얼마나 오래 사용했는지
고장 횟수, 가동시간	시간당 고장 횟수	장비의 상대적인 고장 빈도

사출성형 제조공장


- 경기도에 위치한 H사는 자동차 부품 제조업체
- 사출성형기의 상태/조건에 따라서 제조 결과물의 정상/불량 여부를 판단하고자 함



<출처 : H사>



사출성형이란?



사출성형 제조공장의 현장 문제

- 문제
 - H사는 현재 사출성형기에 설정된 조건으로 제품을 생산해도 될지를 판단할 수 있는 AI 모델을 개발하고자 함
- 특성 데이터
 - 사출성형기에서 수집된 데이터 (사출샷 Lot 단위 PLC 데이터)
- 타겟: 불량 여부
 - 불량 -> 1
 - 정상 -> 0

데이터셋 스크립트

헤더		바디			
No	변수명	척도	유형 타입	변수 설명	속성/범주값
1	Lot no.	범주형	string	일정 단위로 생산된 사출성형물의 고유번호	5자리 문자열
2	금형상온도 (°C)	연속형	float64	금형 상판온도	범위 : 20~80°C, 소수점 8자리
3	금형하온도 (°C)	연속형	float64	금형 하판온도	범위 : 20~80°C, 소수점 8자리
4	냉각시간 (sec)	연속형	float64	금형에 원료 주입되어 사출물이 굳어지기까지 걸리는 시간	범위 : 20~40초, 소수점 8자리
5	노즐온도 (°C)	연속형	float64	사출기의 노즐 온도	범위 : 15~25°C, 소수점 8자리
6	냉각수 In 온도_Avg (°C)	연속형	float64	냉각수 유입온도 평균	범위 : 20~35°C, 소수점 8자리
7	냉각수 In 온도_Std	연속형	float64	냉각수 유입온도 표준편차	범위 : 0.1~3, 소수점 8자리

8	냉각수 Out 온도_Avg (°C)	연속형	float64	냉각수 출수온도 평균	범위 : 180~280°C, 소수점 8자리
9	냉각수 Out 온도_Std	연속형	float64	냉각수 출수온도 표준편차	범위 : 0.1~110, 소수점 8자리
10	보압속도 (mm/sec)	연속형	Float64	금형 내에 원료가 채워지도록 스크류를 전진시키는 속도	범위 : 0.5~6mm/s, 소수점 8자리
11	사출압력 (kg/cm ²)	연속형	float64	스크류가 보압 전환점에 도달했을 때 가해지는 압력	범위 : 10~210kg/cm ² , 소수점 8자리
12	사출시간 (sec)	연속형	float64	재료를 금형에 유입시 키는 데 소요되는 시간	범위 : 1~6초, 소수점 8자리
13	실린더 온도 (°C)	연속형	float64	실린더 내부온도	범위 : 185~275°C, 소수점 8자리
14	작동유 온도 (°C)	연속형	float64	작동유 온도	범위 : 20~40°C, 소수점 8자리
15	쿠션량	연속형	float64	보압 완료 후 스크류의 위치	범위 : 0~10, 소수점 8자리
16	불량 여부	범주형	int64	사출품 품질 정상/불량 여부	0 : 정상, 1 : 불량

실습1. 새로운 특성 추가 후 모델링

- 실습 내용: 데이터의 물리적 의미를 고려하여 새로운 특성을 만들자.
- 실습 단계 :
 - ① 데이터셋 로딩
 - ② 새로운 특성 생성
 - ③ 데이터 탐색: 새로운 특성의 분포 확인
 - ④ 데이터 탐색: 상관관계 분석
 - ⑤ 데이터 분할 및 정규화
 - ⑥ 베이스라인 모델 : 모델링 / 성능평가 / `_coef` 확인
 - ⑦ 랜덤 포레스트 : 모델링 / 성능평가 / 특성 중요도 확인

① 데이터셋 로딩

- 파일 읽어오기: Molding_Numeric_Data.csv
- 컬럼 이름에 공백을 제거하기 위해 컬럼 이름 변경

```
# (Optional) Column 이름을 사용하기 편하게 변경하기
df.columns = ["LOT", "금형상온도", "금형하온도", "냉각시간", "노출온도",
              "냉각수In_Avg", "냉각수In_Std", "냉각수Out_Avg", "냉각수Out_Std",
              "보압속도", "사출압력", "사출시간", "실린더온도", "작동유온도", "쿠션량", "불량여부"]
```

- LOT No. 열 삭제하기

```
# LOT No. 열 삭제하기
df = df.drop(['LOT'], axis=1)
```

② 새로운 특성(파생변수) 생성 (1)

1. 온도 관련 조합

파생 변수명	계산	해결하고자 하는 문제와의 관련성
금형온도차	$\text{금형상온도} - \text{금형하온도}$	- 금형의 상부와 하부 온도차가 크면 수축 불균형을 유발하여 제품이 휘어질 수 있음
냉각수온도차_Avg	$\text{냉각수Out 온도_Avg} - \text{냉각수In 온도_Avg}$	- 냉각수가 금형으로부터 얼마나 열을 빼앗는가, 즉 냉각효율을 나타냄. - 최종 품질과 생산 사이클 타임에 영향을 줌
실린더노즐_온도차	$\text{실린더온도} - \text{노즐온도}$	- 용융된 수지가 사출될 때 온도 강하 - 수지의 점도와 유동성에 영향을 줌

② 새로운 특성(파생변수) 생성 (2)

2. 공정 안정성 관련 조합

파생 변수명	계산	해결하고자 하는 문제와의 관련성
냉각수In_변동계수	$\frac{\text{냉각수In 온도_Std}}{\text{냉각수In 온도_Avg}}$	- 평균 온도 대비 표준편차의 비율 - 온도의 상대적인 안정성을 나타냄 - 이 값이 크다면 냉각공정이 불안정 하다는 신호일 수 있음
냉각수Out_변동계수	$\frac{\text{냉각수Out 온도_Std}}{\text{냉각수Out 온도_Avg}}$	

② 새로운 특성(파생변수) 생성 (3)

3. 에너지 및 효율 관련 조합

파생 변수명	계산	해결하고자 하는 문제와의 관련성
사출에너지	$\text{사출압력} \times \text{사출시간}$	- 사출 공정 동안 가해진 총 에너지 - 일정한 양의 수지를 금형에 채우는 데 필요한 에너지를 나타내므로, 수지의 점도 변화나 유로 저항의 변화를 감지하는데 사용할 수 있음
총냉각효율	$\frac{\text{냉각수_온도차_Avg}}{\text{냉각시간}}$	- 단위 냉각 시간당 얼마나 효율적으로 열을 제거했는지를 나타냄 - 이 값이 낮다면, 냉각 시간을 길게 가져가도 열이 효과적으로 제거되지 않고 있다는 의미일 수 있음

② 새로운 특성(파생변수) 생성 (4)

온도 관련 조합

```
df["금형온도차"] = df["금형상온도"] - df["금형하온도"]
```

```
df["냉각수온도차_Avg"] = df["냉각수Out_Avg"] - df["냉각수In_Avg"]
```

```
df["실린더노즐_온도차"] = df["실린더온도"] - df["노즐온도"]
```

공정 안정성 관련 조합

```
df["냉각수In_변동계수"] = df["냉각수In_Std"] / df["냉각수In_Avg"]
```

```
df["냉각수Out_변동계수"] = df["냉각수Out_Std"] / df["냉각수Out_Avg"]
```

에너지 및 효율 관련 조합


```
df["사출에너지"] = df["사출압력"] * df["사출시간"]
```

```
df["총냉각효율"] = df["냉각수온도차_Avg"] / df["냉각시간"]
```

③ 데이터 탐색 : 새로운 특성의 분포 확인

- 새로운 특성들의 분포를 확인해야 한다.
- 먼저 파생변수 중 “금형온도차”와 타겟값(불량여부)가 유의미한 관계를 갖는지 확인

```
sns.displot(data=df,  
            x="금형온도차",  
            kde=True,  
            hue="불량여부")  
plt.show()
```





③ 데이터 탐색 : 새로운 특성의 분포 확인

- 파생변수 중 “금형온도차”의 박스플롯 그려보기 → 금형온도차의 분포가 타겟을 구별할 수 있는가?

```
plt.figure(figsize=(20, 8))
plt.subplot(1, 2, 1)
sns.boxplot(data=df,
            x="금형온도차")

plt.subplot(1, 2, 2)
sns.boxplot(data=df,
            x="불량여부",
            y="금형온도차" )
plt.show()
```



③ 데이터 탐색 : 새로운 특성의 분포 확인

- 다른 파생 변수에 대해서도
분포그래프와 박스플롯을 그려서 데이터의 특성을 확인하세요.
- `displot()` 함수와 `boxplot()` 함수 사용

④ 데이터 탐색 : 상관관계 분석


- 상관행렬을 히트맵으로 그려보고, 새로운 특성이 타깃값과 얼마나 유의미한 관계를 갖는지 확인

```
plt.figure(figsize=(15,12))
plt.title('Correlation of Features', size=15)

sns.heatmap(df.corr(),
             cmap='RdBu',
             annot=True,
             annot_kws={'size':8})

plt.show()
```

Correlation of Features



⑤ 데이터 분할 및 정규화

- 특성(X)과 타겟(y) 분리 → 훈련 데이터와 테스트 데이터 분할

```
from sklearn.model_selection import train_test_split

# 특성과 타겟 데이터 나누기
df_X = df.drop(['불량여부'], axis=1 )
df_y = df['불량여부']

# 훈련데이터와 테스트 데이터 나누기
train_X, test_X, train_y, test_y = train_test_split(df_X, df_y, test_size=0.2, stratify=df_y)
```

- 데이터 스케일링

```
from sklearn.preprocessing import MinMaxScaler

scaler = MinMaxScaler() # 데이터 정규화
trainX_scaled = scaler.fit_transform(train_X)
```

⑥ 베이스라인 모델 : 모델링 / 성능평가 / _coef 확인

- 베이스라인 모델로서 로지스틱 회귀 모델링 결과

===== 학습된 모델 가중치와 편향 =====

가중치 (Coefficients):

- 금형상온도: -0.5106
- 금형하온도: -0.2852
- 냉각시간: -0.3825
- 노즐온도: 0.4532
- 냉각수In_Avg: 0.1923
- 냉각수In_Std: 0.2058
- 냉각수Out_Avg: 0.5823
- 냉각수Out_Std: -0.0969
- 보압속도: -0.0778
- 사출압력: -1.3430
- 사출시간: -0.8846
- 실린더온도: -0.2194
- 작동유온도: -0.5422
- 쿠션량: 0.1081
- 불량여부: 0.0274
- 금형온도차: 0.5680
- 냉각수온도차_Avg: -0.3194
- 실린더노즐_온도차: 0.2072
- 냉각수In_변동계수: -0.0983
- 냉각수Out_변동계수: -1.6540
- 사출에너지: 0.7937

편향 (Intercept): 0.3200

Confusion Matrix : test

```
[[13  1]
 [ 4  2]]
```

Confusion Matrix : train

```
[[54  1]
 [11 14]]
```

Report : test

	precision	recall	f1-score	support
0	0.76	0.93	0.84	14
1	0.67	0.33	0.44	6
accuracy			0.75	20
macro avg	0.72	0.63	0.64	20
weighted avg	0.74	0.75	0.72	20

Report : train

	precision	recall	f1-score	support
0	0.83	0.98	0.90	55
1	0.93	0.56	0.70	25
accuracy			0.85	80
macro avg	0.88	0.77	0.80	80
weighted avg	0.86	0.85	0.84	80

⑦ 랜덤 포레스트 : 모델링 / 성능평가 / 특성 중요도 확인

- 랜덤 포레스트와 같은 트리 기반 모델을 사용하여 학습 시키기

```
from sklearn.ensemble import RandomForestClassifier  
  
rf = RandomForestClassifier(n_estimators=10, random_state=42)  
  
rf.fit(trainX_scaled, train_y)
```

⑦ 랜덤 포레스트 : 모델링 / 성능평가 / 특성 중요도 확인

- feature_importances_ 속성을 통해
어떤 특성(기존 특성 + 새로 만든 특성)이 불량 여부를 예측하는 데 중요한 역할을 하는지 확인

```
feature_importances = pd.Series(rf.feature_importances_.round(3), index=train_X.columns)
feature_importances_sorted = feature_importances.sort_values(ascending=False)

print(feature_importances_sorted)
```

```
plt.figure(figsize=(8,6))
sns.barplot(x=feature_importances_sorted, y = feature_importances_sorted.index,
            hue=feature_importances_sorted.index, palette='husl')
plt.title('특성 중요도 분석', fontsize=15)
plt.show()
```

⑦ 랜덤 포레스트 : 모델링 / 성능평가 / 특성 중요도 확인

- 성능지표 확인

```
# 성능지표
from sklearn.metrics import confusion_matrix, classification_report

# 테스트 데이터의 모델 예측 값 구함
test_pred = rf_basic.predict(testX_scaled)
# 훈련 데이터의 모델 예측 값 구함
train_pred = rf_basic.predict(trainX_scaled)

# 혼동행렬
cm_test = confusion_matrix(test_y, test_pred)
cm_train = confusion_matrix(train_y, train_pred)

print('\nConfusion Matrix : test')
print(cm_test)
print('\nConfusion Matrix : train')
print(cm_train)

# 분류 성능 지표
print('\nReport : test')
print(classification_report(test_y, test_pred))

print('\nReport : train')
print(classification_report(train_y, train_pred))
```

⑦ 랜덤 포레스트 : 모델링 / 성능평가 / 특성 중요도 확인

- 랜덤 포레스트 모델링 결과

```
사출압력          0.2120
사출에너지        0.1980
사출시간          0.0810
작동유온도        0.0640
금형온도차        0.0580
냉각수In_변동계수 0.0570
냉각수Out_Std     0.0480
총냉각효율        0.0440
금형상온도        0.0360
냉각수In_Avg      0.0280
냉각수Out_변동계수 0.0270
실린더온도        0.0270
냉각수In_Std      0.0240
보압속도          0.0190
노즐온도          0.0170
냉각수Out_Avg     0.0120
실린더노즐_온도차 0.0120
금형하온도        0.0110
냉각시간          0.0110
냉각수온도차_Avg  0.0080
쿠션량            0.0060
dtype: float64
```

```
Confusion Matrix : test
[[13  1]
 [ 1  5]]

Confusion Matrix : train
[[55  0]
 [ 0 25]]

Report : test
```

	precision	recall	f1-score	support
0	0.93	0.93	0.93	14
1	0.83	0.83	0.83	6
accuracy			0.90	20
macro avg	0.88	0.88	0.88	20
weighted avg	0.90	0.90	0.90	20

```
Report : train
```

	precision	recall	f1-score	support
0	1.00	1.00	1.00	55
1	1.00	1.00	1.00	25
accuracy			1.00	80
macro avg	1.00	1.00	1.00	80
weighted avg	1.00	1.00	1.00	80

실습2. 일부 특성 삭제 후 모델링

- 실습 내용:

- 결과에 영향을 많이 미치지 않는 특성을 삭제하여 모델링하고,
- 모든 특성을 사용했을 때와 성능 차이가 나는지 확인하자.

- 실습 단계 :

- ① 모델링에 포함할 특성 선택하기
- ② 데이터 분할 및 정규화
- ③ 특성 선택 후 랜덤 포레스트 : 모델링 / 성능평가 / 특성 중요도 확인


① 모델링에 포함할 특성 선택하기

- 새로운 특성까지 모두 포함하여 학습한 결과

test_accuracy: 0.85
train_accuracy: 1.0

사출압력	0.2530
냉각수Out_Std	0.1070
사출에너지	0.0990
사출시간	0.0800
작동유온도	0.0760
금형하온도	0.0510
냉각수In_Std	0.0500
쿠션량	0.0500
보압속도	0.0500
노즐온도	0.0450
실린더노즐_온도차	0.0360
냉각수온도차_Avg	0.0270
냉각수Out_Avg	0.0240
실린더온도	0.0160
금형상온도	0.0110
냉각시간	0.0100
냉각수In_변동계수	0.0070
금형온도차	0.0050
냉각수Out_변동계수	0.0030
냉각수In_Avg	0.0000
총냉각효율	0.0000

dtype: float64



① 모델링에 포함할 특성 선택하기


- 모든 특성을 쓰지 말고 중요한 특성을 선택해보자.
 - 어떻게 선택할 수 있을까?
 - 상관계수와 특성 중요도 간에 관계가 있을까?
 - 타겟과의 상관계수가 높으면 특성 중요도도 높을까?
 - 특성 중요도가 높은 특성은 타겟과의 상관계수가 높았을까?

① 모델링에 포함할 특성 선택하기


- 기존 특성만 가지고 학습했을 때의 결과

test_accuracy: 0.9
train_accuracy: 0.9875

사출압력	0.3400
작동유온도	0.1980
보압속도	0.0740
사출시간	0.0550
실린더온도	0.0540
금형하온도	0.0500
쿠션량	0.0350
금형상온도	0.0340
냉각수Out 온도_Std	0.0290
냉각수In 온도_Avg	0.0290
노즐온도	0.0270
냉각수In 온도_Std	0.0260
냉각시간	0.0250
냉각수Out 온도_Avg	0.0230
dtype:	float64




Correlation of Features



- 기존 특성만 가지고 학습했을 때의 결과
 - 상관계수와 특성 중요도 간에 어느 정도는 관계가 있어보임

사출압력	0.3400
작동유온도	0.1980
보압속도	0.0740
사출시간	0.0550
실린더온도	0.0540
금형하온도	0.0500
쿠션량	0.0350
금형상온도	0.0340
냉각수Out 온도_Std	0.0290
냉각수In 온도_Avg	0.0290
노즐온도	0.0270
냉각수In 온도_Std	0.0260
냉각시간	0.0250
냉각수Out 온도_Avg	0.0230
dtype: float64	

Correlation of Features



- 새로운 특성을 추가한 버전의 데이터에서 의미 있다고 판단되는 데이터를 선택

① 모델링에 포함할 특성 선택하기

- 나름의 판단으로 특성을 선택하여 새로운 데이터프레임 생성하기


```
# 특성을 선택하여 새로운 데이터프레임 생성하는 방법 예시
selectd_df = df[['금형상온도', '금형하온도', '냉각시간', '보압속도',
                 '사출압력', '사출시간', '실린더온도', '작동유온도',
                 '쿠션량', '냉각수온도차_Avg', '실린더노즐_온도차',
                 '사출에너지', '불량여부' ]]
```

- 데이터 확인

```
selectd_df.sample(5)
```

	금형상온도	금형하온도	냉각시간	보압속도	사출압력	사출시간	실린더온도	작동유온도	쿠션량	냉각수온도차_Avg	실린더노즐_온도차	사출에너지	불량여부
31	59.6514	63.1096	28.4501	4.8016	118.4228	4.7976	268.5764	38.9308	4.6303	240.3974	247.9233	113.6252	0
83	38.3051	41.8278	29.2085	4.1970	83.9077	1.8442	267.3352	26.1722	0.5272	236.6441	246.6821	82.0635	1
77	38.3051	41.8278	29.0178	4.8003	122.0461	1.5352	271.5238	29.6309	1.8092	241.6878	250.8707	120.5109	0
58	21.6963	23.9684	29.2085	4.5990	114.8477	1.7303	265.6115	28.6695	0.4839	236.8588	243.4181	113.1173	1
88	38.3051	41.8278	29.2085	4.6227	92.7338	1.8015	267.8473	28.2600	0.6578	236.7022	247.1942	90.9322	1

Correlation of Features



③ 데이터 선택 후 랜덤 포레스트 : 모델링 / 성능평가 / 특성 중요도 확인

- 선택한 특성만으로 학습한 결과

```
사출압력      0.5140
쿠션량        0.0990
사출에너지    0.0750
실린더온도    0.0560
작동유온도    0.0520
금형하온도    0.0450
냉각수온도차_Avg  0.0400
금형상온도    0.0390
실린더노즐_온도차  0.0230
보압속도      0.0220
냉각시간      0.0200
사출시간      0.0140
dtype: float64
```

Confusion Matrix : test

```
[[14  0]
 [ 3  3]]
```

Confusion Matrix : train

```
[[55  0]
 [ 1 24]]
```

Report : test

	precision	recall	f1-score	support
0	0.82	1.00	0.90	14
1	1.00	0.50	0.67	6
accuracy			0.85	20
macro avg	0.91	0.75	0.78	20
weighted avg	0.88	0.85	0.83	20

Report : train

	precision	recall	f1-score	support
0	0.98	1.00	0.99	55
1	1.00	0.96	0.98	25
accuracy			0.99	80
macro avg	0.99	0.98	0.99	80
weighted avg	0.99	0.99	0.99	80

참고 자료

- 『제조AI빅데이터 분석 기법 (코딩편)』, 김일중 외 6인 공저, 보민출판사 (2024)

끝!