

연습문제: 개인 의료비용 예측

문제 설명:

개인의 건강 및 생활 습관 관련 데이터를 사용하여, 해당 **개인의 예상 의료비용(Medical Charges)**을 예측하는 선형 회귀 모델을 구축해 보세요. 이 문제는 다양한 인구통계학적 특성과 생활 습관이 의료비에 어떻게 영향을 미치는지 분석하는 데 활용될 수 있습니다.

사용할 데이터셋:

이 데이터셋은 sklearn.datasets에 직접 포함되어 있지 않으므로, 일반적으로 Kaggle 등에서 구할 수 있는 Medical Cost Personal Datasets를 기반으로 가이드라인을 제공합니다. 실제 실습 시에는 해당 CSV 파일을 다운로드하여 사용해야 합니다. (예시: insurance.csv)

데이터의 주요 특성(Features):

- age: 나이
- sex: 성별 (male/female)
- bmi: 체질량 지수 (Body Mass Index)
- children: 부양 자녀 수
- smoker: 흡연 여부 (yes/no)
- region: 거주 지역 (northeast, northwest, southeast, southwest)

타겟(Target):

- charges: 예상 의료비용 (달러)

단계별 연습 가이드

다음 단계를 따라가면서 선형 회귀 모델을 구축하고 분석해 보세요. 각 단계에서 어떤 코드를 사용해야 할지, 무엇을 확인해야 할지 스스로 고민해 보는 것이 중요합니다.

단계 1: 데이터 로드 및 탐색

1. 데이터셋 로드:

- CSV 파일(insurance.csv와 같은 이름)을 pandas의 read_csv() 함수를 사용하여 로드합니다.
- **참고:** 만약 파일이 없다면, 인터넷에서 "Kaggle Medical Cost Personal Datasets"를 검색하여 다운로드할 수 있습니다.

2. DataFrame으로 변환:

- 이미 DataFrame 형태이므로 별도 변환이 필요 없습니다.

3. 데이터 기본 정보 확인:

- df.head(): 데이터의 상위 몇 행을 확인하여 데이터의 형태를 파악합니다.
- df.info(): 각 열의 데이터 타입, 결측치 여부, 전체 행 수 등을 확인합니다.
- df.describe(): 각 수치형 특성의 통계적 요약(평균, 표준편차, 최소/최대값 등)을 확인합니다.

단계 2: 데이터 전처리

1. 범주형 특성 인코딩:

- 이 데이터셋에는 sex, smoker, region과 같은 **범주형(Categorical)** 특성이 포함되어 있습니다.
- 선형 회귀 모델은 숫자형 데이터만 처리할 수 있으므로, 이 범주형 특성들을 숫자형으로 변환해야 합니다.
- **pandas.get_dummies()** 함수를 사용하여 **One-Hot Encoding**을 수행해 보세요.
 - sex (male/female) -> sex_male, sex_female (0 또는 1)
 - smoker (yes/no) -> smoker_yes, smoker_no (0 또는 1)
 - region (4가지) -> region_northeast, region_northwest, region_southeast, region_southwest (0 또는 1)
- **질문:** 왜 단순히 0, 1, 2 등으로 숫자를 부여하는 Label Encoding 대신 One-Hot Encoding을 사용해야 할까요? (순서의 의미 부여 문제와 연결하여 생각해 보세요.)

2. 특성(X)과 타겟(y) 분리:

- 전처리된 DataFrame에서 charges 열을 타겟(y)으로, 나머지 열들을 특성(X)으로 분리합니다.

3. 특성 스케일링 (Feature Scaling):

- age, bmi, charges와 같은 수치형 특성들은 값의 범위가 매우 다릅니다.
- StandardScaler 또는 MinMaxScaler를 사용하여 특성들의 스케일을 조정해 보세요.

단계 3: 훈련 세트와 테스트 세트 분할

1. 데이터 분할:

- sklearn.model_selection의 train_test_split 함수를 사용하여 전처리된 데이터를 훈련 세트와 테스트 세트로 나눕니다.
 - test_size는 0.2 또는 0.3 정도로 설정하고, random_state를 고정하여 재현성을 확보합니다.
 - **질문:** 데이터를 훈련 세트와 테스트 세트로 나누는 가장 중요한 이유는 무엇인가요? (모델의 일반화 성능 평가와 연결)
-

단계 4: 선형 회귀 모델 훈련

1. 모델 객체 생성:

- sklearn.linear_model에서 LinearRegression 클래스를 임포트하고 모델 객체를 생성합니다.

2. 모델 훈련:

- fit() 메서드를 사용하여 훈련 세트(X_train, y_train)로 모델을 학습시킵니다.
- **질문:** fit() 메서드 안에서는 어떤 과정이 일어난다고 설명했었죠? (경사 하강법을 통한 최적의 W와 b 찾기)

3. 가중치(W)와 편향(b) 확인:

- model.coef_와 model.intercept_를 출력하여 학습된 모델의 가중치와 편향 값을 확인합니다.
- **질문:** 각 가중치(model.coef_)가 의미하는 바는 무엇일까요? (해당 특성이 타겟에 미치는 영향의 크기와 방향) One-Hot Encoding된 특성들의 가중치도 함께 해석해 보세요.

단계 5: 모델 예측 및 평가

1. 예측 수행:

- 훈련된 모델의 `predict()` 메서드를 사용하여 테스트 세트(`X_test`)에 대한 의료비용을 예측합니다.

2. 모델 평가:

- `sklearn.metrics`에서 `mean_squared_error` (MSE)와 `r2_score` (R2 Score)를 임포트합니다.
 - 테스트 세트의 실제 값(`y_test`)과 예측 값(`y_pred`)을 사용하여 MSE와 R2 Score를 계산하고 출력합니다.
 - **질문:** MSE와 R2 Score는 각각 무엇을 의미하며, 어떤 값이 좋은 성능을 나타내나요?
 - **질문:** 훈련 세트에 대한 MSE와 R2 Score도 계산하여 테스트 세트 결과와 비교해 보세요. 이를 통해 과대적합 또는 과소적합의 징후를 발견할 수 있나요?
-

단계 6: 결과 해석 및 시사점 도출

1. 모델 해석:

- 학습된 가중치(`model.coef_`)와 해당 특성 이름을 매칭하여 다시 확인하며, 어떤 특성(예: 흡연 여부, 나이, BMI)이 의료비용 예측에 가장 큰 영향을 미치는지 해석해 보세요. (가중치의 절댓값이 클수록 영향력이 크다고 볼 수 있습니다.)
- **질문:** 당신의 모델이 예측한 의료비용에 가장 긍정적/부정적인 영향을 미치는 요인은 무엇인가요?

2. 모델의 한계:

- 이 모델이 의료비용을 예측하는 데 어떤 한계를 가질 수 있을까요? (선형성 가정, 데이터의 복잡성, 다른 중요한 특성 누락 가능성 등)