




머신러닝 입문자를 위한 핵심통계

머신러닝 입문자를 위한 핵심 통계



- 머신러닝은 데이터를 통해 학습하고 예측하는 강력한 도구
- 이 도구를 제대로 활용하려면 데이터 자체를 이해하는 것이 중요
- 데이터를 이해하는 가장 기본적인 언어가 바로 '통계'

데이터의 '대표 얼굴' 찾기: 중심 경향성

- 데이터의 중심을 나타내는 값은 무엇일까?
 - 평균(Mean): 모든 값을 더해서 개수로 나눈 값.
 - 중앙값(Median): 데이터를 크기 순으로 쭉 나열했을 때,
정확히 가운데에 있는 값
 - 최빈값(Mode): 데이터에서 가장 자주 나타나는 값



데이터의 '대표 얼굴' 찾기: 중심 경향성


	최빈치(mode)	중앙치(median)	산술평균(mean)
의미	가장 빈번하게 나타나는 값 	자료를 크기 순으로 나열했을 때, 중앙에 위치하는 값 	자료를 모두 더해서 자료의 개수로 나눈 값 
특징	명목자료에서는 최빈치가 대푯값이다.	서열자료의 경우 평균을 사용할 수 없으므로 중앙치를 사용한다.	- 일부 극단적인 값들에 크게 영향을 받는다. - 수학적인 연산에 의해 계산되므로 수학적인 조작이 용이하다.
예	유행하는 가방 인기 투표	학교 석차 100명 중 50 등	년간 평균 강우량 기말 고사 평균 점수

데이터는 얼마나 '퍼져' 있니? - 산포도

- 데이터가 중심 주변에 얼마나 모여 있는지, 아니면 넓게 퍼져 있는지를 나타냄
- 분산 (Variance)
 - 각 데이터가 평균으로부터 얼마나 떨어져 있는지를 '제공'해서 평균 낸 값
- 표준편차 (Standard Deviation)
 - 분산에 제곱근을 취한 값
 - 데이터가 평균으로부터 '평균적으로' 얼마나 떨어져 있는지를 원래 데이터의 단위로 나타냄

데이터는 어떤 '모양'을 하고 있니? - 확률 분포


- 확률분포: 데이터가 특정 패턴을 따르는 경향
- 정규 분포 (Normal Distribution)
 - 데이터가 평균을 중심으로 대칭적으로 분포하고, 가운데가 모양(Bell Curve)의 확률 분포
 - 자연현상, 시험점수, 신체지수 등 많은 실세계 데이터가 근,
 - 많은 머신러닝 알고리즘이 데이터가 정규 분포를 따른다고
- 표준정규분포 (Standard Normal Distribution)
 - 평균 $\mu=0$, 표준편차 $\sigma=1$
 - Z-score로 변환하면 어떤 정규분포든 표준정규분포가 됨




데이터 속 특이점 : 이상치 (Outliers)

- 다른 데이터 포인트들과 비교했을 때, 극단적으로 동떨어져 있는 값을 의미


Negatively-Skewed



Symmetrical



Positively-Skewed



Drhongdatanote.tistory.com

데이터 속 특이점 : 이상치 (Outliers)

- 어떻게 처리할까?
 - 제거: 이상치가 명백한 오류일 경우 데이터를 삭제. 데이터 손실이 발생할 수 있음
 - 변환: 로그 변환 등을 통해 이상치의 영향을 줄임
 - 대체: 이상치를 평균, 중앙값 등 다른 값으로 대체
 - 모델 선택: 이상치에 덜 민감한 모델(예: 트리 기반 모델)을 사용
 - 분리: 이상치 그룹을 따로 분석하거나, 이상치를 다루는 특화된 모델을 사용하기도 함

데이터 스케일

- 스케일 (Scale)
 - 머신러닝에서 스케일 (Scale)은 데이터가 가지고 있는 값의 크기 범위를 의미
 - : 키 데이터: 보통 150cm ~ 190cm 사이의 값. (단위: cm)
 - : 소득 데이터: 연봉 3천만 원 ~ 1억 원 이상까지, 값의 범위가 매우 클 수 있음. (단위: 원)
 - : 시험 점수: 0점 ~ 100점 사이의 값 (단위: 점)
 - 머신러닝 모델은 데이터의 스케일에 민감한 경우가 많음.



데이터 스케일링

- 스케일링(Scaling)
 - 각 데이터(또는 특성, Feature)의 스케일을 맞춰주는 것
- 왜 필요?
 - 값 범위가 큰 특성의 과도한 영향력
 - 경사 하강법 기반 모델의 학습 속도 및 수렴
 - 거리 기반 알고리즘의 민감성
- 어떻게 맞추나? '정규화'와 '표준화'

데이터 스케일링 - 정규화와 표준화

정규화 (Normalization)


- 최솟값 0, 최댓값 1로 바꾸어 모든 특성이 동일한 스케일을 갖도록 함
- 사용 목적: 각기 다른 단위의 특성(feature)을 같은 기준으로 맞춰 줌



데이터 스케일링 - 정규화와 표준화

표준화 (Standardization)

- 평균 0, 표준편차 1이 되도록 변환 (Z-점수 변환)
- 각 데이터 포인트가 평균으로부터 표준편차의 몇 배만큼 떨어져 있는지를 나타냄.



데이터 스케일링 - 정규화와 표준화

- 사이킷런에서 정규화: MinMaxScaler

```
from sklearn.preprocessing import MinMaxScaler
X = np.array([[1], [2], [3], [4], [5]])
scaler = MinMaxScaler()
X_norm = scaler.fit_transform(X)
print(X_norm.ravel()) # 결과: [0.  0.25 0.5  0.75 1.  ]
```

- ```
from sklearn.preprocessing import StandardScaler
scaler = StandardScaler()
X_std = scaler.fit_transform(X)
print(X_std.ravel()) # 결과: 평균 0, 표준편차 1이 되도록 변환
```

# 통계 참고자료

---

- 통계 개념 : 기술통계와 추리통계
  - <https://ikcoo.tistory.com/74>
- 3Blue1Brown 한국어
  - <https://www.youtube.com/@3Blue1BrownKR>
- 정승제의 확률과 통계 유튜브
  - <https://youtube.com/playlist?list=PLEM1jVr2P8dKqfeLdP7IZ5HzdBqnTbos7&si=MAAs9lgxQlEi2olKH>