

머신러닝의 정규화(Regularization) : AI/머신러닝에서 규제는 모델이 학습데이터에 지나치게 맞춰지는 과대적합(Overfitting)을 줄이기 위해 모델의 가중치가 너무 커지지 않도록 패널티를 주는 방법

L1 규제

L1 규제는 가중치의 절댓값을 손실함수에 더합니다.

$$\text{Loss} = \text{Original Loss} + \lambda \sum |w_i|$$

여기서

- w_i : 모델의 가중치
- λ : 규제 강도

L1의 가장 큰 특징은 일부 가중치를 아예 0으로 만들 수 있다는 것입니다.

예를 들어 모델에 입력 변수가 100개 있다고 하면, 온도, 압력, 유량, 진동, 전류, 전압 ... 중요하지 않은 변수의 가중치를 0으로 만들어 실제로 사용하는 변수를 줄일 수 있습니다.

그래서 L1 규제는 Feature Selection 효과가 있습니다.

대표적으로 Lasso Regression에서 사용합니다.

L2 규제

L2 규제는 가중치의 제곱을 손실함수에 추가합니다.

$$\text{Loss} = \text{Original Loss} + \lambda \sum w_i^2$$

L2는 가중치를 완전히 0으로 만들기보다는 전체적으로 작게 만듭니다.

예를 들어 원래 가중치가 10, 8, 5, 3처럼 컸다면 L2 규제를 적용하면, 2.3, 1.8, 1.2, 0.7처럼 작아지는 방향으로 학습됩니다.

대표적으로 Ridge Regression에서 사용합니다.

L1과 L2 차이

구분	L1	L2
계산	가중치의 절댓값을 모두 더함	가중치의 제곱값을 모두 더함
가중치	일부를 0으로 만들	전체를 작게 만들
특징 선택	가능	거의 안 됨
대표 모델	Lasso	Ridge
목적	불필요한 변수 제거	모델 안정화
과적합 방지	O	O

L1은 “필요 없는 특징은 아예 빼버리는 규제”

L2는 “모든 특징을 사용하되 영향력을 너무 크게 하지 않는 규제”

예를 들어 반도체 장비 불량 예측 AI에서 입력값이 온도/압력/가스유량/습도/장비운전시간/진동이라고 하면, L1은 불량 예측에 별로 필요 없는 습도의 가중치를 0으로 만들 수 있습니다. 반면 L2는 습도를 완전히 제거하지 않고 영향력만 작게 만들 수 있습니다.

그리고 규제 강도를 결정하는 것이 λ (람다)입니다.

- $\lambda = 0 \rightarrow$ 규제 없음
- λ 증가 $\rightarrow$ 규제 강해짐
- λ 가 너무 큼 $\rightarrow$ 과소적합(Underfitting) 가능

즉, 규제가 너무 약하면 과적합, 너무 강하면 과소적합이 되는 관계가 핵심입니다.

추가로 L1과 L2를 섞은 Elastic Net도 있습니다.

$$\text{Loss} = \text{Original Loss} + \lambda_1 \sum |w_i|^2 + \lambda_2 \sum w_i^2$$

즉, L1의 변수 선택 효과와 L2의 안정성을 동시에 활용하는 방법입니다.

1. “입력 변수 100개 중 중요한 변수만 골라내고 싶다면 L1과 L2 중 무엇을 쓰는 게 좋을까?”
2. “모든 변수를 유지하면서 모델이 특정 변수에 과도하게 의존하지 않도록 하려면 무엇이 적절할까?”