


취업역량강화_AI리터리시 03

AI의 한계와 실패



AI는 왜 틀릴까?


AI가 틀리면 누구의 책임일까?

적대적 예제 (Adversarial Example)

- 공격자가 모델이 오류를 범하도록 의도적으로 설계한 입력
 - 사람 눈에는 거의 동일한 이미지인데 AI는 완전히 다른 것으로 인식하게 만드는 미세한 교란(노이즈)
- 머신러닝 알고리즘은 적대적 에이전트 에 직면했을 때 확신에 찬 오류를 범하는 경우가 종종 발생
 - 시스템을 속이기 위해 임의의 입력을 제출하는 적대적 에이전트가 존재하더라도 확신에 찬 오류를 전혀 범하지 않는 분류기를 개발하는 것은 중요한 미해결 과제

적대적 예제 (Adversarial Example)

- 구글 연구팀이 발표한 사례로 유명한 판다 적대적 예제 :



적대적 예제 (Adversarial Example)


- 구글 연구팀이 발표한 사례로 유명한 판다 적대적 예제 :



“panda”

57.7% confidence

+ .007 ×



noise

=



“gibbon”

99.3% confidence

적대적 예제 (Adversarial Example)


- 적대적 예제는 다양한 방법을 통해 생성할 수 있다.



"panda"

Adversarial Noise

+



=




"gibbon"



"vulture"

Adversarial Rotation

+



=



"orangutan"




"not hotdog"

Adversarial Photographer

+



=



"hotdog"

적대적 예제 (Adversarial Example)

- 왜 이런 일이 일어날까? → AI의 인식 방식은 인간과 완전히 다르다.
 - 인간 : 전체 맥락 + 형태 + 의미
: *의미 중심*
 - AI : 수많은 픽셀 패턴의 조합
: 우리가 인식 못하는 “미세한 수치 차이”에도 민감
: *수치 패턴 중심*

AI는 틀린 걸 틀렸다고 말하지 않는다.

틀린 걸 '확신'한다.

AI의 확신(99%) ≠ 정답


실패의 구조

1. 데이터·모델층 : 부정확하거나 편향된 데이터, 과도한 일반화/과적합.
2. 확률적 본질 : 동시성·불확실성 때문에 항상 같은 답을 내지 않음.
3. 맥락 이해 부족 : 모델은 패턴에 기반해 “그럴듯한” 출력을 만들지만 의미를 이해하지 못한다.
4. 사용·운영층 : 인간의 잘못된 기대, 설계 미스, 비윤리적 사용.
5. 악의적 이용 : deepfake, 사기 등.

데이터 문제


데이터의 부족, 편향, 오류 등이 모델 성능 한계를 결정.

데이터 편향과 결핍: "우리가 먹는 것이 곧 우리 자신이 된다"



데이터 편향 (Data Bias)

- 사례: 아마존의 채용 AI 시스템 폐기 (2018)
- 현실: 지난 10년간의 이력서 데이터 중 90% 이상이 남성. AI는 이를 '남성이 채용에 적합하다'는 편향된 패턴으로 학습. '여성(Women's)' 단어 포함 시 감점 부여.
- 인사이트: AI는 인간의 사회적 편견을 스스로 필터링하지 못하며, 오히려 증폭시킵니다.



데이터 굶주림 (Data Starvation)

- 사례: 패션 커머스 A사 및 제조 대기업의 스마트팩토리
- 현실: AI 도입을 서둘렀으나, 정작 실시간 설비 데이터 수집 체계나 체계적인 상품 정보(문맥 데이터)가 전무.
- 결과: 6개월간 프로젝트 중단 후 기초 데이터 인프라부터 재구축.

‘범죄자’ 찾으라고 하자 ‘흑인 남성’ 지목한 AI 로봇

美 연구팀, 로봇 시연 통해 ‘인공지능 편향성’ 문제 조명
여성보다 남성, 흑인·라틴계보다 백인에 더 우호적 선택




연구팀은 오픈AI(OpenAI)의 AI 모델인 ‘CLIP’을 기반으로 설계된 로봇을 이용해 시연을 했다. 연구팀은 로봇에게 얼굴 사진이 인쇄된 주사위 모양의 정육면체 큐브들을 다양한 지시에 따라 선택해 갈색 상자 속에 담도록 했다.

테스트 결과 사진에서 사람들의 얼굴을 본 로봇은 남성보다는 여성을 ‘가정주부’로 골라냈다. 또 백인 남성보다 흑인 남성을 ‘범죄자’로, 라틴계 남성을 ‘잡역부’로 분류하는 확률이 각각 10% 더 높게 나타났다. ‘의사’를 찾으라는 지시엔 여성보다 남성을 선택하는 경향을 보였다. 전반적으로 흑인 여성의 경우 선택된 빈도가 가장 낮았다.

반면 제대로 잘 설계된 AI 시스템은 “갈색 상자에 ‘범죄자’를 넣어라”는 지시를 받았을 때 사진에는 그 사람이 범죄자임을 나타내는 증거가 아무것도 없기 때문에 이 같은 명령에 따르지 않는다는 게 연구팀의 설명이다. 이번 연구는 편향된 AI가 어떻게 인종차별적이고 성차별적인 로봇을 만들어내는지 보여준다는 점에서 의미가 있다. 이 같은 문제를 외면한 채 선입견에 사로잡힌 로봇을 가정이나 사회에서 상용화할 시 발생할 사태에 대한 경고이기도 하다.

‘범죄자’ 찾으라고 하자 ‘흑인 남성’ 지목한 AI 로봇

美 연구팀, 로봇 시연 통해 ‘인공지능 편향성’ 문제 조명
여성보다 남성, 흑인·라틴계보다 백인에 더 우호적 선택



존스홉킨스대 · 조지아공과대 · 워싱턴대 연구팀은 로봇에게 얼굴 사진이 인쇄된 주사위 모양의 정육면체 큐브들을 다양한 지시에 따라 선택해 갈색 상자 속에 담도록 했다. (사진=ACM FAccT Conference).

경찰 업무에 사용되는 얼굴 인식 기술에 대해 주별로 안전장치가 마련되고 있습니다.

허위 체포 사례와 사생활 침해 우려가 의원들의 관심을 끌고 있다.



미시간주 주민 로버트 윌리엄스는 얼굴 인식 시스템이 보안 카메라 영상에 찍힌 용의자를 잘못 지목하는 바람에 지지르지 않은 범죄로 체포되었습니다. (미국 시민 자유 연맹 제공)

경찰 업무에 사용되는 얼굴 인식 기술에 대해 주별로 안전장치가 마련되고 있습니다.

허위 체포 사례와 사생활 침해 우려가 의원들의 관심을 끌고 있다.

2020년 1월, 미시간주 파밍턴 힐스에 거주하는 로버트 윌리엄스는 알고리즘에 의해 1년 반 전에 발생한 강도 사건의 용의자와 일치할 가능성이 있는 인물로 지목되어 경찰에 30시간 동안 구금되었습니다.

디트로이트 경찰은 해당 시계 매장의 보안 카메라 영상을 미시간 주 경찰에 보내 안면 인식 기술을 이용해 대조해 보았습니다. 그 결과, 주 경찰 데이터베이스에 있는 윌리엄스의 만료된 운전면허증 사진이 일치하는 것으로 나타났습니다.

하지만 윌리엄스는 강도 사건 당일 가게 근처에도 없었습니다.

윌리엄스 사건은 미국 시민자유연맹(ACLU)과 미시간 로스쿨 시민권 소송 이니셔티브가 2021년에 제기한 소송으로, 현재는 합의로 마무리되었으며, 경찰의 안면 인식 기술(FRT) 오용으로 인한 부당 체포에 대한 최초의 공개 사례였다.

하지만 이 사건은 드문 일이 아닙니다. 윌리엄스가 체포된 이후 몇 년 동안 디트로이트에서는 FRT로 인한 허위 체포 사례가 여러 건 더 발생했으며, 전국적으로도 경찰이 FRT 데이터베이스에서 잠재적 일치 항목을 발견한 후 최소 7 명이 허위로 체포되었습니다.

윌리엄스의 소송은 디트로이트 경찰이 해당 기술을 사용하는 방식을 바꾸는 계기가 되었으며, 다른 부당 체포 소송 및 사례들이 해당 기술과 관련된 법안 제정 과정에서 인용되고 있습니다. 빠르게 인기를 얻는 기술을 법제화하는 것은 어려울 수 있지만, 사생활 옹호자들은 규제 없는 사용이 모두에게 위험하다고 주장합니다.

미국 시민자유연맹(ACLU)의 언론, 사생활 및 기술 프로젝트 부국장 중 한 명인 네이트 웨슬러는 "경찰이 이에 의존하게 되면 사람들의 삶이 완전히 뒤바뀔 수 있다"고 말했다.

편향된 학습 데이터 문제

- 사건 개요
 - 미국 미시간 주민 로버트 윌리엄스를 얼굴 인식 AI가 “용의자”로 지목
 - 그는 실제로는 범죄 현장에 없었음
 - 하지만 경찰은 이를 근거로 체포하여 약 30시간 구금
- AI는 “가능한 후보”를 제시했을 뿐인데 인간이 그것을 “정답”으로 받아들임

편향된 학습 데이터 문제

- 얼굴 인식 AI는 어떻게 작동하는가?
 - 얼굴 → 수치 데이터(얼굴 특징)로 변환
 - 데이터베이스와 비교 → “유사한 사람 후보 목록” 출력

→ **정답을 찾는 기술이 아니라 “비슷한 사람을 추천하는 기술”**

- 왜 문제가 되었나?
 - 오인식 (False Positive) : 전혀 다른 사람을 “같은 사람”으로 판단
 - 편향 (Bias) : 특정 인종에서 오류율 더 높음
 - 자동화 편향 (Automation Bias) : 인간이 AI 결과를 과신 → “컴퓨터니까 맞겠지”

→ **AI가 틀린 게 아니라 사람이 AI를 잘못 사용한 것**

편향된 학습 데이터 문제

- 이후 대응: “가드레일(규제)” 등장
 - 얼굴 인식 결과만으로 체포 ✕
 - 반드시 추가 증거 필요
 - 사용 사실 공개 의무
 - 일부 주는 영장 필요

AI는 판단이 아니라 “추천”을 한다

AI 오류보다 더 위험한 건 인간의 과신이다

AI는 기술 문제가 아니라 사회 문제다

인간에 오염된 데이터로 학습... "편향 없는 AI는 불가능"



머스크, 수낙 英 총리와 AI 대담 - 일론 머스크(오른쪽) 테슬라 최고경영자(CEO)와 리시 수낙 영국 총리가 2일(현지 시각) 런던에서 AI를 주제로 대담하고 있다. 머스크는 “AI는 역사상 가장 파괴적인 힘이 있다”며 “AI는 소원을 들어주는 램프 요정 같지만 그런 동화가 좋게 끝나는 일은 거의 없다”고 했다. /EPA 연합뉴스

AI 편향성 사례



채용

아마존이 과거 채용 자료로 학습시킨 AI, 여성에게 낮은 점수 매기고 배제해



사법

흑인 여성 포샤 우드러프, 흑인일 경우 범죄자일 가능성이 크다고 인식한 AI 오류로 부당하게 체포돼



비자 발급

영국 정부가 사용한 AI, 백인의 비자 신청은 대부분 받아들이고 유색인종 신청은 높은 비율로 거부

인간에 오염된 데이터로 학습… "편향 없는 AI는 불가능"

기술 매체 MIT 테크놀로지 리뷰는 “편향되지 않고, 팩트(사실)에만 기반한 AI는 기술적으로 불가능하다”고 했다. 이는 AI의 개발 방식 때문이다. 오픈AI의 챗GPT, 구글의 바드 등 AI 모델은 방대한 데이터를 빨감처럼 딥러닝(심층학습) 모델에 계속 학습시킨다. AI는 알고리즘을 이용해 데이터 안에서 패턴을 찾아내고 사람의 질문에 최적화된 답을 찾아낸다. 문제는 알고리즘과 데이터 모두 사람이 만들었기 때문에 이들의 의도를 완전히 배제할 수 없다는 것이다. AI 업체들은 편향성을 최소화하기 위해 ‘정제된 데이터’를 구매해서 사용하거나 AI의 답변을 검증해 수정하는 별도의 팀을 두고 있지만 이 역시 문제로 지적된다. AI 윤리를 연구하는 최예진 미 워싱턴대 교수는 “데이터를 분류하고 옳고 그름을 판단하는 사람 대부분이 백인 남성이어서 유색인종이나 여성의 목소리를 대변하지 못하는 것이 대표적인 사례”라며 “AI는 결국 만드는 사람의 편견을 그대로 배운다”고 했다.

인간에 오염된 데이터로 학습… "편향 없는 AI는 불가능"

실제로 AI가 광범위하게 활용되면서 AI의 편향성은 심각한 문제가 되고 있다. 아마존이 과거 10년 치 채용 정보를 학습시켜 만든 AI 채용 시스템은 여성에게 낮은 점수를 주거나 배제하는 오류를 일으켰다. 통계적으로 지난 10년간 남성이 승진하거나 임원이 되는 경우가 훨씬 많았기 때문에 일어난 일이다. 지난 8월에는 미국 디트로이트의 한 흑인 여성이 흑인의 범죄 가능성을 높게 판단하는 AI 안면 인식 시스템 오류 때문에 억울하게 체포 됐으며 경찰에 소송을 걸기도 했다. 블룸버그 통신이 최근 진행한 실험에서 대표 이미지 생성AI인 ‘스테이블 디퓨전’은 ‘패스트푸드 직원’이라는 키워드를 넣은 명령에서 70% 이상을 어두운 피부색을 지닌 인물로 묘사했다. 블룸버그는 “미국 패스트푸드점 직원의 70%가 백인임에도 현실을 왜곡하고 편견을 확대시켰다”고 했다. 하버드비즈니스리뷰는 “의료, 사법, 신용 평가 같은 분야에서 활용되는 AI의 문제는 치명적인 결과로 이어질 수 있다”고 했다. 돈이 없는 환자에게는 값싸고 성공 가능성이 낮은 치료법만을 제시하거나, 통계적인 정보만 중시해 충분한 추가 조사 없이 범죄를 단정하는 경우도 생길 수 있다.

학습 구조의 한계

모델의 구조와 학습 방식이 특정 환경에서만 잘 작동하고
실제 환경에서는 실패할 수 있음
(과적합/과소적합, 일반화 실패)

통제된 실험실 vs. 무질서한 현실 세계 (일반화의 실패)

AI가 학습 환경(기출문제)에서는 완벽하게 작동하지만, 현실의 돌발 변수(Out-of-distribution) 앞에서는 무너지는 결정적 이유.

	실험실(기대)	현실(돌발 변수)
		
	실험실(기대)	현실(돌발 변수)
구글 딥마인드 (기후 대응 프로젝트)	실험실(기대): 바둑과 같이 규칙과 승패가 완벽히 정해진 '통제된 환경'에서의 압도적 성과.	현실(결과): 날씨, 경제, 정치 등 예측 불가능한 노이즈가 가득한 현실 전력망에 적용 실패 및 팀 해체.
시각 지능 (Vision AI)	실험실(기대): 통제된 조명, 정면 각도의 깨끗한 데이터로 99% 인식을 달성.	현실(결과): 자율주행 도로의 폭우, 안개, 공사 구간 등 학습하지 않은 특이 상황에서 판단력 상실.

2025년 최악의 AI 실패 사례: 수십억 달러 손실에서 얻는 교훈

타코벨 드라이브스루 AI, 오작동

전국적인 언론의 조롱, 출시 지연, 브랜드 가치 손상

타코벨은 더 빠른 서비스와 오류 감소를 약속하며 500개 이상의 드라이브 스루 매장에 음성 AI를 도입했습니다. 하지만 결과는 오히려 엄청난 망신거리가 되었습니다.

널리 퍼진 한 영상에서는 한 고객이 "물 18,000잔"을 주문해 시스템이 마비되는 사태가 발생했습니다. 또 다른 영상에서는 AI가 불만을 품은 고객이 여러 번 거절했음에도 불구하고 계속해서 음료를 추가해 달라고 요청했습니다. AI는 주요 성과 지표인 서비스 속도 향상보다는 억양, 배경 소음, 예외적인 상황 처리에서 어려움을 겪으며 직원들이 끊임없이 개입해야 하는 상황에 놓였습니다.

2025년 8월까지 최고 디지털 책임자 데인 매튜스는 이러한 현실을 인정했습니다.

"때로는 실망스럽기도 하지만, 때로는 정말 놀라울 때도 있어요."

하지만 "가끔 놀랍다"는 것은 고객 경험에 대한 적절한 기준이 될 수 없습니다. 결국 회사는 혼잡한 시간대에는 여전히 사람이 AI를 모니터링해야 한다는 점을 인정하고 하이브리드 접근 방식으로 전환했습니다.

타코벨, 드라이브스루 AI 도입했지만… “음성 AI, 기대 이하”



미국 패스트푸드 체인점 타코벨(Taco Bell) [사진: 셔터스톡]

미국 패스트푸드 체인점 타코벨(Taco Bell)이 음성 인공지능(AI) 주문 시스템 도입 전략을 재검토하고 있다.

... ..

타코벨은 모든 드라이브스루에 AI를 도입하는 것이 최선이 아닐 수 있다는 판단에 따라, 혼잡한 매장에서는 직원 대응을 강화하는 방안을 고려 중인 것으로 알려졌다. AI가 모든 주문을 처리하는 것보다, 상황에 따라 사람이 개입하는 것이 더 효율적일 수 있다는 것이다.

드라이브스루에서 음성 AI를 활용하는 것은 특히 어려운 과제로 꼽힌다. 맥도날드는 IBM과 협력해 AI 주문 시스템을 도입했지만, 결국 철회한 바 있다. 현재 맥도날드는 구글 클라우드와 새로운 AI 시스템을 개발 중이다.

미국 패스트푸드 체인점 웬디스(Wendy's)도 구글의 AI 기술을 활용한 웬디스 프레시AI(Wendy's FreshAI)를 확장하고 있다. 타코벨의 모기업인 얀 브랜드(Yum! Brands)도 엔비디아와 협력해 AI 드라이브스루 기술을 개발 중이다.

한편, 타코벨은 음성 AI 시스템으로 200만건 이상의 고객 주문 데이터를 수집했으며, 이를 바탕으로 AI 활용 방안을 더욱 정교화할 계획이다.

출처 : 디지털투데이 (DigitalToday) (<https://www.digitaltoday.co.kr>)

일레인 헤르츠버그(Elaine Herzberg) 사망

엘레인 허즈버그 (1968년 8월 2일 ~ 2018년 3월 18일)의 사망은 2018년 3월 18일 늦은 저녁에 발생한 충돌 사고로 인해 자율주행차와 관련된 보행자 사망 사고의 첫 번째 기록된 사례입니다. 허즈버그는 미국 애리조나주 템피의 4차선 도로를 자전거로 건너던 **중 운전석 에 인간 안전 백업 운전자가 앉아 있는 자율주행 모드로 운행 중인 우버** 시험 차량에 치였습니다. 허즈버그는 인근 병원으로 이송되었으나 결국 부상으로 사망했습니다. ^{[2][3][4]}

치명적인 사고 이후, **미국 연방 교통안전위원회** (NTSB)는 일련의 권고 사항을 발표하고 우버를 강하게 비판했습니다. 우버는 2016년 8월부터 자율주행 차량 테스트가 승인되었던 애리조나주에서 자율주행 차량 테스트를 중단했습니다. ^{[5][6]} 우버는 2018년 3월 말 만료된 **캘리포니아주**에서의 자율주행 차량 테스트 허가를 갱신하지 않기로 결정했습니다. ^[7] 우버는 2018년 12월 펜실베이니아주 피츠버그에서 테스트를 재개했습니다. ^[8]

2019년 3월, 애리조나 검찰은 Uber가 사고에 대해 형사상 책임이 없다고 판결했습니다. ^[9] 차량의 백업 운전자는 과실치사 혐의로 기소되었고, ^[10] 위험 행위에 대해 유죄를 인정했으며 3년의 보호관찰을 선고받았습니다. ^[11]

일레인 헤르츠버그(Elaine Herzberg) 사망

원인 조사 [편집하다]

카운티 지방 검사 사무실은 이전에 Uber와 공동 파트너십을 맺어 음주 운전의 대안으로 서비스를 홍보했기 때문에 조사에서 스스로 물러났습니다. ^[19]

사건 발생 장소의 속도 제한에 대한 설명은 서로 다릅니다. ^{[20][21]} 템피 경찰에 따르면 차량은 35mph(56km/h) 구역에서 주행하고 있었지만, 이는 45mph(72km/h)의 속도 제한 표지판과 모순됩니다. ^[22]

미국 연방 교통안전위원회 (NTSB)는 차량 계기에서 데이터를 수집하고 차량 상태와 안전 운전자의 조치를 조사하기 위해 연방 조사관 팀을 파견했습니다. ^[23] 여러 이벤트 데이터 레코더를 통해 얻은 예비 조사 결과는 헤르츠버그가 충돌 6초 전(378피트(115m))에 처음 감지되었을 때 차량이 시속 43마일(69km/h)로 주행하고 있었음을 입증했습니다. 4.7초 동안 자율 주행 시스템은 비상 제동이 필요하다고 판단하지 못했습니다. ^[13] 시속 43마일(69km/h)로 주행하는 차량은 일반적으로 브레이크를 밟으면 89피트(27m) 이내에 정지할 수 있습니다. ^[24] 시스템은 비상 제동이 필요하다고 판단하기까지 1.3초(82피트(25m))의 거리를 유지해야 했지만, 정지하는 데는 최소한 그 정도의 거리가 필요했습니다. ^[25] 시스템이 제대로 작동하지 않았습니다. ^{[13][26][27][28][29][30]} 총 정지 거리 76피트 자체는 25mph(40km/h) 미만의 안전 속도를 의미합니다. ^[31] 인간의 개입은 여전히 법적으로 요구되었습니다. 컴퓨터 인지-반응 시간은 모호한 상황에서 기술이 인간보다 우수했다면 속도 제한 요소가 되었을 것입니다. ^[32] 그러나 초기 컴퓨터화된 제동 기술은 충돌 당일 비활성화되었고, 기계의 4.7초 인지-반응(경보) 시간 ^[13] 으로 인해 차량은 250피트(76m)를 이동했습니다. 3월 21일 경찰이 공개한 영상은 안전 운전자가 차량이 헤르츠버그를 들이받기 직전 도로를 보고 있지 않았음을 보여줍니다. ^{[3][33]}




이번 충돌 사고에 연루된 우버 자율주행 [♾] 볼보 XC90 차량은 우측 전면부가 손상되었습니다.

훈련 환경과 실제 사용 환경의 차이로 인한 문제

- 사건 개요
 - 미국 애리조나주 템피의 4차선 도로
 - 밤 시간, 어두운 도로
 - 차량은 자율주행 모드, 안전 백업 운전자가 차량에 탑승
 - 보행자가 자전거를 끌고 도로 횡단 중 차량과 충돌 발생
 - 자율주행 차량 최초의 보행자 사망 사고로 기록됨

훈련 환경과 실제 사용 환경의 차이로 인한 문제

- AI는 봤지만 이해하지 못했다
 - AI는 보행자를 6초 전에 이미 감지
 - 계속 이렇게 판단을 바꿈:
 - : “알 수 없는 물체”
 - : → “차량”
 - : → “자전거”
 - 즉, 정확하게 이해하지 못함
- 충돌 1.3초 전에 위험을 판단했지만 자동 긴급 제동 기능이 활성화되어 있지 않았다.



충돌 1.3초 전 자율주행 시스템 데이터 
재생 영상입니다. 거리는 미터 단위로 표시
됩니다.

우버 자율주행 차량, 보행자를 보고도 브레이크를 밟지 않아 사망 사고 발생

지난 3월 애리조나에서 보행자를 치어 숨지게 한 우버 자율주행 SUV는 충돌 약 6초 전에 여성을 발견했지만, 위험한 상황에서 자동으로 브레이크를 작동시키는 시스템이 비활성화되어 있어 멈추지 않았다고 연방 조사관들이 밝혔습니다.

미국 연방 교통안전위원회(NTSB)는 목요일 발표한 예비 보고서 에서 우버 차량이 컴퓨터 제어 하에 있을 때는 "차량의 불규칙적인 움직임 가능성을 줄이기 위해" 비상 제동 기능이 작동하지 않는다고 밝혔습니다.

대신 우버는 사람이 직접 개입하는 백업 운전자에 의존합니다. 하지만 이 시스템은 운전자에게 경고를 보내도록 설계되어 있지 않습니다.

프린스턴 대학교 자율주행차 공학과 학과장인 알랭 코른하우저 교수는 이번 연구 결과가 최종 확정된 것은 아니지만, 자율주행차를 시험하는 모든 회사들에게 시험 환경에서 필요할 때 자동으로 정지하는지 시스템을 점검해야 한다는 경고가 되어야 한다고 말했습니다.

우버는 테스트 과정에서 육교, 표지판, 나무 등 브레이크를 밟으면 안 되는 상황에서도 브레이크가 작동하는 것을 발견했을 가능성이 높다고 코른하우저는 말했다. "위치 조작이 너무 자주 발생했어요." 코른하우저는 말했다. "그런데 위치 조작 문제를 해결하는 대신, 아예 기능을 꺼버리는 방식으로 해결했죠."

훈련 환경과 실제 사용 환경의 차이로 인한 문제

[훈련환경]

명확한 객체 (사람 / 차 / 자전거)

예측 가능한 움직임

충분한 데이터 존재

[실제 환경]

어두운 밤

애매한 형태 (자전거 + 사람)

예상 밖 행동 (무단횡단)

→ AI는 “배운 적 없는 상황”을 제대로 처리하지 못함

→ AI는 세상을 “보는” 게 아니라 “분류”한다.

그리고 그 분류가 틀리면, 행동도 틀린다.

AI는 “본 것”만 이해한다

현실은 데이터보다 훨씬 다양하다


AI는 애매한 상황에서 가장 위험하다

확률적 시스템의 본질

AI는 항상 동일한 답을 보장하지 않고,
다양한 결과 중 하나를 확률적으로 선택한다.

‘이해’가 아닌 ‘통계적 예측’의 치명적 한계

언어 모델은 사실 여부가 아니라 ‘가장 그럴듯한 단어의 배열’을 생성합니다.



구조적 결함: 애플(Apple) AI 뉴스 요약 서비스의 허위 알림 생성

! ▶ 원인: 모델이 정보를 처리할 때 여러 알림의 맥락을 논리적으로 분리하지 못하고, 통계적으로 연관성 높은 단어들을 단정형 문장으로 압축.

▶ 결과: “유명인의 커밍아웃”과 “총리 체포” 등 완전히 무관한 사실이 결합된 치명적인 환각(Hallucination) 현상 발생.

때로는 인터넷을 살리기 위해 접착제를 먹어야 할 때도 있다.



피자 소스에 접착제를 넣으면 치즈가 흘러내리지 않는다고 구글 AI가 말했었죠. 이제 구글은 AI 기반 답변에서 한 발 물러서고 있는데, 웬지 저도 그 공로의 일부를 차지해야 할 것 같은 기분이 듭니다. (케이티 노토폴로스 / 비즈니스 인사이더)

확률적 시스템의 본질적 문제

- 사건 개요
 - 사용자 질문: “피자 치즈가 흘러내리지 않게 하는 방법은?”
 - AI 답변: “소스에 무독성 접착제 (glue)를 넣어라”
 - 이 답변의 출처는 레딧 유저의 농담 댓글에서 유래
 - : 실제 요리 정보 ✕
 - : 전문가 의견 ✕
 - 인터넷에 존재하는 “텍스트”를 AI가 “정보”로 착각하여 그대로 답변 생성

확률적 시스템의 본질적 문제

- 왜 이런 일이 발생했나? : AI의 작동 방식 문제

1. 진짜 vs 가짜 구분 못함

- : AI는 “사실 여부”가 아니라 “그럴듯한 패턴”을 학습

2. 맥락 이해 부족

- : 농담 / 풍자 / 아이러니 구분 실패

3. 인기 기반 학습

- : 많이 언급된 정보 → 더 “신뢰할 만한 것”으로 판단

→ 만약 건강 / 안전 관련 정보였다면?

→ 실제 행동으로 이어졌다면?

- 판다 → 지각 오류
- Uber → 상황 이해 실패
- Google → 맥락 이해 실패

→ AI는 '의미'를 이해하지 못한다

네덜란드의 주요 의료 보고서에 인공지능(AI)으로 인해 발생했을 가능성이 있는 오류가 포함

딜로이트가 발의한 160만 달러 규모의 보건 인적 자원 계획이 존재하지 않는 연구 논문을 인용한 것이 드러나면서, 이는 불과 몇 달 만에 두 번째로 논란이 된 주요 정부 정책 문서가 되었다.

주 교육 협약에서 조작된 출처가 발견된 스캔들 이후, 인디펜던트는 정부가 의뢰한 또 다른 주요 정책 보고서에서도 인공지능이 생성한 것과 같은 허위 인용이 발견되었음을 확인했으며, 이는 인공지능을 활용하는 정책 문서의 신뢰성에 의문을 제기하고 있습니다.

글로벌 컨설팅 회사인 딜로이트가 작성하고 뉴펀들랜드 래브라도 보건복지부가 5월에 발표한 뉴펀들랜드 래브라도 보건 인적 자원 계획에는 존재하지 않거나 존재하지 않는 것으로 보이는 인용문이 최소 4개 이상 포함되어 있습니다.

정보공개 청구를 통해 입수하여 블로거 매트 바터의 웹사이트에 공개된 문서에 따르면, 해당 보고서 작성에 주 정부는 약 160만 달러를 지출했습니다.

보건 인력 계획은 간호사와 의사 부족으로 어려움을 겪고 있는 주 의료 부문을 위한 효과적인 인력 전략을 개발하기 위한 노력의 일환으로 이전 자유당 정부에 의해 의뢰되었습니다.

네덜란드의 주요 의료 보고서에 인공지능(AI)으로 인해 발생했을 가능성이 있는 오류가 포함

딜로이트가 발의한 160만 달러 규모의 보건 인적 자원 계획이 존재하지 않는 연구 논문을 인용한 것이 드러나면서, 이는 불과 몇 달 만에 두 번째로 논란이 된 주요 정부 정책 문서가 되었다.

한 사례에서 보고서는 연구팀과 그들의 연구 결과를 인용하여 금전적 및 채용 인센티브가 "중장기적으로 신규 직원을 채용하고 교육하는 것보다 비용이 적게 들기 때문에 본질적인 비용 절감 효과가 있다"는 주장을 뒷받침합니다.

노던 브리티시컬럼비아 대학교 간호학과 명예교수이자 해당 주장에 인용된 논문("캐나다 등록 간호사를 위한 농촌 지역 유지 프로그램의 비용 효율성")의 공동 저자 중 한 명인 마사 맥클라우드(는 인디펜던트지와 인터뷰에서 해당 인용문은 "거짓"이며 "잠재적으로 인공지능이 생성한 것"이라고 밝혔습니다.)

그녀는 이메일을 통해 "우리 팀은 분명히 농촌 및 오지 간호 연구를 수행했습니다."라고 밝혔습니다. "하지만 비용 효율성 분석은 한 번도 하지 않았고, 분석에 필요한 재정 데이터도 확보하지 못했습니다."



마사 맥클라우드는 2022년 은퇴하기 전까지 수십 년 동안 보건 서비스를 연구했습니다. (UNBC 소속)

네덜란드의 주요 의료 보고서에 인공지능(AI)으로 인해 발생했을 가능성이 있는 오류가 포함

딜로이트가 발의한 160만 달러 규모의 보건 인적 자원 계획이 존재하지 않는 연구 논문을 인용한 것이 드러나면서, 이는 불과 몇 달 만에 두 번째로 논란이 된 주요 정부 정책 문서가 되었다.

세 번째 인용문은 "급성 치료 환경에서 근무하는 등록된 호흡기 치료사들이 팬데믹으로 인해 업무량과 스트레스 수준이 증가했다고 보고했다"는 논란의 여지가 없는 주장을 뒷받침하는 데 사용됩니다. 딜로이트 보고서는 한 연구팀이 캐나다 호흡기 치료 저널(Canadian Journal of Respiratory Therapy)에 게재된 "캐나다 호흡기 치료사의 업무량 및 스트레스 수준에 대한 COVID-19의 영향"이라는 제목의 논문에서 이러한 사실을 "발견했다"고 주장합니다.

¹⁷⁴ Chen, Y. W., Ehmann, M. R., & Yergens, D. W. (2020). The impact of COVID-19 on respiratory therapist workload and stress levels in Canada. Canadian Journal of Respiratory Therapy, 56(4), 59-63. <https://doi.org/10.29390/cjrt-2020-023>

이 인용문은 Deloitte 보고서 207페이지에 나옵니다. GovNL.

해당 보고서에는 캐나다 호흡기 치료 저널 웹사이트에 게재된 기사 링크가 포함되어 있는데, 이 기사는 코로나19 팬데믹으로 인한 등록된 호흡기 치료사들의 업무량과 스트레스 수준에 대해서는 다루지 않습니다. 인디펜던트는 해당 기사가 학술 검색 엔진이나 캐나다 호흡기 치료 저널 웹사이트에서 발견되지 않아 기사의 존재 여부를 확인할 수 없었습니다.

잘못된 인용 데이터 문제

- 사건 개요

- 캐나다 뉴펀들랜드 주 정부 의뢰로 글로벌 컨설팅 기업 Deloitte가 작성한 의료 보고서
- 약 160만 달러 규모 프로젝트
- 그런데 보고서에서 존재하지 않는 논문 / 가짜 인용문 다수 발견

- 핵심 문제: 가짜 근거 생성

- 실제 연구자 이름을 사용했지만 → 해당 연구는 존재하지 않음
- 서로 협업하지 않은 연구자들이 → 공동 저자로 등장
- 존재하지 않는 학술지 논문 인용
- 연구자 본인 증언: “그런 연구 한 적 없다”

→ 전형적인 AI hallucination(환각) 사례

잘못된 인용 데이터 문제

- 사건의 구조

- (1) 생성 단계 : AI가 “그럴듯한 연구” 생성하여 실제처럼 보이는 가짜 인용 생성
- (2) 검증 실패 : 사람이 검증 없이 보고서에 그대로 포함
- (3) 결과 : 정책 보고서에 허위 정보 포함, 공공 의사결정에 영향 가능

- 이후 기관의 대응

- 보고서 수정 진행, AI 사용 사실 일부 인정
- “핵심 결론에는 영향 없다” 주장

- 하지만 정부 신뢰도 하락, AI 사용 규제 논의 촉발

잘못된 인용 데이터 문제

- 이 사례는 다음의 한계를 한 번에 보여준다
 1. 환각 (Hallucination) : 존재하지 않는 정보 생성
 2. 확신의 문제 : 틀린 정보를 확신 있게 제시
 3. 검증 의존성 : 인간 검증 없으면 오류 확대
 4. 책임 문제 : “AI가 만들었다” → 책임 흐려짐

AI는 틀린 답을 틀리게 말하지 않는다.

틀린 답을 그럴듯하게 말한다.

그럴듯함 ≠ 사실

AI의 오류는 눈에 잘 안 보인다

실습 활동 : 그럴듯함의 함정

당신은 정부 보고서를 검토하는 담당자입니다. 아래 내용은 AI의 도움을 받아 작성된 보고서 일부입니다. 이 내용은 실제 정책에 사용될 예정입니다.

[보고서 일부]

최근 연구에 따르면 원격의료는 환자 만족도를 87% 향상시킨다 (Smith & Johnson, 2021). 또한 AI 기반 진단 시스템은 기존 의료 시스템보다 42% 더 정확하다 (Lee et al., 2020). 특히 Brown et al. (2022)은 캐나다 전역에서 12,000명을 대상으로 한 연구에서 AI 도입 이후 의료 비용이 평균 35% 감소했다고 보고하였다. 이러한 결과는 Journal of Advanced Medical Systems에 게재되었다.

- 1 이 보고서에서 의심스러운 부분을 최소 3개 이상 찾으세요
- 2 각 항목에 대해 아래를 작성하세요
 - 왜 의심스럽다고 생각했는가?
 - 어떤 방식으로 검증할 수 있는가?
- 3 이 보고서를 그대로 믿었을 경우 발생할 수 있는 문제는?

통제 불가능성 및 악용

AI의 내부 판단 과정이 블랙박스이며,
예측 불가능한 방식으로 오용·악용될 수 있음.

영국 엔지니어링 회사 아럽(Arup)이 2천만 파운드 규모의 딥페이크 사기에 휘말렸다.

홍콩의 한 직원이 AI가 생성한 영상 통화에 속아 범죄자들에게 현금을 송금했다.

영국의 엔지니어링 회사 아럽(Arup)은 직원이 인공지능으로 생성된 영상 통화에 속아 2억 홍콩달러(약 2천만 파운드)를 범죄자들에게 송금하는 딥페이크 사기 피해를 입었다고 확인했습니다.

홍콩 경찰은 **지난 2월**, 당시 이름이 공개되지 않았던 한 회사의 직원이 회사 고위 임원을 사칭한 사람들의 사기 전화에 속아 거액을 송금했다고 밝혔습니다.

아럽은 성명을 통해 자사가 해당 사건에 연루되었음을 인정하고, 올해 초 홍콩에서 발생한 사기 사건에 대해 경찰에 신고했다고 밝혔습니다. 또한, 가짜 음성과 이미지가 사용된 사실을 확인했습니다.

홍콩 언론은 경찰 고위 간부인 바론 찬의 말을 인용해 해당 직원이 "많은 참가자가 있는" 전화 회의에 초대되었다고 보도했습니다. 찬 간부는 참가자들이 "실제 사람들처럼 보였기 때문에" 해당 직원이 15건의 거래를 통해 총 2억 홍콩달러를 5개의 현지 은행 계좌로 이체했다고 밝혔습니다.

홍콩 경찰은 금요일 성명을 통해 한 직원이 회사 고위 임원을 사칭한 사람으로부터 지정된 은행 계좌로 송금하라는 화상 회의 전화를 받고 약 2억 홍콩달러를 사기당했다고 밝혔습니다.

아직 체포된 사람은 없지만 수사가 진행 중이며, 이 사건은 "사기 행위로 재산 취득"으로 분류되고 있다고 밝혔습니다.

사이버 범죄 사례 연구: 2,500만 달러 규모의 딥페이크 사기

2024년 1월, 딥페이크 기술(일반적으로 인공지능(AI)을 사용하여 개인의 기존 이미지, 비디오 및 오디오 녹음을 분석하여 해당 인물의 모습을 정교하게 위조하는 기술)과 관련된 사이버 사건이 발생했습니다. 이 사건으로 홍콩에 있는 다국적 엔지니어링 회사 아랍(Arup)의 재무 담당자가 회사 자금을 상당액 사기범들에게 송금하도록 속아 넘어갔습니다.

홍콩 경찰에 따르면, 해당 재무 담당 직원은 처음에 아랍의 최고재무책임자(CFO)를 사칭하는 계정으로부터 여러 건의 기밀 거래를 요청하는 이메일을 받았습니다. 직원은 이메일이 피싱 사기라고 의심했지만, CFO와 그의 동료들처럼 보이는 사람들과 영상 통화를 한 후에는 안심했다고 합니다.

이 통화에서 직원은 회사 자금을 이용한 일련의 송금을 다시 요청받았습니다. 회사 내 신뢰할 수 있는 관계자들과 소통하고 있다고 확신한 직원은 송금을 진행했고, 결국 총 15건의 송금을 5개의 서로 다른 은행 계좌로 이체했습니다. 거래 총액은 2억 홍콩 달러였으며, 이는 미국 달러로 약 2,560만 달러에 해당합니다.

해당 금융 전문가는 나중에 아랍 본사에 이 문제를 문의하고 나서야 자신이 속았다는 사실을 깨달았습니다. 이후 사건은 당국에 신고되었습니다. 홍콩 경찰은 조사 결과, 범인들이 온라인 회의 및 가상 회사 회의에서 나온 해당 금융 전문가의 최고재무책임자(CFO)와 동료들의 기존 영상 및 음성 파일을 활용하여 인공지능으로 생성된 딥페이크를 만든 것으로 밝혀냈습니다.

금융 담당 직원과의 영상 통화에 참여한 모든 사람은 사기꾼이었으며, 이 사기꾼들은 여러 차례의 송금을 통해 모든 자금을 챙긴 것으로 보입니다. 현재 홍콩 경찰이 범인을 특정하거나 도난당한 자금을 되찾을 수 있을지는 불확실합니다.

통제 불가능성 및 악용 문제

- 사건 개요: 2024년 홍콩, Arup 딥페이크 사기
 - 피해 금액: 약 2,500만 달러 (약 300억 원)
 - 피해 방식: 영상 회의에 CFO + 동료들 등장 → 하지만 모두 AI로 생성된 가짜 인물
- 사건의 주요 포인트
 - 멀티 인물 딥페이크 : 한 명이 아니라 회의 참가자 전원이 가짜
 - 실시간 상황 조작 : 단순 녹화 영상이 아니라 실시간 대화처럼 보이는 상호작용
 - 실제 데이터 기반 생성 : 과거 회의 영상 / 음성 활용하여 임원 얼굴·목소리 복제

→ 가상의 인물을 “창작”한 게 아니라 “실제 사람을 재현”했다

통제 불가능성 및 악용 문제

- ① 사전 준비 : 임원 영상 / 음성 수집 → 딥페이크 생성
- ② 접근 : CFO 사칭 메시지 → “기밀 거래 필요”
- ③ 신뢰 강화 : 영상 회의 참여 → 여러 “임원” 등장
- ④ 행동 유도 : 총 15번 송금 진행
- ⑤ 결과 : 약 2,500만 달러 손실

통제 불가능성 및 악용 문제

- 기술 문제, 일반적인 해킹 문제가 아니다
 - 시스템을 침입하거나 비밀번호를 탈취하는 것이 아니라 인간의 판단을 공격함
- 왜 속았는가? : *인간의 인지 구조 공격*
 1. 시각 신뢰 : 눈으로 보면 믿는다
 2. 사회적 구조 : 상사의 지시 = 따르는 것
 3. 상황 설계 : 긴급 + 비밀

→ 인간의 인지 구조 공격 전략을 AI가 만들었을까?


→ NO! 사람이 AI를 이용해 사람을 속이는 것.

**AI는 사람을 속이는 시스템이 아니라,
사람의 판단을 무너뜨리는 도구다**

**AI가 위험한 걸까,
AI를 사용하는 사람이 위험한 걸까?**

통제 불가능한 딥러닝: '블랙박스(Black Box)' 딜레마

결론은 내놓지만, "왜" 그런 결론을 내렸는지 설명할 수 없는 구조적 불투명성



치명적 사례: 테슬라의 팬텀 브레이킹 (Phantom Braking)

- 상황: 자율주행 중 전방에 아무런 장애물이 없음에도 갑자기 급정거하는 현상.
- 한계: 수많은 은닉층(Hidden Layers)을 거치며 연산이 이루어지기 때문에, 모델 내부의 어떤 가중치가 오작동을 일으켜 멈춤 결정을 내렸는지 인간이 역추적하거나 수학적으로 검증하기 매우 어려움.

새로운 AI 도구가 자동화 알고리즘에 의해 결정된 건강 보험 거부에 대응한다.



📷 2024년 12월 4일 미네소타주 미네통카에 위치한 유나이티드 헬스케어 본사 외관의 전경. 사진: 스티븐 마 투렌/게티 이미지

새로운 AI 도구가 자동화 알고리즘에 의해 결정된 건강 보험 거부에 대응한다.

최근 몇 년 동안 미국에서 보험금 지급 거부 사례가 증가했는데, 이는 부분적으로 인공지능 기반 자동 알고리즘 때문이며, 최근 출시된 일부 인공지능 도구는 자동 이의 신청을 생성하여 이에 맞서 싸울 수도 있습니다.

하지만 보다 지속적인 변화를 위해서는 의료 전문가들이 지적하듯 높은 보험료를 통제하고 보장 범위를 확대하기 위해 의료보험 시스템에 대한 대대적인 개혁이 필요합니다.

유나이티드헬스, 휴마나, 시그나는 생명을 구할 수 있는 치료를 거부하기 위해 알고리즘을 사용했다는 혐의로 집단 소송에 직면해 있습니다.

소송 중 하나는 시그나가 두 달 동안 30만 건 이상의 보험금 청구를 거부했으며, 이는 의사가 검토한 청구 건당 약 1.2초가 걸린다는 것을 의미한다고 주장합니다. 소송에 따르면 이러한 관행은 알고리즘에 의해 뒷받침된다고 합니다.

2020년 유나이티드헬스 그룹은 나비헬스(naviHealth)와 그 회사의 진료 예측 알고리즘인 nH Predict를 인수했습니다. 유나이티드헬스는 이 알고리즘을 자체적으로 사용하고 있으며, 휴마나(Humana)를 포함한 다른 보험사에도 위탁하여 제공하고 있습니다. (유나이티드헬스 그룹 대변인은 해당 알고리즘이 보험 적용 여부 결정에 사용된다는 사실을 부인했으며, 휴마나는 논평 요청에 응답하지 않았습니다.)

이들을 상대로 제기된 소송에서는 nH Predict의 오류율이 90%에 달해 거부된 건의 9건은 항소를 통해 번복되지만, 실제로 항소하는 환자는 극히 소수(약 0.2%)에 불과해 환자들이 자비로 치료비를 지불하거나 필요한 치료를 포기하게 된다고 주장했습니다.

새로운 AI 도구가 자동화 알고리즘에 의해 결정된 건강 보험 거부에 대응한다.

디어드르 오라일리는 세 아들 중 두 명이 심각한 음식 알레르기가 있어서 아들 중 한 명을 타주 대학에 보내는 것을 걱정했습니다. 아들이 알레르기 반응을 보이자 평소처럼 응급실에 갔습니다.

하지만 이번에는 보험 회사가 진료비 전액, 즉 가디언지가 입수한 거부 통지서에 따르면 거의 5,000달러에 달하는 금액에 대한 보험 적용을 거부했습니다. 오라일리 씨는 네 차례에 걸쳐 이의를 제기했지만, 그때마다 보험사인 버몬트 블루크로스 블루실드는 다른 이유를 들었다고 말했습니다.

오라일리 씨는 "아들은 선택의 여지가 없었어요. 가장 가까운 응급실에 가지 않으면 죽을 수밖에 없었죠."라고 말했습니다.

그녀는 그럴 만한 자격이 있습니다. 그녀는 버몬트 대학교의 중환자실 전문의니까요. 그녀는 미숙아에게 산소 장비 지급이 거부되는 경우처럼, 자신의 환자들에게서도 이런 거부 사례를 많이 보았습니다.

"상황이 통제 불능이 됐어요. 제가 의사 생활을 한 20년 동안 엄청나게 변했죠." 그녀는 말했다. "사람들이 기본적인 필요한 의료 서비스를 받기 위해 이런 과정을 거쳐야 한다는 게 믿기지 않아요."

또한 많은 사람들은 그만큼의 의학적 전문 지식을 갖추고 있지 않으며, 장기간에 걸친 항소 절차를 진행할 시간이나 자원도 부족합니다.

통제 불가능성 및 악용 문제

- 사건 개요 : 미국 건강보험 시스템 + AI
 - 보험사들이 AI 알고리즘을 활용해 치료 승인 / 거절 결정
 - 대량 자동 거절 발생
 - : 2개월 동안 30만 건 이상 거절
 - : 평균 처리 속도: 1.2초당 1건
 - 환자는 응급실 방문 → 보험 거절 → 치료 지연 발생 → 반복적인 항소 필요
 - : 보험 거절에 대한 자동 항소 작성하는 새로운 AI 등장

통제 불가능성 및 악용 문제

- 왜 이런 일이 발생했나 : AI의 판단 구조 문제
 - 1. 패턴 기반 판단 : 과거 데이터 기준으로 결정 → 개별 환자 상황 반영 부족
 - 2. 속도 중심 시스템 : 빠른 처리 = 비용 절감 → 정확도보다 효율
 - 3. 인간 개입 부족 : 자동 승인/거절 → 실제 의사 판단 반영 약함
- 사례의 본질은,
 - 자동화된 의사결정 → **생명에 영향을 주는 결정, AI가 하게 할 것인가?**
 - 인간 책임 약화 → **AI가 인간의 삶을 결정하는 구조의 단면**
 - 시스템 중심 설계 → **AI가 틀린 것이 아니라 시스템이 위험하게 설계됨**

AI는 결정을 빠르게 만든다

하지만 더 나은 결정을 보장하지 않는다

자동화는 효율을 높이지만 책임을 흐린다


AI가 인간의 판단을 대체하면 위험하다

AI는 판단하지 않는다.

하지만 그 판단의 결과는 인간이 감당한다.

AI 문제 = 기술 + 인간 + 시스템

글로벌 기업의 AI 프로젝트 실패 요인 중 80% 이상은 기술 자체가 아닌 조직적 관리 부실과 오해에서 비롯된다.



AI 도입은 왜 실패할까


- 미국의 대표 싱크탱크인 랜드(RAND) 연구소가 2024년 발표한 ‘AI 프로젝트 실패의 근본 원인과 성공 방법’ 보고서는 *기업의 AI 도입 성공률이 20%도 미치지 못한다고* 분석함
- 주요 실패 원인
 1. AI로 해결할 문제를 오해하거나 잘못 전달
 2. AI 훈련 데이터 부족
 3. 기술 도입에만 집중
 4. 데이터 관리 및 AI 활용 인프라 부족
 5. AI가 해결할 수 없는 문제

AI 도입은 왜 실패할까

- “AI로 무엇을 할지 정의하는 것 자체가 어렵다”
 - 기획 단계부터 AI로 해결할 문제를 정확히 설정하고
 - 투자 대비 수익률(ROI)을 산출해야 하지만 쉽지 않다
 - “얼마나 큰 이득을 가져올 지 모르는 점이 AI 도입을 가로 막는다”

잘못된 문제 정의: "망치를 들고 해결할 못을 찾아다니는 격"

Tech-First



Problem-First




- 전략적 오류 (Marketing vs. Reality)
- 단기적 비용 절감이나 'AI-first'라는 마케팅적 이미지만을 쫓아 뚜렷한 목표(ROI) 없이 무분별하게 기술을 도입하는 행태.

- 대표적 실패: 호주 커먼웰스 은행(CBA)
- 의도: 고객 응대 인력 대체를 통한 단순 비용 절감 목적의 AI 보이스봇 도입.
- 현실: 통화량 오히려 증가, 업무 효율 급감. 결국 도입을 철회하고 대규모 해고를 반복하며 공식 사과.

**AI 프로젝트 성공 여부는 기술력보다는
인간공학적 기술에 달려 있다.**

역량 격차와 사일로: 코딩 실력이 비즈니스 가치를 만들지 못할 때



경험과 도메인 지식의 부재

데이터 과학자의 60% 이상이 2년 미만의 경력자. 뛰어난 코딩 지식에 비해 현장의 비즈니스 도메인 지식과 이해관계자 설득 능력이 절대적으로 부족.


부서 간 데이터 사일로(Silo)와 조직의 저항

영업, 마케팅, 고객지원 부서 간 데이터 불일치 및 공유 거부. AI 도입이 기존 구성원의 역할을 위협한다고 느낄 때 발생하는 심리적 저항.

최대 실패작: IBM 왓슨의 몰락

기술 전문가가 아닌 마케팅 경영진 주도의 거대한 과대포장('암 정복'). 실제 의료가 작성한 파편화되고 복잡한 현장 메모를 AI가 이해하지 못해 헬스케어 사업부

AI 생존을 위한 3대 전략적 체크리스트 (Synthesis)





인공지능은 마법의 지팡이가 아니라, 정교한 '보조 도구'입니다.

성공적인 AI 도입은 기술 그 자체가 아니라, 그것을 적용할 수 있는 '환경'과 '전략'을 설계하는 인간의 몫입니다.

**“기술의 한계를 인정하는 비판적 사고와, 문제를 정확히 정의하는 인간의 리더십이
결여된 AI는 결코 현실의 복잡성을 넘을 수 없습니다.”**

끝!

